

## Funzioni di variabili aleatorie

Abbiamo visto durante il corso le distribuzioni: esponenziale, di Weibull e Gaussiana. I matematici con il concetto di funzione di funzione, sono riusciti a costruire dei modelli diversi. Ma che vuol dire funzione di variabili aleatorie?

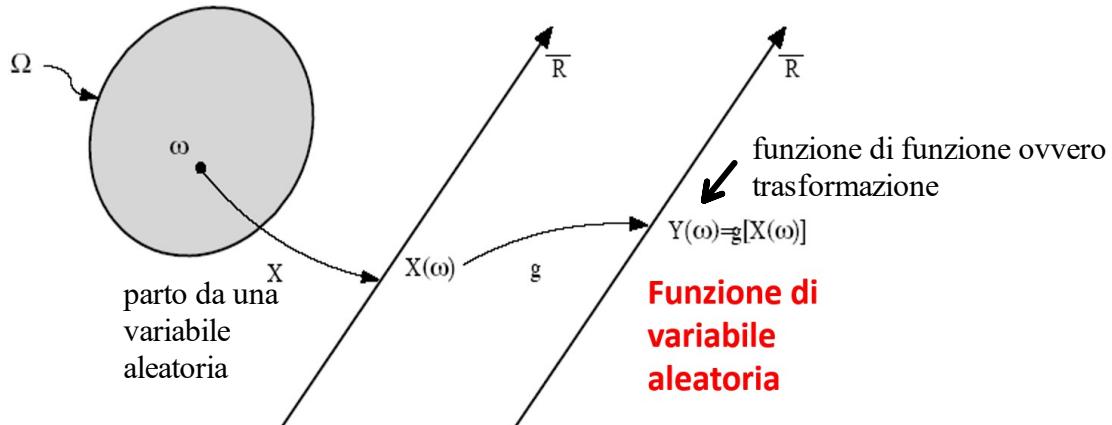
All'interno della letteratura scientifica si usa il termine trasformazioni di una variabile aleatoria. Nel nostro corso utilizzeremo il termine funzione al posto di trasformazione. Una trasformazione consiste in un'operazione algebrica di variabili aleatorie

Dal libro del prof. Gelli, "Probabilità e informazione"

86

Trasformazioni di una variabile aleatoria

**"Trasformazione" = "funzione"**



Il caso più facile è quello in cui  $g$  è funzione differenziabile e strettamente monotona (invertibile su tutti il dominio)

Il caso più difficile è quello in cui  $g$  è funzione differenziabile con punti a derivata nulla e interi intervalli a derivata nulla!

A  $\omega$  risultato elementare, viene associato un numero e dopo tramite  $g$  se ne associa un altro. La domanda che nasce è può cambiare la probabilità di  $\omega$ ?

La risposta è no, non cambia semplicemente la si rappresenta diversamente. Vediamo ciò tramite la proposizione di Miller seguente:

## 4.6 Transformations of Random Variables

$$F_Y(y) = \Pr(g(X) \leq y) = \Pr(X \leq g^{-1}(y)) = F_X(g^{-1}(y)). \quad (4.20)$$

probabilità che Y sia

minore o uguale ad un valore y

Note that this can also be written as

probabilità che X sia

minore o uguale all'inverso

della trasformazione applicata

a y

$F_X(x) = F_Y(g(x))$ . "Si cambia la forma  
ma non la sostanza"

*Differenziale?*

Si ma non detto  
esplicitamente

(4.21)

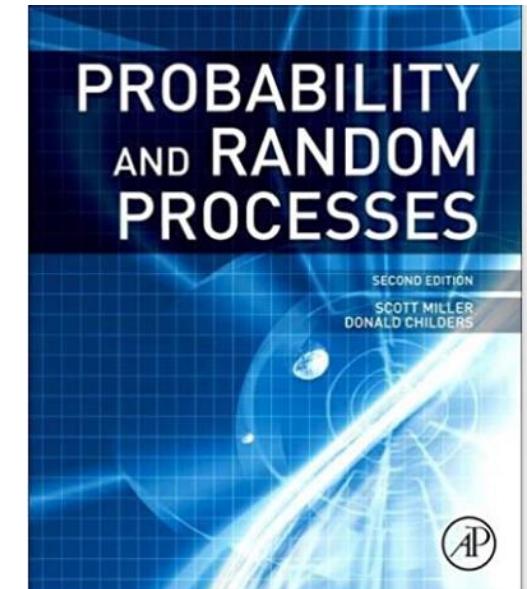
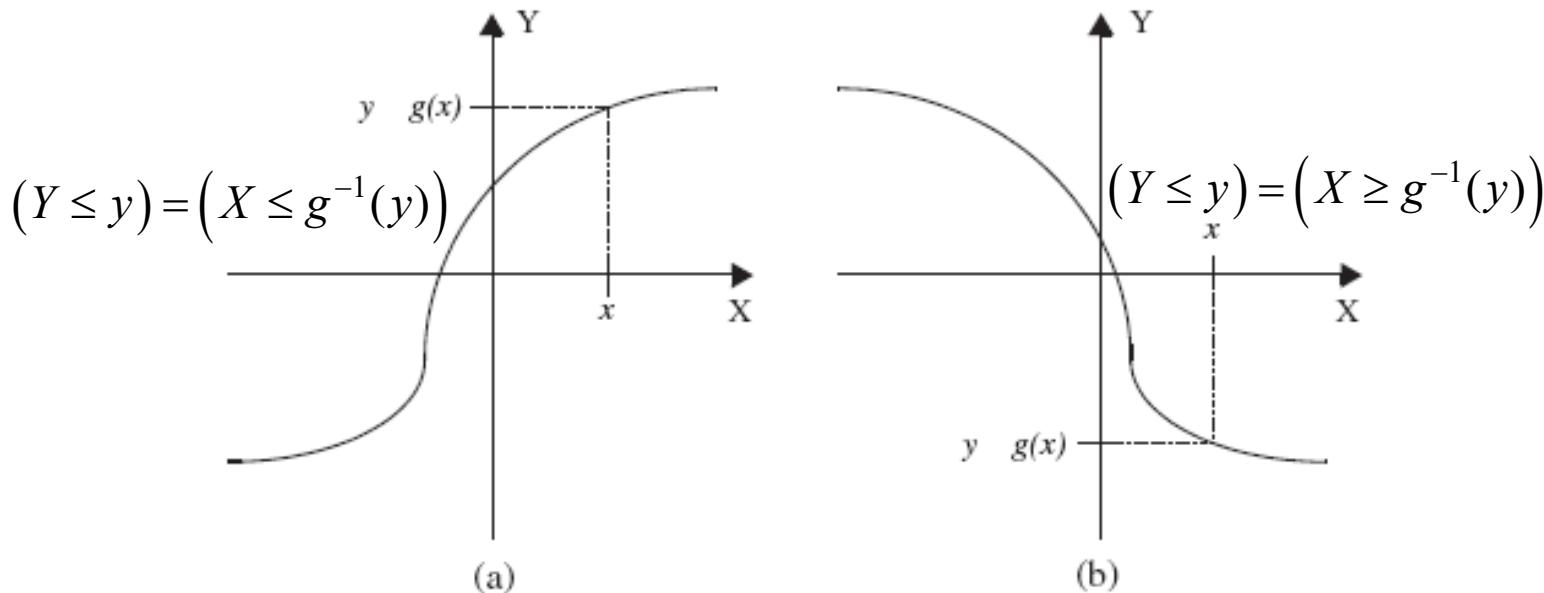


Figure 4.1 A monotonic increasing function (a) and a monotonic decreasing function (b).

Per funzioni **monotone crescenti** ottengo la densità di una variabile trasformata con le regole di derivazione delle funzioni composte

Differentiating Equation 4.20 with respect to  $y$  produces

densità di probabilità  
della variabile trasformata Y

$$f_Y(y) = f_X(g^{-1}(y)) \frac{dg^{-1}(y)}{dy} = f_X(x) \frac{dx}{dy} \Big|_{x=g^{-1}(y)},$$

La densità di probabilità di Y in un punto y  
è pari alla densità di X in un punto x  
(4.22)

while differentiating Equation 4.21 with respect to  $x$  gives

Da questa slide si capisce che  
la funzione è differenziabile!

$$f_X(x) = f_Y(g(x)) \frac{dy}{dx} \Rightarrow f_Y(y) = \frac{f_X(x)}{\frac{dy}{dx}} \Big|_{x=g^{-1}(y)} \quad \leftarrow \text{come ottenere  
la densità di Y  
a partire dalla  
densità di X}$$
(4.23)

Per funzioni **monotone decrescenti** si parte dalla distribuzione

La direzione della diseguaglianza  
nella probabilità arancio a differenza  
della funzione crescente si inverte  
per la natura decrescente della  
trasformazione

Differentiating with respect to  $y$  gives

$$f_Y(y) = -f_X(x) \frac{dx}{dy} \Big|_{x=g^{-1}(y)} \quad \begin{array}{l} \text{usa la complementare} \\ \text{segno negativo perché la} \\ \text{funzione è decrescente!} \end{array} \quad (4.25)$$

(4.24) Spiegazione evidenziato  
arancione:  
la probabilità che Y sia  $\leq y$   
corrisponde alla probabilità che  
X è  $\geq g^{-1}(y)$  perché la funzione  
è decrescente, quindi i valori  
più grandi di y corrispondono a  
valori più piccoli di x

Similarly, writing  $F_Y(g(x)) = 1 - F_X(x)$  and differentiating with respect to  $x$  results in

$$f_Y(y) = -\frac{f_X(x)}{\frac{dy}{dx}} \Big|_{x=g^{-1}(y)} . \quad (4.26)$$

## Dal libro del prof. Gelli, "Probabilità e informazione"

### ► Esempio 4.7. Consideriamo nuovamente la trasformazione lineare

$$Y = aX + b, \quad \text{ricordando che } X \text{ è la variabile originale e } Y \text{ è la variabile ricavata}$$

Qualunque sia  $y \in \mathbb{R}$ , e per ogni  $a \neq 0$ , l'equazione  $y = g(x) = ax + b$  ammette l'unica soluzione

$$X = \frac{y - b}{a}, \quad \text{ricavata tramite differenziabilità}$$

ed inoltre risulta

$$|g'(x)| = |a|, \quad \text{per cui: } f_Y(y) = \frac{1}{|a|} f_X\left(\frac{y - b}{a}\right) \quad \text{permette di ricavare la non standard a partire dalla standard}$$

Si può procedere anche diversamente, ottenendo la distribuzione prima e derivando poi:

Nel caso  $a > 0$ , si ha:

$$F_Y(y) = P(Y \leq y) = P(aX + b \leq y) = P\left(X \leq \frac{y - b}{a}\right) = F_X\left(\frac{y - b}{a}\right). \quad \text{usando la 4.22 per funzioni monotone crescenti}$$

Per  $a < 0$ , il verso della diseguaglianza si inverte,

$$\begin{aligned} F_Y(y) &= P(Y \leq y) = P(aX + b \leq y) = P\left(X \geq \frac{y - b}{a}\right) \\ &= 1 - P\left(X < \frac{y - b}{a}\right) = 1 - F_X\left(\frac{y - b}{a}\right). \end{aligned}$$

la probabilità che  $Y$  sia  $\leq$  di un valore  $y$  corrisponde a calcolare la probabilità che  $X$  sia maggiore uguale al valore  $x$

otteniamo lo stesso risultato per  $a > 0$   
e  $a < 0$

$$\frac{d}{dy} F_Y(y) = \frac{1}{|a|} \cdot f_X\left(\frac{y - b}{a}\right)$$

Giustifico la forma della densità Gaussiana non standard a partire dalla standard

## Valore atteso della funzione di una variabile aleatoria (non negativa)

ricorda  $g(x) = y = ax + b$

Il valore atteso di  $Y$   $E[Y] \hat{=} \int_{y=0}^{\infty} y \cdot f_Y(y) dy$ , con  $Y \hat{=} a \cdot X$ ,  $a > 0$  (esempio)  
quindi  $b=0$

$$E[aX] \hat{=} \int_{ax=0}^{\infty} ax \cdot f(ax) d(ax)$$

utilizzando  $\frac{d}{dy} F_Y(y) = \frac{1}{|a|} \cdot f_X\left(\frac{y-b}{a}\right)$  con  $b=0$

$$= \int_{x: ax=0}^{\infty} ax \cdot (1/a) f(y/a) \cdot d(ax) = \int_{x: ax=0}^{\infty} ax \cdot (1/a) f(ax/a) \cdot adx$$

$$= \int_{x=0}^{\infty} ax \cdot f(x) \cdot dx$$

**Generalizzazione, con  $g(x)$  idonea:**

per idonea si intende monotona non decrescente e differenziabile

$$E[g(X)] \hat{=} \int_{x: g(x)=0}^{\infty} g(x) \cdot f(x) dx, \quad g(x) \geq 0$$

è esattamente la definizione del valore atteso di  $X$  per la costante  $a$

## Theorem: pdf for a transformed RV

Sia  $X$ : variabile aleatoria continua con densità  $f_X$  che non è 0 su un sottoinsieme  $I$  di numeri reali [i.e.,  $f_X(x) > 0, x \in I$  and  $f_X(x) = 0, x \notin I$ ]. I può essere un punto!

Sia  $g$  : funzione monotona differenziabile con dominio  $I$  e immagine l'insieme dei reali.

Allora  $Y = g(X)$  : variabile aleatoria continua con densità  $f_Y$  definita come :

Densità di  $X$  valutata rispetto alla trasformazione inversa  $g$  nel punto  $y$

$$f_Y(y) = \begin{cases} f_X[g^{-1}(y)][|(g^{-1})'(y)|], & y \in g(I) \\ 0, & \text{altrimenti} \end{cases}$$

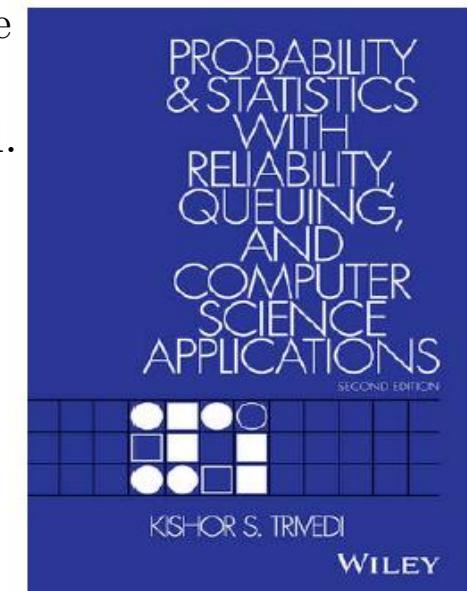
la derivata è la pendenza della funzione. Il valore assoluto mi dice di quanto sto "stirando" o "comprimendo" la distribuzione di probabilità

Prova:

Derivando ed utilizzando la regola di derivazione delle funzioni composte si ottiene che

$$F_Y(y) = P(Y \leq y) = P[g(X) \leq y] = P[X \leq g^{-1}(y)] = F_X[g^{-1}(y)]$$

Conosco la distribuzione di  $X$  e  
 la funzione che trasforma  $X$  in  $Y$ ,  
 quindi calcolo la distribuzione in  $Y$



**Consideriamo adesso la funzione quadratica:** (che è monotona crescente strettamente)

## Example 3.8

<https://ece.duke.edu/faculty/kishor-trivedi>

Distribuzione per  $Y = g(X) = X^2$  Ricorda che  
 $F_Y(y) = P(Y \leq y)$

$F_Y(y) = 0$ , per  $y \leq 0$   $P(Y \leq y)$  è zero! Essendo  $Y = X^2 \implies X^2 \leq y$  ovvero  $X^2 \leq$   
di una quantità  $\leq$  di zero si risolve appunto solo  
invece nel caso  $y > 0$  : per  $X=0$

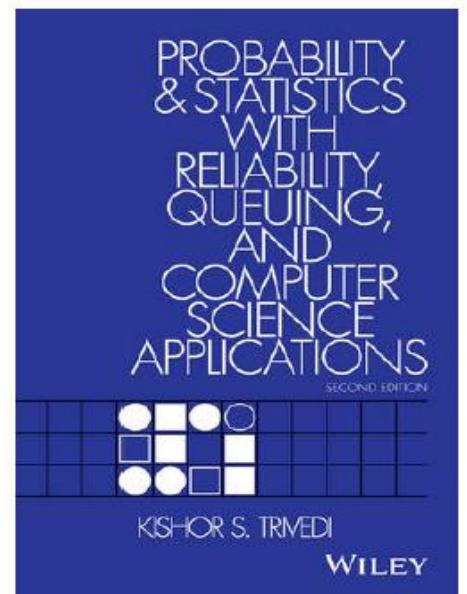
$$F_Y(y) = P(Y \leq y) = P(X^2 \leq y) = P(-\sqrt{y} \leq X \leq \sqrt{y}) = F_X(\sqrt{y}) - F_X(-\sqrt{y})$$

Esprimo  $X \in [-\sqrt{y}, \sqrt{y}]$  come differenza esplicitando la definizione di distribuzione

La densità di  $Y$ ,  $f_Y$  si ottiene con la regola di derivazione per funzioni composte,

$$f_Y(y) = \frac{dF_Y(y)}{dy} = \begin{cases} \frac{1}{2\sqrt{y}} [f_X(\sqrt{y}) + f_X(-\sqrt{y})], & y > 0, \\ 0, & \text{altrimenti.} \end{cases}$$

Quando elevo al quadrato una variabile aleatoria sto "comprimendo" la parte negativa della distribuzione e sto "stirando" quella positiva



Per chiarezza, vi anticipo la densità della V.A. gamma, che sarà dimostrata più avanti nel corso come generalizzazione del modello di Erlang:

[https://en.wikipedia.org/wiki/Agner\\_Krarup\\_Erlang](https://en.wikipedia.org/wiki/Agner_Krarup_Erlang)

## Variabile aleatoria Gamma

A partire dal secondo integrale di Eulero si definisce la funzione  
portando fuori  $\Gamma(\alpha)$  di densità Gamma  
perchè costante  
ottengo  $\frac{1}{\Gamma(\alpha)} \cdot \Gamma(\alpha) = 1$

$$f(t) = \frac{\lambda^\alpha t^{\alpha-1} e^{-\lambda t}}{\Gamma(\alpha)}, \quad \alpha > 0, \quad t > 0$$

$$\int_0^\infty \frac{\hat{f}(t)}{\Gamma(\alpha)} dt = 1$$

appunto l'integrale  
di una densità deve  
essere pari a 1

dove

$$\Gamma(\alpha) = \int_0^\infty x^{\alpha-1} e^{-x} dx, \quad \alpha > 0$$

- Show the recurrence for the gamma function:  
 $\Gamma(\alpha) = (\alpha-1) \Gamma(\alpha-1)$ ; and show that  $\Gamma(1/2) = \sqrt{\pi}$
- Because  $\Gamma(1) = 1$ , it follows that for an integer  $r$ ,  $\Gamma(r) = (r-1) \Gamma(r-1) = \dots = (r-1)!$
- So gamma with a positive integer valued shape parameter is the Erlang random variable

La variabile aleatoria Gamma con parametro di forma  $\alpha = \frac{n}{2}$ ,

parametro di scala  $\lambda = \frac{1}{2}$  è nota come variabile aleatoria "chi-square", (chi-quadrato) con  $n$  gradi di libertà

Se integro  $\hat{f}(t)$

ottengo

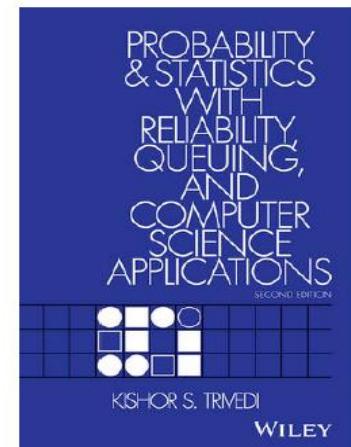
$$\Gamma(\alpha) = \int_{t=0}^{\infty} (\lambda t)^{\alpha-1} \cdot e^{-\lambda t} d(\lambda t), \quad \lambda > 0$$

sostituendo con

$$x \triangleq \lambda t \Rightarrow dx = \lambda dt$$

$$\Rightarrow x^{\alpha-1} \cdot dx = \lambda \cdot (\lambda t)^{\alpha-1}$$

Al crescere di alfa,  
la distribuzione è  
più simmetrica a destra  
Al crescere di lambda  
la distribuzione è  
concentrata attorno a 0



IMPORTANTE  
NOTIZIA

## Caso particolare famoso (della funzione quadratica):

Quadrato della Gaussiana standard  $N(0,1)$  Come calcoliamo le caratteristiche di densità e distribuzione del quadrato? Applicando il risultato del esempio 3.8 evidenziato in verde!

### Example 3.9



In Example 3.8, assume  $X$  to be  $N(0,1)$ :

quindi si sa che la densità è  $f_X(x) = \frac{1}{\sqrt{2\pi}}e^{-x^2/2}$ ,  $-\infty < x < \infty$ .

- Using result from Example 3.8:

$$f_Y(y) = \begin{cases} \frac{1}{2\sqrt{y}} \left( \frac{1}{\sqrt{2\pi}}e^{-y/2} + \frac{1}{\sqrt{2\pi}}e^{-y/2} \right), & y > 0, \\ 0, & y \leq 0, \end{cases}$$

or,  $f_Y(y) = \begin{cases} \frac{1}{\sqrt{2\pi y}}e^{-y/2}, & y > 0, \\ 0, & y \leq 0. \end{cases}$

i.e.,

$Y$  has a *gamma* distribution with  $\alpha = 1/2$  and  $\lambda = 1/2$  e  $y \equiv t$

- Which is also known as chi-square distribution with 1 degree of freedom

$$\Gamma(\alpha) = \int_{t=0}^{\infty} (\lambda t)^{\alpha-1} \cdot e^{-\lambda t} d(\lambda t), \lambda > 0$$

Passaggi algebrici

$$\begin{aligned} f(y) &= \frac{1}{\Gamma(\frac{1}{2})} \cdot \frac{1}{2} \cdot \left(\frac{y}{2}\right)^{-\frac{1}{2}} \cdot e^{-\frac{y}{2}} \\ &= \frac{1}{\Gamma(\frac{1}{2})} \cdot \frac{1}{\sqrt{2} \cdot \sqrt{2}} \cdot \frac{\sqrt{2}}{\sqrt{y}} \cdot e^{-\frac{y}{2}} \\ &= \frac{1}{\sqrt{\pi}} \cdot \frac{1}{\sqrt{2}} \cdot \frac{1}{\sqrt{y}} \cdot e^{-\frac{y}{2}} \end{aligned}$$

Il quadrato di una standard porta ad una funzione gamma particolare con alfa e lambda particolari detta chi-quadrato che servirà per la statistica della varianza

## Una funzione logaritmo (ad hoc) su una var. al. X, UNIFORME in (0,1):

FINO A QUI DOMANDE DI ESAME!

Logaritmo è sempre  
monotona e differenziabile come  
vuole l'ipotesi ipotesi (slide 1)

$$Y \doteq -\lambda^{-1} \cdot \ln(1-X)$$

X distribuito uniformemente da 0 a 1 è un  
generatore di numeri casuali

### Example 3.10

- Let  $X$  be uniformly distributed,  $\text{Unif}(0,1)$
- Then,  $Y = -\lambda^{-1} \ln(1-X)$  is  $\text{EXP}(\lambda)$ .

$$\text{for } y \leq 0, F_Y(y) = 0$$

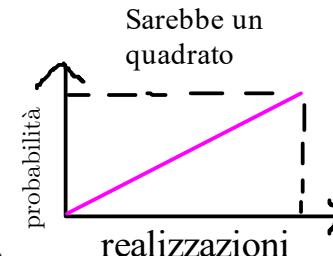
for  $y > 0$ ,

$$\begin{aligned} F_Y(y) &= P(Y \leq y) = P[-\lambda^{-1} \ln(1-X) \leq y] \\ &= P[\ln(1-X) \geq -\lambda y] \\ &= P[(1-X) \geq e^{-\lambda y}] \quad (\text{since } e^x \text{ is an increasing function of } x,) \\ &= P(X \leq 1 - e^{-\lambda y}) \\ &= F_X(1 - e^{-\lambda y}). \end{aligned}$$

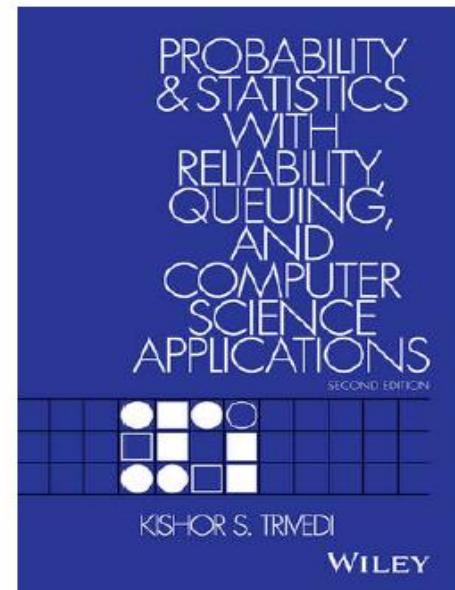
Se  $X$  è uniforme distribuito tra 0 e 1  
la densità sarà costante dunque  
la distribuzione che è la funzione l'integrale  
della densità è lineare. Appunto integrale di una  
costante funzione lineare da analisi 1

Since  $X$  is  $\text{U}(0,1)$ ,  $F_X(x) = x, 0 \leq x \leq 1$ . Therefore,

$$F_Y(y) = 1 - e^{-\lambda y} \Rightarrow Y \text{ is } \text{EXP}(\lambda)$$



la realizzazione è  
uguale alla probabilità  
con cui si osserva la  
realizzazione. Quindi  
la distribuzione è la  
diagonale del quadrato  
vedi Monte Carlo



IN PARTICOLARE  
La funzione (inversa) quantile è la  
trasformazione che permette di  
produrre realizzazioni a partire da  
una funzione di distribuzione  
invertibile (Esponenziale, Weibull ecc)

**IDEA:** avendo a disposizione un generatore di numeri casuali uniformemente distribuiti in (0,1) potremmo generare realizzazioni della V.A. esponenziale di parametro  $\lambda$  sarà il laboratorio di Excel

**Example 8.1.2** (Log-Normal PDF). Let  $X \sim \mathcal{N}(0, 1)$ ,  $Y = e^X$ . In Chapter 6 we named the distribution of  $Y$  the Log-Normal, and we found all of its moments using the MGF of the Normal distribution. Now we can use the change of variables formula to find the PDF of  $Y$ , since  $g(x) = e^x$  is strictly increasing. Let  $y = e^x$ , so  $x = \log y$  and  $dy/dx = e^x$ . Then

$$f_Y(y) = f_X(x) \left| \frac{dx}{dy} \right| = \varphi(x) \frac{1}{e^x} = \varphi(\log y) \frac{1}{y}, \quad y > 0.$$

Note that after applying the change of variables formula, we write everything on the right-hand side in terms of  $y$ , and we specify the support of the distribution. To determine the support, we just observe that as  $x$  ranges from  $-\infty$  to  $\infty$ ,  $e^x$  ranges from 0 to  $\infty$ .

We can get the same result by working from the definition of the CDF, translating the event  $Y \leq y$  into an equivalent event involving  $X$ . For  $y > 0$ ,

$$F_Y(y) = P(Y \leq y) = P(e^X \leq y) = P(X \leq \log y) = \Phi(\log y),$$

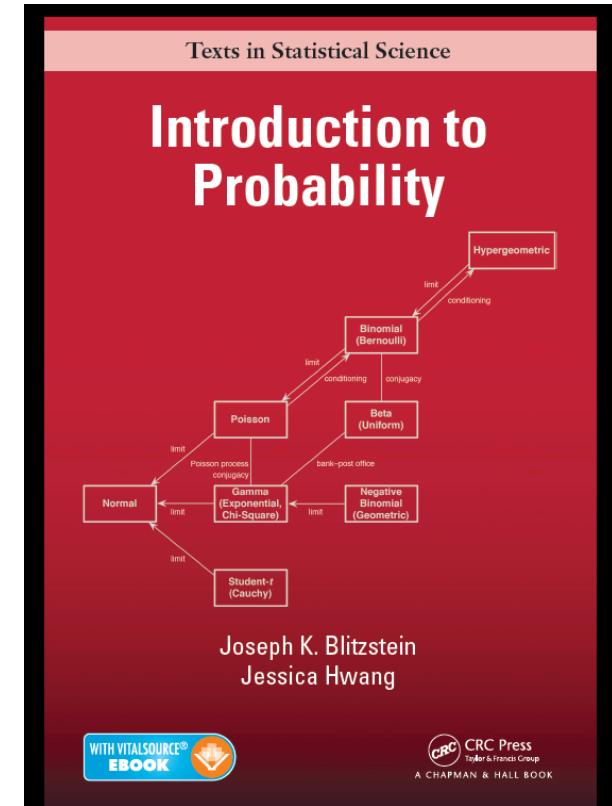
so the PDF is again

$$f_Y(y) = \frac{d}{dy} \Phi(\log y) = \varphi(\log y) \frac{1}{y}, \quad y > 0.$$

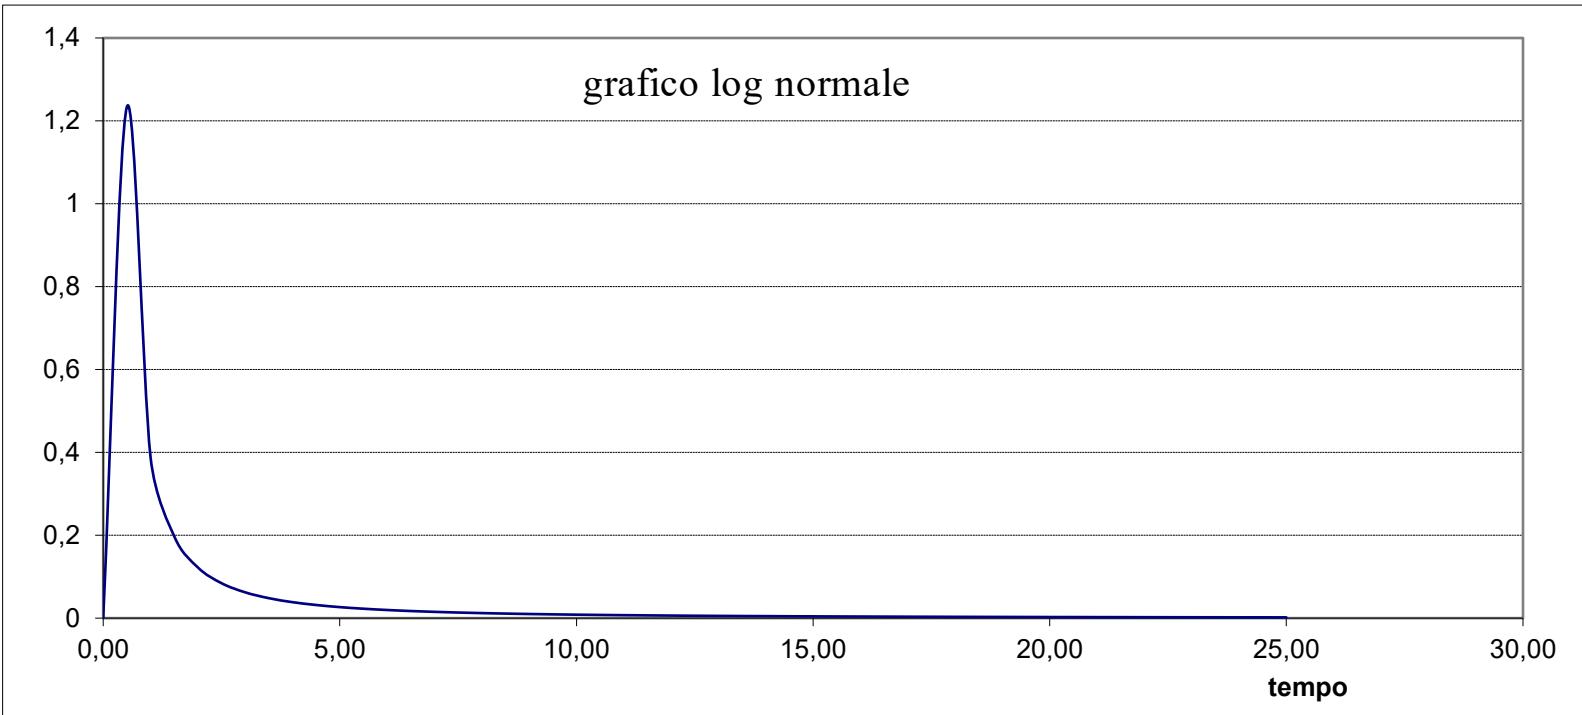
*log normale* *monotone* *gaussiana* *log normale*

*distribuzione gaussiana*

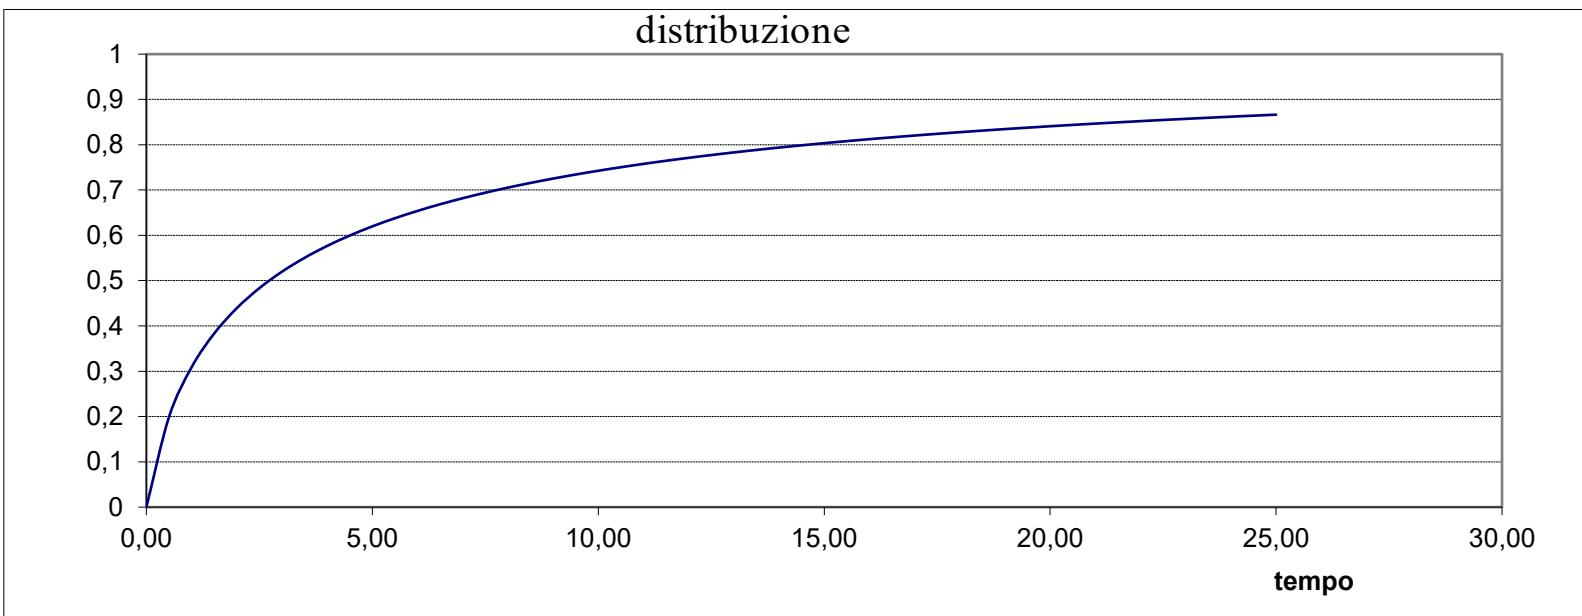
*Φ è densità Gauss*  
*Φ è distrib. Gauss*



Take a look at my excel file «Modello lognormale (Legato)», please!



simile alla Weibull  
ma qui la discesa/decrescita  
è molto più ripida/veloce



# From WIKIPEDIA

inverte la x con y

X=lognorm Y=norm

Notation	$\text{Lognormal}(\mu, \sigma^2)$
Parameters	$\mu \in (-\infty, +\infty)$ , $\sigma > 0$
Support	$x \in (0, +\infty)$
PDF	$\frac{1}{x\sigma\sqrt{2\pi}} \exp\left(-\frac{(\ln x - \mu)^2}{2\sigma^2}\right)$
CDF	$\frac{1}{2} + \frac{1}{2} \operatorname{erf}\left[\frac{\ln x - \mu}{\sqrt{2}\sigma}\right]$
Quantile	$\exp(\mu + \sqrt{2\sigma^2} \operatorname{erf}^{-1}(2F - 1))$
Mean	$\exp\left(\mu + \frac{\sigma^2}{2}\right)$
Median	$\exp(\mu)$
Mode	$\exp(\mu - \sigma^2)$
Variance	$[\exp(\sigma^2) - 1] \exp(2\mu + \sigma^2)$
Skewness	$(e^{\sigma^2} + 2)\sqrt{e^{\sigma^2} - 1}$
Ex. kurtosis	$\exp(4\sigma^2) + 2\exp(3\sigma^2) + 3\exp(2\sigma^2) - 6$

$\Phi \triangleq \text{GAUSS DISTRIBUTION}$

$$x = e^y \implies y = \ln x$$

dimostrazione (non richiesta)

$$\begin{aligned} f_X(x) &= \frac{d}{dx} \Pr(X \leq x) = \frac{d}{dx} \Pr(\ln X \leq \ln x) \\ &= \frac{d}{dx} \Phi\left(\frac{\ln x - \mu}{\sigma}\right) \\ &= \varphi\left(\frac{\ln x - \mu}{\sigma}\right) \frac{d}{dx} \left(\frac{\ln x - \mu}{\sigma}\right) \\ &= \varphi\left(\frac{\ln x - \mu}{\sigma}\right) \frac{1}{\sigma x} \\ &= \frac{1}{x} \cdot \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(\ln x - \mu)^2}{2\sigma^2}\right). \end{aligned}$$

normale  
standardizzata

$$F_X(x) = \Phi\left(\frac{(\ln x) - \mu}{\sigma}\right)$$

$$\frac{1}{2} \left[ 1 + \operatorname{erf}\left(\frac{\ln x - \mu}{\sigma\sqrt{2}}\right) \right] = \frac{1}{2} \operatorname{erfc}\left(-\frac{\ln x - \mu}{\sigma\sqrt{2}}\right)$$

where  $\operatorname{erf}(z) \triangleq \frac{2}{\sqrt{\pi}} \int_{t=0}^z e^{-t^2} dt$

and  $\operatorname{erfc}(z) \triangleq 1 - \operatorname{erf}(z)$

# **EXTRA**

## **Appendice I**

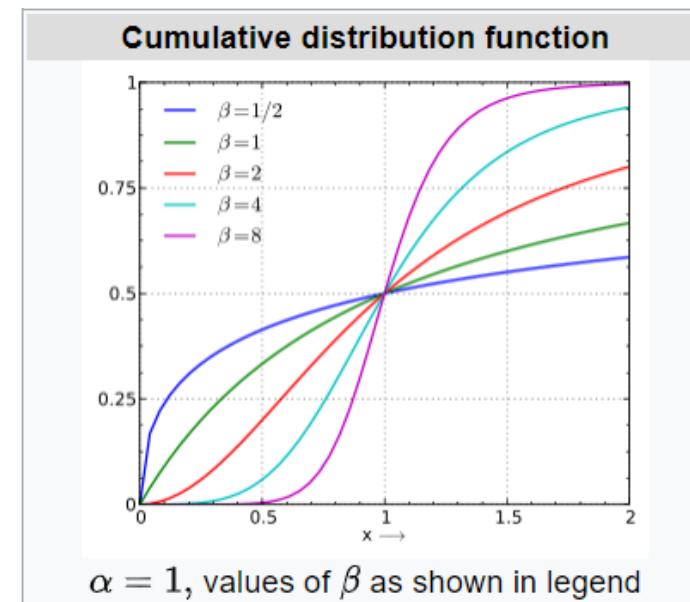
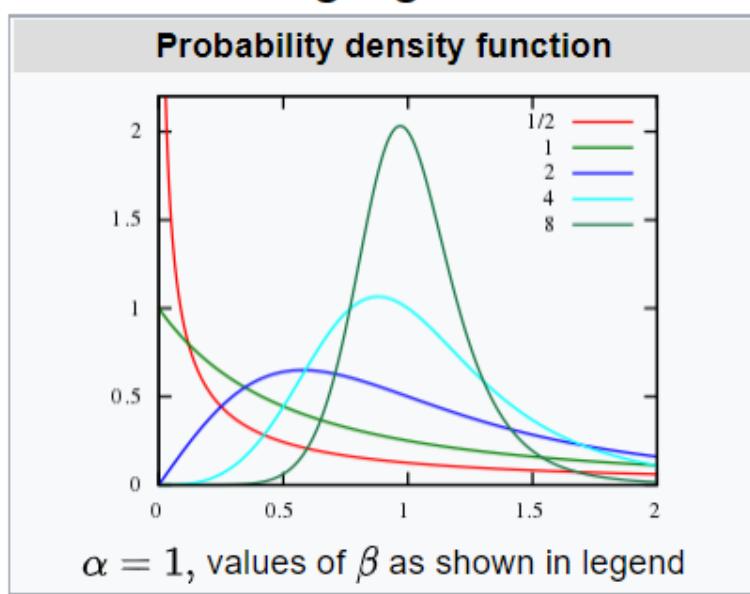
La funzione di distribuzione  
Log-Logistic

# Log-logistic distribution

From Wikipedia, the free encyclopedia

In probability and statistics, the **log-logistic distribution** (known as the **Fisk distribution** in economics) is a continuous probability distribution for a non-negative random variable. It is used in **survival analysis** as a parametric model for events whose rate increases initially and decreases later, as, for example, mortality rate from cancer following diagnosis or treatment. It has also been used in **hydrology** to model stream flow and **precipitation**, in **economics** as a simple model of the **distribution of wealth or income**, and in **networking** to model the transmission times of data considering both the network and the software.

The log-logistic distribution is the probability distribution of a random variable whose **logarithm** has a **logistic distribution**. It is similar in shape to the **log-normal distribution** but has **heavier tails**. Unlike the log-normal, its **cumulative distribution function** can be written in **closed form**.



There are several different parameterizations of the distribution in use. The one shown here gives reasonably interpretable parameters and a simple form for the cumulative distribution function.<sup>[3][4]</sup> The parameter  $\alpha > 0$  is a scale parameter and is also the median of the distribution. The parameter  $\beta > 0$  is a shape parameter. The distribution is unimodal when  $\beta > 1$  and its dispersion decreases as  $\beta$  increases.

The cumulative distribution function is

$$\begin{aligned} F(x; \alpha, \beta) &= \frac{1}{1 + (x/\alpha)^{-\beta}} \\ &= \frac{(x/\alpha)^\beta}{1 + (x/\alpha)^\beta} \\ &= \frac{x^\beta}{\alpha^\beta + x^\beta} \end{aligned}$$

where  $x > 0, \alpha > 0, \beta > 0$ .

The probability density function is

$$f(x; \alpha, \beta) = \frac{(\beta/\alpha)(x/\alpha)^{\beta-1}}{(1 + (x/\alpha)^\beta)^2}$$

Attenzione:  
questa volta  $\alpha$  è usato per indicare  
il fattore di scala e  $\beta$  il fattore di  
forma!

## Quantiles [edit]

The quantile function (inverse cumulative distribution function) is :

$$F^{-1}(p; \alpha, \beta) = \alpha \left( \frac{p}{1-p} \right)^{1/\beta}.$$

Può essere usata per generare realizzazioni!

It follows that the median is  $\alpha$ , the lower quartile is  $3^{-1/\beta}\alpha$  and the upper quartile is  $3^{1/\beta}\alpha$ .

Se  $F(\bar{x}_p) = p$ ,  $p \in (0,1)$   
allora  $\bar{x}_p$  è detto  
 $p$ -simo quantile della  $F$   
 $p \doteq 0.5$  è detto mediana

## Moments [ edit ]

The  $k$ th raw moment exists only when  $k < \beta$ , when it is given by<sup>[5][6]</sup>

$$E(X^k) = \alpha^k B(1 - k/\beta, 1 + k/\beta)$$

$$= \alpha^k \frac{k\pi/\beta}{\sin(k\pi/\beta)}$$

where B is the beta function. Expressions for the mean, variance, skewness and kurtosis can be derived from this. Writing  $b = \pi/\beta$  for convenience, the mean is

$$E(X) = \alpha b / \sin b, \quad \beta > 1,$$

and the variance is

$$\text{Var}(X) = \alpha^2 (2b / \sin 2b - b^2 / \sin^2 b), \quad \beta > 2.$$

Explicit expressions for the skewness and kurtosis are lengthy.<sup>[7]</sup> As  $\beta$  tends to infinity the mean tends to  $\alpha$ , the variance and skewness tend to zero and the excess kurtosis tends to 6/5 (see also related distributions below).

Per esercizio, potete graficare densità e distribuzione del modello "Log-logistic"!

## Survival analysis [edit]

# (RELIABILITY)

The log-logistic distribution provides one parametric model for survival analysis. Unlike the more commonly used Weibull distribution, it can have a non-monotonic hazard function: when  $\beta > 1$ , the hazard function is unimodal (when  $\beta \leq 1$ , the hazard decreases monotonically). The fact that the cumulative distribution function can be written in closed form is particularly useful for analysis of survival data with censoring.<sup>[8]</sup> The log-logistic distribution can be used as the basis of an accelerated failure time model by allowing  $\alpha$  to differ between groups, or more generally by introducing covariates that affect  $\alpha$  but not  $\beta$  by modelling  $\log(\alpha)$  as a linear function of the covariates.<sup>[9]</sup>

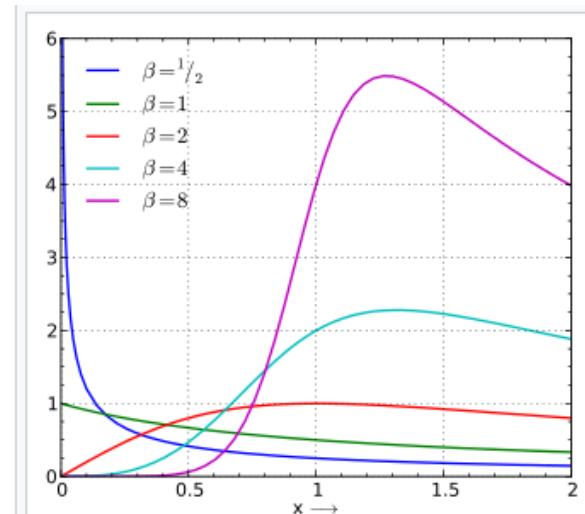
The survival function is

$$S(t) = 1 - F(t) = [1 + (t/\alpha)^\beta]^{-1},$$

and so the hazard function is

$$h(t) = \frac{f(t)}{S(t)} = \frac{(\beta/\alpha)(t/\alpha)^{\beta-1}}{1 + (t/\alpha)^\beta}.$$

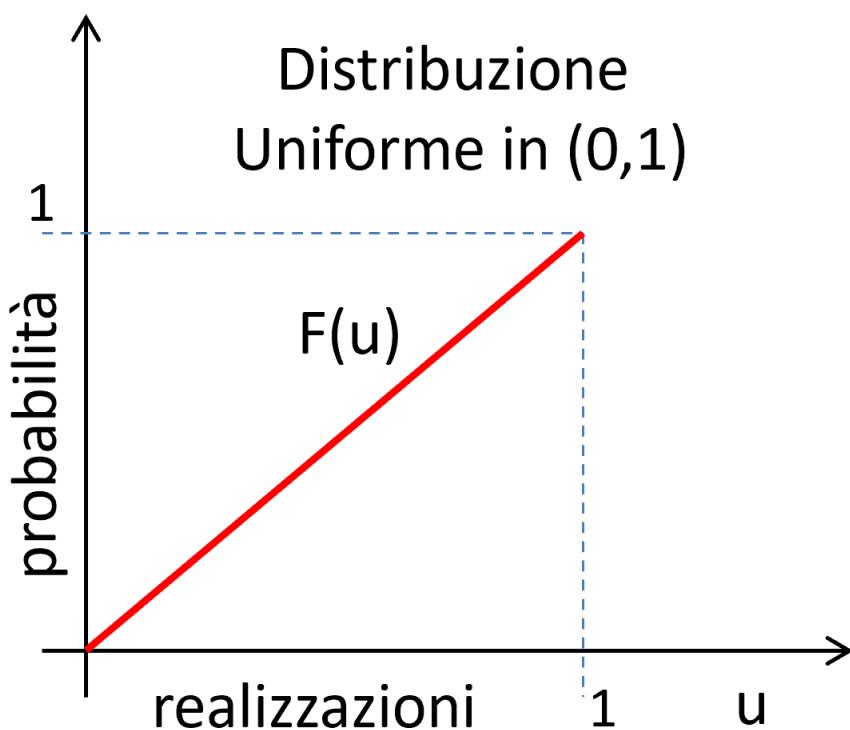
A anche questi grafici  
potete riprodurre  
con Excel !



Hazard function.  $\alpha = 1$ , values of  $\beta$  as shown in legend

### IMPORTANTE

Come si è visto precedentemente, la funzione (inversa) quantile è la trasformazione che permette di produrre realizzazioni a partire da una funzione di distribuzione invertibile (Esponziale, Weibull ecc)



In generale dunque si ha che:

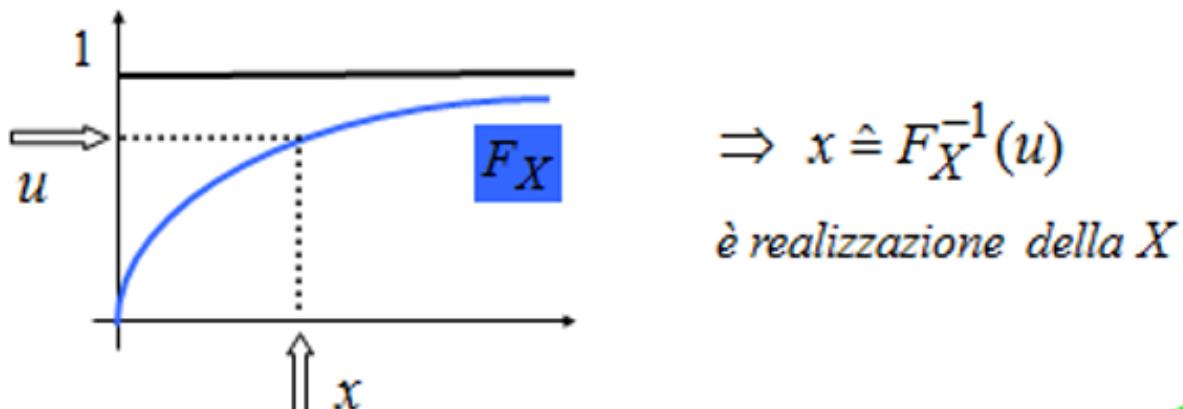
### **Dai numeri casuali alle realizzazioni di v.a.**

$\{u_1, u_2, \dots, u_n, \dots\}$  realizzazioni indipendenti di  $U\{0,1\}$

Generazione di realizzazioni delle Var. Al. d'ingresso

*Metodo della trasformazione inversa*  
dimostrazione

$$\Pr\{X \leq x\} \hat{=} F_X(x) = F_X(F_X^{-1}(u)) = u = \Pr\{U \leq u\}$$



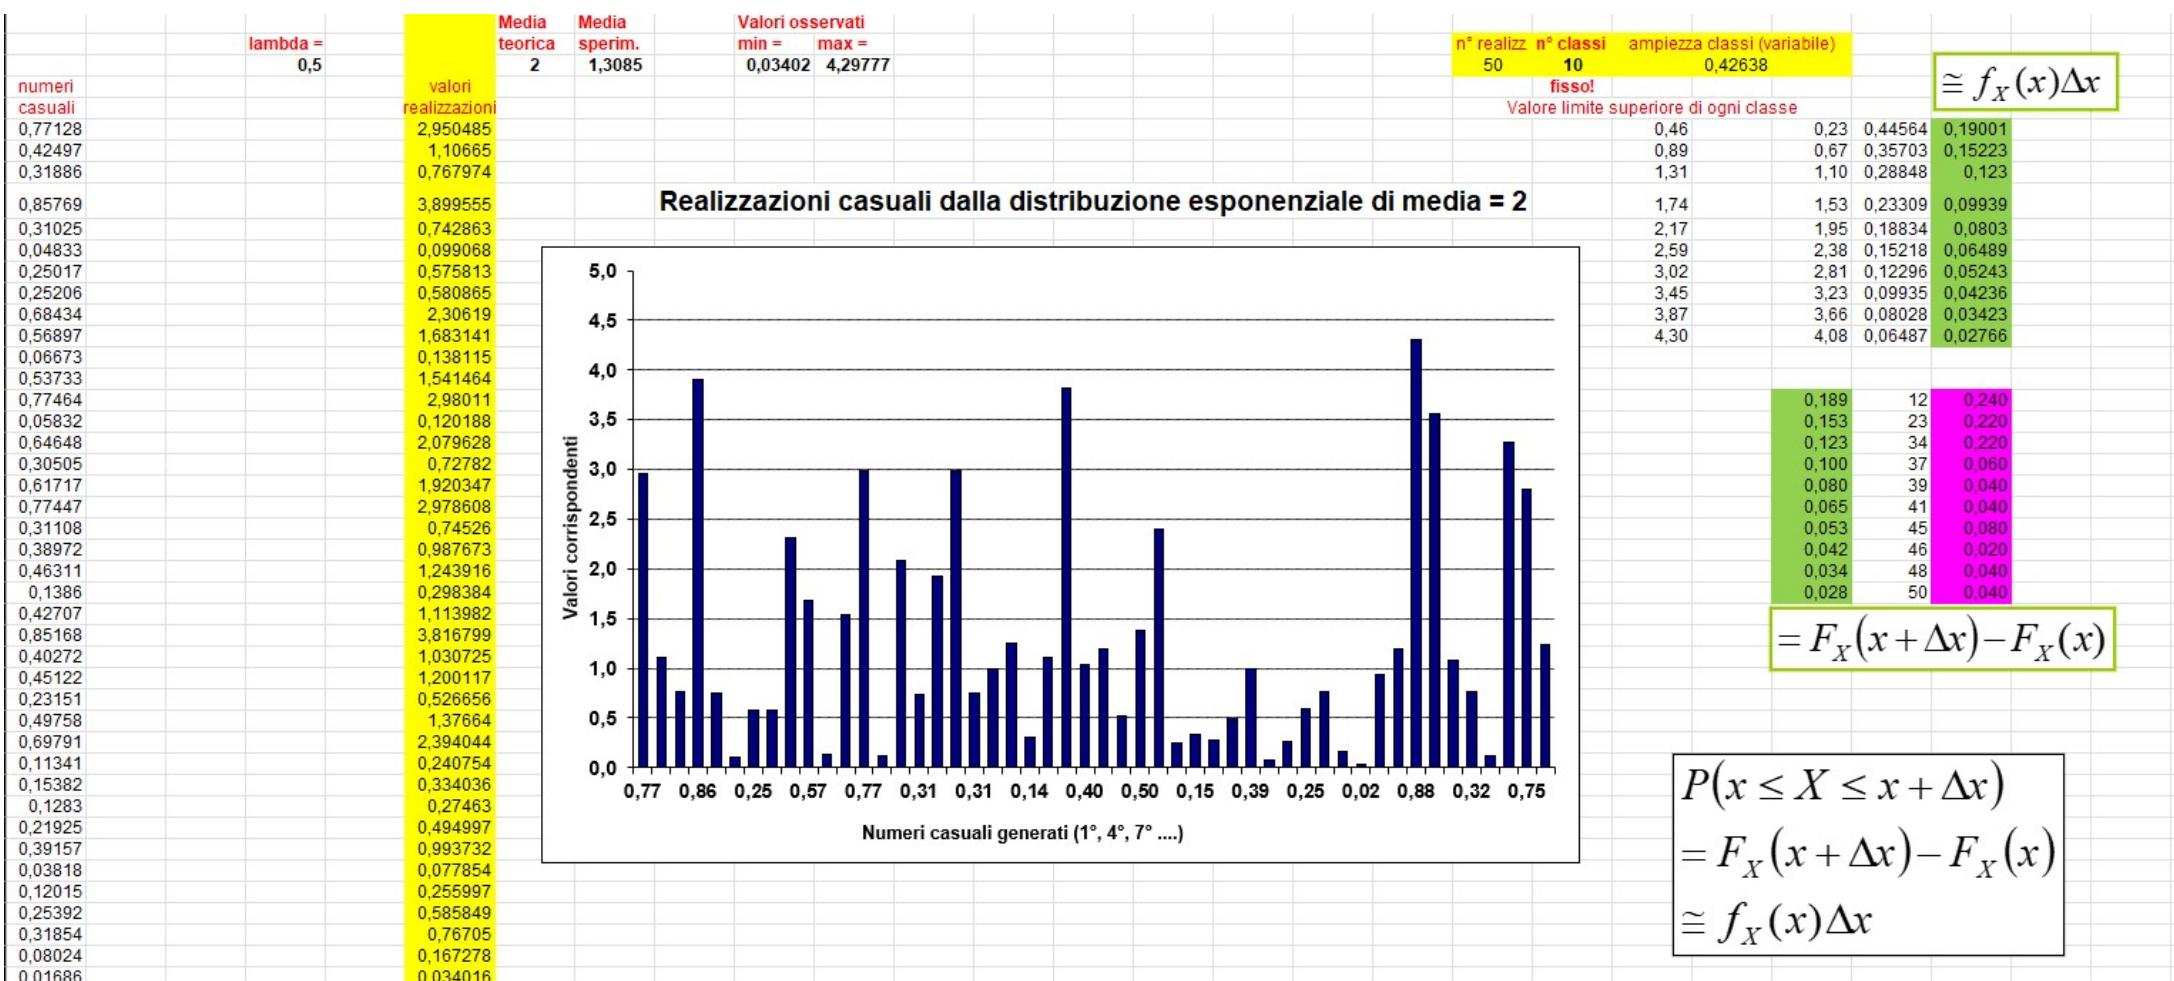
A parole: presa una funzione di **distribuzione invertibile**  $F_x(x)$  allora si ha che

$F_X(F_X^{-1}(u)) = u$  dunque la funzione di distribuzione nell'inversa della distribuzione in u ritorna u. Esempio esponenziale con  $\lambda = 1 \Rightarrow F_X(x) = 1 - e^{-x} \Rightarrow F_X^{-1}(x) = -\ln(1 - x)$

$F_X(F_X^{-1}(u)) = 1 - e^{-\ln(1+u)} = 1 - (1 - u) = u$  Quindi come abbiamo visto in precedenza la realizzazione è uguale alla probabilità con cui si osserva la realizzazione L'unica distribuzione che ha ascissa pari a ordinata è  $F_X(x) = x$  appunto la diagonale del quadrato.

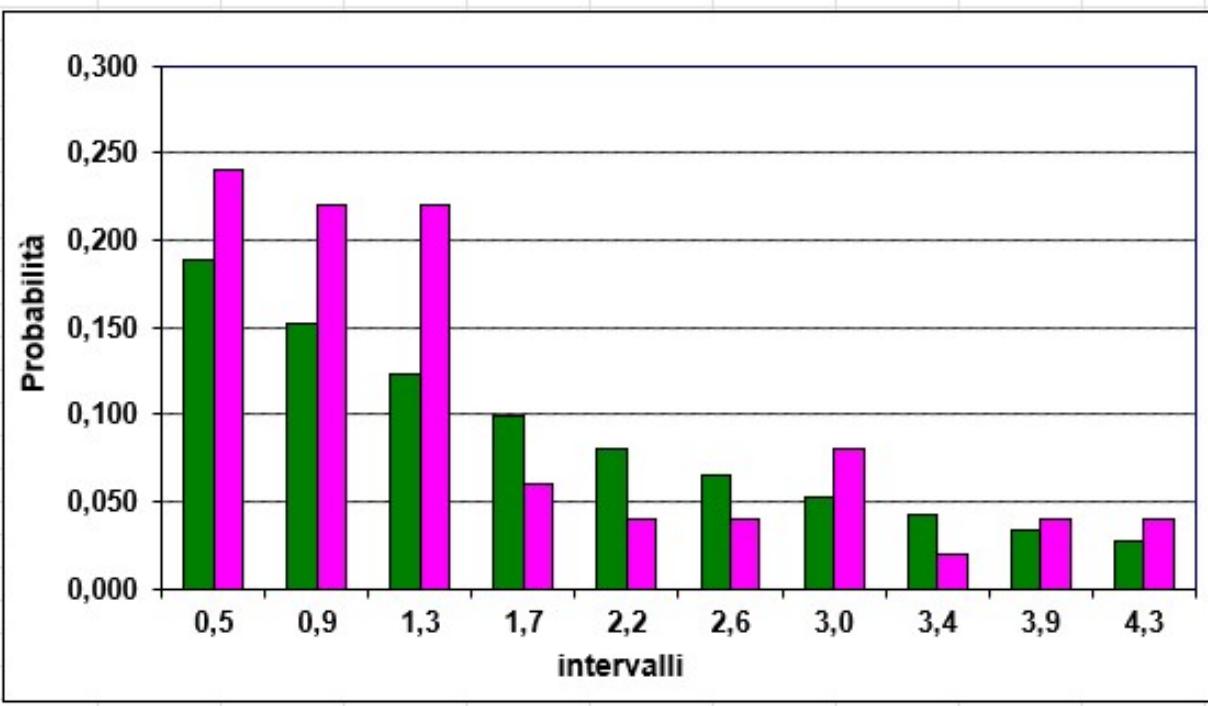
Ci mettiamo nell'ipotesi di modelli in cui la distribuzione è invertibile.

Il metodo non è utilizzabile per tutte le distribuzioni



Grazie al **metodo della trasformazione inversa** si sono generate molte realizzazioni, che appunto nella cella mostrano la formula inversa. La media sperimentale sarebbe la classica media aritmetica e mostra nella simulazione che facendo più prove, tende al valore della media teorica. La media teorica sarebbe il valore atteso appunto. Quindi si capisce e vedremo in futuro che per n tendente all'infinito la media aritmetica tenda al valore atteso. Facendo simulazioni si ottengono valori che sono più piccoli o più grandi del valore atteso. L'oscillazione dei risultati a parità di dimensione del campione, è dovuta alla varianza! Non solo per la casualità. (Non si sa ancora di quanto si sbaglia) Si hanno poi i valori min e max, che mostrano quanto ad esempio un tempo di esecuzione può essere piccolissimo oppure molto grande. Il grafico ci potrebbe ad esempio mostrare il fenomeno di burst all'interno di una coda. Ad esempio vado dall'elettrauto e devo cambiare la lampadine e sto 0.3 secondi, mentre può capitare che arriva quello che deve cambiare la batteria ed i cavi annessi e sta 4.3 secondi (ovviamente non impiega secondi un elettrauto). Riordinare i valori non basta per ricostruire la legge esponenziale di media. Oltre ai valori di min e max occorre fissare un numero di classi, ovvero un numero di raggruppamenti dove i valori possono finire, un numero di realizzazione da prendere in esame e l'ampiezza delle classi, che sarebbe la differenza tra max e min diviso il numero di classi fissato.

### Ricostruzione legge esponenziale di media = 2



lizz	n° classi	ampiezza classi (variabile)	
	10	0,42638	
<b>fisso!</b>			
Valore limite superiore di ogni classe			
2			
	0,46	0,23	0,44564
	0,89	0,67	0,35703
	1,31	1,10	0,28848
	1,74	1,53	0,23309
	2,17	1,95	0,18834
	2,59	2,38	0,15218
	3,02	2,81	0,12296
	3,45	3,23	0,09935
	3,87	3,66	0,08028
	4,30	4,08	0,06487
			0,19001
			0,15223
			0,123
			0,09939
			0,0803
			0,06489
			0,05243
			0,04236
			0,03423
			0,02766

$$\cong f_X(x)\Delta x$$

Il limite superiore di ogni classe si ottiene partendo da 0 e sommando l'ampiezza della classe al valore minimo. L'ultimo limite sarà il valore di max.

$f_X(x)\Delta x$  corrisponde alla percentuale di valori che ci si aspettano in una classe. (19% nello screen)  
Ma tale percentuale si può ottenere anche con la distribuzione

$$\cong f_X(x)\Delta x$$

classe

0,23	0,44564	0,19001
0,67	0,35703	0,15223
1,10	0,28848	0,123
1,53	0,23309	0,09939
1,95	0,18834	0,0803
2,38	0,15218	0,06489
2,81	0,12296	0,05243
3,23	0,09935	0,04236
3,66	0,08028	0,03423
4,08	0,06487	0,02766

0,189	12	0,240
0,153	23	0,220
0,123	34	0,220
0,100	37	0,060
0,080	39	0,040
0,065	41	0,040
0,053	45	0,080
0,042	46	0,020
0,034	48	0,040
0,028	50	0,040

$$= F_X(x + \Delta x) - F_X(x)$$

Guardando il grafico con 15 classi si nota come il modello teorico approssima ancora meglio la legge esponenziale, mentre la simulazione sballa di molto! Da notare che la media sperimentale nel esempio è di 1.9835! MOLTO VICINA A 2. Quindi la casualità anche se c'è non porta solo lei a sbagliare! Quanto si peggiora per caso dipende dalla varianza

$$\text{In particolare si sa che: } F_X(x + \Delta x) - F_X(x) \cong f_X(x)\Delta x$$

per il concetto di limite di rapporto incrementale. Dunque guardando le due colonne in verde le percentuali a meno di qualche decimale si approssima abbastanza bene. Ovviamente per applicazioni critiche ad esempio: percentuale di sopravvivenza di un uomo, i decimali (delta x) fanno la differenza. In conclusione l'istogramma è diviso in due: la parte verde è il modello teorico, la parte fucsia è il modello ricavato dalla simulazione. Il numero di classi ovviamente ha un ruolo nel mostrare il modello. Magari più classi mostrano meglio o magari no se la varianza è molto alta. Sotto un esempio con 15 classi:

1° classi ampiezza classi (variabile)

15 0,41535

fisso!

re limite superiore di ogni classe

0,42	0,21	0,45039	0,18707
0,83	0,63	0,36568	0,15189
1,25	1,04	0,29711	0,1234
1,66	1,46	0,24139	0,10026
2,08	1,87	0,19612	0,08146
2,49	2,29	0,15935	0,06618
2,91	2,70	0,12946	0,05377
3,33	3,12	0,10519	0,04369
3,74	3,53	0,08546	0,0355
4,16	3,95	0,06943	0,02884
4,57	4,36	0,05641	0,02343
4,99	4,78	0,04583	0,01904
5,40	5,19	0,03724	0,01547
5,82	5,61	0,03026	0,01257
6,23288	6,03	0,02458	0,01021

$$\cong f_X(x)\Delta x$$

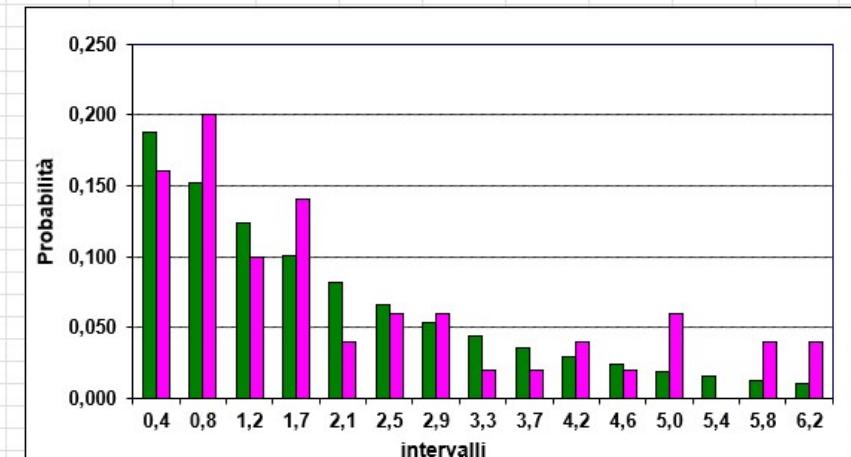
$$P(x \leq X \leq x + \Delta x)$$

$$= F_X(x + \Delta x) - F_X(x)$$

$$\cong f_X(x)\Delta x$$

$$= F_X(x + \Delta x) - F_X(x)$$

Ricostruzione legge esponenziale di media = 2



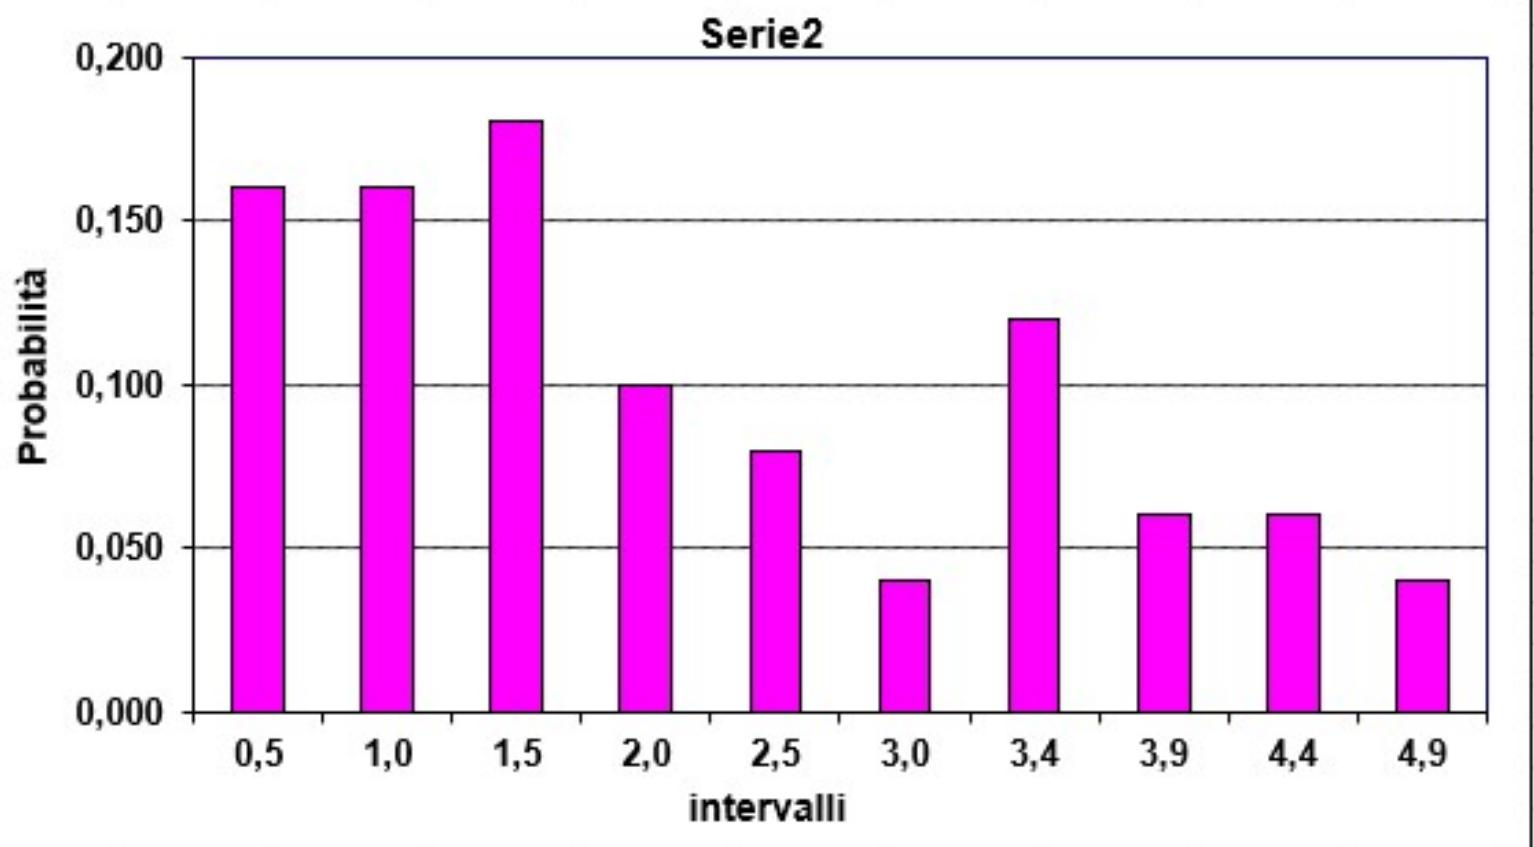
0,187	8	0,160
0,152	18	0,200
0,124	23	0,100
0,100	30	0,140
0,082	32	0,040
0,066	35	0,060
0,054	38	0,060
0,044	39	0,020
0,036	40	0,020
0,029	42	0,040
0,023	43	0,020
0,019	46	0,060
0,015	46	0,000
0,013	48	0,040
0,010	50	0,040

Noi faremo statistica inferenziale.

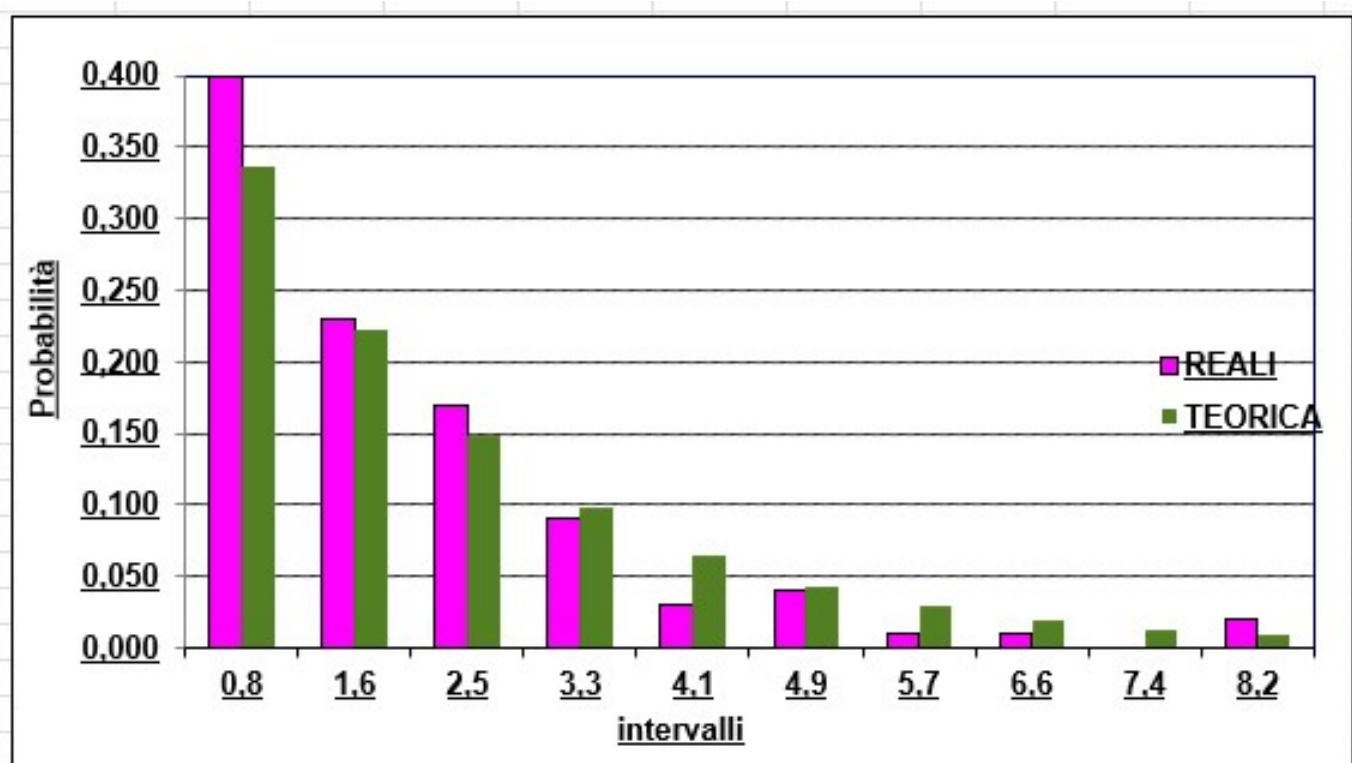
La **statistica descrittiva** consiste nel dire quali parametri ci danno una caratteristica sintetica sulla forma: valore atteso, varianza, momento del secondo ordine, simmetria ecc.

L'**inferenza** (deduzione vedi dizionario) sono i metodi per dire quanto sarà il valore atteso.

Quindi prendo un oggetto/un fenomeno, di cui scelgo quanti e quali attributi e ne provo a dedurre la forma. Quindi in questo caso l'inferenza completa che noi facciamo è la forma della legge. Prendiamo ad esempio il seguente istogramma:



Non assomiglia per niente alla curva della legge esponenziale. La statistica consiste nel ricavare con pochi dati o meno dati possibili una risposta accettando il rischio di sbagliare. Quindi per prima cosa interessa il numero di dati. Poi il numero di classi.

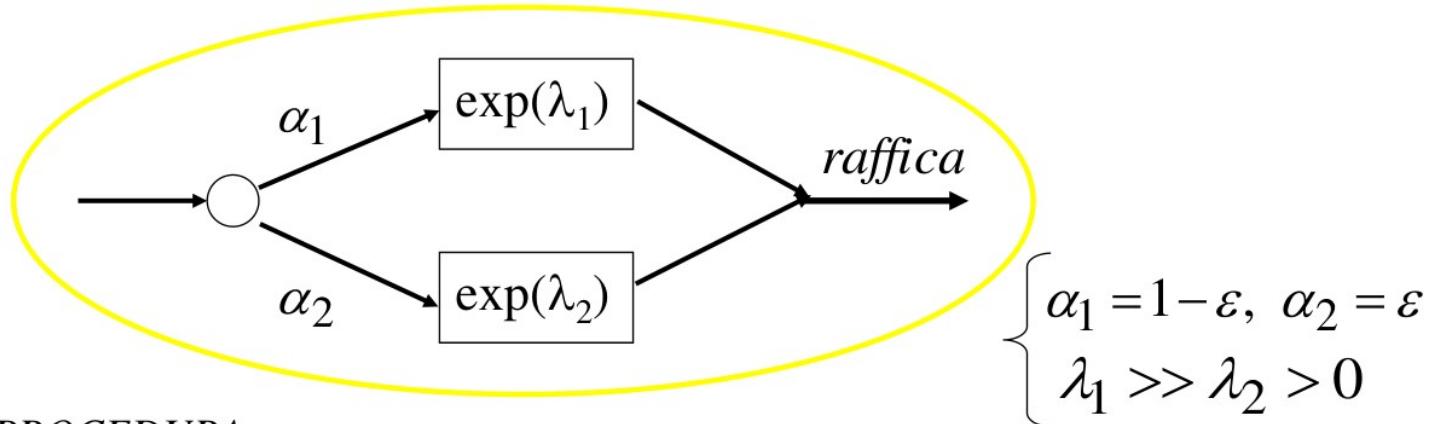


Nel grafico precedente si vede che anche se con media sperimentale 1.62(!), se uso 100 realizzazione quindi il doppio dei dati, per 10 classi la curva della legge esponenziale è abbastanza simile alla teorica. Prendiamo adesso la distribuzione iperesponenziale:

## Trasformazione inversa per la distribuzione iperesponenziale

$$F_Y(y) \hat{=} \sum_{i=1}^n \alpha_i (1 - \exp\{-\lambda_i y\}), \quad \lambda_1 \neq \lambda_2 \neq \dots \neq \lambda_n$$

$$\text{con: } \sum_{i=1}^n \alpha_i = 1, \quad \alpha_i > 0 \quad i = 1, \dots, n$$



**PROCEDURA:**

*genera*  $u \in U\{0,1\}$

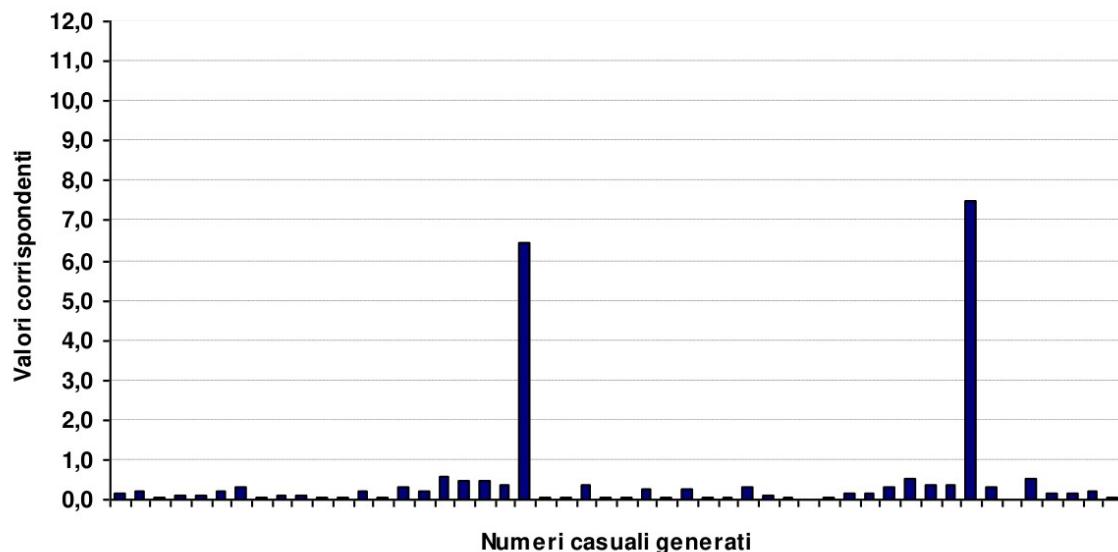
*if*  $u \leq \alpha_1$  *then* *genera*( $y \approx EXP(\lambda_1)$ )

*else* *genera*( $y \approx EXP(\lambda_2)$ )

La trasformazione inversa del iperesponenziale è una combinazione convessa. Tramite l'iperesponenziale si può studiare l'effetto di bursting. In particolare come mostra l'immagine si ha che  $\lambda_1$  è molto grande, quindi l'esponenziale molto veloce e tempi brevi  $\lambda_2$  è piccolissimo quindi esponenziale lento e tempi lunghissimi. Quindi generato un numero casuale u tra 0 e 1, si ha che  $u \leq \alpha_1$ ,  $\alpha_1 = 0.95$  genera una realizzazione di  $e^{\lambda_1}$  altrimenti di  $e^{\lambda_2}$ . I numeri "passano" uno alla volta ecco perchè si osserva un effetto raffica. Il compito della statistica sarà capire i valori di alpha e lambda, a partire da dei dati. Vediamo di seguito la generazione monte carlo di realizzazioni iperesponenziali

Realizzazioni casuali dalla legge IPEResponenziale

( alfa = 0,95 - lambda\_1 = 5 - lambda\_2 = 0,5 )

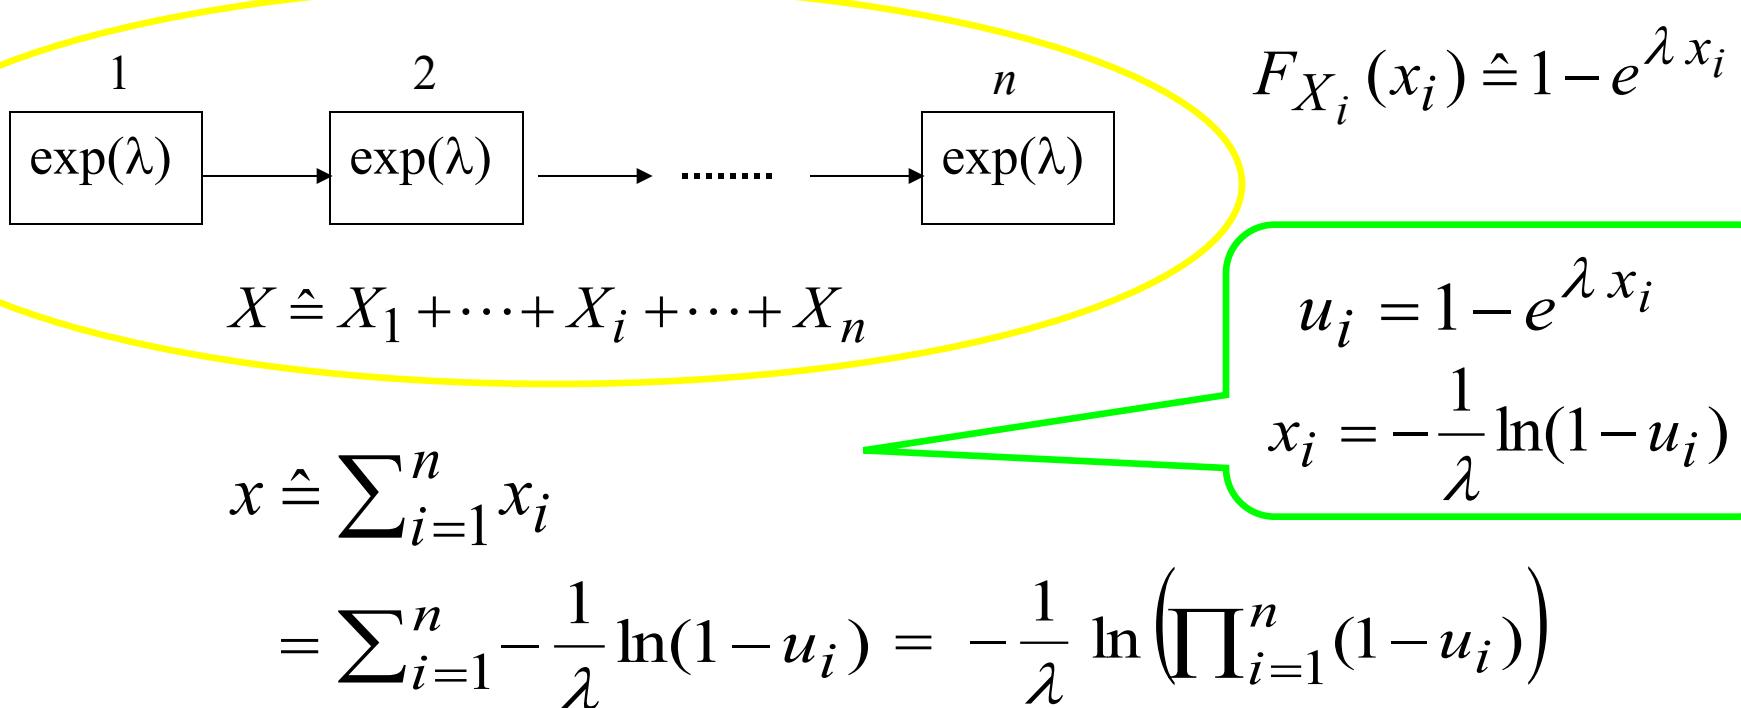


# Metodo della trasformazione inversa e legge di Erlang

$$F_X(x) \hat{=} 1 - e^{-\lambda x} \sum_{i=0}^{n-1} \frac{(\lambda x)^i}{i!} \quad \lambda > 0$$

Come anticipato nella lezione 13, la gamma è una Erlang generalizzata

*Somma di esponenziali identiche e indipendenti*



Erlang come vedremo anche dopo non ha assenza di memoria! Questo perché essendo somma di esponenziali identiche e indipendenti può essenzialmente ritornare la "posizione" all'interno della sua storia.

# STATISTICHE E STIMATORI

Una **statistica** è una variabile aleatoria funzione di un numero fissato ( $n \geq 1$ ) di altre variabili aleatorie, ma che **non contiene** alcun parametro incognito.

La realizzazione della statistica è una quantità numerica calcolata a partire da un campione di dati (variabile aleatoria funzione di un numero fissato di altre variabili aleatorie). Proprio perché parte da un campione di dati, non dipende da parametri incogniti

Sia  $T$  una statistica per le variabili aleatorie i.i.d.  $X_1 \dots X_n$  e sia  $\theta$  un parametro incognito di queste ultime; allora  $T(\mathbf{X})$  è detto **stimatore corretto di  $\theta$**  se risulta  $E[T(\mathbf{X})] = \theta$ .

- popolazione: tutti gli studenti di ingegneria
- campione: gruppo di  $n$  studenti presi casualmente dalla facoltà di ingegneria

## CARATTERISTICHE e valutazione di uno stimatore

( $E[T(\mathbf{X})] - \theta$ ) è detto **errore sistematico (bias)**

è la differenza tra il valore atteso dello stimatore ed il vero valore del parametro. Uno stimatore corretto perciò ha un bias nullo

$MSE \hat{=} E[(T(X_1, \dots, X_n) - \theta)^2]$  è l'**errore quadratico medio**

Misura la variabilità dello stimatore attorno al vero valore del parametro. Un MSE basso indica uno stimatore più preciso

**Stimatore consistente se:**

quindi è consistente se per  $n$  tendente all'infinito, converge in probabilità al parametro da stimare

$\lim_{n \rightarrow \infty} \Pr\left(|T(X_1, \dots, X_n) - \theta| \geq \varepsilon\right) = 0$

stimatore  
vero valore del parametro  
valore molto piccolo  
la stima diventa sempre più precisa man mano che si raccolgono più dati  
"all'aumentare del campione"  
probabilità che la stima  $T$  si discosti dal vero valore, diventa sempre più piccola

Valutare tutte le suddette caratteristiche con riferimento ad uno stimatore trovato e usato dagli statistici non è cosa facile, in generale!

# Anticipazione di due risultati di analisi probabilistica utili adesso

Come già anticipato in passate lezioni questi risultati sono rilevanti all'interno del corso

Dimostreremo in una lezione futura che:

1. il valore atteso di una somma di variabili aleatorie è pari alla somma dei valori attesi di ciascuna, senza bisogno di assumere che quelle variabili siano indipendenti.
2. La varianza di una somma di variabili aleatorie è pari alla somma delle varianze di ciascuna se assumiamo che quelle variabili siano indipendenti.

# La statistica “media campionaria”

E' detta media campionaria la var. al seguente :

$$\bar{X}(n) \hat{=} \frac{1}{n} \sum_{i=1}^n X_i$$

X<sub>1</sub> pari alla realizzazione  
del primo run  
della monte carlo  
↓  
singole osservazioni  
del campione  
→ dimensioni  
del campione

Se le X<sub>i</sub> sono identicamente distribuite e con lo stesso valore atteso,

$$E[X_i] \hat{=} \mu_i = \mu, \quad i = 1, 2, \dots, n.$$

il rapporto sta fuori grazie a quanto visto per val. att. di funzioni di v. a.

Valore atteso  
media campionaria

$$E[\bar{X}(n)] = \frac{1}{n} E\left[\sum_{i=1}^n X_i\right] = \frac{1}{n} \sum_{i=1}^n E[X_i] = \frac{n \cdot \mu}{n} = \mu$$

somma  
valori attesi

media della  
popolazione

⇒  $\bar{X}(n)$  e' uno stimatore corretto di  $\mu$

se calcolassi la media di tutte le possibili medie campionarie che potrei ottenere da tutti i possibili campioni, otterrei esattamente il valore della media della popolazione.

poiché le osservazioni sono indipendenti e identicamente distribuite il valore atteso della somma è uguale alla somma dei valori attesi

il valore atteso di ogni singola osservazione è pari alla media della popolazione

$$E[\bar{X}(n)] = \frac{1}{n} (\mu + \mu + \dots + \mu) = \frac{1}{n} \cdot n \cdot \mu$$

Passando alla varianza della media campionaria e assumendo che le X<sub>i</sub> siano INDIPENDENTI e con la stessa varianza:  $\sigma_i^2 = \sigma^2 \quad \forall i$

indica quanto le medie campionarie di diversi campioni estratti dalla stessa popolazione variano tra loro

$$\begin{aligned} Var[\bar{X}(n)] &= \frac{1}{n^2} E\left[\left(\sum_{i=1}^n X_i - E\left[\sum_{i=1}^n X_i\right]\right)^2\right] = \\ &\quad \text{quadrato della dimensione del campione} \\ &\quad \text{varianza "bassa" allora stima più precisa} \end{aligned}$$

I passaggi algebrici saranno mostrati in una futura lezione!

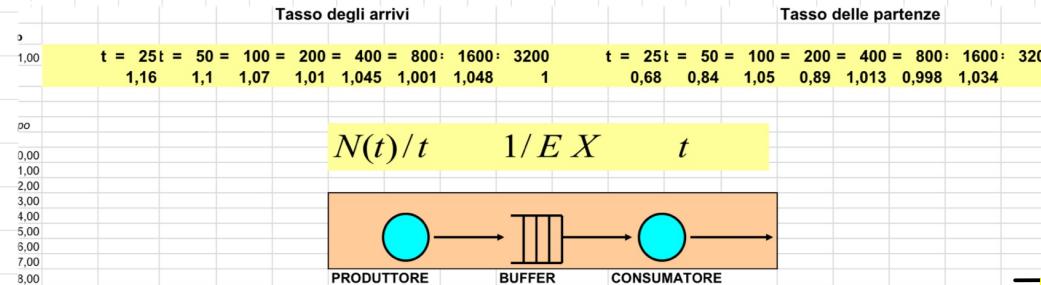
MSE coincide con la varianza!

$$= \dots = \frac{\sigma^2}{n} \Rightarrow \bar{X}(n) \text{ stimatore di bontà crescente con "n"} \quad \text{la varianza della media campionaria}$$

# MODELLO PRODUTTORE-CONSUMATORE

## MODELLO PRODUTTORE-CONSUMATORE

Tramite la simulazione monte carlo posso riprodurre la storia del sistema.



IN PIÙ...

Se gli interarrivi sono esponenziali, anche i tempi di servizio dunque gli input sono di carattere esponenziale. L'output invece non sarà di carattere esponenziale.

Si propone di studiare un classico modello gestionale produttore-consumatore (client-server) con distribuzione nota ed altri utili vincoli come ad esempio impossibilità di guasti. La politica che si utilizzerà sarà FIFO e ci si pone di analizzare, il tempo medio di attesa in coda in un intervallo di tempo fissato. Dunque si andranno a valutare: il tempo di soggiorno (attesa) dell'i-esimo client, tempo di servizio dell'i-esimo client e l'interarrivo dell'i+1-esimo client, ovvero l'intervallo di tempo tra l'arrivo dell'i-esimo e quello dell'i+1-esimo. Graficamente:



In arancione l'arrivo dell'i-esimo, in rosso l'arrivo dell'i+1-esimo, in blu il tempo di servizio dell'i-esimo, in giallo l'interarrivo ed in verde il tempo di servizio dell'i+1-esimo.

Contatore	Numeri Casuali	Tempi di Interarrivo	Istanti di Arrivo	Tasso di Servizio		Tempi di Soggiorno
				Valore Atteso in Input	Valore Atteso in Input	
1	0,514899008	0,663784498	0,663784498	1	1,1	Media su 3200 Osservazioni
2	0,887865793	0,118934682	0,782719181	Ordine	Tempi di Servizio (1/ $\mu$ )	Media su 3200 Osservazioni
3	0,887994107	0,118790172	0,901509353	FIFO	Media su 3200 Osservazioni	Tempi di Soggiorno
4	0,706357031	0,34763446	1,249143813		Tempi di Servizio	0,907979337
5	0,998920204	0,001080379	1,250224192			
6	0,285359542	1,254005343	2,504229535			
7	0,71201352	0,339658379	2,843887914			
8	0,695067289	0,363746619	3,207634533			
9	0,383131575	0,959376812	4,16701344			
10	0,759480021	0,275121262	4,442132607			
11	0,698349439	0,359035673	4,80116828			
12	0,516391639	0,660889818	5,462058091			
13	0,084551549	2,470393884	7,932451976			
14	0,922743416	0,080404072	8,012856048			
15	0,536793467	0,622141683	8,634997911			
16	0,683086114	0,381134348	9,016132256			
17	0,734663742	0,308342379	9,324474635			
18	0,0565606035	2,720487588	12,04856222			
19	0,178758964	1,721716952	13,77027918			
20	0,538244808	0,619441788	14,38972096			
21	0,92428958	0,078147977	14,46786676			
22	0,571644757	0,559237535	15,0271043			
23	0,057883943	2,849315255	17,87641955			
24	0,750335687	0,287234591	18,16365414			
25	0,4968653655	0,69945975	18,86311389			
26	0,090907199	2,397916082	21,26102998			
27	0,131174381	2,03122769	23,29225767			
28	0,851756029	0,160455144	23,45271281			
29	0,538789346	0,618430607	24,07114342			
30	0,051844256	2,959511139	27,03065456			
31	0,685667236	0,377362848	27,40801741			
32	0,663793344	0,409784407	27,81780181			
33	0,21724197	1,526742431	29,34454424			

Da notare: tasso di interarrivi in questa simulazione è pari a 1, mentre il tasso di servizio è pari a 1,1

Parto dal generare numeri casuali per generare l'interarrivo. Per passare dal primo al secondo uso la trasformazione inversa e segno l'istante d'arrivo.

\* Tramite un altro numero casuale genero un tempo di servizio, dove il primo tempo di servizio ottenuto è proprio quello della prima persona.

Utilizzo il generatore di numeri casuali PERCHÉ VOGLIO GARANTIRE L'INDIPENDENZA.

Gli istanti di partenza sono dati dalla somma dell'istante di arrivo più il servizio. Posso ricavarli anche ricorsivamente. Mi concentro sul processo delle partenze che è simmetrico rispetto al processo degli arrivi

Tempo di Attesa in Coda		Modello analitico di riferimento		passo
Valore Atteso Calcolato	E[W]=p/(μ*(1-p))=	9.090909091		
Media su 3200 Osservazioni				
Tempo di Attesa in Coda	13,01393943	13,01393943		
Tempi di Soggiorno	Tempi di Attesa in Coda	Equazione di Lindley W <sub>i</sub>		
0,866715914	0	0	Pearson	
1,784991261	0,747781	0,747781232	Correlazione	
3,11619316	1,666201	1,666201089	-0,152677476	-0,152677476
3,941814402	2,768559	2,7685587	-0,026784313	-0,008168125
4,124712027	3,940734	3,940734023	0,01868795	-0,026082237
3,986466977	2,870707	2,870706684	-0,023201384	-0,016934534
5,447764384	3,646809	3,646808598	0,002299292	-0,027880259
6,657270853	5,084018	5,084017765	12	5
6,344688281	5,697894	5,697894041	12	6
6,810749438	6,069567	6,069567018	13	6
9,005299962	6,451714	6,451713765	13	7
8,674615465	8,34441	8,34441015	15	8
6,565357375	6,204222	6,204221581	17	9
8,514319352	6,484953	6,484953303	17	10
9,209361204	7,892177	7,892177489	18	10
9,418595597	8,828227	8,8282226859	19	11
13,6058386	9,110253	9,110253218	21	13
14,35938563	10,881751	10,88175101	22	13
14,45397615	12,637669	12,63766868	22	14
14,93949357	13,834534	13,83453437	23	15
16,19357514	14,861348	14,86134778	25	16
15,73265041	15,634338	15,63433761	25	16
13,48894705	12,883335	12,88333515	21	20
14,12720376	13,201712	13,20171246	22	20
13,66876378	13,427744	13,42774401	23	20
11,46984841	11,270848	11,2708477	24	20
9,439901216	9,438621	9,438620721	25	20
10,36663458	9,279446	9,279446072	26	20
10,87855175	9,748204	9,748203972	27	20
11,22180258	7,919041	7,919040612	28	20
12,07879412	10,84444	10,84443974	29	20
12,31984311	11,66901	11,66900972	30	20
	11,70210068	11,70210068	31	20
	11,70210068	11,70210068	32	20

Lindley: relazione ricorsiva tra il tempo di attesa del n-esimo e il tempo del (n-i)-esimo. Ad esempio relazione tra tempo di attesa della 10° persona (ultima) che attende il servizio e della 9°

Calcolo i tempi di attesa mediante l'equazione di Lindley :

tempo d'attesa i-esimo + tempo servizio i-esimo - interarrivo i+1-esimo

I tempi di soggiorno sono variabili aleatorie, il primo valore coincide con il servizio. Immagino al sequenza temporale di soggiorno (X<sub>1</sub>, X<sub>2</sub>...X<sub>n</sub>), le X sarebbero le realizzazioni dei tempi di soggiorno a partire dal primo. Esempio: ogni mattina vado alla posta a vedere quanto tempo aspetta la terza persona in fila. Il terzo di ogni mattina rappresenta un campione, dunque soggiorno della terza persona.

per ogni variabile aleatoria viene generata una realizzazione indipendente corrispondente ogni volta che si fa un run

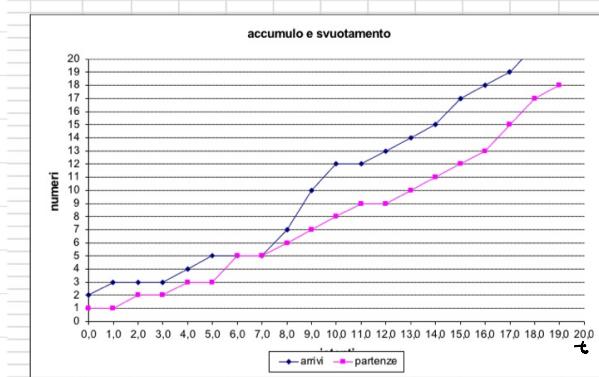
- Potrebbe servire la statistica? La realizzazione di S3 rispetto a quella di S5 è indipendente? O meglio, la sequenza dell'uscita del sistema di osservazioni è indipendente? Gli input per ipotesi sono indipendenti. La realizzazione di S5 è correlata a quella di S3. Le due realizzazioni sono identicamente distribuite? Concetto di stazionarietà (un qualcosa poi non cambia più)

se dovessi studiare questo sistema, spero che per  $n \rightarrow \infty$  ci sarà una sola variabile aleatoria, ossia "soggiorno n-esimo", dopo 1000 o più realizzazioni (a lungo termine) diventerà una sola realizzazione. "Ne studio uno ed è come se li studiassi tutti"

- Come stimo la varianza? Se implemento la varianza campionaria sorge il problema della indipendenza e della correlazione (che si vedrà in futuro)

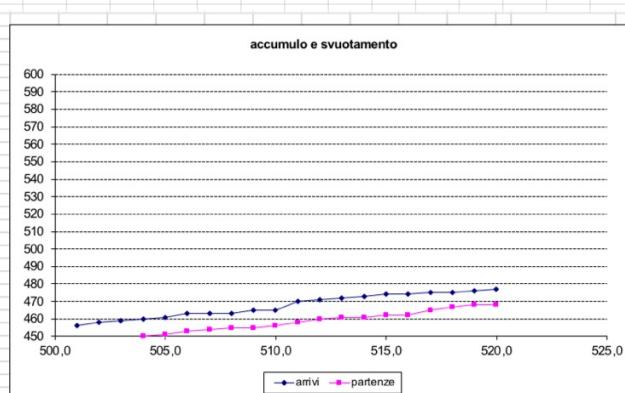
- Mi focalizzo sul tempo di attesa in coda (è una media aritmetica). Se clicco sulla sua casella mi rendo conto che salto da circa 10 a circa 5 con una "pigiata", quindi che varianza c'è? Come la stimo? Che "fiducia" posso dare a quel valore? Nascono le stime intervallari (intervallo di confidenza). Esse vengono utilizzate per stimare delle prestazioni. Per esempio ad un indice di prestazione (variabile aleatoria) come il tempo di risposta, quale valore atteso minimo "posso chiedere"?

Simulazione Monte Carlo: riproduco la storia degli stati. Di segui le traiettorie che rappresentano arrivi e partenze:



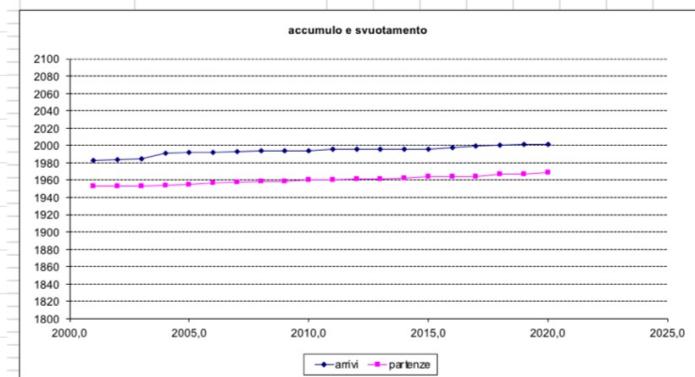
$0 \leq t \leq 20$  (inizio)

Simulo la traiettoria del processo stocastico degli arrivi e quello delle partenze. Inizialmente, non posso sapere se il sistema è congestionato o no



$500 \leq t \leq 525$  (metà)

Osservo il sistema a lungo termine



$2000 \leq t \leq 2025$  (verso la fine)

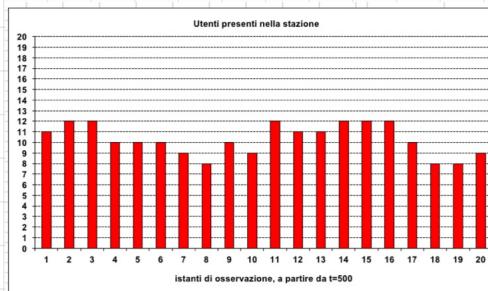
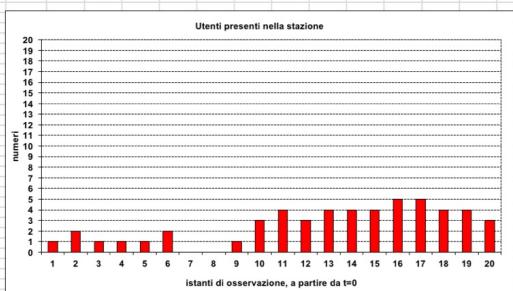
Quando il sistema arriva a regime il numero di arrivi e partenze tende a uguagliarsi

Arrivi ( $x_0, y_0$ ) – Partenze( $x_0, y_0$ ) = numero di persone coinvolte

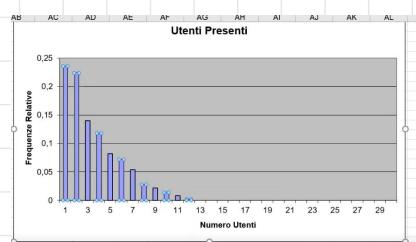
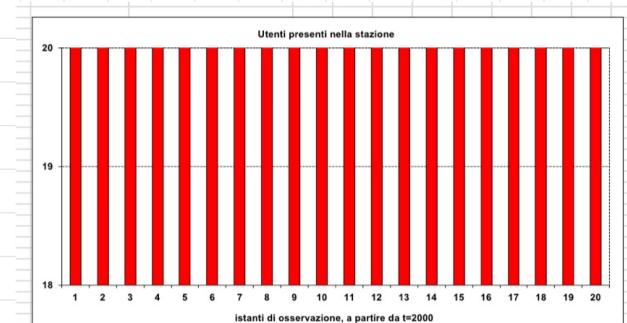
Tasso Interarrivi	1
Valore Atteso in Input	
Interarrivi ( $1/\lambda$ )	1
Media su 3200 Osservazioni	
Interarrivi	0.958853087

Tasso di Servizio	1,1
Valore Atteso in Input	
Ordine	FIFO
Tempo di Servizio ( $1/\mu$ )	0,909090909
Media su 3200 Osservazioni	
Tempo di Servizio	0,907979337

Tempi di Soggiorno	
Valore Atteso Calcolato	
$E[S]=1/[\mu*(1-p)] =$	10
Media su 3200 Osservazioni	
Tempi di Soggiorno	13,92191877



In questo caso, **TASSO DI SERVIZIO > TASSO INTERARRIVI**  
→ 10% più veloce



Il grafico rappresenta proprio il modello geometrico di occupazione del buffer

Cosa accade se tasso di servizio<tasso interarrivi? Cosa accade se se tasso di servizio=tasso interarrivi? Cosa accade se tasso di servizio>>tasso interarrivi? Da notare che con un tasso 10% più alto di quello degli interarrivi, il sistema comunque tende a congestionarsi.

A lungo andare se non "chiudo" il sistema ci sarà solo congestione

## Il TLC per la “media campionaria”

Nell’analisi statistica del modello PRODUTTORE - CONSUMATORE, è assai utile poter assumere che una realizzazione della media campionaria corrisponda alla media aritmetica di una sequenza di realizzazioni indipendenti della stessa variabile aleatoria,  $X$ , magari rilevate con osservazioni sperimentali, indipendenti (runs del Metodo Monte Carlo).

Infatti, particolarizzando il teorema limite centrale a questo caso, risulta:

in giallo sarebbe la standardizzazione della media campionaria     $\tilde{Z}_n = \frac{\bar{X}(n) - E[\bar{X}(n)]}{\sqrt{VAR[\bar{X}(n)]}} = \frac{\bar{X}(n) - \mu}{\sqrt{\sigma^2 / n}}$  ricordando che il TCL riguarda la somma di variabili aleatorie.

che tende alla normale standard per  $n \rightarrow \infty$  e, di conseguenza:

$$\bar{X}(n) = \frac{\sigma}{\sqrt{n}} \tilde{Z}_n + \mu \quad \text{tende ad essere distribuita come una legge normale di media } \mu \text{ e varianza } \sigma^2/n \text{ al crescere di } n$$

deviazione standard

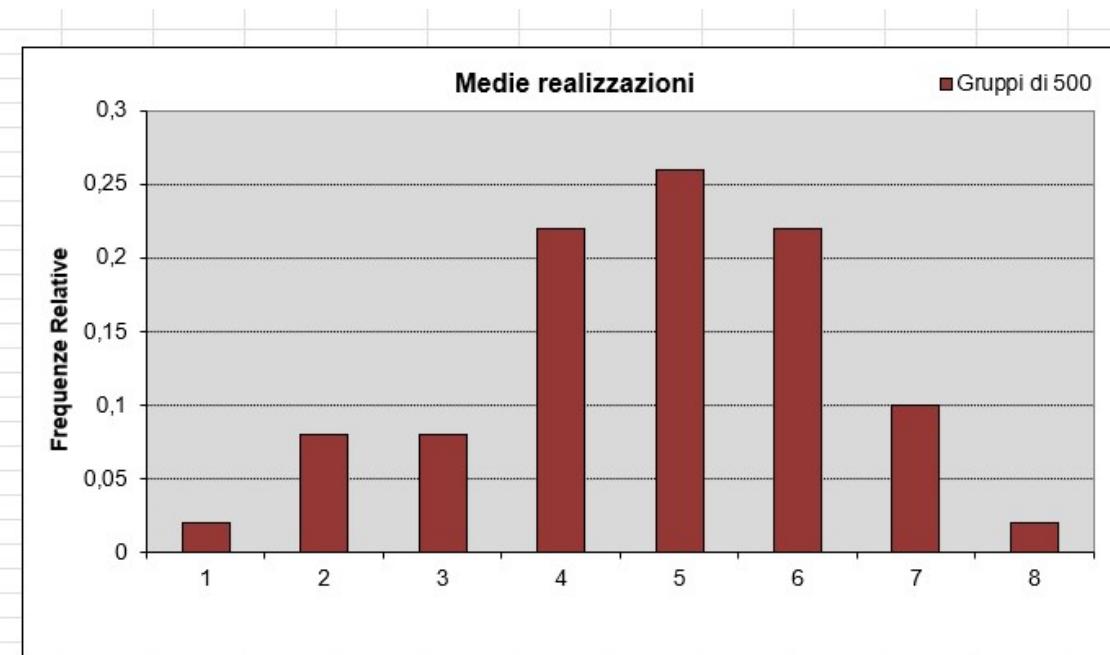
In particolare, si verifica sperimentalmente che la forma della  $\bar{X}(n)$  diventa approssimabile ai fini pratici con la forma normale per  $n > 30$

Per il modello produttore consumatore

## Sperimentalmente aprodo il foglio excel: normalità della media campionaria si verifica il teorema del limite centrale

**TESI:**  
La media campionaria tende a essere distribuita come una gaussiana centrata sul valore medio della legge esponenziale

Attraverso le generazioni Montecarlo, l'obiettivo di tale esperimento è stato quello di cercare di convalidare il teorema del limite centrale. Nella pratica, aumentando le  $n$  (dimensione del campione) ho cercato di approssimare fedelmente la "campana di Gauss". Con un numero di medie campionarie pari a 200 e poi ancora più con un numero di campioni pari 500, riesco a verificare sperimentalmente il suddetto teorema, ottenendo nelle varie simulazioni, sempre risultati più o meno attendibili. Ovviamente per campioni sempre maggiori l'attendibilità del teorema risulterà ancora più evidente.



Appunto più sale il gruppo di medie più si tende alla gaussiana. Oppure si poteva salire con il numero di realizzazioni!

La media di medie è detta grande media, il cui valore atteso della grande media è pari alla somma tra il valore atteso delle singole medie.

valori individuali di un campione di dimensione n ad esempio n=50, media campionaria di 50.

## L'intervallo di confidenza per la media (valore atteso)

Siano  $X_1, X_2, \dots, X_n$  variabili aleatorie tutte indipendenti e identicamente distribuite

$\approx N(\mu, \sigma^2)$ , allora:

la media campionaria tende ad

essere distribuita come una normale di media  $\mu$  e varianza  $\frac{\sigma^2}{n}$

grazie al TCL appena visto

per il "teorema di riproducibilità" della normale. Ovvero che la somma di v.a. mantiene la forma di una normale

Rammentando che: (grazie all'indipendenza)

utilizzo la v.a. della  
media campionaria  
non una realizzazione

$$\bar{X}(n) \stackrel{d}{=} \frac{\sum_{i=1}^n X_i}{n} \approx N\left(\mu, \frac{\sigma^2}{n}\right)$$

Z è una statistica!

Ricorda che il valore atteso non è una media di per sé, ma perché la media aritmetica lo stima!

e che:

$$\Pr[-z_{\alpha/2} \leq Z \leq z_{\alpha/2}] = 1 - \alpha$$

dove:

$$\alpha/2 = \int_{-\infty}^{z_{\alpha/2}} f_Z(z) dz = \int_{z_{\alpha/2}}^{+\infty} f_Z(z) dz$$

si ottiene: (isolando  $\mu$ )

$$\Pr\left[\bar{X} - \frac{\sigma}{\sqrt{n}} z_{\alpha/2} \leq \mu \leq \bar{X} + \frac{\sigma}{\sqrt{n}} z_{\alpha/2}\right] = 1 - \alpha$$

ricorda nella realtà si usa una stima della deviazione, non la deviazione reale!

In pratica, è stato stabilito che l'intervalllo aleatorio:

$$\left[ \bar{X} - \frac{\sigma}{\sqrt{n}} z_{\alpha/2}, \bar{X} + \frac{\sigma}{\sqrt{n}} z_{\alpha/2} \right]$$

(IC) Da notare che l'intervalllo è simmetrico!

contiene, con probabilità  $1 - \alpha$ , il valore (incognito) del parametro .

Ogni realizzazione (intervallo numerico) di (IC) può essere considerata una stima di ,

ma non si può dire che essa contiene e tanto meno che il valore corrispondente a è

il centro dell'intervalllo: ogni punto dell'intervalllo ha la stessa probabilità di essere .

(IC) è detto intervallo di confidenza al  $100(1 - \alpha)\%$  (livello di confidenza).

Dunque per progettare un intervallo di confidenza serve un parametro incognito ed una statistica. Inoltre la simmetria dell'intervalllo è anche frutto della Gaussiana che di per sé è simmetrica

**OSSERVAZIONE:** Per ottenere una realizzazione dell'intervallo di confidenza sulla media del processo, occorre una stima della varianza del processo!

### Importanza dell'intervallo di confidenza:

- introduce l'idea di stimare un parametro non più attraverso la realizzazione di una variabile aleatoria, bensì attraverso la realizzazione di un intervallo aleatorio che contiene, con la probabilità voluta, il parametro stesso.

L'intervallo però non deve essere né troppo grande né troppo piccolo.

### Qualità dell' intervallo:

- fissato il livello di confidenza,  $100(1-\alpha)\%$ , e con una certa deviazione standard ( $\sigma$ ), intervalli migliori (cioè più ristretti) possono essere ottenuti solo aumentando di parecchio la numerosità ( $n$ ) del campione.

### Problemi d'uso:

- La stima per intervallo di un parametro del 1° ordine, quale la “media”, richiederebbe la conoscenza di un parametro del 2° ordine, quale la “deviazione standard”.
- Sembrerebbe valido solo nell'ipotesi che il parametro-media da stimare sia quello di una legge normale.

### Soluzione dei problemi:

- Si può usare la varianza campionaria al posto della varianza vera e, sfruttando il teorema limite centrale, si può dimostrare che:

$$\Pr\left[\bar{X} - \frac{S}{\sqrt{n}} z_{\alpha/2} \leq \bar{X} \leq \bar{X} + \frac{S}{\sqrt{n}} z_{\alpha/2}\right] \cong 1 - \alpha \quad \text{per } n \rightarrow \infty$$

quando manca l'ipotesi di normalità delle variabili i.i.d.  $X_1, X_2, \dots, X_n$ .

L'intervallo:  $\left[\bar{X} - \frac{S}{\sqrt{n}} z_{\alpha/2}, \bar{X} + \frac{S}{\sqrt{n}} z_{\alpha/2}\right]$  è considerato una buona approssimazione dell'intervallo vero già con  $n \geq 30$ .

### NOTA:

Nella pratica si usa fissare il livello di confidenza al 90% o 95% a ciò corrisponde:  $\alpha = 0.10$   $\alpha = 0.05$   $z_{\frac{\alpha}{2}} = 1.645$   $z_{\frac{\alpha}{2}} = 1.960$

# La statistica “varianza campionaria” 1(2)

Siano  $X_1, X_2, \dots, X_n$  I.I.D.  $E[X_i]$  è il valore atteso della popolazione da cui è estratto il campione

con:  $E[X_i] \hat{=} \mu, \quad Var[X_i] \hat{=} \sigma^2, \quad i = 1, \dots, n$

DA:  $\sum_{i=1}^n (X_i - \bar{X})^2 = \sum_{i=1}^n (X_i - \mu)^2 - n(\bar{X} - \mu)^2 \quad (\bar{X} \hat{=} \frac{1}{n} \sum_{i=1}^n X_i)$

SI OTTIENE:  $E \left[ \sum_{i=1}^n (X_i - \bar{X})^2 \right] = (n-1)\sigma^2$  (n-1) è importante e si riflette sulla correttezza dello stimatore

I passaggi algebrici sono stati indicati nella dispensa del corso, parte II, “Analisi Statistica”, pag. 24 e 25, ma NON fanno parte del programma di esame!

Si userà come stima della varianza S al posto di sigma

**IN CONCLUSIONE:**

“n-1” e non “n” perchè per ottenere una stima più accurata della varianza usiamo un “aggiustamento statistico”

$$E \left[ \frac{1}{(n-1)} \sum_{k=1}^n (X_k - \bar{X})^2 \right] = \sigma^2$$

NON SI TRATTA DI GAUSS

se calcolo la varianza campionaria su molti campioni diversi le media di questa varianza campionaria si avvicinerebbe sempre di più alla vera varianza della popolazione

**Osservazione:** La varianza campionaria è la stima puntuale della varianza.

Nella parentesi quadrata c’è uno **stimatore corretto del parametro varianza**, cioè la statistica “varianza campionaria”!

# Formula alternativa usata in Excel per esprimere lo stimatore della varianza

[https://www2.isye.gatech.edu/people/faculty/David\\_Goldsman/](https://www2.isye.gatech.edu/people/faculty/David_Goldsman/)

$$S^2 = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n - 1}$$

Ottengo lo stesso risultato visto nella slide precedente appunto

$$= \frac{\sum_{i=1}^n (X_i^2 - 2\bar{X}X_i + \bar{X}^2)}{n - 1}$$

$$= \frac{\sum_{i=1}^n X_i^2 - 2\bar{X} \sum_{i=1}^n X_i + n\bar{X}^2}{n - 1}$$

$$= \frac{\sum_{i=1}^n X_i^2 - 2n\bar{X}^2 + n\bar{X}^2}{n - 1}$$

$$= \frac{\sum_{i=1}^n X_i^2 - n\bar{X}^2}{n - 1}$$

## La statistica “varianza campionaria” 2(2)

In base al precedente risultato, la variabile aleatoria:

$$S^2 \triangleq \frac{1}{(n-1)} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{\sum_{i=1}^n X_i^2 - n\bar{X}^2}{n-1}$$

è detta “varianza campionaria” e viene usata per “stimare” “puntualmente” il parametro  $\sigma^2$  grazie alla seguente (che non dimostreremo):

$$Var[S^2] = \frac{2\sigma^4}{n-1} \rightarrow 0 \quad \text{per } n \rightarrow \infty$$

quadrato della varianza!

### Osservazione:

Lo stimatore corretto del parametro varianza migliora al crescere di “n” (perché si riduce la sua varianza)

Però, purtroppo, questo stimatore ha una varianza sua che è pari al quadrato della varianza che deve stimare!

## PRODURRE STIME INTERVALLARI

casuale	LAMBDA	ESPOENZIALE	scarti	scarti^2		stima della media e della varianza	n	n-1	alfa	alfa/2	1-alfa/2
0,907059	0,25	B - tempo di soggiorno	A	A		A	100	99	0,05	0,025	0,975
0,071457	MEDIA	5,649488	31,91671								
0,475876	3,853689	-3,55713	12,6532								
0,620852		2,58411	-1,26958	1,61183							
0,881526	SOM SCA	3,879311	0,025624	0,000656							
0,242467	2152,032	8,532253	4,678564	21,88896							
0,62759		1,110751	-2,74294	7,523707							
0,94516		3,951039	0,097349	0,009477							
0,210836		11,61336	7,759668	60,21245							
0,315209		0,947125	-2,90566	8,448114							
0,750039		1,514568	-2,33912	5,471486							
0,293832		5,545806	1,692117	2,863259							
0,202667		1,39161	-2,46208	6,061832							
0,146378		0,905933	-2,94776	8,689265							
0,844105		0,633068	-3,22062	10,3724							
0,571085		7,434278	3,580589	12,82061							
0,3715		3,385983	-0,46771	0,218749							
0,997946		1,857675	-1,99601	3,984071							
0,815052		24,75135	20,89767	436,7124							
0,010066		6,750719	2,89703	8,392782							
0,256869		0,040468	4,767497	4,767496981							
0,464483		1,187533	-2,66616	7,10839							
		2,49809	-1,3556	1,83765							

LIVELLO DI "CONFIDENZA" o "FIDUCIA" (DALL'INGLESE "CONFIDENCE")

Il valore atteso del tempo di soggiorno, in precedenza era pari a: 11.055934. Potrebbe cambiare rendendo più complicato il modello se vengono applicate politiche differenti (round-robin, ecc.) In questi casi occorre fare delle simulazioni

In questo caso specifico, non sono sicuro di trovarmi di fronte ad un errore quindi faccio una stima intervallare.

Se volessi cambiare i dati, l'unico valore che potrei variare è n altrimenti cambierei il problema.

$z_{\frac{\alpha}{2}}$  valori della Gaussiana in corrispondenza del quantile  $\frac{\alpha}{2}$   
1.96 è l'ascissa entro cui realizzo  $\frac{\alpha}{2}$

Non so come si produce una realizzazione da una normale perché non vale il metodo delle trasformazioni inverse. Utilizzo il metodo implementato da Excel

aumento la varianza da 10 a 20 per aggiornare i valori



La media campionaria prende la varianza del processo e la lascia immutata. La varianza invece amplifica

Gli intervalli di confidenza NON SONO simmetrici ma quello della media lo è. Ha come variabile la gaussiana  $Z$

Quando si valuta il grado di confidenza entra in gioco una statistica a prescindere dalle realizzazioni con cui lavoro. Per il valore atteso è la gaussiana, per la varianza è la chi-square.

Lavoro con un modello esponenziale applicato ad una realizzazione di una variabile aleatoria di forma nota. Nel file vengono riportati 2 casi: quello normale ed esponenziale. Il primo rappresenta gli intervalli di confidenza per la Gaussiana. In verità i tempi di soggiorno non sono né gaussiani né esponenziali. Ipotizzo che siano esponenziali (input e output esponenziale)

casuale	media	10	normale( $\mu, \sigma$ )	scarti	scarti^2		stima della media e della varianza	n	n-1	alfa	alfa/2	1-alfa/2
0,93641	media	10	normale( $\mu, \sigma$ )	A	8,9583		A	50	49	0,05	0,025	0,975
0,90393	varianza	4	B	2,99304	2,99304							
0,38798				13,05063868	12,60859815							
0,73052				9,430834362	-0,62676	0,39283						
0,66088				11,22875651	1,71116	1,37161						
0,18201				10,82973808	0,77214	0,5962						
0,45214				8,184505265	-1,87309	3,50847						
0,96925				9,759509861	-0,29809	0,08886						
0,46606				13,73990095	3,6823	13,5594						
0,53401				9,829635879	-0,22796	0,05197						
0,79892				10,17071052	0,11311	0,01279						
0,51266				11,67553457	1,61794	2,61772						
0,06273				10,06350167	0,0059	3,5E-05						
0,79957				6,935544614	-3,12205	9,74721						
0,00776				11,68020263	1,62261	2,63285						
0,95412				5,159899376	-4,8977	23,9874						
0,68681				13,37227692	3,31468	10,9871						
0,05664				10,97364108	0,91604	0,83914						
0,05435				6,832797054	-3,2248	10,3993						
0,16272				6,7918386	-3,26576	10,6652						
0,85231				8,033329709	-2,02427	4,09766						
0,65749				12,09279673	2,0352	4,14204						
				10,81127127	0,75367	0,56802						

Devo dimostrare che con probabilità 0.95 ottengo l'intervalllo che contiene il valore VERO. Tale intervallo garantisce che al 95% (livello di confidenza) contiene il valore vero. Dunque il valore vero è equiprobabile e non si trova solo al centro.

$$X - \frac{S}{\sqrt{n}} z_{\frac{\alpha}{2}} \leq \mu \leq X + \frac{S}{\sqrt{n}} z_{\frac{\alpha}{2}}$$

L'intervalllo è corretto sotto l'ipotesi di v.a. i.i.d. come una Gaussiana. Quindi anche grazie al TCL

Stima centrale che oscilla tra il suo valore meno qualcosa ed il suo valore sommato a qualcosa

$\bar{X}$  è la media campionaria

$\frac{S}{\sqrt{n}}$  è la deviazione standard della varianza campionaria

$\bar{X} \pm \frac{S}{\sqrt{n}} z_{\frac{\alpha}{2}}$  è l'intervalllo aleatorio

L'ampiezza dell'intervalllo è proporzionale a "S". Se ho un'ampiezza "larga" e voglio diminuirla posso lavorare solo su "n" ossia sul carico di dati. Data la radice quadrata il numero di dati deve aumentare sostanzialmente

## La distribuzione chi-quadrato

è una particolare Gamma ricordalo!

Come si è già detto, la distribuzione gamma, ha dato vita ad una particolare distribuzioni, dette chi-quadrato. Andiamo adesso a caratterizzarne la densità della variabile aleatoria chi-square. Considerando una variabile aleatoria  $X_\gamma^2$ , detta chi-square la densità della chi-square è pari a:

$$f_X(x) = \frac{1}{\Gamma(\gamma/2)2^{\gamma/2}} x^{\frac{\gamma}{2}-1} e^{-\frac{x}{2}} \text{ con } x \geq 0$$

con  $X \equiv X_\gamma^2 \equiv x_\gamma^2$  con  $\gamma$  "gradi di libertà". Su Excel la densità gamma è pari a:

$$f_X(x) = \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-\frac{x}{\beta}} \text{ con } \beta = \frac{1}{\lambda} \quad \text{dunque è una gamma con: } \beta = 2 \alpha = \frac{\gamma}{2} \gamma \in [1, 2 \dots n]$$

$x_\gamma^2$  individua il punto della semiretta reale a partire dal quale l'area sottesa della densità è proprio  $\gamma$ , ovvero  $Pr[X_\gamma^2 \geq x_\gamma^2] = \gamma$  (N.B. sta definizione nel powerpoint non c'è)

Si ricava che la media è la varianza sono pari a rispettivamente a:  $E[X] = \gamma$   $Var[X] = 2 \cdot \gamma$

In particolare i gradi di libertà coincidono con il valore atteso. Si vuole dimostrare il seguente teorema: la variabile aleatoria "chi-quadrato" con 1 grado di libertà corrisponde al quadrato della "normale standard".

$$F_{Z^2}(z) \hat{=} \Pr\{Z^2 \leq z\} = \Pr\{-\sqrt{z} \leq Z \leq \sqrt{z}\} \quad \text{Sarebbe la dimostrazione di Trivedi funzioni di v.a. lezione 13}$$

$$= F_Z(\sqrt{z}) - F_Z(-\sqrt{z}) = 2 \int_0^{\sqrt{z}} \frac{1}{\sqrt{2\pi}} \cdot \exp(-u^2/2) \cdot du$$

$$= 2 \int_0^{\sqrt{z}} \left(1/\Gamma(1/2)\sqrt{2}\right) \cdot \exp(-u^2/2) \cdot du$$

$$\left( \text{con } u \hat{=} \sqrt{v} \Rightarrow du = v^{-1/2} \cdot dv = v^{1/2-1} \cdot dv \right)$$

$$= \int_0^z \left(1/\Gamma(1/2)2^{1/2}\right) \cdot v^{1/2-1} \cdot \exp(-v/2) \cdot dv \quad \text{Ricordando che:}$$

$$f_{x_\gamma^2}(x) = \left(\frac{1}{\Gamma(\frac{\gamma}{2})}2^{\frac{\gamma}{2}}\right) \cdot x^{\frac{\gamma}{2}-1} \cdot e^{-\frac{x}{2}} \implies F_{x_\gamma^2}(z) = F_{Z^2}(z)$$

Teorema di riproducibilità della legge chi-quadrato (non dimostrato)

Siano:  $X_{\gamma_1}^2, X_{\gamma_2}^2 \dots X_{\gamma_n}^2$  indipendenti, con i rispettivi gradi di libertà:  $\gamma_1^2, \gamma_2^2 \dots \gamma_n^2$  allora:

$X_{\gamma_1}^2 + X_{\gamma_2}^2 + \dots + X_{\gamma_n}^2$  è ancora una chi-quadrato, con gradi di libertà pari a:  $\gamma_1, \gamma_2 \dots \gamma_n$

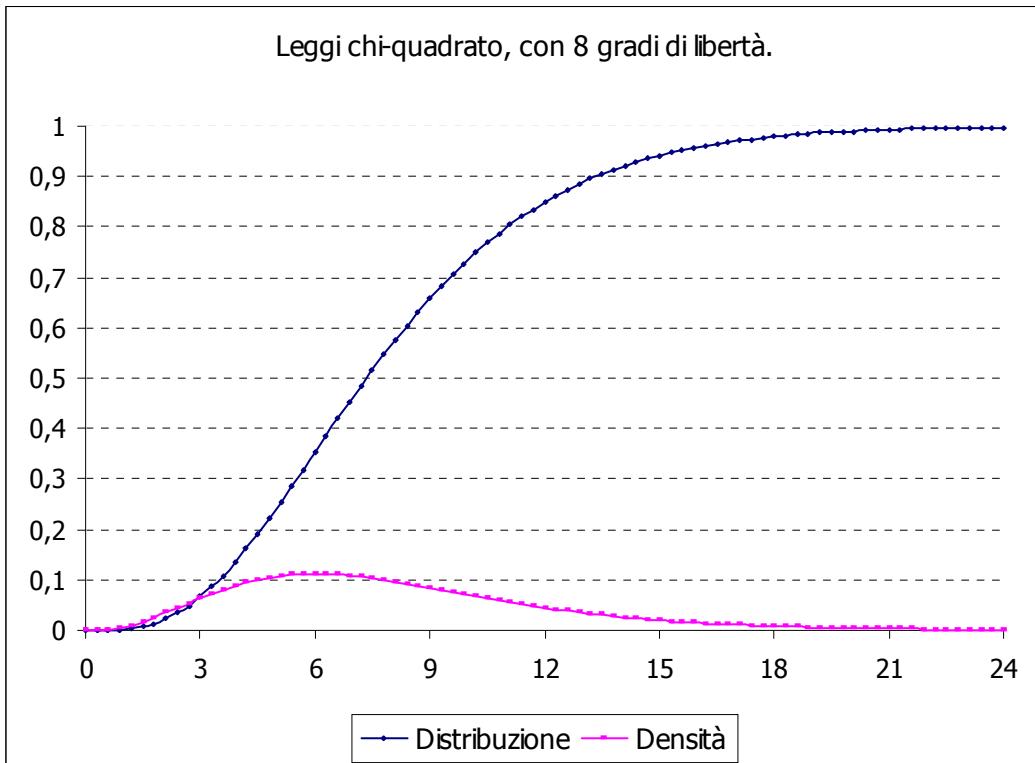
Attraverso le trasformate di Laplace ed al prodotto di convoluzione si prova il teorema.

**IMPORTANZA:** per "stimare" la varianza e la forma di una distribuzione, a partire da un insieme di realizzazioni sperimentali.

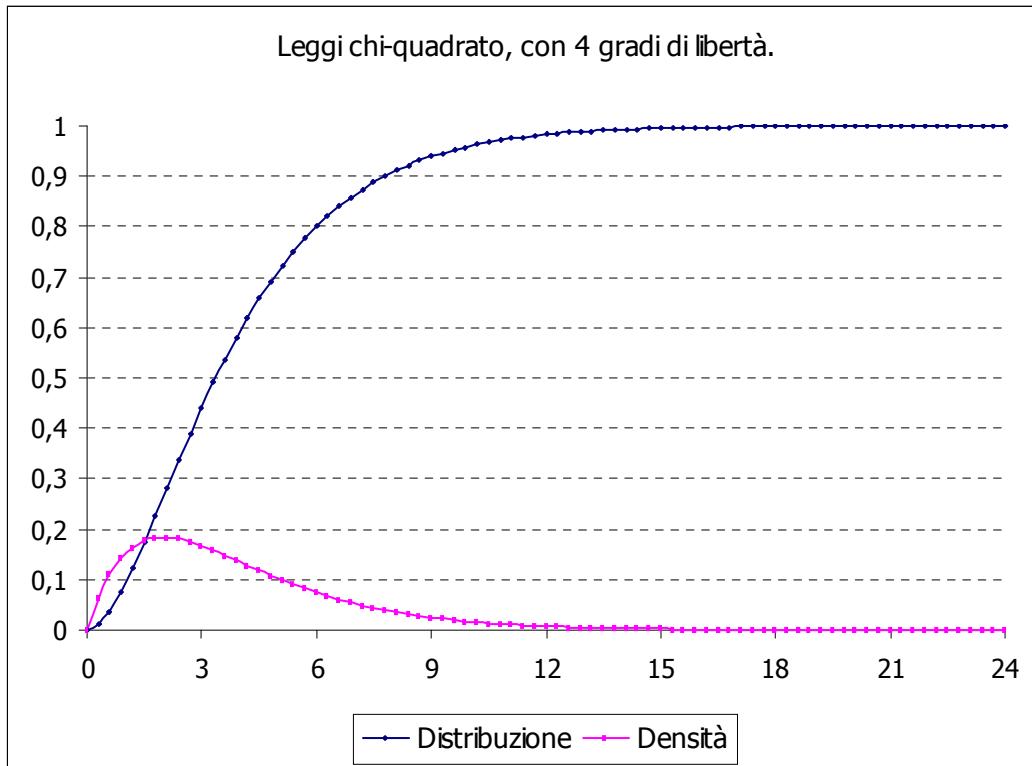
In parole povere il teorema afferma che la somma di chi-quadrato è ancora una chi-quadrato dove i gradi di libertà si sommano. Come detto è importante per "stimare" la varianza e la bontà della forma. (Si vedrà in futuro)(Test sulla forma con chi-square)

Bisognerebbe separare il grafico,  
ad esempio il punto di intersezione  
non si capisce ed una curva "sovrastra"  
l'altra

### Rappresentazione della chi-quadrato



da notare anche che non c'è nessun valore negativo. la chi-square è solo positiva!



N.B. più aumentano i gradi di libertà più la chi-quadrato tende in forma ad una normale.  
Vedi EXCEL In particolare a 12/13 circa si ha una normale mentre a già a 2 si ha uno spike

## L'intervallo di confidenza per la varianza

Ripensando al ragionamento che ha condotto a “scoprire” un intervallo stimatore (detto, poi, intervallo di confidenza) per il parametro  $\sigma^2$ , si dovrebbe riconoscere che è stata fondamentale la disponibilità di una variabile aleatoria di distribuzione nota che conteneva quel parametro:

$$Z \triangleq \frac{\bar{X} - \mu}{\sigma / \sqrt{n}} \approx N(0,1)$$

Dunque, volendo insistere su una strada analoga per individuare un intervallo di confidenza per un altro parametro importante quale la varianza, si deve cercare un'altra variabile aleatoria di distribuzione nota che contenga il parametro varianza e, se possibile, priva di ulteriori parametri che potrebbero creare complicazioni nell'uso pratico dell'intervallo, perché incogniti. Nel linguaggio degli statistici, si direbbe che si sta cercando una “statistica”, cioè una variabile aleatoria capace di produrre una stima.

Col seguente teorema si trova la statistica per la varianza:

**Teorema (nascita della chi-square)** Stessa ipotesi della media campionaria

Siano  $X_1, X_2, \dots, X_n$  indipendenti e identicamente distribuite  $\approx N(\mu, \sigma^2)$ , allora:

$$\text{statistica} \rightarrow \frac{(n-1)S^2}{\sigma^2} = \frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \bar{X})^2 = \chi^2_{\gamma=n-1} \quad (\text{Tesi}) \quad \begin{array}{l} \text{ricordando la varianza campionaria} \\ S^2 = \frac{1}{(n-1)} \sum_{i=1}^n (X_i - \bar{X})^2 \end{array}$$

La statistica è:  $(n-1)S^2 / \sigma^2$ . Infatti, grazie al teorema, si può scrivere:

$$\Pr[\chi^2_{1-\alpha/2} \leq (n-1)S^2 / \sigma^2 \leq \chi^2_{\alpha/2}] = 1 - \alpha \quad \begin{array}{l} \text{ricorda che } S \text{ è la} \\ \text{stima della varianza} \end{array}$$

da cui: probabilità che la realizzazione della statistica cada nell'intervallo/quantili  
isolando sigma

$$\Pr\left[\frac{(n-1)S^2}{\chi^2_{\alpha/2}} \leq \sigma^2 \leq \frac{(n-1)S^2}{\chi^2_{1-\alpha/2}}\right] = 1 - \alpha$$

Quindi,

$$\left[ \frac{(n-1)S^2}{\chi^2_{\alpha/2}}, \frac{(n-1)S^2}{\chi^2_{1-\alpha/2}} \right]$$

è l'intervallo di confidenza al  $100(1-\alpha)\%$  per  $\sigma^2$ .

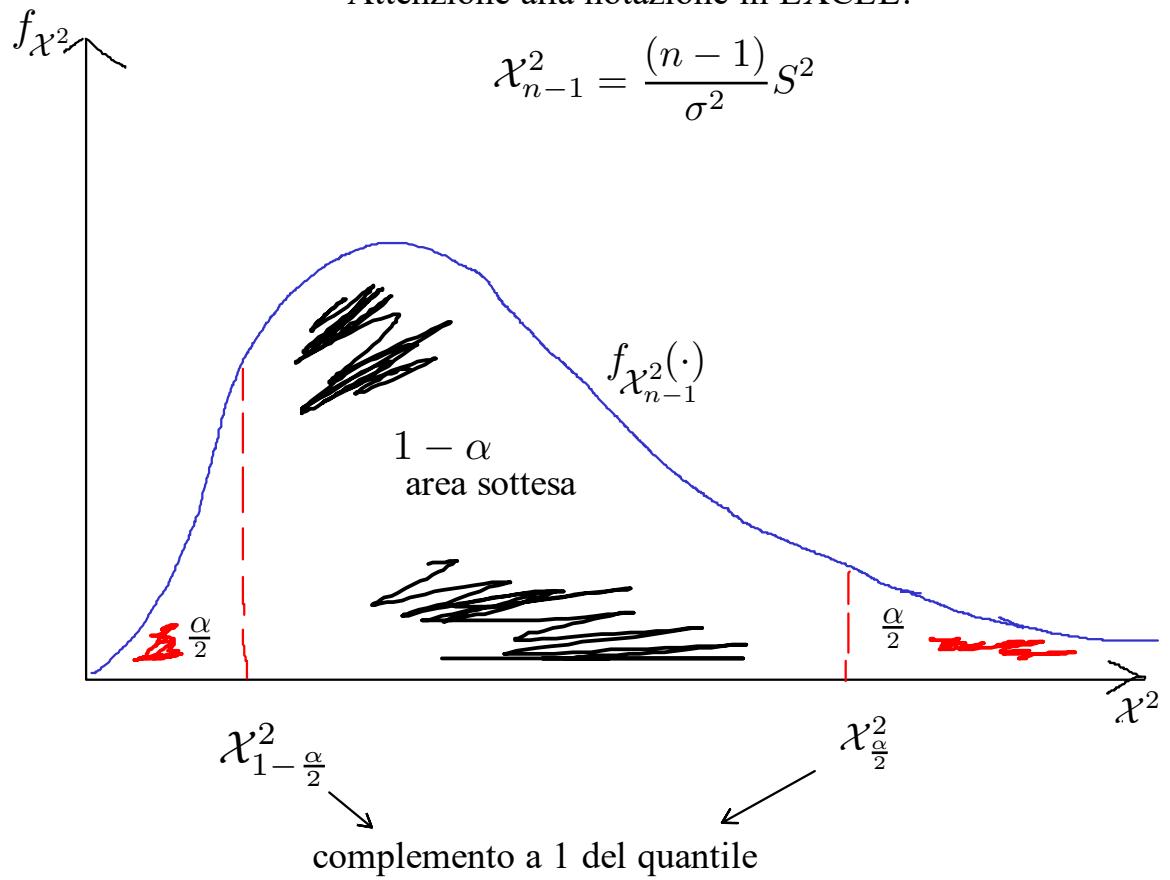
Da notare che in particolare gli intervalli di confidenza sulla varianza a differenza di quelli sulla media campionaria, escono "larghi" già in partenza. Si possono stringere quanto si vuole ma resteranno comunque "larghi". Vedi file Excel

INOLTRE NON SONO SIMMETRICI COME NEL CASO DELLA MEDIA CAMPIONARIA  
basta guarda i due denominatori dell'intervallo.

Attenzione alla notazione in EXCEL:

$$\chi_{n-1}^2 = \frac{(n-1)}{\sigma^2} S^2$$

In rosso si ha l'area pari a  $\frac{\alpha}{2}$



$\chi_{\frac{\alpha}{2}}^2$  sarebbe l'area che si lascia a destra  
ovvero il complemento del quantile

# Relazione base per la dimostrazione della tesi

$$\frac{(n-1)S^2}{\sigma^2} = \sum_{i=1}^n \left( \frac{X_i - \mu}{\sigma} \right)^2 - \left( \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \right)^2$$

$$\begin{aligned}\frac{(n-1)S^2}{\sigma^2} &= \frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{1}{\sigma^2} \sum_{i=1}^n [(X_i - \mu) - (\bar{X} - \mu)]^2 \\ &= \frac{1}{\sigma^2} \left[ \sum_{i=1}^n (X_i - \mu)^2 - 2(\bar{X} - \mu) \sum_{i=1}^n (X_i - \mu) + n \cdot (\bar{X} - \mu)^2 \right] \\ &= \frac{1}{\sigma^2} \left[ \dots - 2(\bar{X} - \mu) \left( \sum_{i=1}^n X_i - n\mu \right) + \dots \right] \\ &= \frac{1}{\sigma^2} \left[ \dots - 2n(\bar{X} - \mu)^2 + \dots \right] = \sum_{i=1}^n \left( \frac{X_i - \mu}{\sigma} \right)^2 - \left( \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \right)^2\end{aligned}$$

# Completamento della dimostrazione

A partire dalla relazione base:

$$\frac{(n-1)S^2}{\sigma^2} = \sum_{i=1}^n \left( \frac{X_i - \mu}{\sigma} \right)^2 - \left( \frac{\bar{X} - \mu}{\sigma / \sqrt{n}} \right)^2 \quad (+)$$

Si sfruttano i seguenti:

## Teorema 1:

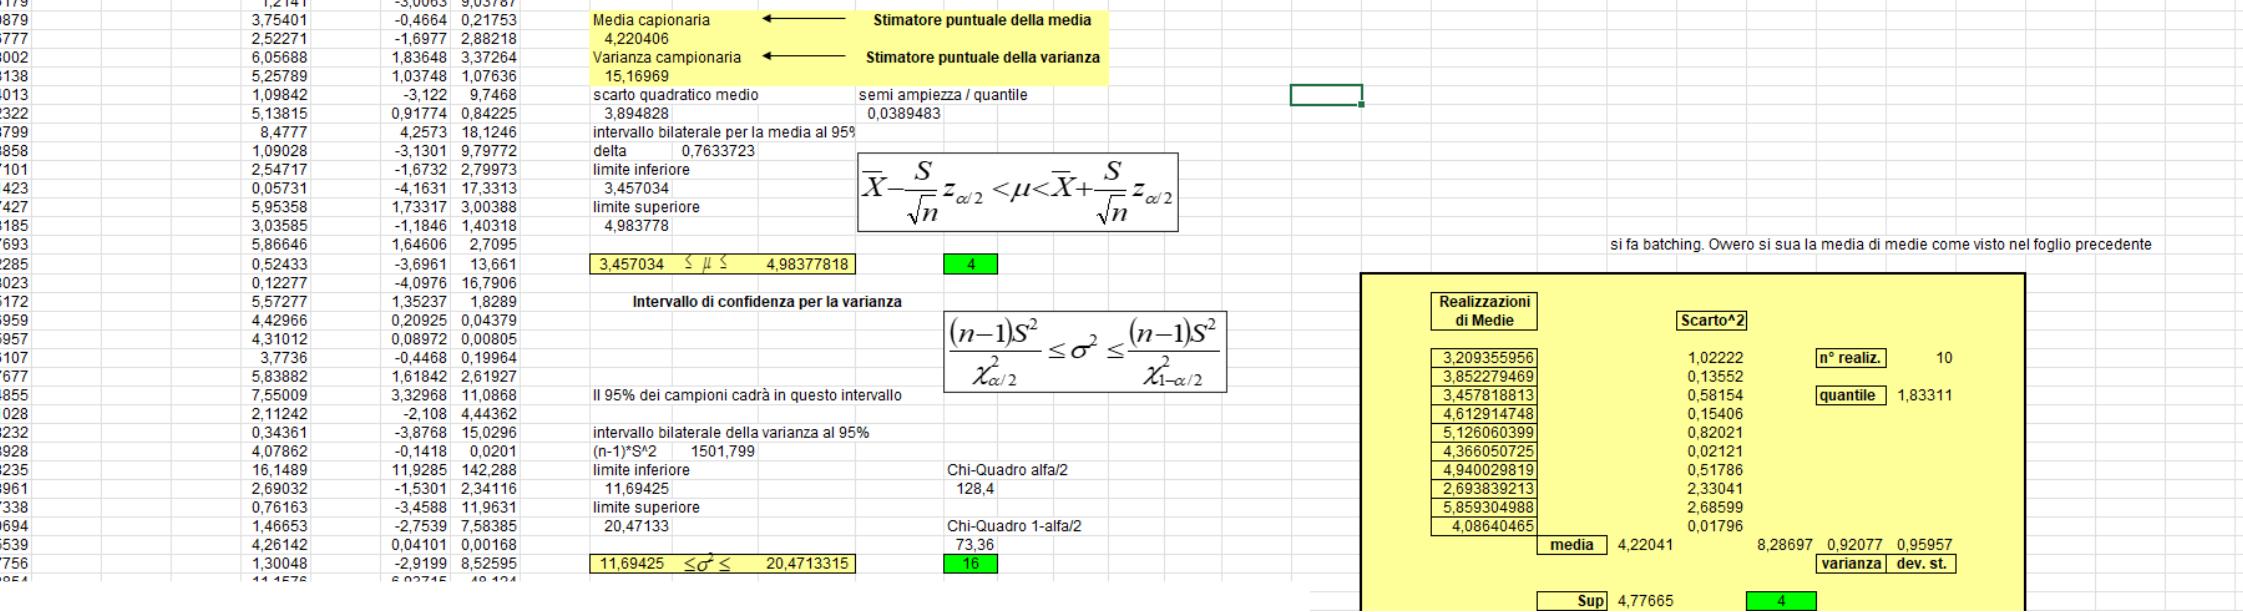
La variabile aleatoria “chi-quadrato” con “1” grado di libertà corrisponde al quadrato della “normale standard”.

## Teorema 2:

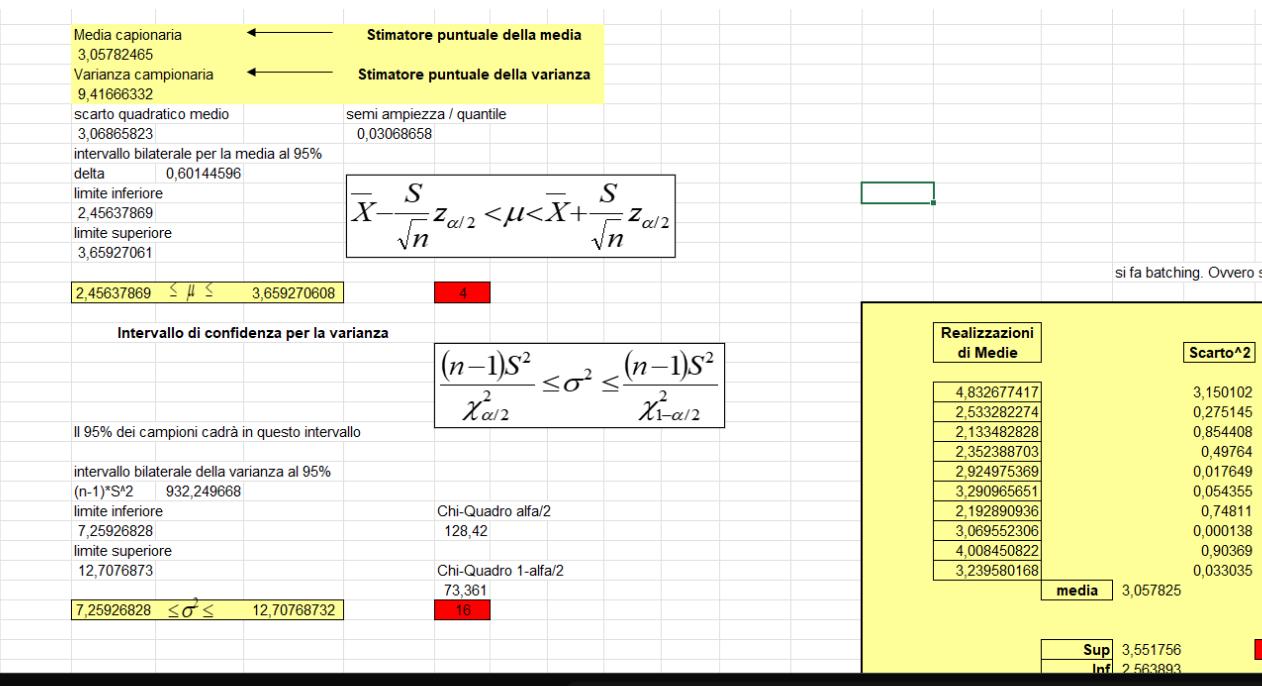
La somma di “n” variabili “chi-quadrato” con “1” grado di libertà corrisponde ad una “chi-quadrato” con “n” gradi di libertà.

Per interpretare la (+)  
alla seguente maniera:

$$X_{\gamma=n-1}^2 = X_{\gamma=n}^2 - X_1^2$$



Nello screenshot si nota che gli intervalli sia per media che per varianza contengono il valore vero rispettivo. In particolare l'intervalllo per la media è sufficientemente largo, ma non simmetrico(!) dato il caso esponenziale. Mentre il caso della varianza è molto largo. Le stime sono uscite anche relativamente buone. Con un 4.22 a fronte di 4 e 15.19 a fronte di 16.



In questo altro caso invece, si hanno intervalli errati! Per la media si ha una stima di 3.05 a fronte di 4. ed un intervallo "stretto" di : 1.2 e spostato a sinistra del valore reale. Per la varianza si ha una stima di 9.4(!) a fronte di 16. L'intervalllo è largo 5.5 e spostato a destra del valore reale.

# STIMATORI CORRETTI, ASINTOTICAMENTE CORRETTI E CONSISTENTI

- )  $X_1, \dots, X_n$  v. a. ind. e id. distr. con media  $\mu$  e var  $\sigma^2$

$$T(X_1, \dots, X_n) \hat{=} \frac{1}{n} \sum_{i=1}^n X_i \equiv \bar{X}(n) \equiv \bar{X}$$

si puo' omettere di indicare la dipendenza da "n" o "n-1"

$$T(X_1, \dots, X_n) \hat{=} \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 \equiv S^2(n-1) \equiv S^2$$

stimatore CORRETTO  
varianza

per n grande il rapporto si semplifica.  
quindi asintoticamente corretto

$$T(X_1, \dots, X_n) \hat{=} \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 \equiv S^2(n) = \frac{n-1}{n} S^2(n-1)$$

Quindi uno stimatore è asintoticamente corretto se per n tendente all'infinito risulta corretto

## RISULTATI UTILI PER STABILIRE LE PROPRIETA'(o caratteristiche) DEGLI STIMATORI:

$$E[\bar{X}] = \mu, \quad VAR[\bar{X}] = \frac{\sigma^2}{n} \quad E[S^2] = \sigma^2, \quad VAR[S^2] = \frac{2\sigma^4}{n-1}$$

deviazione tra la stima e valore atteso

**Lemma di Chebyshev:**

$$\Pr \left\{ |T - \theta| \geq n \cdot \sqrt{Var[T]} \right\} \leq \left( 1/n^2 \right)^{\text{di quante deviazioni ti allontani dalla deviazione standard?}}$$

n<1 non ha senso perché le prob. SONO 1

Probabilità che la deviazione sia maggiore di n volte della deviazione standard.

# Lo stimatore $S^2(n-1)$ è corretto

Dimostrazione

$$T(X_1, \dots, X_n) \hat{=} \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 \equiv S^2(n-1) \equiv S^2$$

Mi gioco l'ipotesi che le variabili aleatorie sono indipendenti ed identicamente distribuite. Vale perciò che il valore atteso di una somma è pari alla somma dei valori attesi. (Identicamente distribuite)

$$\begin{aligned}\mathbb{E}[S^2] &= \mathbb{E}\left[\frac{\sum_{i=1}^n X_i^2 - n\bar{X}^2}{n-1}\right] = \frac{\sum_{i=1}^n \mathbb{E}[X_i^2] - n\mathbb{E}[\bar{X}^2]}{n-1} \\ &= \frac{n}{n-1} \left( \mathbb{E}[X_1^2] - \mathbb{E}[\bar{X}^2] \right) \quad \text{si usa: } VAR[X] = E[X^2] - E[X]^2 \\ &= \frac{n}{n-1} \left( \text{Var}(X_1) + (\mathbb{E}[X_1])^2 - \text{Var}(\bar{X}) - (\mathbb{E}[\bar{X}])^2 \right) \\ &= \frac{n}{n-1} (\sigma^2 - \sigma^2/n) = \sigma^2. \quad \text{Done.}\end{aligned}$$

# Risultato fondamentale sull' errore quadratico medio

$MSE \doteq E[(T(X_1, \dots, X_n) - \theta)^2]$  è l'**errore quadratico medio**

ALLORA RISULTA:

$$MSE(T(\mathbf{X})) = E[T^2] - 2\theta E[T] + \theta^2$$

$$= E[T^2] - (E[T])^2 + (E[T])^2 - 2\theta E[T] + \theta^2$$

$$= \text{Var}(T) + \underbrace{(E[T] - \theta)^2}_{\substack{\text{intervallo più} \\ \text{largo o stretto}}}.$$

il bias sposta centro del intervallo ed è indotto dal casualità  
Bias vista nell'intervallo di confidenza

Per il momento non fornisco alcun esempio di calcolo di MSE.

Mi limito a definire “stima puntuale” (del parametro  $\theta$ ) qualunque realizzazione della variabile aleatoria stimatore. Pertanto, maggiore è il MSE dello stimatore e più rischioso risulta affidarsi a quella stima.

## Stimatori efficienti

conosciamo lo stimatore del valore atteso ovvero la media campionaria. Ma è il migliore stimatore?

Siano  $T_1(X)$  e  $T_2(X)$  due stimatori differenti dello stesso parametro  $\theta$ . E siano valide le seguenti:

- 1)  $T_1(X)$  e  $T_2(X)$  sono entrambi non distorti per  $\theta$ ; distorto se  $MSE = E[T(X)] \neq \theta$
- 2)  $Var [T_1(X)] \leq Var [T_2(X)]$ , per ogni valore di  $\theta$ ;
- 3)  $Var [T_1(X)] < Var [T_2(X)]$ , per qualche valore di  $\theta$ ; per qualche valore è più preciso

Allora si dirà che  $T_1(X)$  è stimatore più efficiente di  $T_2(X)$  per  $\theta$

ESEMPIO: la media campionaria è lo stimatore più efficiente tra quelli definibili tramite una combinazione lineare delle  $X_1, \dots, X_n$ , di coefficienti  $a_1, \dots, a_n$ .

Infatti:

$$T(X_1, \dots, X_n) \triangleq \sum_{i=1}^n a_i X_i \Rightarrow Var \left[ \sum_{i=1}^n a_i X_i \right] = \dots = \sum_{i=1}^n a_i^2 \sigma^2$$

essendo indipendenti

risolvendo il problema di ricerca operativa, si dimostra che la media campionaria è lo stimatore più efficiente

Da qui:

$$\begin{cases} \text{MIN : } \sigma^2 \sum_{i=1}^n a_i^2 \\ \text{a}_1, \dots, \text{a}_n \\ \text{sub. to : } \sum_{i=1}^n a_i = 1, \end{cases}$$

$$\rightarrow \boxed{a_i = 1/n, \quad i = 1, \dots, n.}$$

## Stimatore consistente: la distribuzione empirica

Sia  $n_x$  il numero di valori generati dal modello  $F$

che cadono nell'intervallo  $(0,x]$  e sia  $\hat{F}_n(x) \triangleq n_x / n$ .

Intervalli visti in Monte Carlo

Ebbene, la distribuzione empirica,  $\hat{F}$ ,  
è uno stimatore consistente della distribuzione vera,  $F$ .

Osservando che un meccanismo bernoulliano è alla base del risultato  
“numero di realizzazioni che cadono in un intervallo  $x$ ” e che la  
corrispondente probabilità (di successo) è  $p=F(x)$ :

La distribuzione  
empirica porta  
ad uno stimatore consistente.

$$\hat{F}(x) \triangleq \frac{n_x}{n} = \frac{1}{n} \sum_{i=1}^n B_i \quad \begin{matrix} \text{binomiale} \\ \text{ovvero} \end{matrix} \quad \text{con } E[\bar{B}(n)] = np / n = p$$

0,1. cade o non cade nell'intervallo

Grazie al teorema di Bernoulli, caso particolare della LGN:

$$\lim_{n \rightarrow \infty} P(|\bar{B}(n) - E[\bar{B}(n)]| \geq \varepsilon) = 0 \quad \text{appunto DEFINIZIONE stimatore consistente}$$

**Stimatore consistente se:**  $\lim_{n \rightarrow \infty} \Pr(|T(X_1, \dots, X_n) - \theta| \geq \varepsilon) = 0$

Ovvero, esprimendo il risultato in termini di  $F$  e di  $\hat{F}$

$$\lim_{n \rightarrow \infty} P(|\hat{F}_n(x) - F(x)| \geq \varepsilon) = 0$$

$\hat{F}_n(x)$  sarebbe una famiglia di funzioni  
che converge tutta in forma.

I parametri definiscono/caratterizzano il sistema. L'uscita non è un parametro

**Stima di parametri** di una distribuzione (in input)  
con  
**Metodo dei momenti** (equazioni)  
e  
**Metodo della massima verosimiglianza**  
(problema di ricerca operativa)

Applicazione alle distribuzioni seguenti:

ESPONENZIALE, NORMALE,  
IPERESPONENZIALE, di ERLANG,  
di BERNOULLI, di POISSON e di WEIBULL

Ricordando che per Weibull i parametri ci fanno ricavare media e varianza

# STIMA DEI PARAMETRI

## IMPOSTAZIONE FREQUENTISTA

Le realizzazioni che formano il campione contengono tutta la informazione necessaria per fare inferenza sul VERO, UNICO e INCOGNITO valore del parametro di interesse diretto o indiretto perché vogliamo inferire alcune caratteristiche del fenomeno governato da quel parametro.

## IMPOSTAZIONE BAYESIANA

Al parametro di interesse, incognito, viene attribuita un modello probabilistico iniziale, a prescindere dalle realizzazioni del campione, e del quale esso sarebbe una realizzazione. Il modello probabilistico iniziale è detto “modello a priori” e sarà aggiornato sulla base delle realizzazioni che formano il campione. Il modello aggiornato è detto “modello a posteriori”.

Ad esempio voglio calcolare il valore atteso in un modello che sembra un exp, allora modello a priori lo pongo appunto come exp.

# DALLA FORMULA DI BAYES ALL'INFERENZA BAYESIANA

Ricordando Bayes

A è un evento di interesse e  $B_1, \dots, B_n$  sono eventi di probabilità nota

$$P(B_j | A) = \frac{P(B_j \cap A)}{P(A)} = \frac{P(A \cap B_j)}{P(A)}$$

$B_1, \dots, B_n$  è una partizione di  $\Omega$

$$= \frac{P(A | B_j)P(B_j)}{\sum_{i=1}^n P(A | B_i)P(B_i)}$$

Problema:

Abbiamo un campione di realizzazioni indipendenti (D) di una variabile aleatoria che afferisce certamente ad un modello esistente in letteratura e caratterizzato dal parametro  $\theta$ : vogliamo individuare questo parametro a partire da quei dati!

$$P(\theta | D) = \frac{P(D | \theta) \cdot P(\theta)}{\sum_{\substack{\text{possibili} \\ \text{valori di } \theta}} P(D | \theta) \cdot P(\theta)}$$

$P(\theta)$  è la prob. "a priori"  
 $P(\theta | D)$  è la prob. "a posteriori"

$P(D | \theta)$  è detta  
"Verosimiglianza di  $\theta$ "

# Il metodo dei momenti

*Siano  $X_1, X_2, \dots, X_n$  indip. e id. distr.  
con  $\mu^k$  momento di ordine "k",  $k = 1, 2, \dots$*

Allora, pensando alla legge dei grandi numeri: (che vedremo)

$$\sum_{i=1}^n \frac{X_i}{n} \xrightarrow{\text{media campionaria converge al valore atteso come visto tramite monte carlo}} E[X_i] \hat{=} \mu, \quad \sum_{i=1}^n \frac{X_i^2}{n} \xrightarrow{} E[X_i^2] \hat{=} \mu^2, \quad \dots$$

Spesso è utile la seguente:

$$VAR[X_i] = E[X_i^2] - (E[X_i])^2$$

$$\Rightarrow \widetilde{S}^2 \hat{=} \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2 = \frac{\sum_{i=1}^n X_i^2 - n\bar{X}^2}{n} = \frac{n-1}{n} S^2$$

# Il metodo dei momenti (MOM)

- Il MOM **consiste nell'eguagliare i momenti** di ordine 1, 2, ...  $k$  ( $m_1, m_2, \dots m_k$ ) **con le corrispondenti formule di stima, fino ad ottenere (non sempre facile!) tante equazioni quanti sono i parametri incogniti:**

$$\sum_{i=1}^n \frac{x_i^k}{n} = m_k, \quad k = 1, 2, \dots$$

momento di  
ordine k    momento k-esimo

- Per il modello esponenziale di parametro  $\lambda$ , **siamo alla banalità!**  
perchè è  $k=uno$ !

$$\frac{1}{n} \sum_{i=1}^n x_i^1 = m_1 (= 1/\lambda) \Rightarrow \hat{\lambda} \equiv m_1 = n / \sum x_i$$

senza saperlo su Excel si stava attuando il metodo dei momenti

# M O M per la distribuzione normale:

- **X<sub>1</sub>, ..., X<sub>n</sub> estratte da N(μ, σ<sup>2</sup>)**
- **2 parametri da stimare ⇒ sistema in 2 equazioni:**  
valore atteso e varianza

$$\begin{cases} E(X) = \mu = \frac{1}{n} \sum_{i=1}^n X_i & (\hat{=} \bar{X}) \quad \text{momento primo ordine} \\ \\ E(X^2) = \mu^2 + \sigma^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 & \text{momento del secondo ordine} \end{cases}$$

appunto utilizzando:  $VAR[X] = E[X^2] - E[X]^2$

- Dunque:

$$\hat{\mu} = \bar{X} \quad \text{e} \quad \hat{\sigma}^2 = \frac{n-1}{n} S^2$$

(stessi risultati  
della stima MLE)

# Es3: MOM per la distribuzione iperesponenziale

(vedi anche file Excel)

Il metodo di massima verosimiglianza per la iperesponenziale è complicato da attuare

- **Distribuzione iperesponenziale**

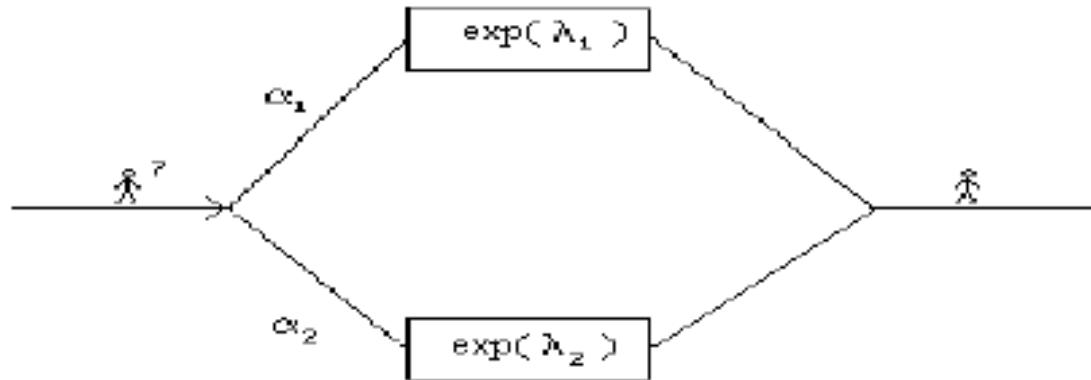
$$F_y(y) = \sum_{i=1}^n \alpha_i \left(1 - e^{-\lambda_i y}\right) \quad y \geq 0$$

parametri della distribuzione

- 3 parametri da stimare:  $\alpha, \lambda_1, \lambda_2$ . e non 2 banali

$$\alpha_1 = \alpha$$

$$\alpha_2 = 1 - \alpha$$



- In questo caso ci servirebbero i momenti del 1°, 2° e 3° ordine. Ma abbiamo a disposizione solo la media e la varianza campionaria (un livello di libertà!).
- Perciò si sceglie di impostare un'ulteriore condizione per rendere determinato il sistema:

$$\frac{1}{\lambda_1 + \lambda_2} = \frac{\frac{\alpha}{\lambda_1} + \frac{1-\alpha}{\lambda_2}}{2}$$

a questo punto sostituendo con gli stimatori di media e varianza

$\bar{X}$  media c.  $\frac{(n-1)}{n} S^2$  varianza campionaria

- momento del 1° ordine :

$$E[Y] = \sum_{i=1}^n \frac{\alpha_i}{\lambda_i} = \left( \frac{\alpha}{\lambda_1} + \frac{1-\alpha}{\lambda_2} \right)$$

probabilità totale  
cioè valore atteso condizionato  
da  $\lambda_1$  e condizionato da  $\lambda_2$

- Varianza:

$$VAR[Y] = E[Y^2] - E^2[Y]$$

- momento del 2° ordine :

$$E[Y^2] = \sum_{i=1}^n \frac{2\alpha_i}{\lambda_i^2} = 2 \left( \frac{\alpha}{\lambda_1^2} + \frac{1-\alpha}{\lambda_2^2} \right)$$

anche qui  
probabilità totale

- Stimatore:

- 1° ordine :  $M_1 \rightarrow \bar{X}$
- 2° ordine :

$$M_2 \rightarrow S^2 - E^2[Y]$$

nello svolgimento useremo  
 $S^2$  e non  $(n-1)S^2/n$

- Il nostro sistema di 3 equazioni in 3 incognite diventa perciò:

$$\left\{ \begin{array}{l} \frac{1}{\lambda_1 + \lambda_2} = \frac{\frac{\alpha}{\lambda_1} + \frac{1-\alpha}{\lambda_2}}{2} \quad \text{condizione aggiunta} \\ \\ \bar{X} = \frac{\alpha}{\lambda_1} + \frac{1-\alpha}{\lambda_2} \quad \text{media ottenuta} \\ \\ S^2 = 2 \left( \frac{\alpha}{\lambda_1^2} + \frac{1-\alpha}{\lambda_2^2} \right) - \left( \frac{\alpha}{\lambda_1} + \frac{1-\alpha}{\lambda_2} \right)^2 \quad \text{varianza ottenuta} \end{array} \right.$$

risoluzione che puoi "saltare"

- Osservando che il secondo membro della prima equazione è uguale a quello della seconda:  $\lambda_1 = \frac{2}{\bar{X}} - \lambda_2$
- Dalla seconda equazione ricaviamo:  $\hat{\alpha} = \frac{\lambda_1(\lambda_2 \bar{X} - 1)}{\lambda_2 - \lambda_1}$
- Sostituendo  $\lambda_1$ :  $\alpha = 1 - \frac{\lambda_2 \bar{X}}{2}$
- Osserviamo che :

$$\frac{\alpha}{\lambda_1} = \frac{1-\alpha}{\lambda_2} = \frac{\bar{X}}{2} \quad \frac{\alpha}{\lambda_1^2} = \frac{\bar{X}^2}{2(2 - \lambda_2 \bar{X})} \quad \frac{1-\alpha}{\lambda_2^2} = \frac{\bar{X}}{2\lambda_2}$$

- La terza equazione diventa:

$$S^2 = 2 \left( \frac{\bar{X}^2}{2(2 - \lambda_2 \bar{X})} + \frac{\bar{X}}{2\lambda_2} \right) - \left( \frac{\bar{X}}{2} + \frac{\bar{X}}{2} \right)^2$$

da cui:

$$\lambda_2(2 - \lambda_2 \bar{X}) = \frac{2\bar{X}}{S^2 + \bar{X}^2}$$

- Manipolando tale equazione giungiamo ad un'equazione di 2° grado in  $\lambda_2$  ...

$$\lambda_2^2 \bar{X} (S^2 + \bar{X}^2) - 2\lambda_2 (S^2 + \bar{X}^2) + 2\bar{X} = 0$$

si arriva ad un problema di analisi numerica che si risolve

- ... che ammette come soluzioni:

$$\hat{\lambda}_2 = \frac{1}{\bar{X}} \pm \frac{1}{\bar{X}} \sqrt{\frac{(S^2 - \bar{X}^2)}{(S^2 + \bar{X}^2)}}$$

- Da cui:  $\hat{\lambda}_1 = \frac{1}{\bar{X}} \mp \frac{1}{\bar{X}} \sqrt{\frac{(S^2 - \bar{X}^2)}{(S^2 + \bar{X}^2)}}$

(si suppone che  $S^2 \geq \bar{X}^2$  )

- Per completezza riscriviamo il terzo coefficiente:

$$\hat{\alpha} = \frac{\lambda_1(\lambda_2 \bar{X} - 1)}{\lambda_2 - \lambda_1}$$

## Il metodo della massima verosimiglianza.

Consideriamo delle variabili casuali i.i.d.  $X_1, \dots, X_n$  con una funzione di densità  $f(x)$ .

Definiamo nel modo seguente la **funzione di verosimiglianza**:

$$L(\theta) \equiv f(X_1) \cdot f(X_2) \cdots f(X_n) = \prod_{i=1}^n f(X_i) \text{ produttoria perché indipendenti}$$

Poiché conosciamo le  $X_i$ , tale funzione ha come unica incognita il parametro (o i parametri)  $\theta$  che si vuole valutare.

La stima di massima verosimiglianza (MLE) di  $\theta$  è il valore di  $\theta$  che massimizza la funzione di verosimiglianza, ponendo uguale a zero la sua derivata rispetto il parametro o nel caso di più parametri ponendo le derivate parziale rispetto ad ogni parametro. Se all'interno della funzione inserisco anche i differenziali:  $dx_1, dx_2, \dots, dx_n$  ottengo una produttoria tra probabilità. Quindi si mira a massimizzare la probabilità che le realizzazioni sono figlie della forma con il parametro incognito. Per facilitare la ricerca del massimo viene utilizzata la seguente funzione:

$$l(\theta) = \ln[L(\theta)]$$

che è nota come **funzione di verosimiglianza ridotta**.

I massimi restano sempre uguali ed essendo il logaritmo una funzione monotona è corretto l'uso della funzione di verosimiglianza ridotta. Si utilizza il logaritmo anche perché distribuzioni comuni sono espresse con esponenziali e prodotti. Infatti come già detto per l'iperesponenziale, il logaritmo di una somma non facilita nulla mentre il logaritmo di prodotti esponenziali sì.

Per essere sicuri che  $\theta$  sia un massimo, piuttosto che un minimo o un punto di flesso, la derivata di  $l(\theta)$ , valutata in  $\theta$  deve essere negativa.

## Es. 1: la densità esponenziale,

A partire da:  $f_x(X) = \lambda e^{-\lambda x}$  ricocco  $\lambda$

$$L(\theta) \hat{=} \prod_{i=1}^n f(x_i) = \prod_{i=1}^n \theta e^{-\theta x_i} = \theta^n e^{-\theta \sum_i x_i}$$

$$\ln [L(\theta)] = \ln \left[ \theta^n e^{-\theta \sum_i x_i} \right] = n \ln \theta - \theta \sum_i x_i$$

$$\frac{d}{d\theta} l(\theta) = \frac{d}{d\theta} [n \ln \theta - \theta \sum_i x_i]$$

non è detto che i due metodi diano la stessa stima

$$= \frac{n}{\theta} - \sum_i x_i = 0 \Rightarrow \hat{\theta} = n / \sum_{i=1}^n x_i$$

## Es. 2: la distribuzione normale

Ho 2 parametri da stima, valore atteso e varianza quindi andrò a risolvere le derivate parziali per ognuno.

$$L(\mu, \sigma^2) = \prod_{i=1}^n f(x_i)$$

$$= \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left\{-\frac{1}{2} \frac{(x_i - \mu)^2}{\sigma^2}\right\}$$

$$= \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\left\{-\frac{1}{2} \sum_{i=1}^n \frac{(x_i - \mu)^2}{\sigma^2}\right\}$$

- Stima del parametro  $\mu$

$$\ln(L(\mu, \sigma^2)) = -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln(\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2$$

$$\frac{\partial}{\partial \mu} \ln(L(\mu, \sigma^2)) = \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu) \equiv 0$$

$$\Rightarrow 0 = \sum_{i=1}^n (x_i - \mu) = \sum_{i=1}^n x_i - n\mu$$

$$\Rightarrow \mu = \frac{1}{n} \sum_{i=1}^n x_i$$

- Stima del parametro  $\sigma^2$

$$\frac{\partial}{\partial \sigma^2} \ln(L(\mu, \sigma^2)) = -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^n (x_i - \hat{\mu})^2 \equiv 0$$

$$\Rightarrow -n\sigma^2 + \sum_{i=1}^n (x_i - \bar{x})^2 = 0$$

la stima qui risulta non distorta

$$\Rightarrow \widehat{\sigma^2} = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n} = \boxed{\frac{n-1}{n} S^2}$$

## Es. 3: la ripartizione bernoulliana

Caso particolare essendo la Bernoulliana una densità nel discreto e non nel continuo

Example: Suppose  $X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Bern}(p)$ . Find the MLE for  $p$ .

Useful trick for this problem: Since

$$X_i = \begin{cases} 1 & \text{w.p. } p \\ 0 & \text{w.p. } 1 - p \end{cases},$$

we can write the p.m.f. as

probability max function. perchè nel discreto non si usa la densità. noi la potremmo chiamare ripartizione massima di probabilità

$$f(x) = p^x(1-p)^{1-x}, \quad x = 0, 1.$$

# La funzione di verosimiglianza per la legge bernoulliana:

$$L(p) = \prod_{i=1}^n f(x_i)$$

$$= \prod_{i=1}^n p^{x_i} (1-p)^{1-x_i}$$

$$= p^{\sum_{i=1}^n x_i} (1-p)^{n-\sum_{i=1}^n x_i}$$

**ESPRIME LA PROBABILITA' DI OSSERVARE CONGIUNTAMENTE LE REALIZZAZIONI  $x_i$ ,  $i = 1, \dots, n$**

## Lo stimatore di massima verosimiglianza:

$$\ln(L(p)) = \sum_{i=1}^n x_i \ln(p) + (n - \sum_{i=1}^n x_i) \ln(1-p)$$

$$\frac{\partial}{\partial p} \ln(L(p)) = \frac{\sum_i x_i}{p} - \frac{n - \sum_i x_i}{1-p} \equiv 0.$$

derivata parziale perchè  
ho  $\ln(L(p))$

$$(1-p)\left(\sum_{i=1}^n x_i\right) - p\left(n - \sum_{i=1}^n x_i\right) = 0$$

andando ad isolare per ottenere lo stimatore di massima verosimiglianza, ottengo appunto la media campionaria

$$\sum_{i=1}^n x_i - pn = 0 \quad \Rightarrow \hat{p} = \frac{1}{n} \sum_{i=1}^n x_i$$

e ricordando che una binomiale converge ad una Gaussiana riusciamo a fare un intervallo di confidenza

## Es. 4: la ripartizione poissoniana

Si parte dalla densità della Poissoniana per ricavare  $\lambda$

$$L(\lambda) \doteq \prod_{i=1}^n \frac{\lambda^{x_i}}{x_i!} e^{-\lambda} = \frac{\lambda^{\sum x_i}}{x_1! x_2! \cdots x_n!} \cdot e^{-n\lambda}$$

$$\ln [L(\lambda)] = -\ln(x_1! x_2! \cdots x_n!) - n\lambda + \left(\sum_i x_i\right) \cdot \ln(\lambda)$$

$$\frac{d}{d\lambda} \ln[L(\lambda)] = -n + \frac{1}{\lambda} \sum_i x_i$$

$$\Rightarrow \hat{\lambda} = \frac{1}{n} \sum_{i=1}^n x_i$$

## Es. 5: la distribuzione di Weibull

Weibull di Trivedi e non di EXCEL

$$L(\lambda, \alpha) = \prod_{i=1}^n f(x_i) = \prod_{i=1}^n \lambda \alpha \cdot {x_i}^{\alpha-1} \cdot e^{-\lambda {x_i}^\alpha}$$

$$= \lambda^n \alpha^n \cdot \left( \prod_{i=1}^n x_i \right)^{\alpha-1} \cdot e^{-\lambda \sum_{i=1}^n {x_i}^\alpha}$$

$$\ln L(\lambda, \alpha) = n \ln \lambda + n \ln \alpha + (\alpha - 1) \sum_{i=1}^n \ln x_i - \lambda \sum_{i=1}^n {x_i}^\alpha$$

altro problema di analisi numerica

$$\left\{ \begin{array}{l} \frac{n}{\lambda} - \sum_{i=1}^n {x_i}^\alpha = 0 \\ \frac{n}{\alpha} + \sum_{i=1}^n \ln x_i - \lambda \sum_{i=1}^n {x_i}^\alpha \ln x_i = 0 \end{array} \right.$$

Se cerco di massimizzare i parametri lambda e alpha, ottengo un sistema che non ha un'unica soluzione, cioè non vi sono soluzioni in forma chiusa.

Appunto

- Non esistono soluzioni in forma chiusa per  $\lambda$  ed  $\alpha$ .  
Comunque si può scrivere  $\lambda$  in funzione di  $\alpha$ . per risolvere il problema

formula per stimare  
lambda

$$\hat{\lambda} = \frac{n}{\sum_{i=1}^n x_i^\alpha}$$

appunto fissando alpha. si ottiene  
lambda

- Sostituendo nella seconda equazione:

problema di analisi numerica

$$\frac{n}{\alpha} + \sum_{i=1}^n \ln x_i - \frac{n \sum_{i=1}^n x_i^\alpha \ln x_i}{\sum_{i=1}^n x_i^\alpha} = 0$$

che può essere risolta con un metodo di “punto fisso”

Trovato il valore di  $\alpha$ , lo si userà per ricavare  $\lambda$ .

ovvero calcolo  
numerico. Un metodo  
è ad esempio l'iterazione

## Tramite Excel andiamo a stimare i parametri di una Weibull con una generazione Monte Carlo

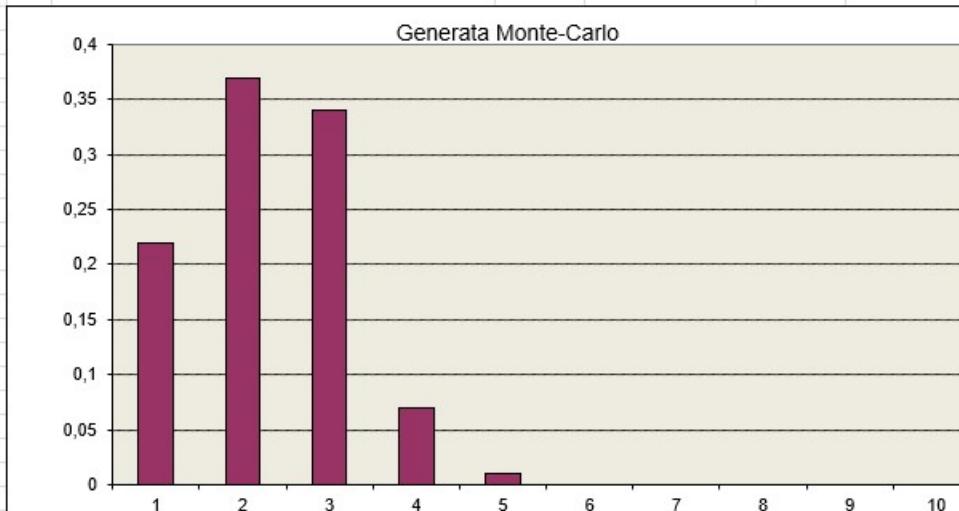
Realizz di una Weibull	Real Weib ^alpha	alfa	assegnato. Per ipotesi stimato	media camp di real Weib ovvero media aritmetica la sua realizzazione =	num realizzazioni =
2,278184076	5,190122686	2		1,753074621	100
2,980528663	8,883551111				
1,374309393	1,888726308	somma x-i ^ $\alpha$			
4,09979484	16,80831773	388,3024			
2,178630612	4,746431344	lambda_cap			
0,513064168	0,26323484	0,2575			
1,272460527	1,619155792				
0,729703423	0,532467086				
0,371302031	0,137865198				
2,035413355	4,142907527				
1,164327462	1,356558439				
3,003493793	9,020974966				
2,568384657	6,596599748				
1,937524553	3,754001395				
1,226054467	1,503209556				
1,551545773	2,407294287				
1,528032867	2,334884444				
0,925785038	0,857077937				
2,9857528	8,914719784				
3,009518122	9,057199324				
1,187021164	1,409019245				
1,496110558	2,238346801				
2,741617091	7,516464273				
3,167702269	10,03433767				
0,559882418	0,313468322				
1,655650865	2,741179787				
2,424995768	5,880604476				
1,027026841	1,054784131				
1,590254249	2,528908578				
1,75606515	3,083764812				
0,913556142	0,834584825				
2,510023938	6,300220168				
1,19593173	1,430252702				
0,327620248	0,107335027				
0,880801391	0,77581109				
2,501043325	6,255217714				

$$\hat{\lambda} = \frac{n}{\sum_{i=1}^n x_i^\alpha}$$

$$E[Weib] = \beta \cdot \Gamma(1 + 1/\alpha)$$

beta  
2

La stima risulta abbastanza vicina al valore vero



L'analisi sui parametri di una Weibull porta alla conclusione che:

- Lambda è il parametro di scala, solitamente durante una ricostruzione non "danneggia" il risultato
- Alpha è il parametro di forma, è consigliato scegliere un valore maggiore di 1 per visualizzare bene il metodo di Monte Carlo

# La densità “gamma”

Si ottiene dalla funzione gamma ed è un'estensione della densità di Erlang dove il parametro di forma diventa un reale positivo. Serve indirettamente a costruire altre funzioni utili nella statistica

- La funzione gamma (Il integrale di Eulero):

$$\Gamma(\alpha) \hat{=} \int_0^\infty x^{\alpha-1} e^{-x} dx, \quad \alpha \in \Re^+$$

E' facile verificare che:  $\Gamma(1) = 1$ , meno facile che:  $\Gamma(1/2) = \sqrt{\pi}$

- Integrando per parti, si ottiene la seguente:

$$\Gamma(\alpha) = (\alpha - 1)\Gamma(\alpha - 1), \quad \text{se } \alpha > 1 \quad \text{natura ricorsiva}$$

$$\text{e quindi: } \underset{\text{importante}}{\Gamma(n)} = (n-1)!, \quad \text{se } \alpha \equiv n \in \mathbb{N}$$

- E' utile riscriverla nella forma seguente, con  $x = \lambda y$  e  $\lambda > 0$ :

$$\Gamma(\alpha) = \int_0^\infty (\lambda y)^{\alpha-1} \cdot e^{-\lambda y} \cdot d(\lambda y) = \int_0^\infty (\lambda y)^{\alpha-1} \cdot e^{-\lambda y} \cdot \lambda dy$$

$$\Rightarrow 1 = \int_0^\infty \frac{(\lambda y)^{\alpha-1} \cdot \lambda e^{-\lambda y}}{\Gamma(\alpha)} \cdot dy \quad (*)$$

mostra come costruire una densità  
visto nella lezione 13, nascita della v.a. gamma 4

## La densità di Erlang

Erlang si ottiene a partire da una somma di esponenziali identiche e indipendenti

- Dalla densità di una Erlang {n,λ}:

$$f_X(x) = \frac{(\lambda x)^{n-1}}{(n-1)!} \lambda e^{-\lambda x}, \quad \lambda > 0, x \geq 0$$

La densità di Erlang può quindi essere riscritta con la funzione Gamma e passando da n numero naturale ad alpha numero reale si possono generare realizzazioni

la seguente rispetta i requisiti di una densità grazie alla (\*):

$$f_X(x) = \frac{(\lambda x)^{\alpha-1}}{\Gamma(\alpha)} \lambda e^{-\lambda x}, \quad \alpha > 0, \lambda > 0, x \geq 0$$

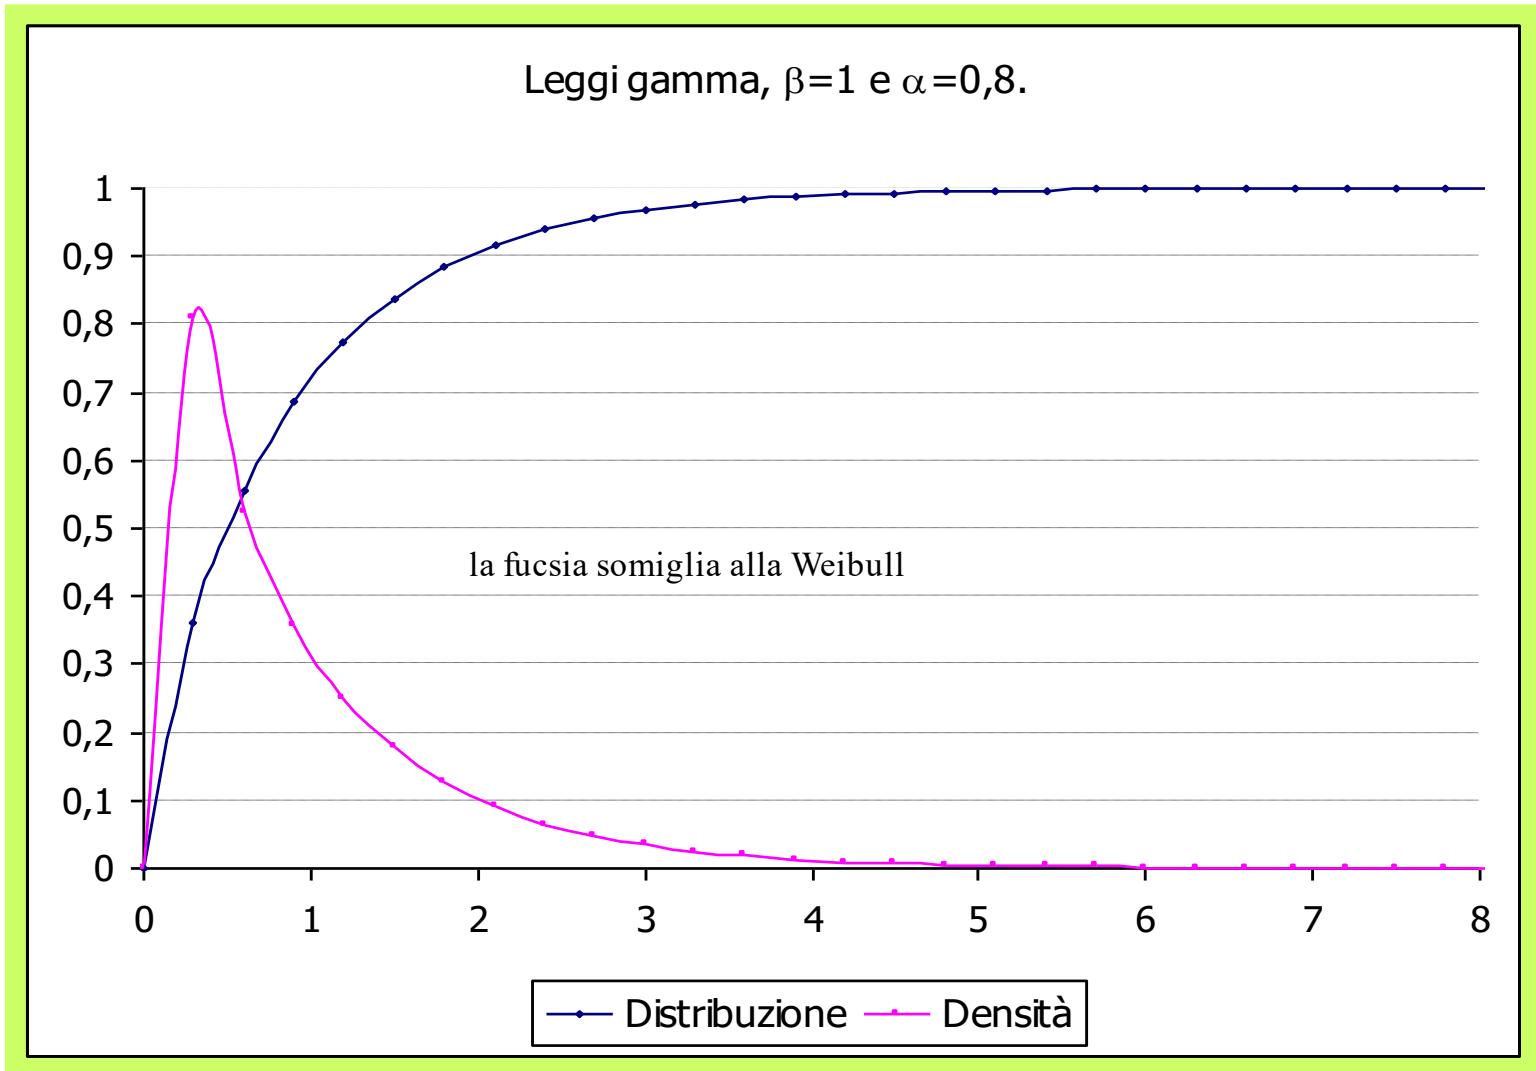
**IN EXCEL:**  $f_X(x) = \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-x/\beta}, \quad \beta \triangleq \frac{1}{\lambda}$

parametro di scala perché rapporto tra 1 e valore atteso. Quindi alpha sarà parametro di forma

Valore atteso e varianza:  $E[X] = \alpha \beta, \text{Var}[X] = \alpha \beta^2$

ricorrendo a:  $L_X(s) \triangleq \int_{x=0}^{\infty} e^{-sx} f_X(x) dx = (1 - \beta s)^{-\alpha}, \quad 0 \leq s < \beta^{-1}$

# La densità e la distribuzione “gamma”



## MOM PER LA GAMMA

### *Esempio di applicazione n. 1: distribuzione gamma*

Si supponga di disporre di un campione di  $n$  misurazioni, e si ipotizzi che le misurazioni siano tutte modellabili con variabili aleatorie indipendenti con distribuzione di probabilità  $\Gamma(\alpha, \beta)$ . Si ipotizzi inoltre che  $\alpha$  e  $\beta$  siano parametri incogniti e che si desideri fornirne delle stime  $\hat{\alpha}$  e  $\hat{\beta}$ .

Allora, seguendo il procedimento descritto poco fa, calcoliamo il momento primo  $\bar{X}$  e il momento secondo  $M_2$  (che saranno semplicemente dei numeri ottenuti a partire dai dati sperimentali), e costruiamo il sistema:

$$\begin{cases} \mu_1(\alpha, \beta) = \bar{X} \text{ media} \\ \mu_2(\alpha, \beta) = M_2 \text{ scarto quadratico} \end{cases}$$

Ricordando che in una distribuzione gamma la media è data dal prodotto tra i due parametri:

$$\mu_1(\alpha, \beta) = \alpha\beta$$

E che vale la relazione:

$$\mu_2(\alpha, \beta) - [\mu_1(\alpha, \beta)]^2 = Var(X) = \sigma^2 \rightarrow \mu_2(\alpha, \beta) = \sigma^2 + [\mu_1(\alpha, \beta)]^2 = \sigma^2 + (E[X])^2$$

Dove, nel caso di distribuzione gamma:

In arancione la nota relazione  
 che la varianza è esprimibile come  
 momento del secondo ordine meno  
 momento del primo ordine al quadrato.

$$\sigma^2 = \alpha\beta^2$$

Andando a creare il sistema di equazioni

Otteniamo:

$$\begin{cases} \alpha\beta = \bar{X} \\ \alpha\beta^2 + (\text{E}[X])^2 = M_2 \end{cases} \rightarrow \begin{cases} \alpha\beta = \bar{X} \\ \alpha\beta^2 = M_2 - (\text{E}[X])^2 \end{cases} \rightarrow \begin{cases} \alpha\beta = \bar{X} \\ \alpha\beta^2 = M_2 - \bar{X}^2 \end{cases}$$

Notando che:

$$\sum_{j=1}^n (X_j - \bar{X})^2 = \sum_{j=1}^n X_j^2 - 2\bar{X} \sum_{j=1}^n X_j + n\bar{X}^2 = nM_2 - 2n\bar{X}^2 + n\bar{X}^2 = nM_2 - n\bar{X}^2$$

Possiamo riscrivere il sistema come segue:

$$\begin{cases} \alpha\beta = \bar{X} \\ \alpha\beta^2 = \frac{1}{n} \sum_{j=1}^n (X_j - \bar{X})^2 \end{cases}$$

Ricordando poi che lo stimatore varianza campionaria è definito come:

$$S^2 = \frac{1}{n-1} \sum_{j=1}^n (X_j - \bar{X})^2$$

Otteniamo facilmente:

$$\begin{cases} \alpha\beta = \bar{X} \\ \alpha\beta^2 = \frac{n-1}{n} S^2 \end{cases} \rightarrow \begin{cases} \frac{n-1}{n} \frac{S^2}{\beta} = \bar{X} \\ \alpha = \frac{n-1}{n} \frac{S^2}{\beta^2} \end{cases} \rightarrow \begin{cases} \hat{\beta}_{mom} = \frac{S^2}{\bar{X}} \frac{n-1}{n} \\ \hat{\alpha}_{mom} = \frac{\bar{X}}{\beta} = \frac{n}{n-1} \frac{\bar{X}^2}{S^2} \end{cases}$$

# La disuguaglianza di Chebyshev

Sia  $Y$  variabile aleatoria di media  $\mu$  e varianza  $\sigma^2$  con funzione di densità definita da  $-\infty$  a  $+\infty$  quindi Gaussiana e non. Si definisce disuguaglianza di Chebyshev quella sottostante, che è utilizzata per calcolare la probabilità che una realizzazione si trovi entro una certa distanza dalla media espressa in multipli della deviazione standard o meglio la probabilità che si trovi all'interno di un intervallo di confidenza.

$h > 0$  costante

$$\Pr \left\{ |Y - \mu| \geq h \right\} \leq \frac{\sigma^2}{h^2}$$

scarto, ancora v.a.

se  $k\sigma \hat{=} h \Rightarrow$   
considero  
multipli della deviazione standard

disuguaglianza vista nella lezione degli stimatori

$$\Pr \left\{ |Y - \mu| \geq k\sigma \right\} \leq \frac{1}{k^2}$$

ovvero:

esplcitando il valore assoluto  
ottengo appunto un intervallo

$$\Pr \left\{ \mu - k\sigma \leq Y \leq \mu + k\sigma \right\} \geq 1 - \frac{1}{k^2}$$

con  $k > 0 : (1/k) \leq 1$

quantità arbitrariamente vicina a 1

Cantelli si usa per il caso di v.a. continue e non negative come Weibull, exp ecc.

**Cantelli per densità in  $[0, +\infty)$**  →

Prova: partendo dalla def. di varianza oppure  
ricordando il collegamento tra scarti e varianza

$$\sigma^2 \hat{=} \int_{-\infty}^{+\infty} (y - \mu)^2 f(y) dy$$

maggiore uguale perchè  
si taglia un pezzo di area,  
e dato che  $f(y) > 0$ , allora  
l'area è  $>= 0$  quindi anche  
 $(y - \mu)^2 f(y) \geq 0$

non si perde e non si deve  
perdere la disuguaglianza

1° integrale vale  
 $Pr\{Y < \mu - h\}$   
2° integrale vale  
 $Pr\{Y > \mu + h\}$

estensione di Chebyshev  
 $\Pr \left\{ Y \leq \mu + k\sigma \right\} \geq 1 - \frac{1}{1 + k^2}$

appunto prendo solo la disuguaglianza  
destra maggiore di zero

$$\geq \int_{-\infty}^{\mu-h} (y - \mu)^2 f(y) dy + \int_{\mu+h}^{+\infty} (y - \mu)^2 f(y) dy \quad \text{sia } h = y - \mu$$

$$\geq h^2 \left( \int_{-\infty}^{\mu-h} f(y) dy + \int_{\mu+h}^{+\infty} f(y) dy \right)$$

il primo integrale risulta  $< h$  mentre il secondo  $> h$

con  $h \hat{=} k\sigma \Rightarrow$  tesi

Il primo integrale è una distribuzione il secondo no!

$$\Rightarrow \sigma^2 \geq h^2 \left( \Pr \left\{ |Y - \mu| \geq h \right\} \right) = \Pr \left\{ |Y - \mu| \geq h \right\} \leq \frac{\sigma^2}{h^2}$$

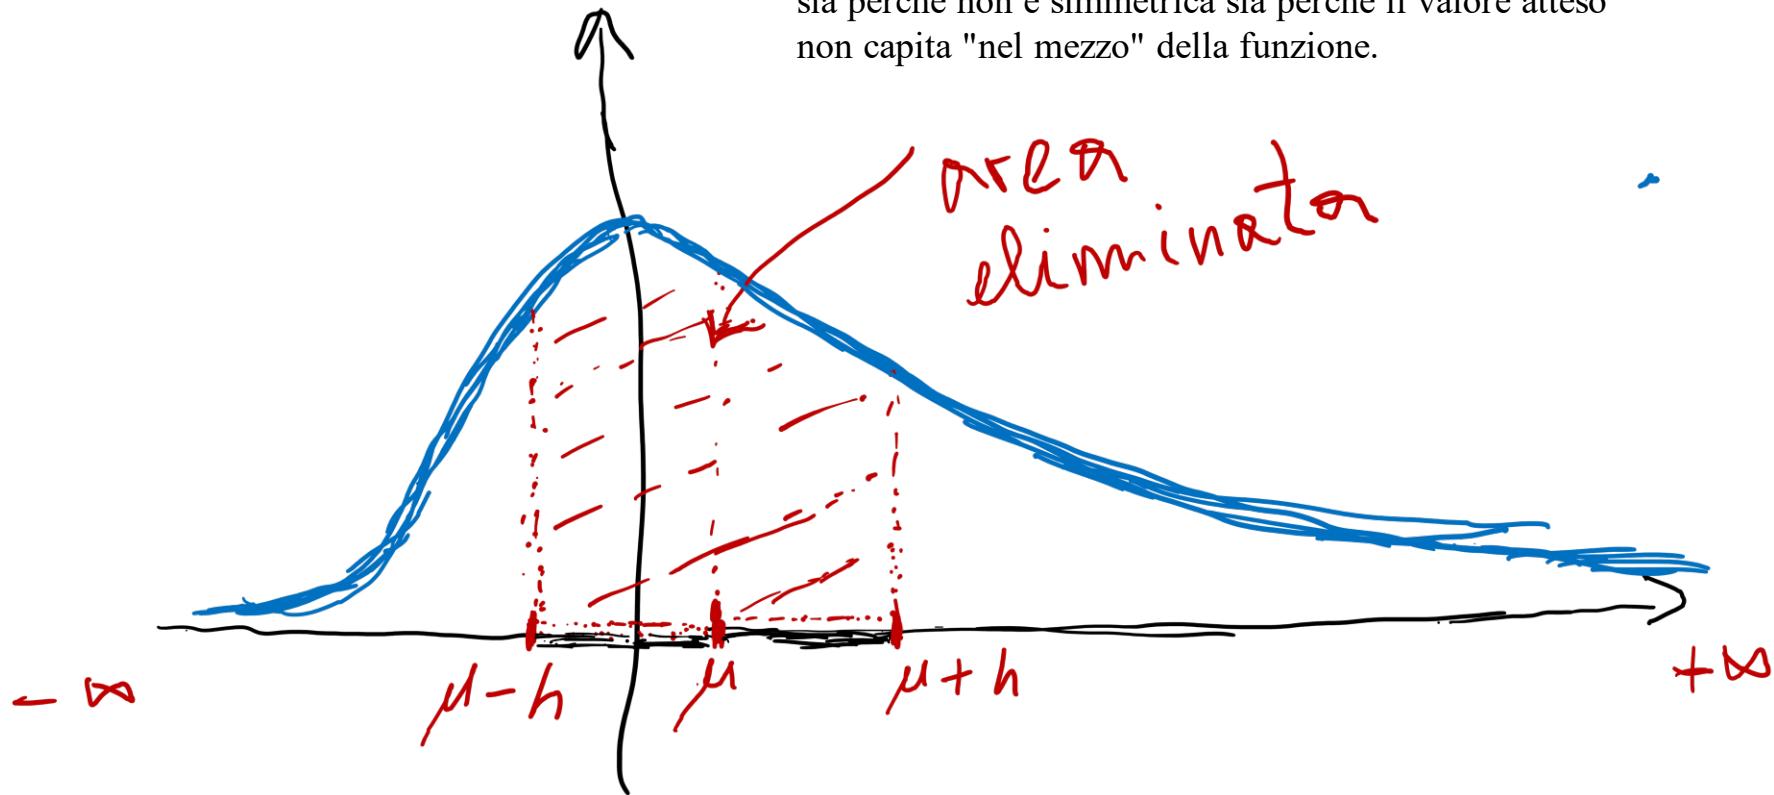
a questo punto ci si esprime  
con la deviazione standard

Se  $Y$  è la variabile aleatoria media campionaria, allora  $VAR[Y] = \frac{\sigma^2}{n}$  e sostituendo nella diseguaglianza di Chebyshev, si ottiene che

$$Pr\{|Y - \mu| \geq h\} \leq \frac{VAR[Y]}{h^2} = \frac{\sigma^2}{n} \cdot \frac{1}{h^2} \quad \text{se } h = \sigma \quad Pr\{|Y - \mu| \geq \sigma\} \leq \frac{1}{n} \quad \text{dunque la dimensione del campione } n, \text{ influisce.}$$

Al crescere del campione, la probabilità che una realizzazione della media campionaria abbia una distanza apprezzabile dal valore atteso diventa sempre più piccola.

La funzione si nota che non è una Gaussiana sia perché non è simmetrica sia perché il valore atteso non capita "nel mezzo" della funzione.



Ricorda il punto di Chebyshev è: in che misura, le realizzazioni sono significativamente distanti dalla media? Nella misura in cui al crescere del campione tale distanza va via via sparando.

# CONVERGENZA IN PROBABILITÀ

Nata grazie a disuguaglianza di Chebyshev

Si dice che una **generica** sequenza di variabili aleatorie:

(non dice se indipendenti ed identicamente distribuite e o altro)

$Y_1, Y_2, \dots, Y_n \rightarrow \vartheta$  (valore finito)  
(che convergono, tutte  
o a meno di poche che si ignorano)

Converge in probabilità  
ad un valore finito.

e si scrive:  $\lim_{n \rightarrow \infty} \Pr \{ |Y_n - \vartheta| < \delta \} = 1, \quad \forall \delta > 0$

notazione

sarebbe diverso  
il lim della sequenza di v.a.

quando:

fissati  $\varepsilon > 0$  e quindi  $\delta > 0$   $\exists \tilde{n}$  tale che

NON DÀ N TILDE IN POI!

sono diverse

grazie a Chebyshev

risulta:  $\Pr \{ |Y_{\tilde{n}} - \vartheta| < \delta \} > 1 - \varepsilon$

$$\delta \triangleq \delta_\varepsilon$$

$\delta$  dipende da  $\varepsilon$ !  
 $\varepsilon$  piccolo a piacere

probab. che da una v.a. la distanza dal valore finito è minore di delta è molto vicino a 1, quindi quasi certa!

Si osservi che l'affermazione "risulta Pr ..." si riferisce ad una sola diseguaglianza e non può essere estesa alla seguente:

sarebbe un AND  $|Y_{\tilde{n}+1} - \vartheta| \cap |Y_{\tilde{n}+2} - \vartheta| \cap |Y_{\tilde{n}+3} - \vartheta| \cap \dots$   
avranno valori variabili. chi più vicino e chi meno vicino

che esprime un tipo di convergenza detta "forte". Che quindi vale per più variabili aleatorie

In pratica invece di avere una convergenza che al crescere di n ammetta casi in cui la distanza dal valore atteso è troppo grande, (rettangolo rosso su Excel) si ha una convergenza forte che è AND logico.

## Teorema di Bernoulli - Teorema di convergenza debole

Prese  $X_1, X_2, \dots$  variabili aleatorie **indipendenti BERNOULLIANE** ovvero:

$$X_i = \begin{cases} 1 & \text{con prob} = p \\ 0 & \text{con prob} = 1-p \end{cases}, \quad i=1,2,\dots,n$$

$B \triangleq \sum_{i=1}^n X_i$  è la binomiale con  $E[B]=np$  e  $\text{VAR}[B]=np(1-p)$  allora:  
**LA BINOMIALE È UNA SOMMA!**

$$\lim_{n \rightarrow \infty} \Pr\left\{\left|\frac{B}{n} - p\right| < \delta\right\} = 1, \forall \delta > 0$$

Il limite per n che tende a infinito della probabilità che  $B/n$  è abbastanza vicina a p è minore di delta è pari a 1 ovvero:

il rapporto tra casi favorevoli e casi possibili può approssimare la probabilità vera, su un numero infinitamente grande di esperimenti indipendenti.

**Prova:** parto dalla distanza dal valore atteso espressa rispetto a k deviazioni standard. (quante deviazioni standard sono lontano dal valore atteso?)

$$\Pr\left\{\left|B - E[B]\right| < k\sqrt{\text{Var}[B]}\right\} > 1 - \frac{1}{k^2}$$

$$\Pr\left\{\left|\frac{B - np}{n}\right| < \frac{k}{n}\sqrt{np(1-p)}\right\} > 1 - \varepsilon$$

esplicito varianza

$$\Pr\left\{\left|\frac{B}{n} - p\right| < \sqrt{\frac{k^2}{n} p(1-p)}\right\} > 1 - \varepsilon$$

$\delta$

Il rapporto tra casi favorevoli e casi possibili approssima la probabilità vera su un numero infinitamente grande di esperimenti indipendenti

Per n infinitamente grande, non si esclude il caso in cui, la differenza  $B - np$  fra il numero di successi realizzati e numero di successi attesi (testa che escono e testa che mi aspetto ovvero 50%) diverge (non ho 50% di fare testa) con la velocità della radice di n mentre n cresce linearmente verso l'infinito. In parole povere se  $B-np$  cresce alla velocità della radice di n mentre n cresce linearmente verso l'infinito, la probabilità a cui si vuole convergere. Quindi Bernoulli cattura debolmente la convergenza, diciamo "che non copre la realtà" ovvero che tutto questo non accade. Per n che tende a infinito si ha quel 50% di probabilità. Borel si pone di eliminare questa debolezza e rafforzare la convergenza

Visto che non è negativa la binomiale uso:  
**(Chebyshev-Cantelli)**

$$k^2 := 1 + k^2$$

assegnazione non uguale

$$\text{con } \varepsilon \hat{=} 1/k^2$$

$$\text{con } \delta \hat{=} \sqrt{\frac{p(1-p)}{n\varepsilon}}$$

delta dipende da epsilon ed è inversamente proporzionale.  
più piccolo epsilon, più è grande delta e viceversa.

# IL TEOREMA DI BOREL

da guardare alla fine

Stabilisce un risultato di convergenza “forte”:

$$\Pr \left\{ \lim_{n \rightarrow \infty} \left| \frac{B}{n} - p \right| < \delta \right\} = 1, \quad \forall \delta > 0$$

rafforza la convergenza debole vista in precedenza

Si dice che  $\frac{B}{n} \rightarrow p$  "con prob. 1", per  $n \rightarrow \infty$

e si intende che  $\forall \varepsilon > 0$  e quindi  $\delta > 0$   $\exists \tilde{n}, \tilde{n}+1, \tilde{n}+2, \dots$  tale che  
qui debbo dire da  $n$  tilde in poi!

$$Prob \left[ \left| \frac{B}{\tilde{n}} - p \right| < \delta \cap \left| \frac{B}{\tilde{n}+1} - p \right| < \delta \cap \left| \frac{B}{\tilde{n}+2} - p \right| < \delta \cap \dots \right] < 1 - \varepsilon$$

Questo risultato forte della legge dei grandi numeri garantisce che a partire da un “certo  $n$ ” in poi le realizzazioni della variabile aleatoria  $B/n$  che risulteranno tanto vicine a  $p$  quanto più si vuole corrisponderanno ad un sottospazio di  $\Omega$  che ha probabilità 1 (convergenza “con prob 1”).

quasi sempre negli esperimenti  
quasi tutti i risultati elementari  
quasi ovunque nello spazio

In questo senso, il verificarsi di realizzazioni apprezzabilmente distanti da  $p$  è un evento che ha probabilità  $1 - P(\Omega)$ , dunque nulla. Cioè tutte le realizzazioni convergono tranne al più un sottoinsieme dello spazio dei risultati a cui si da probabilità nulla, perché non si da importanza.

# Legge (debole) dei grandi numeri (per la media campionaria)

Che si può dimostrare

La legge dei grandi numeri si applica per somme di variabili aleatoria, ed essendo la media somma di variabili diviso una costante non ci sono problemi nell'applicarla.

## Prima ipotesi:

- )  $X_1, X_2, \dots$  var. al. ind., con valore atteso finito e identico,  $\mu$  e varianze sia pur non identiche ma finite,  $\sigma_k^2, k = 1, \dots, n$  e tutte limitate da una stessa costante, C.

## Oppure seconda ipotesi:

- )  $X_1, X_2, \dots$  var. al. con val.att.identico e finito,  $\mu$  (non indipendenti)

Quindi la varianza dovrà essere in gerarchia degli infiniti sotto n quadro così da rispettare la condizione di limite pari a 0

e con  $\lim_{n \rightarrow \infty} \frac{Var\left[\sum_{i=1}^n X_i\right]}{n^2} = 0$  non somma delle varianze perchè non sono indipendenti!

OSSERVAZIONE: La prima ipotesi serve sulla sequenza di input al modello P-C (tempi di interarrivo, ad esempio), mentre la seconda serve sulla sequenza di output (tempi di soggiorno, ad esempio).

perché output non sono indipendenti

# Legge (debole) dei grandi numeri (per la media campionaria)

TESI comune alle due ipotesi :

Per la v.a. med camp:  $\bar{X}(n) \hat{=} (X_1 + \dots + X_n) / n$  ma anche per somme di v.a.

risulta:

$$\lim_{n \rightarrow \infty} \text{Prob} \left[ |\bar{X}(n) - E[\bar{X}(n)]| < \delta \right] = 1, \quad \forall \delta > 0$$

Il limite significa che dopo molto tempo è certo (=1) che la distanza tra media campionaria (stima del valore atteso) e valore atteso è molto piccola

Il problema è che nella realtà non si può aspettare per sempre.

e s'intende che:

fissati  $\varepsilon > 0$  e quindi  $\delta_\varepsilon > 0$   $\exists \tilde{n}$  tale che

risulta:  $\text{Prob} \left[ |\bar{X}(\tilde{n}) - E[\bar{X}(\tilde{n})]| < \delta_\varepsilon \right] > 1 - \varepsilon$

rivediamo il concetto di convergenza in probabilità

Quindi a un certo  $n$  tilde, la probabilità che la distanza tra stima del valore atteso e valore atteso sia minore di delta arbitrariamente piccolo è arbitrariamente vicino a 1, ovvero alla certezza. Ad esempio dopo 500 tiri di moneta, si sa dalla vita che la probabilità che esca testa è 50%.

La legge ci dice che facendo 500 tiri quasi sicuramente sarai sarà uscito testa circa il 50% dei tiri. Infatti empiricamente dopo 500 tiri si stima che la probabilità è attorno al 50%, magari 49.87%, 48%. Questa convergenza è debole perché è maggiore di  $1 - \varepsilon$  non è esattamente 1!

La potenza della legge dei grandi numeri sta anche nel fatto che è applicabile a variabili non indipendenti

# *Dimostrazione della legge debole (per var. al. correlate)*

(non indipendenti)

A partire dalla ipotesi:  
seconda

La tesi da validare è che valgano:

- 1)  $\text{Prob} \left[ |\bar{X}(\tilde{n}) - E[\bar{X}(\tilde{n})]| < \delta_\varepsilon \right] > 1 - \varepsilon$
- 2)  $\lim_{n \rightarrow \infty} \text{Prob} \left[ |\bar{X}(n) - E[\bar{X}(n)]| < \delta \right] = 1, \quad \forall \delta > 0$

$$VAR[\bar{X}(n)] = \frac{1}{n^2} VAR \left[ \sum_{i=1}^n X_i \right] \stackrel{\text{costruisco una}}{\hat{=}} v^2(n) \stackrel{\text{funzione dalla varianza della media}}{\text{funzione che rispetta}} \text{ l'ipotesi}$$

basta riprendere la diseguaglianza di Chebyshev-Cantelli:

essendo  $v^2(n)$  sempre positiva

$$\Pr \left\{ |\bar{X}(n) - \mu| \geq k \cdot v(n) \right\} \leq \frac{1}{k^2}$$

e porre:  $\varepsilon \hat{=} (1/k^2)$  e  $\delta \hat{=} k \cdot v(n)$

posto ciò si può  
riscrivere alla seguente maniera:

$$\Pr \left\{ |\bar{X}(n) - \mu| < k \cdot v(n) = \delta \right\} > 1 - \left( v^2(n) / \delta^2 \right) = 1 - \varepsilon$$

ho dimostrato la tesi 1)

qui sfrutto l'ipotesi 2 ovvero il limite del rapporto tra varianza della sommatoria e  $n^2$  è 0  
e riconoscere che l'ipotesi fatta:

è sufficiente a provare la tesi. 2)

$$\lim_{n \rightarrow \infty} v^2(n) = 0 \rightarrow \text{serve per validare}$$

$\lim_{n \rightarrow \infty} \text{Prob} \left[ |\bar{X}(n) - E[\bar{X}(n)]| < \delta \right] = 1, \quad \forall \delta > 0$

perchè così facendo  $\varepsilon = \frac{v^2(n)}{\delta^2} = 0$  quindi  $1 - \varepsilon = 1$

# Dimostrazione della legge debole (per var. indipendenti)

Per la PRIMA IPOTESI

partendo ancora da Chebyshev

$$\Pr \left\{ \left| \bar{X}(n) - E[\bar{X}(n)] \right| \geq h \right\} \leq \left( \text{VAR}[\bar{X}(n)] / h^2 \right) \quad (h \doteq n \sqrt{\text{VAR}[\bar{X}(n)]})$$

riscrivo il tutto sotto Chebyshev-Cantelli

$$\Pr \left\{ \left| \bar{X}(n) - E[\bar{X}(n)] \right| < h \right\} \geq 1 - \left( \text{Var}[\bar{X}(n)] / h^2 \right)$$

e sfruttando l'ipotesi di varianze finite, limitate da una medesima costante C

$$\left. \text{Var}[\bar{X}(n)] = \frac{1}{n^2} \sum_{k=1}^n \text{Var}[X_k] \right\}$$

 sommatoria pari a nC

con:  $\text{Var}[\bar{X}(n)] = \frac{1}{n^2} \sum_{k=1}^n \sigma_k^2 < \frac{C}{n}$  l'ipotesi di costanza di C servirà per il limite.

andando a sostituire si ottiene che:

$$\Pr \left\{ \left| \bar{X}(n) - E[\bar{X}(n)] \right| < h \right\} > 1 - \left( \frac{C}{n \cdot h^2} \right) > 1 - \varepsilon$$

dunque se n tende a infinito  
il rapporto è 0

tollerò di meno  
lo sbaglio di tanto,  
ma tollero di più  
lo sbaglio di poco.

ovvero:

$$\lim_{n \rightarrow \infty} \Pr \left\{ \left| \bar{X}(n) - E[\bar{X}(n)] \right| < h \right\} = 1, \quad \forall h > 0$$

# Legge forte dei grandi numeri (per la media campionaria)

non dimostrabile

IPOTESI ALTERNATIVE:

- )  $X_1, X_2, \dots$  v.a. ind. e id. distr., con media  $\mu$  finita

**OPPURE**

- )  $X_1, X_2, \dots$  v.a. ind.  $\left\{ \begin{array}{l} \text{con media identica, } \mu, \text{ finita} \\ \text{e non ident. varianze } \sigma_1^2, \sigma_2^2, \dots \end{array} \right.$   
con  $\sum_{k=1}^{\infty} \frac{\sigma_k^2}{k^2} < \infty$

TESI COMUNE:

Allora, con:  $\bar{X}(n) \hat{=} (X_1 + \dots + X_n)/n$  media campionaria

$$Prob \left[ \lim_{n \rightarrow \infty} |\bar{X}(n) - \mu| < \delta \right] = 1, \quad \forall \delta > 0$$

probabilità di limite non limite di probabilità!

E s'intende che:

$$\forall \varepsilon > 0, \delta_\varepsilon > 0 \quad \exists \tilde{n} \mid \forall m \in [1, 2, \dots]$$

$$\begin{aligned} Prob \left[ \left| \bar{X}(\tilde{n}) - E[\bar{X}(\tilde{n})] \right| < \delta_\varepsilon \cap \left| \bar{X}(\tilde{n}+1) - E[\bar{X}(\tilde{n}+1)] \right| < \delta_\varepsilon \cap \dots \right. \\ \left. \dots < \delta_\varepsilon \right] > 1 - \varepsilon \end{aligned}$$

AND visto nella slide della convergenza in probabilità

Di grande interesse pratico: (si lavora con)

- $X_1, X_2, \dots$  v.a. ind.e id.distr. con  $E[X] = \mu$

ALLORA  $\bar{X}(n) \hat{=} \frac{\sum_{i=1}^n X_i}{n} \xrightarrow{\text{converge}} \mu$  "con pr 1"  
quasi sempre  
quasi ovunque

# Applicazione della legge forte

Sia “X” la variabile aleatoria bernelliana (real. 0 e 1) che indica il verificarsi o meno di un evento “A” e sia “n” il numero di esperimenti indipendenti.

$$\begin{aligned} \text{Siccome: } E[X] &= 0 \cdot \Pr(0) + 1 \cdot \Pr(1) \\ &\Rightarrow \text{Prob}(A) \equiv E[X] \end{aligned}$$

$$\text{allora: } \bar{X}(n) \hat{=} \frac{\sum_{i=1}^n X_i}{n} \stackrel{pr\ 1}{\rightarrow} \text{Prob}(A), \quad n \rightarrow \infty$$

## IMPORTANTE

Il rapporto fra il numero di volte in cui si verifica l’evento  $A$  e il numero sufficientemente grande di esperimenti indipendenti effettuati può essere preso come la  $\text{Prob}(A)$ .

## Seconda applicazione della Legge forte dei G.N. :

$$\Pr \left\{ \lim_{t \rightarrow \infty} \frac{N(t)}{t} = \frac{1}{E[X]} \hat{=} \lambda \right\} = 1$$

Sperimentazione  
della convergenza  
forte:

*con :*

$$N(t) \hat{=} \text{ numero di arrivi in } (0, t] \quad \begin{array}{l} \text{se uso t1, t2, ecc.} \\ \text{sarebbe un processo stocastico} \end{array}$$

$$X_1, X_2, \dots, X_{N(t)} \quad \text{INTERARRIV ind. e id. distr.} \equiv X$$

$$S_{N(t)} \hat{=} X_1 + X_2 + \dots + X_{N(t)} \quad \begin{array}{l} \text{somma di tempi aleatori. se N(t) fissato} \\ \text{ho somma di tempi finiti} \end{array}$$

**PROVA:** t istante tra l'ultimo arrivato e quello che deve arrivare

$$\frac{S_{N(t)}}{N(t)} \leq \frac{t}{N(t)} < \frac{S_{N(t)+1}}{N(t)} \quad \Rightarrow \quad \frac{S_{N(t)}}{N(t)} \leq \frac{t}{N(t)} < \frac{S_{N(t)+1}}{N(t)+1} \frac{N(t)+1}{N(t)}$$

non è lim di prob,  
ma prob di lim

$$\lim_{t \rightarrow \infty} \frac{S_{N(t)}}{N(t)} = \lim_{t \rightarrow \infty} \frac{X_1 + X_2 + \dots + X_{N(t)}}{N(t)} = E[X] \quad \begin{array}{l} \text{con probabilità 1} \\ \text{quasi ovunque,} \\ \text{quasi sempre} \end{array}$$

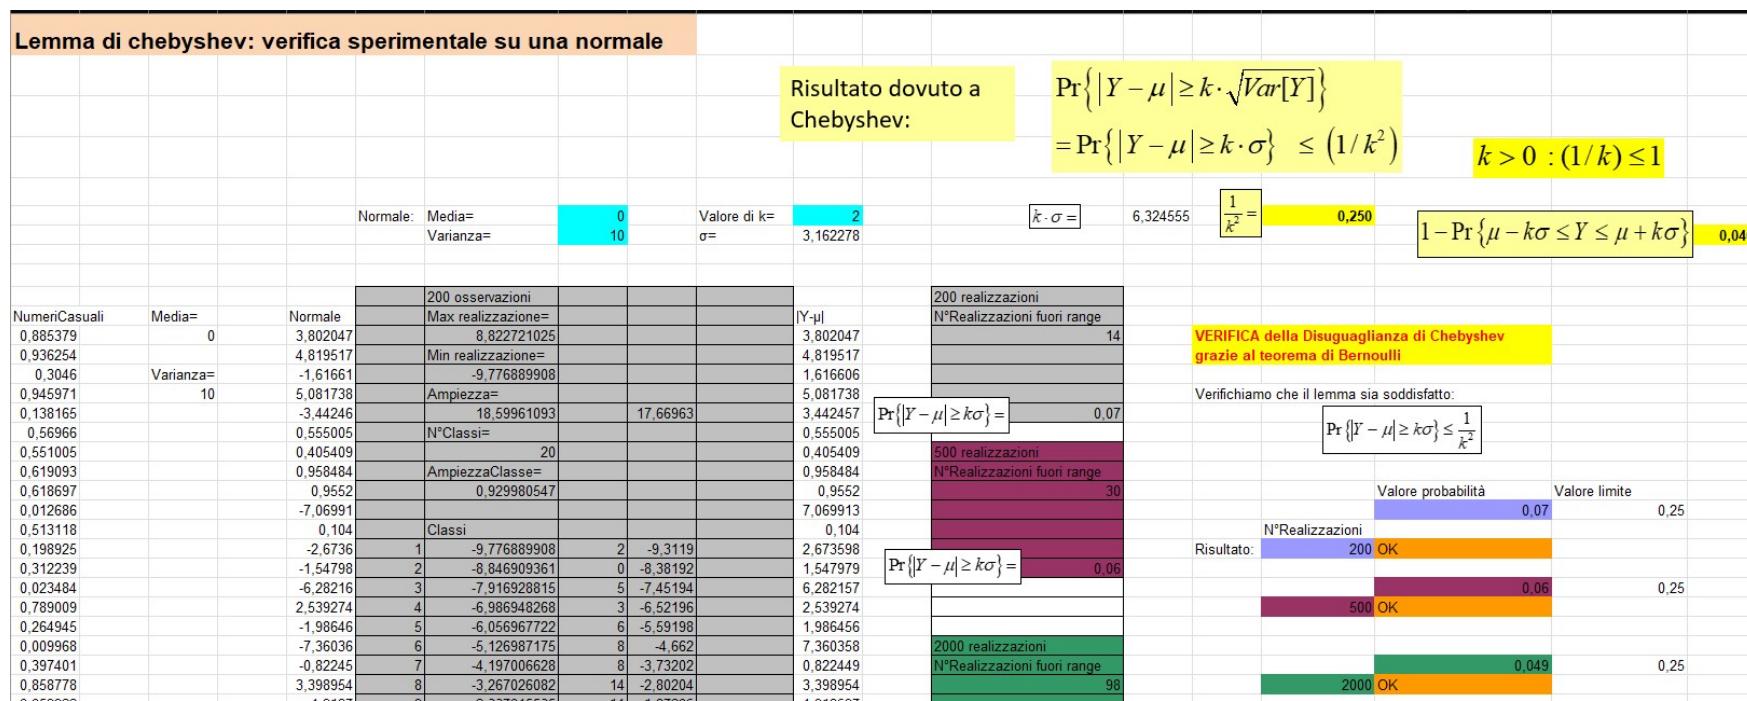
grazie alla legge forte converge al valore atteso con prob 1

$$\lim_{t \rightarrow \infty} \left[ \frac{S_{N(t)+1}}{N(t)+1} \frac{N(t)+1}{N(t)} \right] = E[X] \lim_{t \rightarrow \infty} \frac{N(t)+1}{N(t)} = E[X] \quad \text{con prob 1}$$

tramite teorema del confronto

$$\Rightarrow E[X] \leq \lim_{t \rightarrow \infty} \frac{t}{N(t)} < E[X] \quad \text{con probabilità 1}$$

Tramite monte carlo andiamo a provare la disegualanza di Chebyshev su una normale con:



Media=0

Varianza=10

$k=2$

Ricordando che  $k$  non deve essere intero.

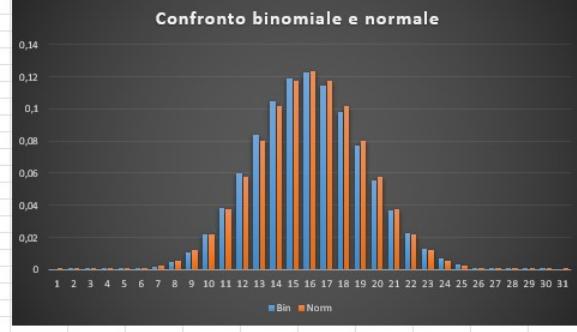
$$\frac{1}{k^2} = 0.25$$

L'esperimento funziona perché della normale conosciamo la distribuzione, quindi possiamo calcolare il valore vero!

Perciò con questi parametri Chebyshev afferma che la probabilità che la realizzazione differisca dal valore atteso per 2 volte ( $k=2$ ) la deviazione standard è minore uguale di 0.25. Ma utilizzando la distribuzione della normale andando a calcolare su Excel  $1 - (\text{DISTRIB.NORM}(\mu+k\sigma; \mu; \sigma; \text{VERO}) - \text{DISTRIB.NORM}(\mu-k\sigma; \mu; \sigma; \text{VERO}))$  si ottiene 0.046! Si deduce che il bound di Chebyshev è lasso! Si vogliono bound sufficientemente stretti altrimenti se troppo stretti si hanno problemi con il bias (ovvero lo spostamento a destra o sinistra rispetto al valore). Si è poi andato a verificare la disegualanza di Chebyshev su 200, 500 e 2000 realizzazioni. Da notare che con varianza 10 con 2000 realizzazioni l'istogramma assomiglia alla normale, ma se aumenta le realizzazioni ovviamente la rappresentazione viene più fine. Con una varianza diversa magari servono meno o più osservazioni per rappresentare bene la normale. Su Excel c'è anche la verifica di Chebyshev, o meglio Cantelli per l'esponenziale con una modifica sulla disegualanza.

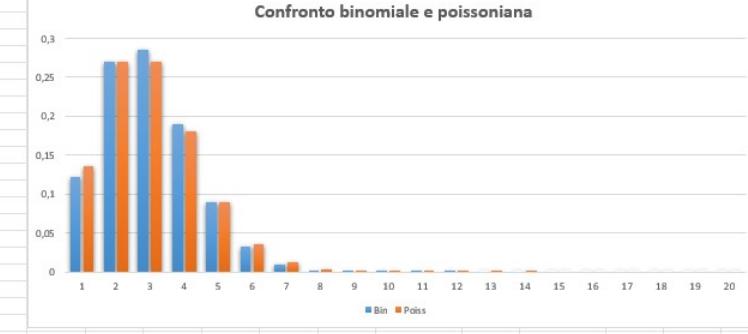
n	p	q
50	0,3	0,7
media	15	
varianza	10,5	
deviazione st.		
3,24037		
$(X \sim B(n,p)) \rightarrow (X \sim N(np, np(1-p)))$		
se media >= 5 e varianza >= 5		
N(np,npq)		
2,73628E-06		
1,08868E-05		
3,93803E-05		
0,000129508		
0,000387215		
0,001052559		
0,002601235		
0,005644553		
0,011938826		
0,022172292		
0,037436753		
0,057467775		
0,080202741		
0,101763646		
0,11733098		
0,123116261		
0,11739098		
0,101763646		
0,080202741		
0,057467775		
0,037436753		
0,022172292		
0,011938826		
0,005644553		
0,002601235		
0,001052559		
0,000387215		
0,000129508		
3,93803E-05		
1,08868E-05		
2,73628E-06		

## Confronto tra binomiale e normale.



passo 1	k	Coeff.Bin.	B(n,p)	n1	p1	q1	passo 1	k	Coeff.Bin.	B(n,p)	P(λ)
	0		1,79847E-08	20	0,1	0,9		0		0,121576655	0,135335283
	1		3,85385E-07					1		0,270170344	0,270670566
mostro come la binomiale di media n e varianza p tende ad una normale con valore atteso np e varianza np(1-p)	2		4,04655E-06	media	2			2		0,285179807	0,270670566
	3		4,77447E-05	varianza	3			3		0,19019871	0,180447044
	4		0,00013973		4			4		0,089778928	0,090223522
	5		0,000550934		5			5		0,031921361	0,036089409
	6		0,00177086	deviazione st.	6			6		0,008867045	0,012029803
	7		9,9884400		7			7		0,001970454	0,003437087
	8		53,6878650		8			8		0,000355776	0,000859272
	9		250,5433700		9			9		5,27076E-05	0,000190949
	10		10272278170		10			10		6,44204E-06	3,81899E-05
	11		37353738800		11			11		6,50711E-07	6,94361E-06
	12		1,214E+11		12			12		5,4226E-08	1,15727E-06
	13		3,54861E+11		13			13		3,70776E-09	1,78041E-07
	14		9,37846E+11		14			14		2,05987E-10	2,54345E-08
	15		2,25083E+12		15			15		9,15496E-12	3,39126E-09
	16		4,92369E+12		16			16		3,1788E-13	4,23908E-10
	17		9,84738E+12		17			17		8,3106E-15	4,98715E-11
	18		1,80535E+13		18			18		1,539E-16	5,54128E-12
	19		3,04059E+13		19			19		5,83292E-13	
	20		4,71292E+13		20			20		1,8E-18	
	21		6,73274E+13		21			21			
	22		8,87498E+13		22			22			
	23		1,08043E+14		23			23			
	24		1,21549E+14		24			24			
	25		1,26411E+14		25			25			
	26		1,21549E+14		26			26			
	27		1,08043E+14		27			27			
	28		8,87498E+13		28			28			
	29		6,73274E+13		29			29			

la poissoniana converge alla gaussiana, la binomiale converge alla gaussiana. Ma comunque la binomiale converge alla poissoniana



se invece p si avvicina a 1, si può contare il numero di insuccessi anziché quello dei successi in modo tale che la probabilità di insuccesso 1-p sia piccola e si può ancora usare la distribuzione di Poisson