

Funzioni di variabili aleatorie

Abbiamo visto durante il corso le distribuzioni: esponenziale, di Weibull e Gaussiana. I matematici con il concetto di funzione di funzione, sono riusciti a costruire dei modelli diversi. Ma che vuol dire funzione di variabili aleatorie?

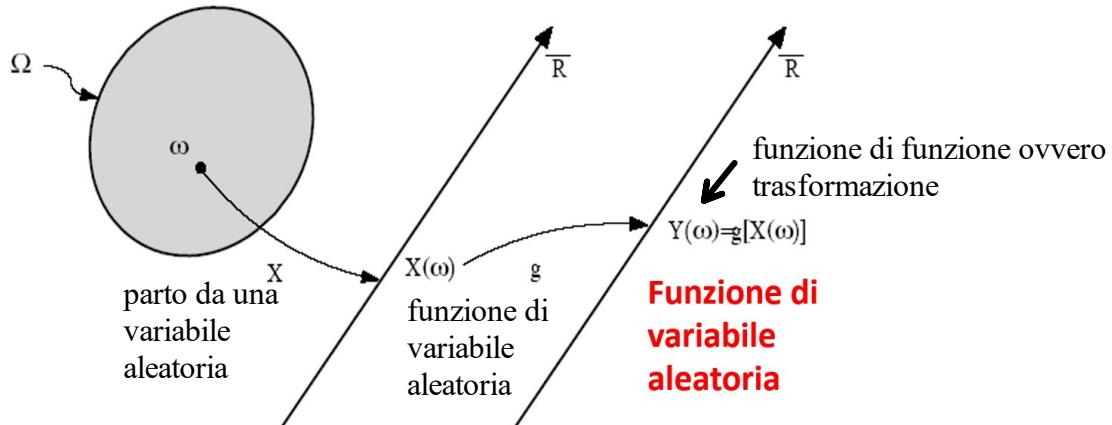
All'interno della letteratura scientifica si usa il termine trasformazioni di una variabile aleatoria. Nel nostro corso utilizzeremo il termine funzione al posto di trasformazione. Una trasformazione consiste in un'operazione algebrica di variabili aleatorie

Dal libro del prof. Gelli, "Probabilità e informazione"

86

Trasformazioni di una variabile aleatoria

"Trasformazione" = "funzione"



Il caso più facile è quello in cui g è funzione differenziabile e strettamente monotona (invertibile su tutti il dominio)

Il caso più difficile è quello in cui g è funzione differenziabile con punti a derivata nulla e interi intervalli a derivata nulla!

A ω risultato elementare, viene associato un numero e dopo tramite g se ne associa un altro. La domanda che nasce è può cambiare la probabilità di ω ?

La risposta è no, non cambia semplicemente la si rappresenta diversamente. Vediamo ciò tramite la proposizione di Miller seguente:

4.6 Transformations of Random Variables

$$F_Y(y) = \Pr(g(X) \leq y) = \Pr(X \leq g^{-1}(y)) = F_X(g^{-1}(y)). \quad (4.20)$$

probabilità che Y sia

minore o uguale ad un valore y

Note that this can also be written as

probabilità che X sia

minore o uguale all'inverso

della trasformazione applicata

a y

$F_X(x) = F_Y(g(x))$. "Si cambia la forma
ma non la sostanza"

Differenziale?

Si ma non detto
esplicitamente

(4.21)

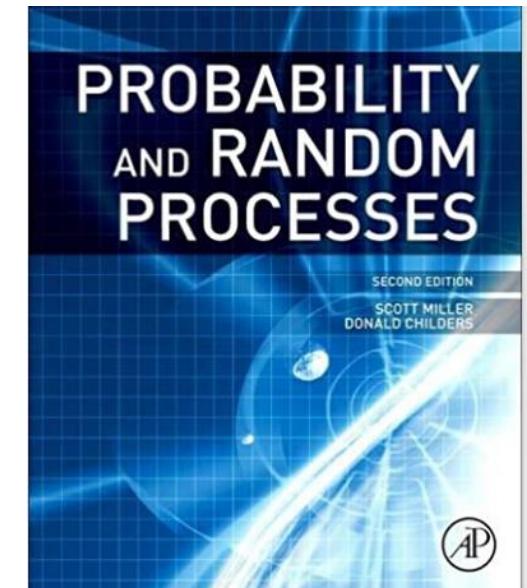
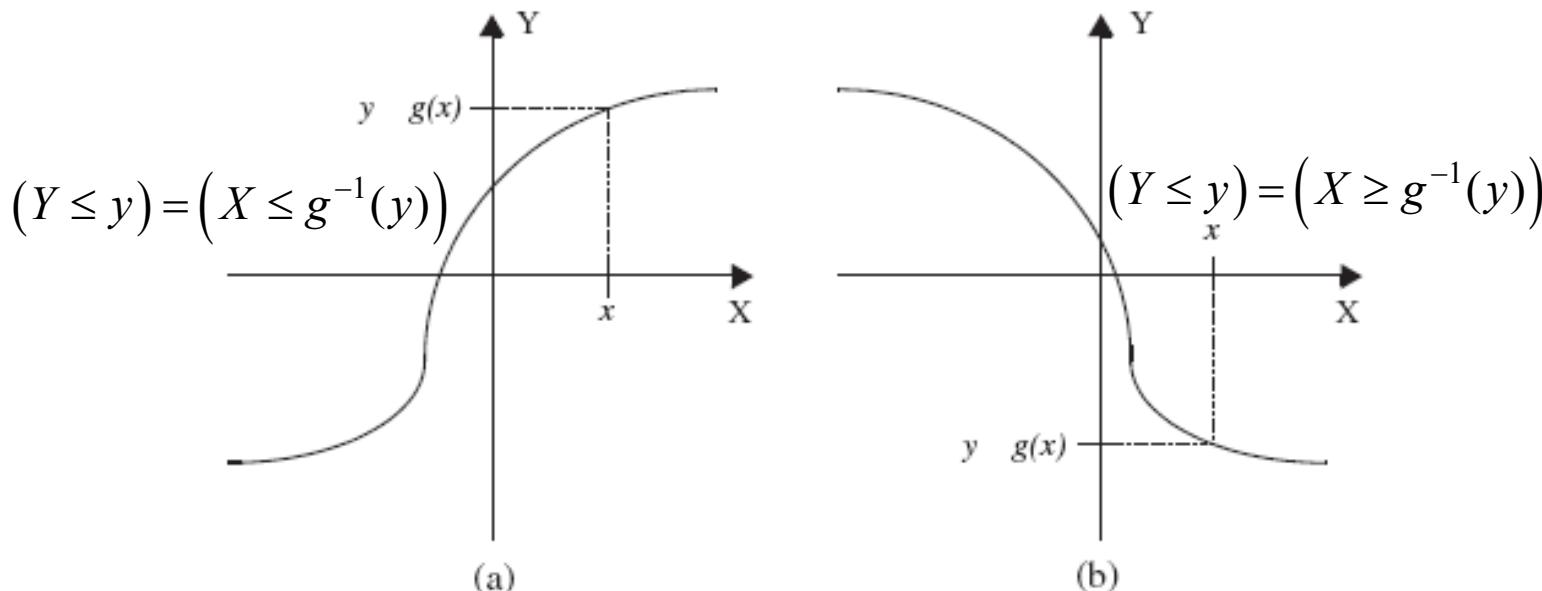


Figure 4.1 A monotonic increasing function (a) and a monotonic decreasing function (b).

Per funzioni **monotone crescenti** ottengo la densità di una variabile trasformata con le regole di derivazione delle funzioni composte

Differentiating Equation 4.20 with respect to y produces

densità di probabilità
della variabile trasformata Y

$$f_Y(y) = f_X(g^{-1}(y)) \frac{dg^{-1}(y)}{dy} = f_X(x) \frac{dx}{dy} \Big|_{x=g^{-1}(y)},$$

La densità di probabilità di Y in un punto y
è pari alla densità di X in un punto x
(4.22)

while differentiating Equation 4.21 with respect to x gives

Da questa slide si capisce che
la funzione è differenziabile!

$$f_X(x) = f_Y(g(x)) \frac{dy}{dx} \Rightarrow f_Y(y) = \frac{f_X(x)}{\frac{dy}{dx}} \Big|_{x=g^{-1}(y)} \quad \leftarrow \text{come ottenere
la densità di Y
a partire dalla
densità di X}$$
(4.23)

Per funzioni **monotone decrescenti** si parte dalla distribuzione

La direzione della diseguaglianza
nella probabilità arancio a differenza
della funzione crescente si inverte
per la natura decrescente della
trasformazione

Differentiating with respect to y gives

$$f_Y(y) = -f_X(x) \frac{dx}{dy} \Big|_{x=g^{-1}(y)} \quad \begin{array}{l} \text{usa la complementare} \\ \text{segno negativo perché la} \\ \text{funzione è decrescente!} \end{array} \quad (4.25)$$

(4.24)

Spiegazione evidenziato
arancione:

la probabilità che Y sia $\leq y$
corrisponde alla probabilità che
X è $\geq g^{-1}(y)$ perché la funzione
è decrescente, quindi i valori
più grandi di y corrispondono a
valori più piccoli di x

Similarly, writing $F_Y(g(x)) = 1 - F_X(x)$ and differentiating with respect to x results in

$$f_Y(y) = -\frac{f_X(x)}{\frac{dy}{dx}} \Big|_{x=g^{-1}(y)}.$$
(4.26)

Dal libro del prof. Gelli, "Probabilità e informazione"

► Esempio 4.7. Consideriamo nuovamente la trasformazione lineare

$$Y = aX + b, \quad \text{ricordando che } X \text{ è la variabile originale e } Y \text{ è la variabile ricavata}$$

Qualunque sia $y \in \mathbb{R}$, e per ogni $a \neq 0$, l'equazione $y = g(x) = ax + b$ ammette l'unica soluzione

$$X = \frac{y - b}{a}, \quad \text{ricavata tramite differenziabilità}$$

ed inoltre risulta

$$|g'(x)| = |a|, \quad \text{per cui: } f_Y(y) = \frac{1}{|a|} f_X\left(\frac{y - b}{a}\right) \quad \text{permette di ricavare la non standard a partire dalla standard}$$

Si può procedere anche diversamente, ottenendo la distribuzione prima e derivando poi:

Nel caso $a > 0$, si ha:

$$F_Y(y) = P(Y \leq y) = P(aX + b \leq y) = P\left(X \leq \frac{y - b}{a}\right) = F_X\left(\frac{y - b}{a}\right). \quad \text{usando la 4.22 per funzioni monotone crescenti}$$

Per $a < 0$, il verso della diseguaglianza si inverte,

$$\begin{aligned} F_Y(y) &= P(Y \leq y) = P(aX + b \leq y) = P\left(X \geq \frac{y - b}{a}\right) \\ &= 1 - P\left(X < \frac{y - b}{a}\right) = 1 - F_X\left(\frac{y - b}{a}\right). \end{aligned}$$

la probabilità che Y sia \leq di un valore y corrisponde a calcolare la probabilità che X sia maggiore uguale al valore x

otteniamo lo stesso risultato per $a > 0$ e $a < 0$

$$\frac{d}{dy} F_Y(y) = \frac{1}{|a|} \cdot f_X\left(\frac{y - b}{a}\right)$$

Giustifico la forma della densità Gaussiana non standard a partire dalla standard

Valore atteso della funzione di una variabile aleatoria (non negativa)

ricorda $g(x) = y = ax + b$

Il valore atteso di Y $E[Y] \hat{=} \int_{y=0}^{\infty} y \cdot f_Y(y) dy$, con $Y \hat{=} a \cdot X$, $a > 0$ (esempio)
quindi $b=0$

$$E[aX] \hat{=} \int_{ax=0}^{\infty} ax \cdot f(ax) d(ax)$$

utilizzando $\frac{d}{dy} F_Y(y) = \frac{1}{|a|} \cdot f_X\left(\frac{y-b}{a}\right)$ con $b=0$

$$= \int_{x: ax=0}^{\infty} ax \cdot (1/a) f(y/a) \cdot d(ax) = \int_{x: ax=0}^{\infty} ax \cdot (1/a) f(ax/a) \cdot adx$$

$$= \int_{x=0}^{\infty} ax \cdot f(x) \cdot dx$$

Generalizzazione, con $g(x)$ idonea:

per idonea si intende monotona non decrescente e differenziabile

$$E[g(X)] \hat{=} \int_{x: g(x)=0}^{\infty} g(x) \cdot f(x) dx, \quad g(x) \geq 0$$

è esattamente la definizione del valore atteso di X per la costante a

Theorem: pdf for a transformed RV

Sia X : variabile aleatoria continua con densità f_X che non è 0 su un sottoinsieme I di numeri reali [i.e., $f_X(x) > 0, x \in I$ and $f_X(x) = 0, x \notin I$]. I può essere un punto!

Sia g : funzione monotona differenziabile con dominio I e immagine l'insieme dei reali.

Allora $Y = g(X)$: variabile aleatoria continua con densità f_Y definita come :

Densità di X valutata rispetto alla trasformazione inversa g nel punto y

$$f_Y(y) = \begin{cases} f_X[g^{-1}(y)][|(g^{-1})'(y)|], & y \in g(I) \\ 0, & \text{altrimenti} \end{cases}$$

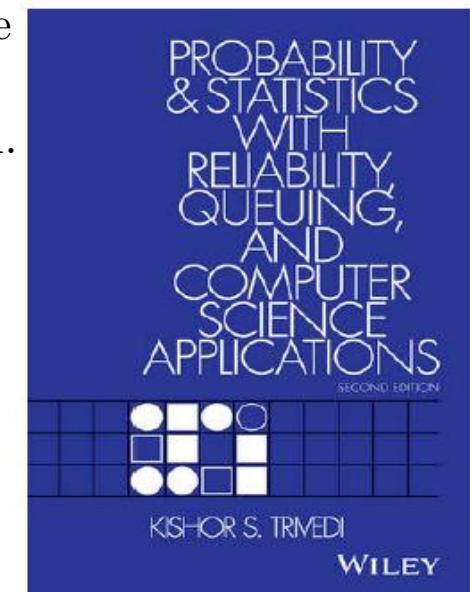
la derivata è la pendenza della funzione. Il valore assoluto mi dice di quanto sto "stirando" o "comprimendo" la distribuzione di probabilità

Prova:

Derivando ed utilizzando la regola di derivazione delle funzioni composte si ottiene che

$$F_Y(y) = P(Y \leq y) = P[g(X) \leq y] = P[X \leq g^{-1}(y)] = F_X[g^{-1}(y)]$$

Conosco la distribuzione di X e
 la funzione che trasforma X in Y ,
 quindi calcolo la distribuzione in Y



Consideriamo adesso la funzione quadratica: (che è monotona crescente strettamente)

Example 3.8

<https://ece.duke.edu/faculty/kishor-trivedi>

Distribuzione per $Y = g(X) = X^2$ Ricorda che
 $F_Y(y) = P(Y \leq y)$

$F_Y(y) = 0$, per $y \leq 0$ $P(Y \leq y)$ è zero! Essendo $Y = X^2 \implies X^2 \leq y$ ovvero $X^2 \leq$
di una quantità \leq di zero si risolve appunto solo
invece nel caso $y > 0$: per $X=0$

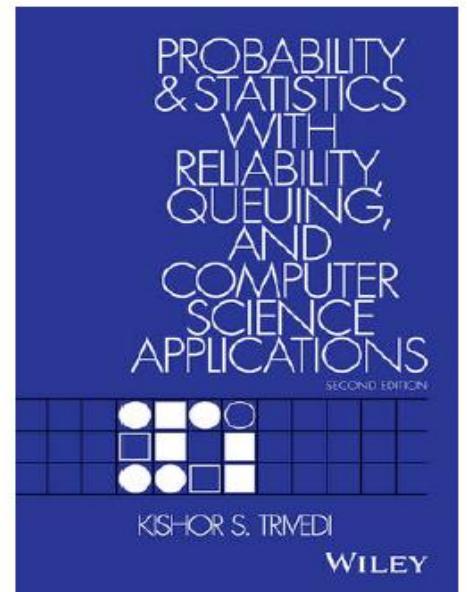
$$F_Y(y) = P(Y \leq y) = P(X^2 \leq y) = P(-\sqrt{y} \leq X \leq \sqrt{y}) = F_X(\sqrt{y}) - F_X(-\sqrt{y})$$

Esprimo $X \in [-\sqrt{y}, \sqrt{y}]$ come differenza esplicitando la definizione di distribuzione

La densità di Y , f_Y si ottiene con la regola di derivazione per funzioni composte,

$$f_Y(y) = \frac{dF_Y(y)}{dy} = \begin{cases} \frac{1}{2\sqrt{y}} [f_X(\sqrt{y}) + f_X(-\sqrt{y})], & y > 0, \\ 0, & \text{altrimenti.} \end{cases}$$

Quando elevo al quadrato una variabile aleatoria sto "comprimendo" la parte negativa della distribuzione e sto "stirando" quella positiva



Per chiarezza, vi anticipo la densità della V.A. gamma, che sarà dimostrata più avanti nel corso come generalizzazione del modello di Erlang:

https://en.wikipedia.org/wiki/Agner_Krarup_Erlang

Variabile aleatoria Gamma

A partire dal secondo integrale di Eulero si definisce la funzione
portando fuori $\Gamma(\alpha)$ di densità Gamma
perchè costante
ottengo $\frac{1}{\Gamma(\alpha)} \cdot \Gamma(\alpha) = 1$

$$f(t) = \frac{\lambda^\alpha t^{\alpha-1} e^{-\lambda t}}{\Gamma(\alpha)}, \quad \alpha > 0, \quad t > 0$$

$$\int_0^\infty \frac{\hat{f}(t)}{\Gamma(\alpha)} dt = 1$$

appunto l'integrale
di una densità deve
essere pari a 1

dove

$$\Gamma(\alpha) = \int_0^\infty x^{\alpha-1} e^{-x} dx, \quad \alpha > 0$$

- Show the recurrence for the gamma function:
 $\Gamma(\alpha) = (\alpha-1) \Gamma(\alpha-1)$; and show that $\Gamma(1/2) = \sqrt{\pi}$
- Because $\Gamma(1) = 1$, it follows that for an integer r , $\Gamma(r) = (r-1) \Gamma(r-1) = \dots = (r-1)!$
- So gamma with a positive integer valued shape parameter is the Erlang random variable

La variabile aleatoria Gamma con parametro di forma $\alpha = \frac{n}{2}$,

parametro di scala $\lambda = \frac{1}{2}$ è nota come variabile aleatoria "chi-square", (chi-quadrato) con n gradi di libertà

Se integro $\hat{f}(t)$

ottengo

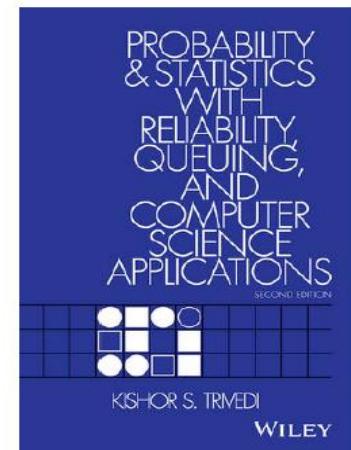
$$\Gamma(\alpha) = \int_{t=0}^{\infty} (\lambda t)^{\alpha-1} \cdot e^{-\lambda t} d(\lambda t), \quad \lambda > 0$$

sostituendo con

$$x \triangleq \lambda t \Rightarrow dx = \lambda dt$$

$$\Rightarrow x^{\alpha-1} \cdot dx = \lambda \cdot (\lambda t)^{\alpha-1}$$

Al crescere di alfa,
la distribuzione è
più simmetrica a destra
Al crescere di lambda
la distribuzione è
concentrata attorno a 0



IMPORTANTE
NOTIZIA

Caso particolare famoso (della funzione quadratica):

Quadrato della Gaussiana standard $N(0,1)$ Come calcoliamo le caratteristiche di densità e distribuzione del quadrato? Applicando il risultato del esempio 3.8 evidenziato in verde!

Example 3.9

In Example 3.8, assume X to be $N(0,1)$:

quindi si sa che la densità è $f_X(x) = \frac{1}{\sqrt{2\pi}}e^{-x^2/2}$, $-\infty < x < \infty$.

- Using result from Example 3.8:

$$f_Y(y) = \begin{cases} \frac{1}{2\sqrt{y}} \left(\frac{1}{\sqrt{2\pi}}e^{-y/2} + \frac{1}{\sqrt{2\pi}}e^{-y/2} \right), & y > 0, \\ 0, & y \leq 0, \end{cases}$$

or, $f_Y(y) = \begin{cases} \frac{1}{\sqrt{2\pi y}}e^{-y/2}, & y > 0, \\ 0, & y \leq 0. \end{cases}$

i.e.,

Y has a *gamma* distribution with $\alpha = 1/2$ and $\lambda = 1/2$ e $y \equiv t$

- Which is also known as chi-square distribution with 1 degree of freedom

$$\Gamma(\alpha) = \int_{t=0}^{\infty} (\lambda t)^{\alpha-1} \cdot e^{-\lambda t} d(\lambda t), \lambda > 0$$

Passaggi algebrici

$$\begin{aligned} f(y) &= \frac{1}{\Gamma(\frac{1}{2})} \cdot \frac{1}{2} \cdot \left(\frac{y}{2}\right)^{-\frac{1}{2}} \cdot e^{-\frac{y}{2}} \\ &= \frac{1}{\Gamma(\frac{1}{2})} \cdot \frac{1}{\sqrt{2} \cdot \sqrt{2}} \cdot \frac{\sqrt{2}}{\sqrt{y}} \cdot e^{-\frac{y}{2}} \\ &= \frac{1}{\sqrt{\pi}} \cdot \frac{1}{\sqrt{2}} \cdot \frac{1}{\sqrt{y}} \cdot e^{-\frac{y}{2}} \end{aligned}$$

Il quadrato di una standard porta ad una funzione gamma particolare con alfa e lambda particolari detta chi-quadrato che servirà per la statistica della varianza

Una funzione logaritmo (ad hoc) su una var. al. X, UNIFORME in (0,1):

FINO A QUI DOMANDE DI ESAME!

Logaritmo è sempre
monotona e differenziabile come
vuole l'ipotesi ipotesi (slide 1)

$$Y \doteq -\lambda^{-1} \cdot \ln(1-X)$$

X distribuito uniformemente da 0 a 1 è un
generatore di numeri casuali

Example 3.10

- Let X be uniformly distributed, $\text{Unif}(0,1)$
- Then, $Y = -\lambda^{-1} \ln(1-X)$ is $\text{EXP}(\lambda)$.

$$\text{for } y \leq 0, F_Y(y) = 0$$

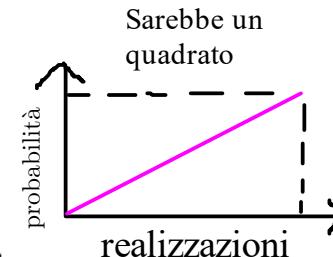
for $y > 0$,

$$\begin{aligned} F_Y(y) &= P(Y \leq y) = P[-\lambda^{-1} \ln(1-X) \leq y] \\ &= P[\ln(1-X) \geq -\lambda y] \\ &= P[(1-X) \geq e^{-\lambda y}] \quad (\text{since } e^x \text{ is an increasing function of } x,) \\ &= P(X \leq 1 - e^{-\lambda y}) \\ &= F_X(1 - e^{-\lambda y}). \end{aligned}$$

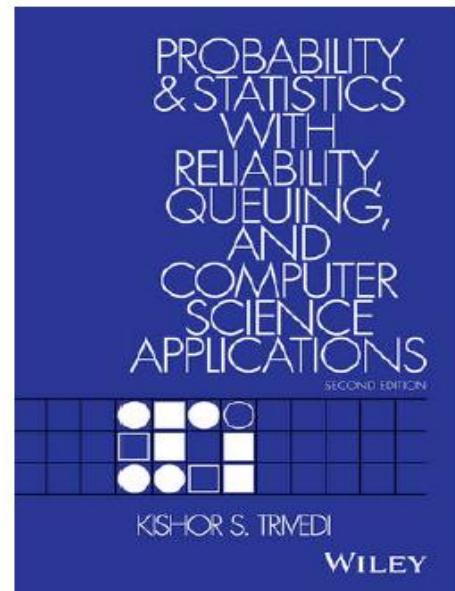
Se X è uniforme distribuito tra 0 e 1
la densità sarà costante dunque
la distribuzione che è la funzione l'integrale
della densità è lineare. Appunto integrale di una
costante funzione lineare da analisi 1

Since X is $\text{U}(0,1)$, $F_X(x) = x, 0 \leq x \leq 1$. Therefore,

$$F_Y(y) = 1 - e^{-\lambda y} \Rightarrow Y \text{ is } \text{EXP}(\lambda)$$



la realizzazione è
uguale alla probabilità
con cui si osserva la
realizzazione. Quindi
la distribuzione è la
diagonale del quadrato
vedi Monte Carlo



IN PARTICOLARE

La funzione (inversa) quantile è la
trasformazione che permette di
produrre realizzazioni a partire da
una funzione di distribuzione
invertibile (Esponenziale, Weibull ecc)

IDEA: avendo a disposizione un generatore di numeri casuali uniformemente distribuiti in (0,1) potremmo generare realizzazioni della V.A. esponenziale di parametro λ sarà il laboratorio di Excel

Example 8.1.2 (Log-Normal PDF). Let $X \sim \mathcal{N}(0, 1)$, $Y = e^X$. In Chapter 6 we named the distribution of Y the Log-Normal, and we found all of its moments using the MGF of the Normal distribution. Now we can use the change of variables formula to find the PDF of Y , since $g(x) = e^x$ is strictly increasing. Let $y = e^x$, so $x = \log y$ and $dy/dx = e^x$. Then

$$f_Y(y) = f_X(x) \left| \frac{dx}{dy} \right| = \varphi(x) \frac{1}{e^x} = \varphi(\log y) \frac{1}{y}, \quad y > 0.$$

Note that after applying the change of variables formula, we write everything on the right-hand side in terms of y , and we specify the support of the distribution. To determine the support, we just observe that as x ranges from $-\infty$ to ∞ , e^x ranges from 0 to ∞ .

We can get the same result by working from the definition of the CDF, translating the event $Y \leq y$ into an equivalent event involving X . For $y > 0$,

$$F_Y(y) = P(Y \leq y) = P(e^X \leq y) = P(X \leq \log y) = \Phi(\log y),$$

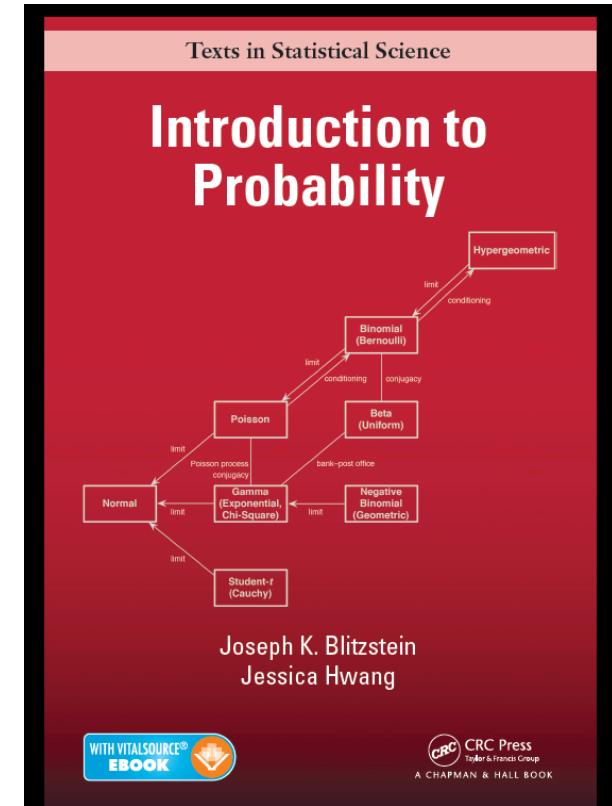
so the PDF is again

$$f_Y(y) = \frac{d}{dy} \Phi(\log y) = \varphi(\log y) \frac{1}{y}, \quad y > 0.$$

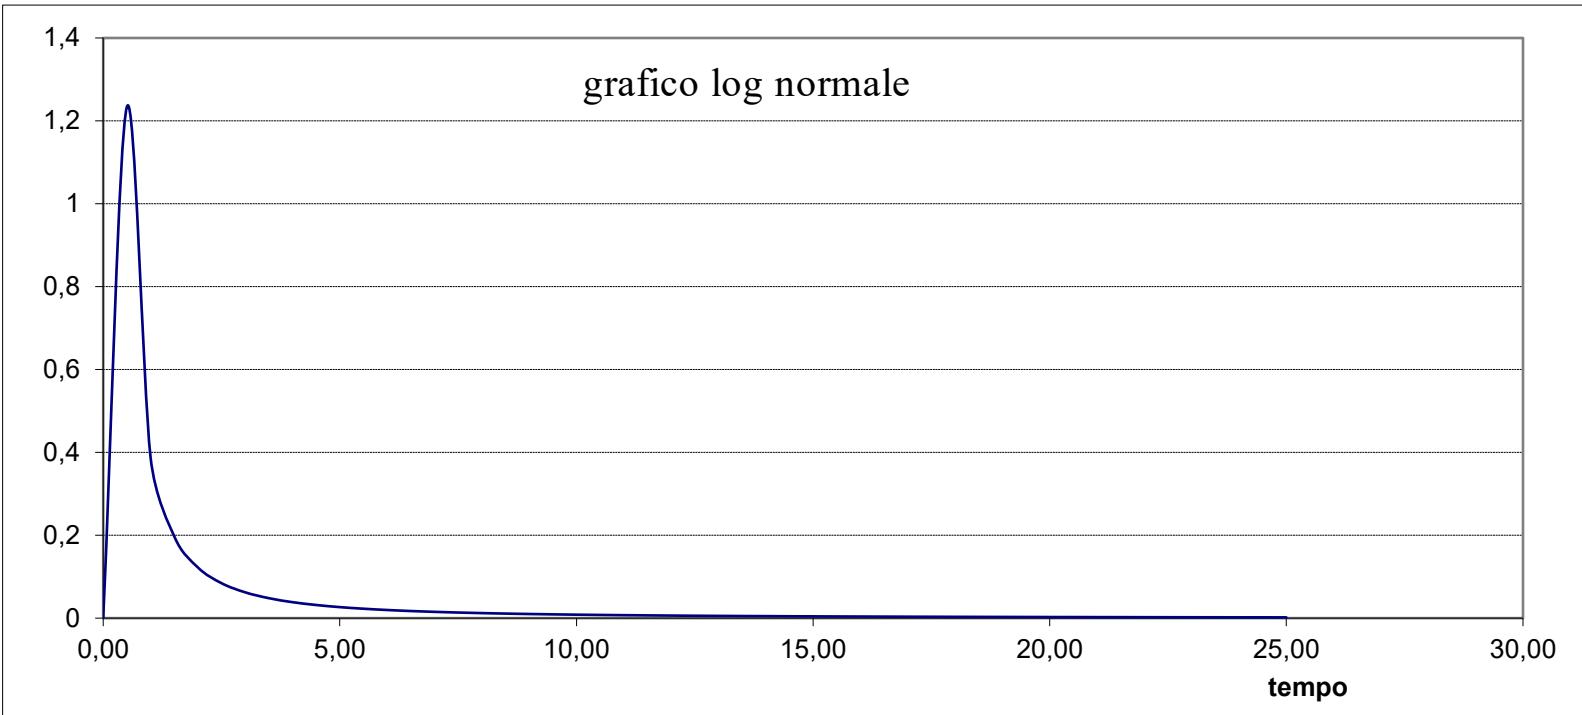
log normale *monotone* *gaussiana* *log normale*

distribuzione gaussiana

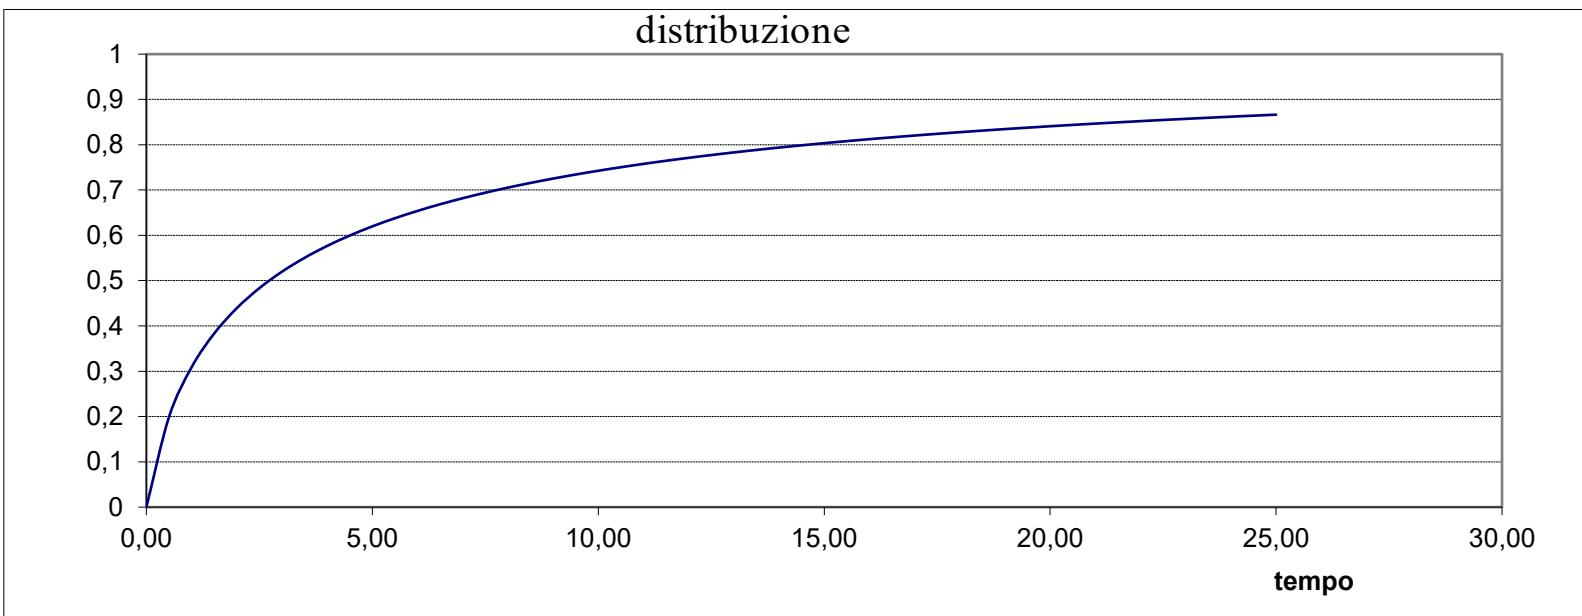
Φ è densità Gauss
Φ è distrib. Gauss



Take a look at my excel file «Modello lognormale (Legato)», please!



simile alla Weibull
ma qui la discesa/decrescita
è molto più ripida/veloce



From WIKIPEDIA

inverte la x con y

X=lognorm Y=norm

Notation	$\text{Lognormal}(\mu, \sigma^2)$
Parameters	$\mu \in (-\infty, +\infty)$, $\sigma > 0$
Support	$x \in (0, +\infty)$
PDF	$\frac{1}{x\sigma\sqrt{2\pi}} \exp\left(-\frac{(\ln x - \mu)^2}{2\sigma^2}\right)$
CDF	$\frac{1}{2} + \frac{1}{2} \operatorname{erf}\left[\frac{\ln x - \mu}{\sqrt{2}\sigma}\right]$
Quantile	$\exp(\mu + \sqrt{2\sigma^2} \operatorname{erf}^{-1}(2F - 1))$
Mean	$\exp\left(\mu + \frac{\sigma^2}{2}\right)$
Median	$\exp(\mu)$
Mode	$\exp(\mu - \sigma^2)$
Variance	$[\exp(\sigma^2) - 1] \exp(2\mu + \sigma^2)$
Skewness	$(e^{\sigma^2} + 2)\sqrt{e^{\sigma^2} - 1}$
Ex. kurtosis	$\exp(4\sigma^2) + 2\exp(3\sigma^2) + 3\exp(2\sigma^2) - 6$

$\Phi \triangleq \text{GAUSS DISTRIBUTION}$

$$x = e^y \implies y = \ln x$$

dimostrazione (non richiesta)

$$\begin{aligned} f_X(x) &= \frac{d}{dx} \Pr(X \leq x) = \frac{d}{dx} \Pr(\ln X \leq \ln x) \\ &= \frac{d}{dx} \Phi\left(\frac{\ln x - \mu}{\sigma}\right) \\ &= \varphi\left(\frac{\ln x - \mu}{\sigma}\right) \frac{d}{dx} \left(\frac{\ln x - \mu}{\sigma}\right) \\ &= \varphi\left(\frac{\ln x - \mu}{\sigma}\right) \frac{1}{\sigma x} \\ &= \frac{1}{x} \cdot \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(\ln x - \mu)^2}{2\sigma^2}\right). \end{aligned}$$

normale
standardizzata

$$F_X(x) = \Phi\left(\frac{(\ln x) - \mu}{\sigma}\right)$$

$$\frac{1}{2} \left[1 + \operatorname{erf}\left(\frac{\ln x - \mu}{\sigma\sqrt{2}}\right) \right] = \frac{1}{2} \operatorname{erfc}\left(-\frac{\ln x - \mu}{\sigma\sqrt{2}}\right)$$

where $\operatorname{erf}(z) \triangleq \frac{2}{\sqrt{\pi}} \int_{t=0}^z e^{-t^2} dt$

and $\operatorname{erfc}(z) \triangleq 1 - \operatorname{erf}(z)$

EXTRA

Appendice I

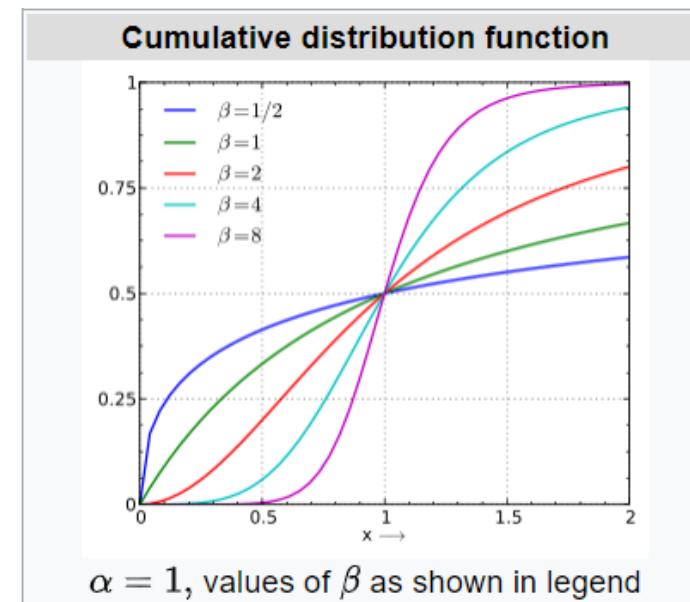
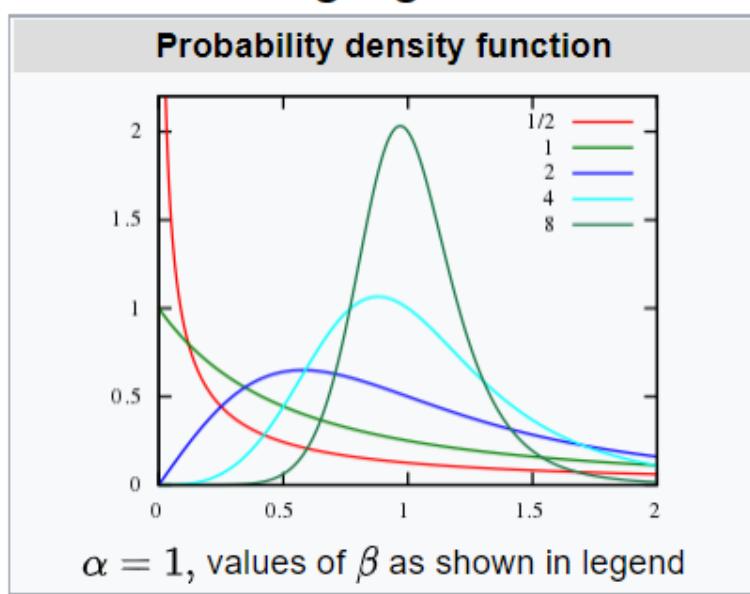
La funzione di distribuzione
Log-Logistic

Log-logistic distribution

From Wikipedia, the free encyclopedia

In probability and statistics, the **log-logistic distribution** (known as the **Fisk distribution** in economics) is a continuous probability distribution for a non-negative random variable. It is used in **survival analysis** as a parametric model for events whose rate increases initially and decreases later, as, for example, mortality rate from cancer following diagnosis or treatment. It has also been used in **hydrology** to model stream flow and **precipitation**, in **economics** as a simple model of the **distribution of wealth or income**, and in **networking** to model the transmission times of data considering both the network and the software.

The log-logistic distribution is the probability distribution of a random variable whose **logarithm** has a **logistic distribution**. It is similar in shape to the **log-normal distribution** but has **heavier tails**. Unlike the log-normal, its **cumulative distribution function** can be written in **closed form**.



There are several different parameterizations of the distribution in use. The one shown here gives reasonably interpretable parameters and a simple form for the cumulative distribution function.^{[3][4]} The parameter $\alpha > 0$ is a scale parameter and is also the median of the distribution. The parameter $\beta > 0$ is a shape parameter. The distribution is unimodal when $\beta > 1$ and its dispersion decreases as β increases.

The cumulative distribution function is

$$\begin{aligned} F(x; \alpha, \beta) &= \frac{1}{1 + (x/\alpha)^{-\beta}} \\ &= \frac{(x/\alpha)^\beta}{1 + (x/\alpha)^\beta} \\ &= \frac{x^\beta}{\alpha^\beta + x^\beta} \end{aligned}$$

where $x > 0, \alpha > 0, \beta > 0$.

The probability density function is

$$f(x; \alpha, \beta) = \frac{(\beta/\alpha)(x/\alpha)^{\beta-1}}{(1 + (x/\alpha)^\beta)^2}$$

Attenzione:
questa volta α è usato per indicare
il fattore di scala e β il fattore di
forma!

Quantiles [edit]

The quantile function (inverse cumulative distribution function) is :

$$F^{-1}(p; \alpha, \beta) = \alpha \left(\frac{p}{1-p} \right)^{1/\beta}.$$

Può essere usata per generare realizzazioni!

It follows that the median is α , the lower quartile is $3^{-1/\beta}\alpha$ and the upper quartile is $3^{1/\beta}\alpha$.

Se $F(\bar{x}_p) = p$, $p \in (0,1)$
allora \bar{x}_p è detto
 p -simo quantile della F
 $p \doteq 0.5$ è detto mediana

Moments [edit]

The k th raw moment exists only when $k < \beta$, when it is given by^{[5][6]}

$$E(X^k) = \alpha^k B(1 - k/\beta, 1 + k/\beta)$$

$$= \alpha^k \frac{k\pi/\beta}{\sin(k\pi/\beta)}$$

where B is the beta function. Expressions for the mean, variance, skewness and kurtosis can be derived from this. Writing $b = \pi/\beta$ for convenience, the mean is

$$E(X) = \alpha b / \sin b, \quad \beta > 1,$$

and the variance is

$$\text{Var}(X) = \alpha^2 (2b / \sin 2b - b^2 / \sin^2 b), \quad \beta > 2.$$

Explicit expressions for the skewness and kurtosis are lengthy.^[7] As β tends to infinity the mean tends to α , the variance and skewness tend to zero and the excess kurtosis tends to 6/5 (see also related distributions below).

Per esercizio, potete graficare densità e distribuzione del modello "Log-logistic"!

Survival analysis [edit]

(RELIABILITY)

The log-logistic distribution provides one parametric model for survival analysis. Unlike the more commonly used Weibull distribution, it can have a non-monotonic hazard function: when $\beta > 1$, the hazard function is unimodal (when $\beta \leq 1$, the hazard decreases monotonically). The fact that the cumulative distribution function can be written in closed form is particularly useful for analysis of survival data with censoring.^[8] The log-logistic distribution can be used as the basis of an accelerated failure time model by allowing α to differ between groups, or more generally by introducing covariates that affect α but not β by modelling $\log(\alpha)$ as a linear function of the covariates.^[9]

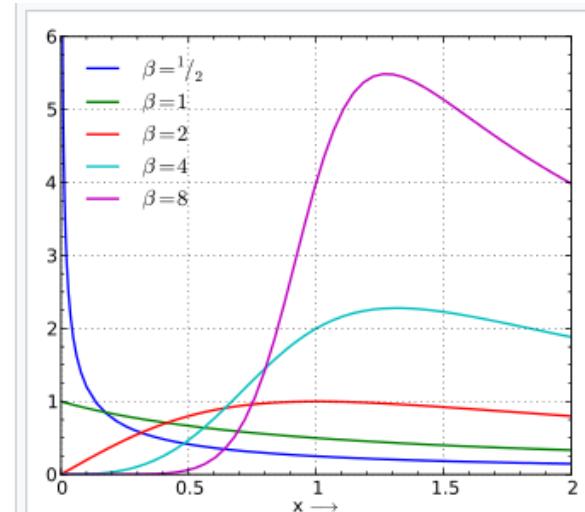
The survival function is

$$S(t) = 1 - F(t) = [1 + (t/\alpha)^\beta]^{-1},$$

and so the hazard function is

$$h(t) = \frac{f(t)}{S(t)} = \frac{(\beta/\alpha)(t/\alpha)^{\beta-1}}{1 + (t/\alpha)^\beta}.$$

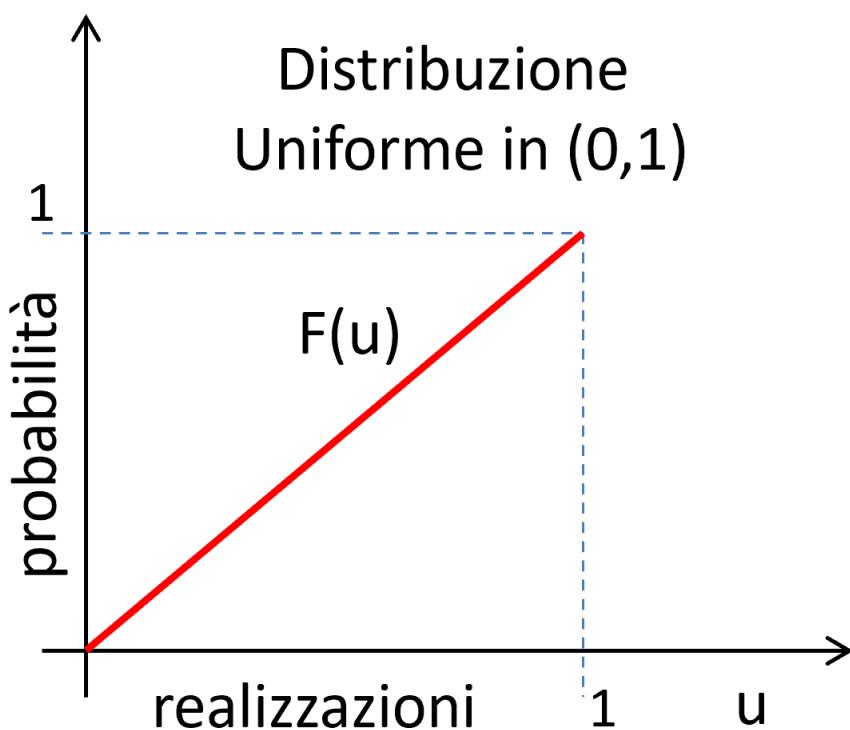
A anche questi grafici
potete riprodurre
con Excel!



Hazard function. $\alpha = 1$, values of β as shown in legend

IMPORTANTE

Come si è visto precedentemente, la funzione (inversa) quantile è la trasformazione che permette di produrre realizzazioni a partire da una funzione di distribuzione invertibile (Esponziale, Weibull ecc)



In generale dunque si ha che:

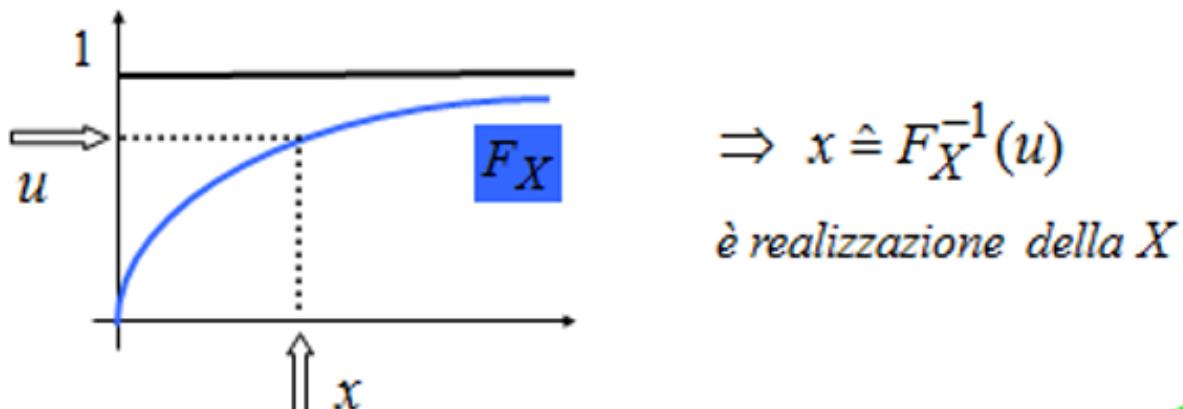
Dai numeri casuali alle realizzazioni di v.a.

$\{u_1, u_2, \dots, u_n, \dots\}$ realizzazioni indipendenti di $U\{0,1\}$

Generazione di realizzazioni delle Var. Al. d'ingresso

Metodo della trasformazione inversa
dimostrazione

$$\Pr\{X \leq x\} \hat{=} F_X(x) = F_X(F_X^{-1}(u)) = u = \Pr\{U \leq u\}$$



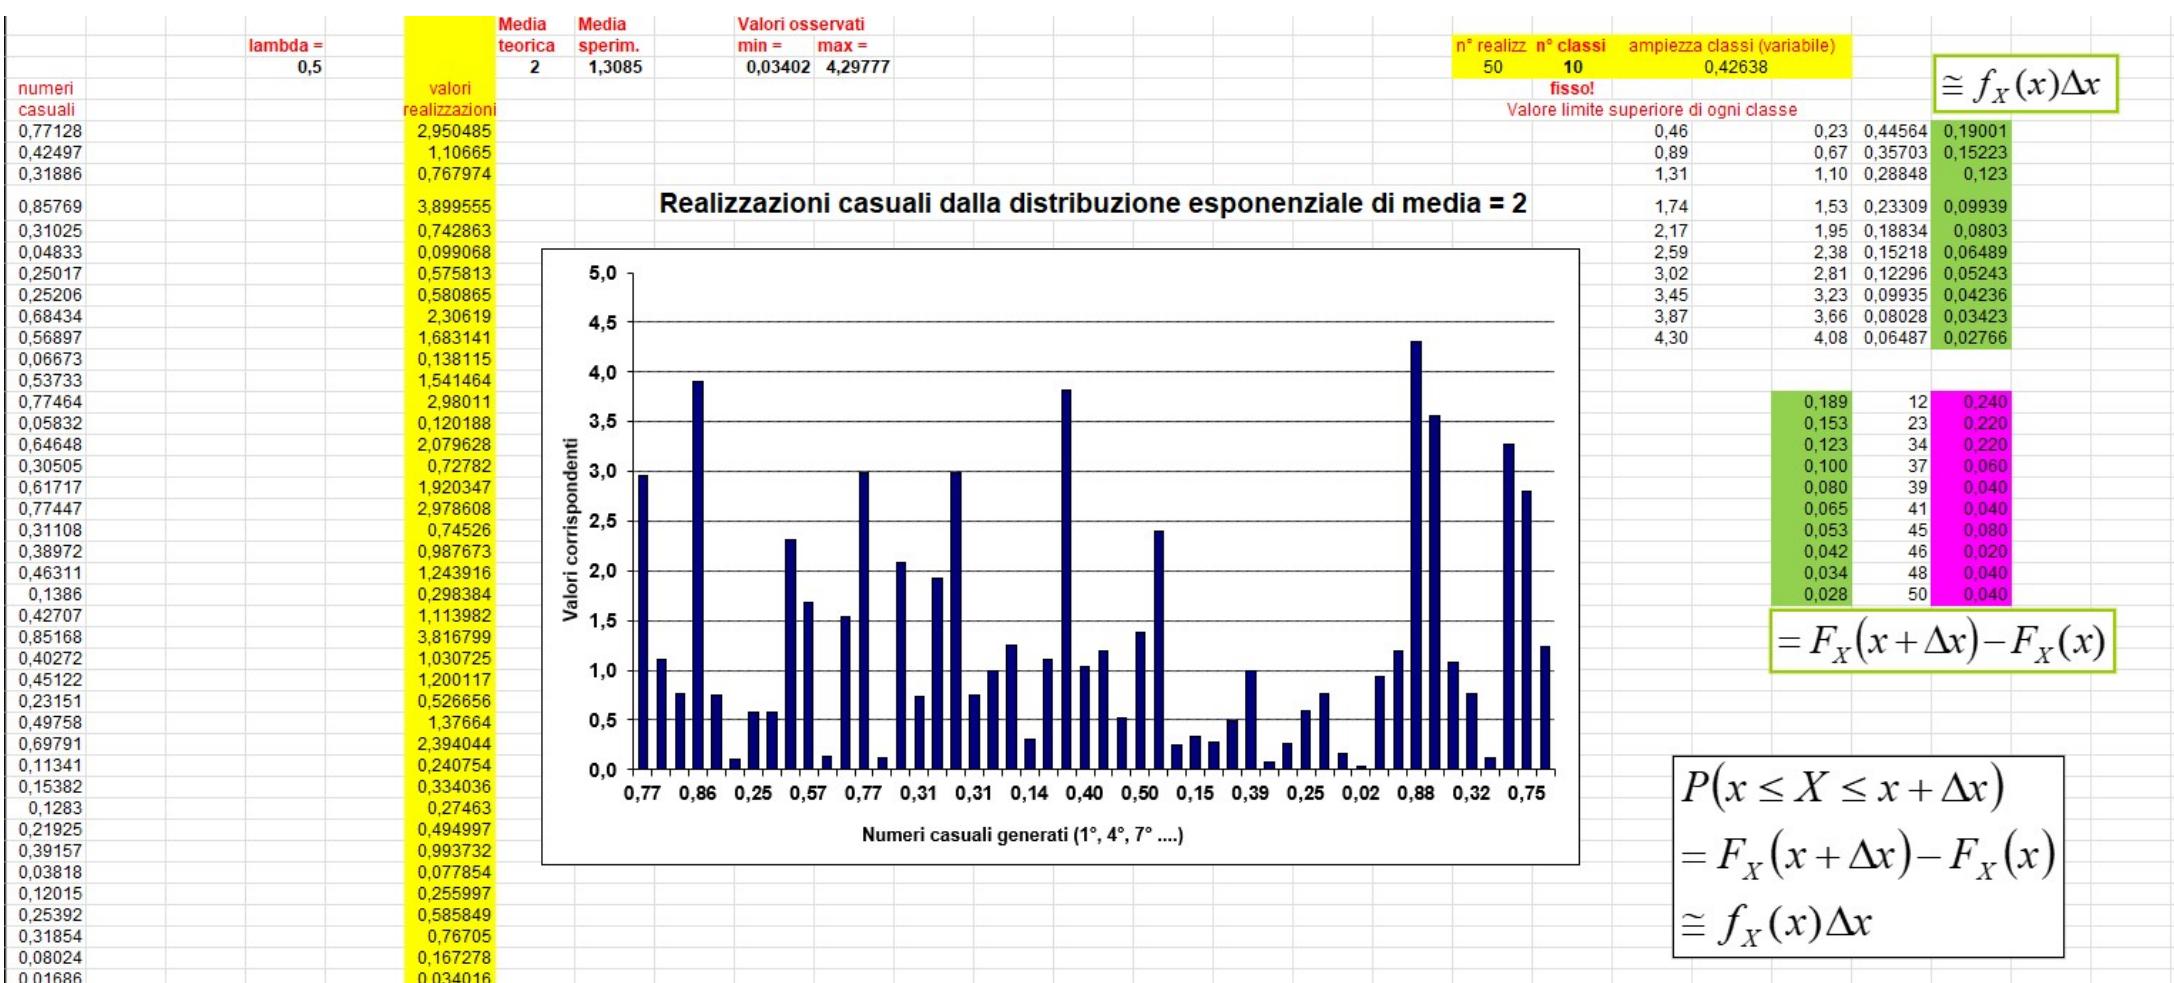
A parole: presa una funzione di **distribuzione invertibile** $F_x(x)$ allora si ha che

$F_X(F_X^{-1}(u)) = u$ dunque la funzione di distribuzione nell'inversa della distribuzione in u ritorna u. Esempio esponenziale con $\lambda = 1 \Rightarrow F_X(x) = 1 - e^{-x} \Rightarrow F_X^{-1}(x) = -\ln(1 - x)$

$F_X(F_X^{-1}(u)) = 1 - e^{-\ln(1+u)} = 1 - (1 - u) = u$ Quindi come abbiamo visto in precedenza la realizzazione è uguale alla probabilità con cui si osserva la realizzazione L'unica distribuzione che ha ascissa pari a ordinata è $F_X(x) = x$ appunto la diagonale del quadrato.

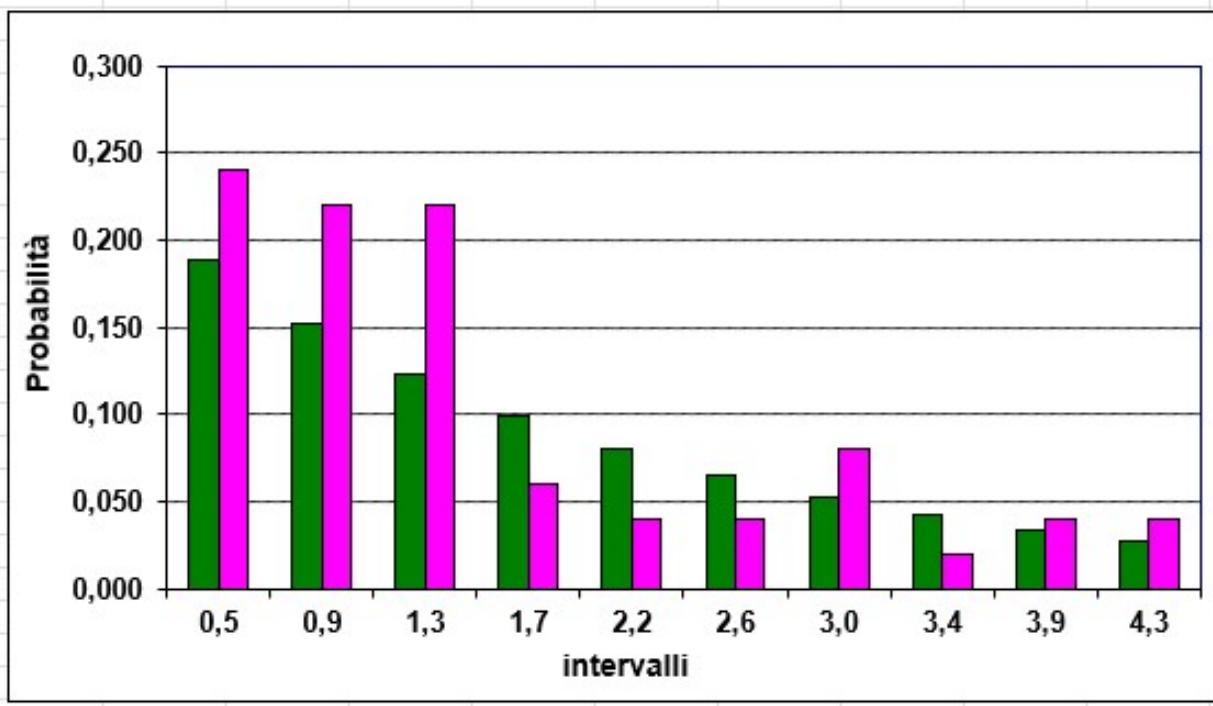
Ci mettiamo nell'ipotesi di modelli in cui la distribuzione è invertibile.

Il metodo non è utilizzabile per tutte le distribuzioni



Grazie al **metodo della trasformazione inversa** si sono generate molte realizzazioni, che appunto nella cella mostrano la formula inversa. La media sperimentale sarebbe la classica media aritmetica e mostra nella simulazione che facendo più prove, tende al valore della media teorica. La media teorica sarebbe il valore atteso appunto. Quindi si capisce e vedremo in futuro che per n tendente all'infinito la media aritmetica tenda al valore atteso. Facendo simulazioni si ottengono valori che sono più piccoli o più grandi del valore atteso. L'oscillazione dei risultati a parità di dimensione del campione, è dovuta alla varianza! Non solo per la casualità. (Non si sa ancora di quanto si sbaglia) Si hanno poi i valori min e max, che mostrano quanto ad esempio un tempo di esecuzione può essere piccolissimo oppure molto grande. Il grafico ci potrebbe ad esempio mostrare il fenomeno di burst all'interno di una coda. Ad esempio vado dall'elettrauto e devo cambiare la lampadine e sto 0.3 secondi, mentre può capitare che arriva quello che deve cambiare la batteria ed i cavi annessi e sta 4.3 secondi (ovviamente non impiega secondi un elettrauto). Riordinare i valori non basta per ricostruire la legge esponenziale di media. Oltre ai valori di min e max occorre fissare un numero di classi, ovvero un numero di raggruppamenti dove i valori possono finire, un numero di realizzazione da prendere in esame e l'ampiezza delle classi, che sarebbe la differenza tra max e min diviso il numero di classi fissato.

Ricostruzione legge esponenziale di media = 2



lizz	n° classi	ampiezza classi (variabile)	
	10	0,42638	
fisso!			
Valore limite superiore di ogni classe			
2			
	0,46	0,23	0,44564
	0,89	0,67	0,35703
	1,31	1,10	0,28848
	1,74	1,53	0,23309
	2,17	1,95	0,18834
	2,59	2,38	0,15218
	3,02	2,81	0,12296
	3,45	3,23	0,09935
	3,87	3,66	0,08028
	4,30	4,08	0,06487
			0,19001
			0,15223
			0,123
			0,09939
			0,0803
			0,06489
			0,05243
			0,04236
			0,03423
			0,02766

$$\cong f_X(x)\Delta x$$

Il limite superiore di ogni classe si ottiene partendo da 0 e sommando l'ampiezza della classe al valore minimo. L'ultimo limite sarà il valore di max.

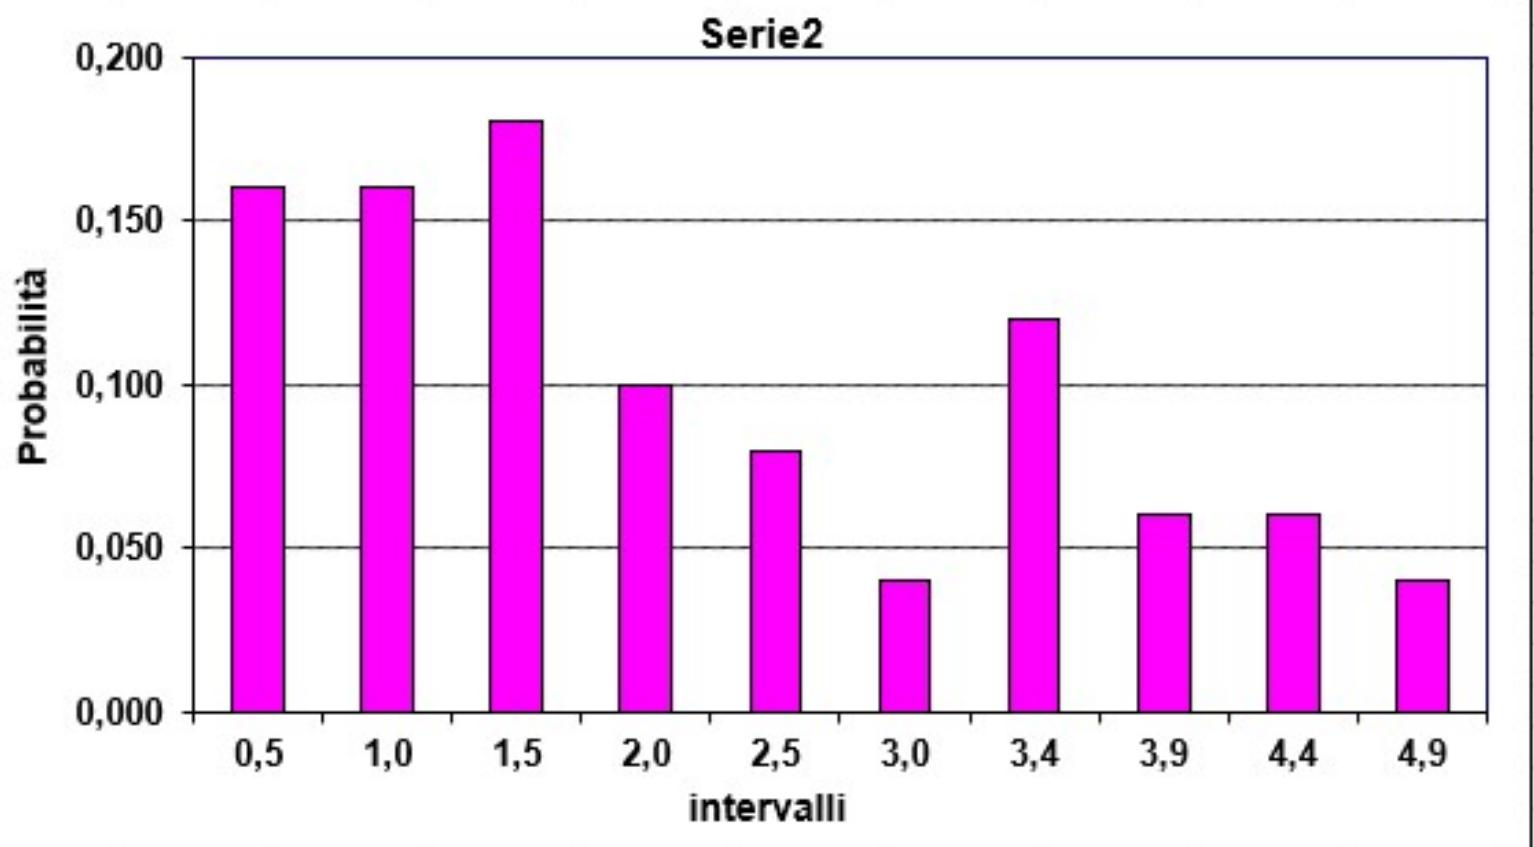
$f_X(x)\Delta x$ corrisponde alla percentuale di valori che ci si aspettano in una classe. (19% nello screen)
Ma tale percentuale si può ottenere anche con la distribuzione

Noi faremo statistica inferenziale.

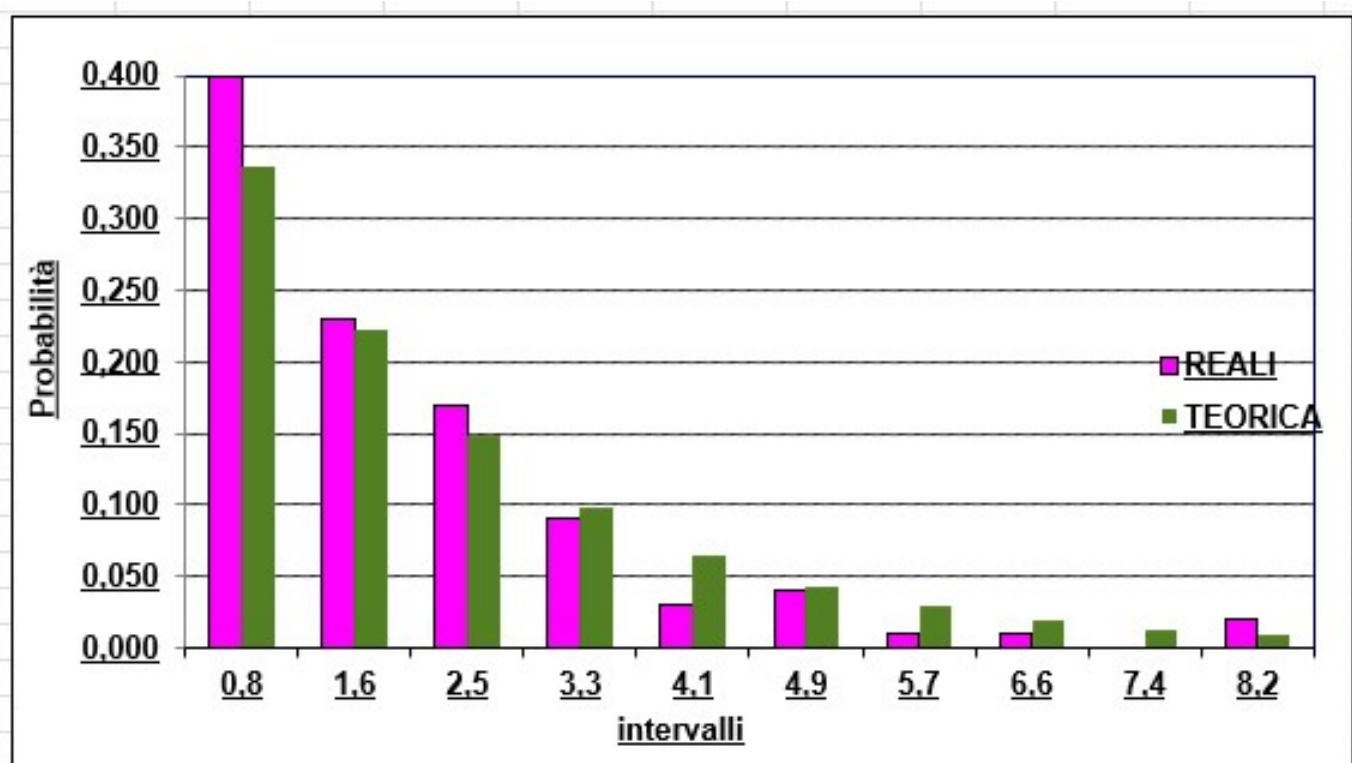
La **statistica descrittiva** consiste nel dire quali parametri ci danno una caratteristica sintetica sulla forma: valore atteso, varianza, momento del secondo ordine, simmetria ecc.

L'**inferenza** (deduzione vedi dizionario) sono i metodi per dire quanto sarà il valore atteso.

Quindi prendo un oggetto/un fenomeno, di cui scelgo quanti e quali attributi e ne provo a dedurre la forma. Quindi in questo caso l'inferenza completa che noi facciamo è la forma della legge. Prendiamo ad esempio il seguente istogramma:



Non assomiglia per niente alla curva della legge esponenziale. La statistica consiste nel ricavare con pochi dati o meno dati possibili una risposta accettando il rischio di sbagliare. Quindi per prima cosa interessa il numero di dati. Poi il numero di classi.

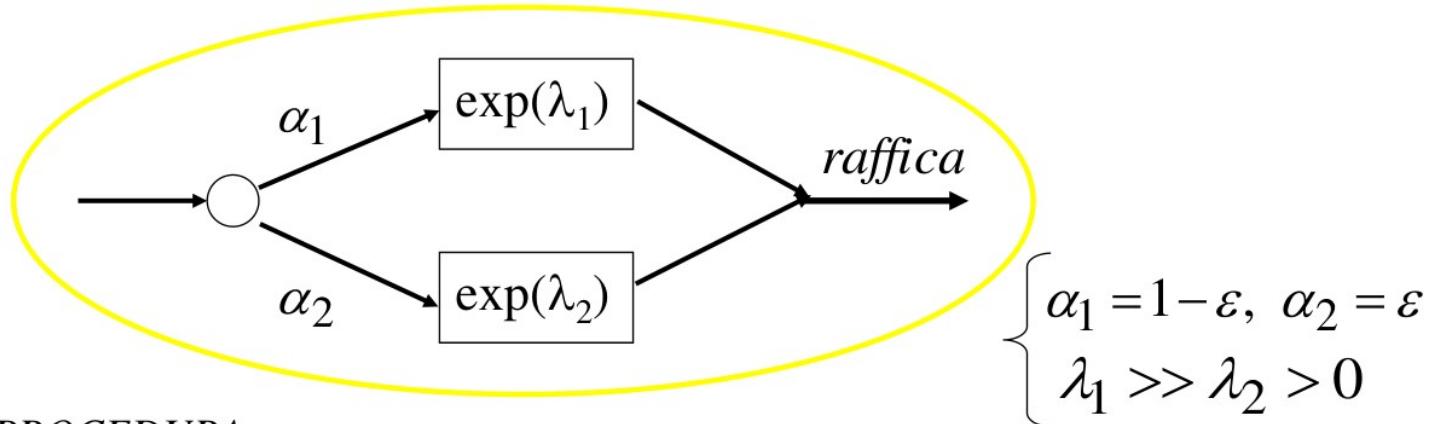


Nel grafico precedente si vede che anche se con media sperimentale 1.62(!), se uso 100 realizzazione quindi il doppio dei dati, per 10 classi la curva della legge esponenziale è abbastanza simile alla teorica. Prendiamo adesso la distribuzione iperesponenziale:

Trasformazione inversa per la distribuzione iperesponenziale

$$F_Y(y) \hat{=} \sum_{i=1}^n \alpha_i (1 - \exp\{-\lambda_i y\}), \quad \lambda_1 \neq \lambda_2 \neq \dots \neq \lambda_n$$

$$\text{con: } \sum_{i=1}^n \alpha_i = 1, \quad \alpha_i > 0 \quad i = 1, \dots, n$$



PROCEDURA:

genera $u \in U\{0,1\}$

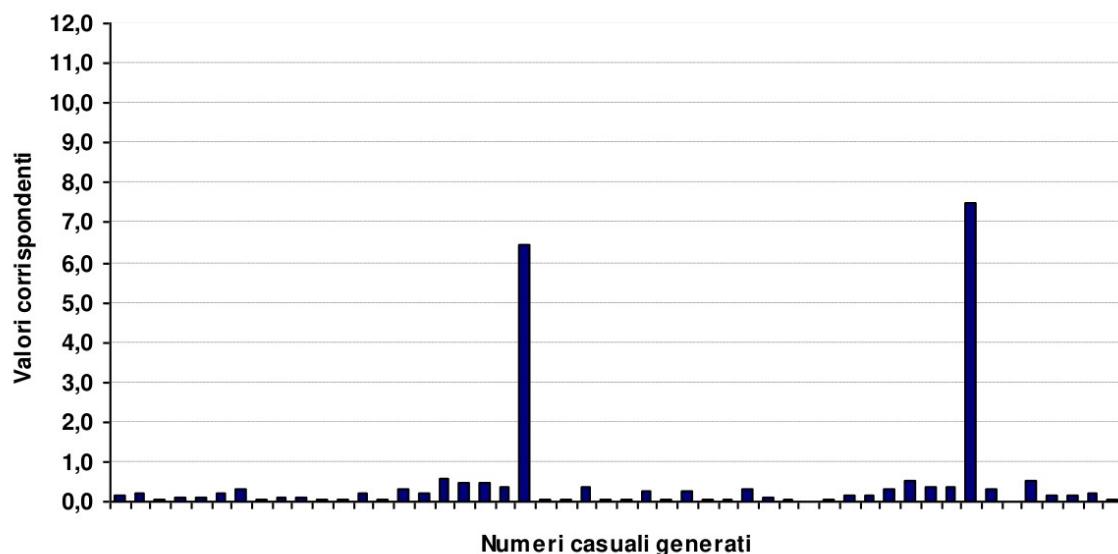
if $u \leq \alpha_1$ *then* *genera*($y \approx EXP(\lambda_1)$)

else *genera*($y \approx EXP(\lambda_2)$)

La trasformazione inversa del iperesponenziale è una combinazione convessa. Tramite l'iperesponenziale si può studiare l'effetto di bursting. In particolare come mostra l'immagine si ha che λ_1 è molto grande, quindi l'esponenziale molto veloce e tempi brevi λ_2 è piccolissimo quindi esponenziale lento e tempi lunghissimi. Quindi generato un numero casuale u tra 0 e 1, si ha che $u \leq \alpha_1$, $\alpha_1 = 0.95$ genera una realizzazione di e^{λ_1} altrimenti di e^{λ_2} . I numeri "passano" uno alla volta ecco perchè si osserva un effetto raffica. Il compito della statistica sarà capire i valori di alpha e lambda, a partire da dei dati. Vediamo di seguito la generazione monte carlo di realizzazioni iperesponenziali

Realizzazioni casuali dalla legge IPEResponenziale

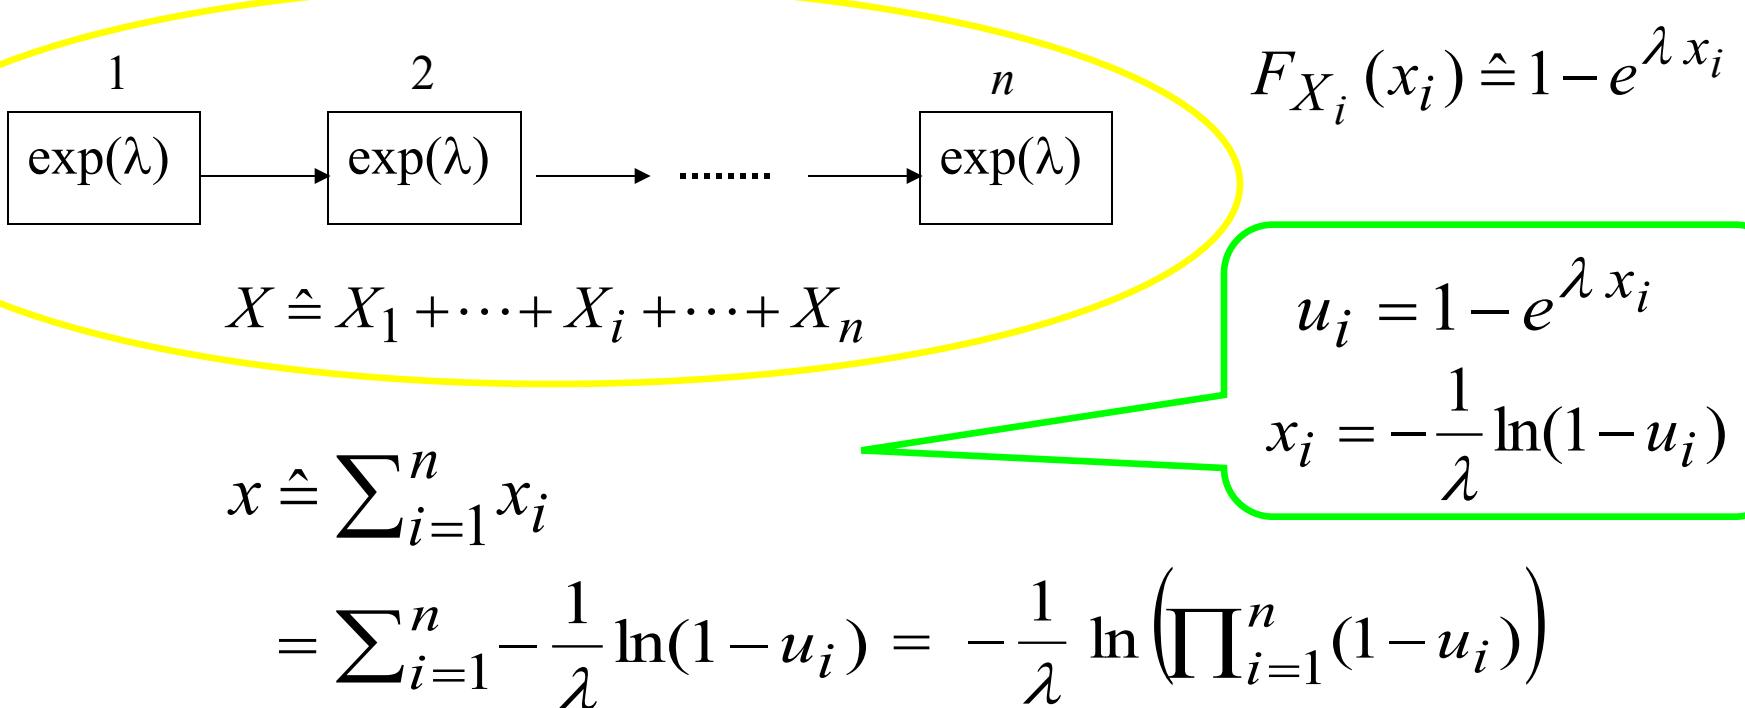
(alfa = 0,95 - lambda_1 = 5 - lambda_2 = 0,5)



Metodo della trasformazione inversa e legge di Erlang

$$F_X(x) \hat{=} 1 - e^{-\lambda x} \sum_{i=0}^{n-1} \frac{(\lambda x)^i}{i!} \quad \lambda > 0$$

Somma di esponenziali identiche e indipendenti



Erlang come vedremo anche dopo non ha assenza di memoria! Questo perchè essendo somma di esponenziali identiche e indipendenti può essenzialmente ritornare la "posizione" all'interno della sua storia.

STATISTICHE E STIMATORI

Una **statistica** è una variabile aleatoria funzione di un numero fissato ($n \geq 1$) di altre variabili aleatorie, ma che **non contiene** alcun parametro incognito.

La realizzazione della statistica è una quantità numerica calcolata a partire da un campione di dati (variabile aleatoria funzione di un numero fissato di altre variabili aleatorie). Proprio perché parte da un campione di dati, non dipende da parametri incogniti

Sia T una statistica per le variabili aleatorie i.i.d. $X_1 \dots X_n$ e sia θ un parametro incognito di queste ultime; allora $T(\mathbf{X})$ è detto **stimatore corretto di θ** se risulta $E[T(\mathbf{X})] = \theta$.

- popolazione: tutti gli studenti di ingegneria
- campione: gruppo di n studenti presi casualmente dalla facoltà di ingegneria

CARATTERISTICHE e valutazione di uno stimatore

($E[T(\mathbf{X})] - \theta$) è detto **errore sistematico (bias)**

è la differenza tra il valore atteso dello stimatore ed il vero valore del parametro. Uno stimatore corretto perciò ha un bias nullo

$MSE \hat{=} E[(T(X_1, \dots, X_n) - \theta)^2]$ è l'**errore quadratico medio**

Misura la variabilità dello stimatore attorno al vero valore del parametro. Un MSE basso indica uno stimatore più preciso

Stimatore consistente se:

quindi è consistente se per n tendente all'infinito, converge in probabilità al parametro da stimare

$\lim_{n \rightarrow \infty} \Pr\left(|T(X_1, \dots, X_n) - \theta| \geq \varepsilon\right) = 0$

stimatore
vero valore del parametro
valore molto piccolo
la stima diventa sempre più precisa man mano che si raccolgono più dati
"all'aumentare del campione"
probabilità che la stima T si discosti dal vero valore, diventa sempre più piccola

Valutare tutte le suddette caratteristiche con riferimento ad uno stimatore trovato e usato dagli statistici non è cosa facile, in generale!

Anticipazione di due risultati di analisi probabilistica utili adesso

Dimostreremo in una lezione futura che:

1. il valore atteso di una somma di variabili aleatorie è pari alla somma dei valori attesi di ciascuna, senza bisogno di assumere che quelle variabili siano indipendenti.
2. La varianza di una somma di variabili aleatorie è pari alla somma delle varianze di ciascuna se assumiamo che quelle variabili siano indipendenti.

La statistica “media campionaria”

E' detta media campionaria la var. al seguente :

$$\bar{X}(n) \hat{=} \frac{1}{n} \sum_{i=1}^n X_i$$

X_1 pari alla realizzazione
del primo run
della monte carlo
↓
singole osservazioni
del campione
→ dimensioni
del campione

Se le X_i sono identicamente distribuite e con lo stesso valore atteso, $E[X_i] \hat{=} \mu_i = \mu, i = 1, 2, \dots, n.$

Valore atteso
media campionaria

$$E[\bar{X}(n)] = \frac{1}{n} E\left[\sum_{i=1}^n X_i\right] = \frac{1}{n} \sum_{i=1}^n E[X_i] = \frac{n \cdot \mu}{n} = \mu$$

⇒ $\bar{X}(n)$ e' uno stimatore corretto di μ

se calcolassi la media di tutte le possibili medie campionarie che potrei ottenere da tutti i possibili campioni, otterrei esattamente il valore della media della popolazione.

media della
popolazione

poiché le osservazioni
sono indipendenti e
identicamente distribuite il
valore atteso della somma
è uguale alla somma dei
valori attesi

il valore atteso di ogni
singola osservazione
è pari alla media
della popolazione

$$E[\bar{X}(n)] = \frac{1}{n} (\mu + \mu + \dots + \mu) = \frac{1}{n} \cdot n \cdot \mu$$

Passando alla varianza della media campionaria e assumendo che le X_i siano INDIPENDENTI e con la stessa varianza: $\sigma_i^2 = \sigma^2 \forall i$

indica quanto le medie campionarie di diversi campioni estratti dalla stessa popolazione variano tra loro

$$\begin{aligned} Var[\bar{X}(n)] &= \frac{1}{n^2} E\left[\left(\sum_{i=1}^n X_i - E\left[\sum_{i=1}^n X_i\right]\right)^2\right] = \\ &\quad \text{quadrato della dimensione del campione} \end{aligned}$$

varianza "bassa" allora
stima più precisa

I passaggi algebrici
saranno mostrati in
una futura lezione!

= ...

$$= \frac{\sigma^2}{n}$$

⇒ $\bar{X}(n)$ stimatore di bontà crescente con "n"
la varianza della media campionaria

Tempo di Attesa in Coda		Modello analitico di riferimento		passo
Valore Atteso Calcolato	E[W]=p/(μ*(1-p))=	9.090909091		
Media su 3200 Osservazioni				
Tempo di Attesa in Coda	13,01393943	13,01393943		
Tempi di Soggiorno	Tempi di Attesa in Coda	Equazione di Lindley W _i		
0,866715914	0	0	Pearson	
1,784991261	0,747781	0,747781232	Correlazione	
3,11619316	1,666201	1,666201089	-0,152677476	-0,152677476
3,941814402	2,768559	2,7685587	-0,026784313	-0,008168125
4,124712027	3,940734	3,940734023	0,01868795	-0,026082237
3,986466977	2,870707	2,870706684	-0,023201384	-0,016934534
5,447764384	3,646809	3,646808598	0,002299292	-0,027880259
6,657270853	5,084018	5,084017765	12	5
6,344688281	5,697894	5,697894041	12	6
6,810749438	6,069567	6,069567018	13	6
9,005299662	6,451714	6,451713765	13	7
8,674615465	8,34441	8,34441015	15	8
6,565357375	6,204222	6,204221581	17	9
8,514319352	6,484953	6,484953303	17	10
9,209361204	7,892177	7,892177489	18	10
9,418595597	8,828227	8,8282226859	19	11
13,6058386	9,110253	9,110253218	21	13
14,35938563	10,881751	10,88175101	22	13
14,45397615	12,637669	12,63766868	22	14
14,93949357	13,834534	13,83453437	23	15
16,19357514	14,861348	14,86134778	25	16
15,73265041	15,634338	15,63433761	25	16
13,48894705	12,883335	12,88333515	21	21
14,12720376	13,201712	13,20171246	22	22
13,66876378	13,427744	13,42774401	23	23
11,46984841	11,270848	11,2708477	24	24
9,439901216	9,438621	9,438620721	25	25
10,36663458	9,279446	9,279446072	26	26
10,87855175	9,748204	9,748203972	27	27
11,22180258	7,919041	7,919040612	28	28
12,07879412	10,84444	10,84443974	29	29
12,31984311	11,66901	11,66900972	30	30
	11,70210068	11,70210068	31	31
	11,70210068	11,70210068	32	32

Lindley: relazione ricorsiva tra il tempo di attesa del n-esimo e il tempo del (n-i)-esimo. Ad esempio relazione tra tempo di attesa della 10° persona (ultima) che attende il servizio e della 9°

Calcolo i tempi di attesa mediante l'equazione di Lindley :

tempo d'attesa i-esimo + tempo servizio i-esimo - interarrivo i+1-esimo

I tempi di soggiorno sono variabili aleatorie, il primo valore coincide con il servizio. Immagino al sequenza temporale di soggiorno (X₁, X₂...X_n), le X sarebbero le realizzazioni dei tempi di soggiorno a partire dal primo. Esempio: ogni mattina vado alla posta a vedere quanto tempo aspetta la terza persona in fila. Il terzo di ogni mattina rappresenta un campione, dunque soggiorno della terza persona.

per ogni variabile aleatoria viene generata una realizzazione indipendente corrispondente ogni volta che si fa un run

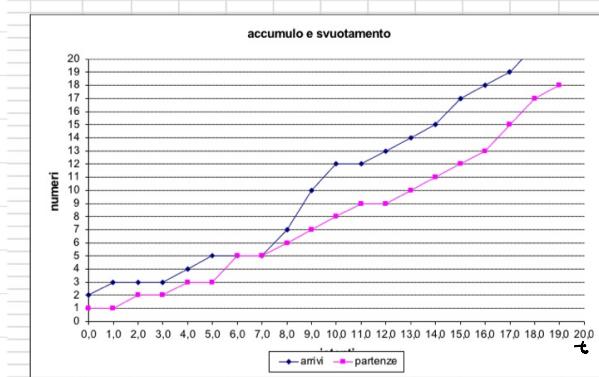
- Potrebbe servire la statistica? La realizzazione di S3 rispetto a quella di S5 è indipendente? O meglio, la sequenza dell'uscita del sistema di osservazioni è indipendente? Gli input per ipotesi sono indipendenti. La realizzazione di S5 è correlata a quella di S3. Le due realizzazioni sono identicamente distribuite? Concetto di stazionarietà (un qualcosa poi non cambia più)

se dovessi studiare questo sistema, spero che per $n \rightarrow \infty$ ci sarà una sola variabile aleatoria, ossia "soggiorno n-esimo", dopo 1000 o più realizzazioni (a lungo termine) diventerà una sola realizzazione. "Ne studio uno ed è come se li studiassi tutti"

- Come stimo la varianza? Se implemento la varianza campionaria sorge il problema della indipendenza e della correlazione (che si vedrà in futuro)

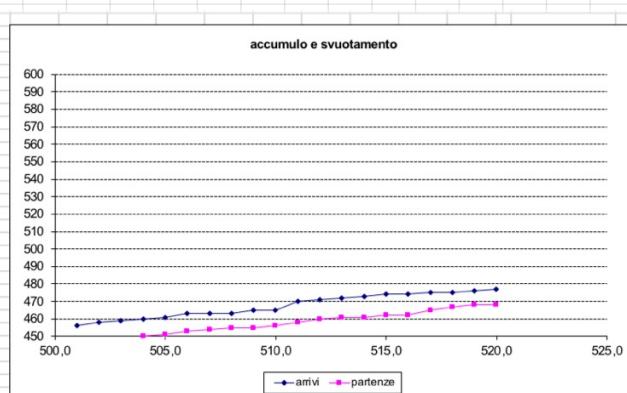
- Mi focalizzo sul tempo di attesa in coda (è una media aritmetica). Se clicco sulla sua casella mi rendo conto che salto da circa 10 a circa 5 con una "pigiata", quindi che varianza c'è? Come la stimo? Che "fiducia" posso dare a quel valore? Nascono le stime intervallari (intervallo di confidenza). Esse vengono utilizzate per stimare delle prestazioni. Per esempio ad un indice di prestazione (variabile aleatoria) come il tempo di risposta, quale valore atteso minimo "posso chiedere"?

Simulazione Monte Carlo: riproduco la storia degli stati. Di segui le traiettorie che rappresentano arrivi e partenze:



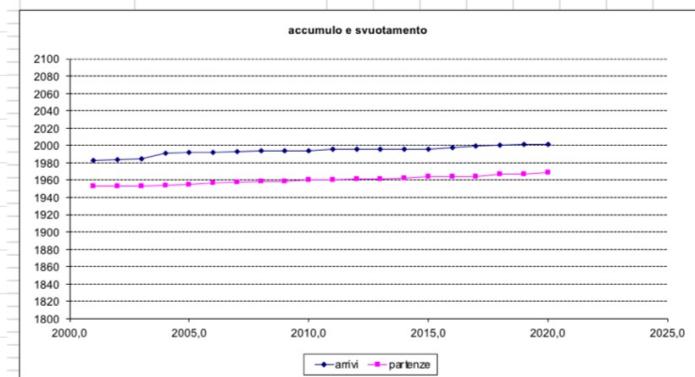
$0 \leq t \leq 20$ (inizio)

Simulo la traiettoria del processo stocastico degli arrivi e quello delle partenze. Inizialmente, non posso sapere se il sistema è congestionato o no



$500 \leq t \leq 525$ (metà)

Osservo il sistema a lungo termine



$2000 \leq t \leq 2025$ (verso la fine)

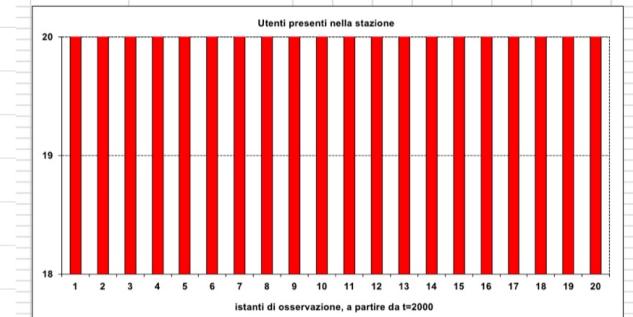
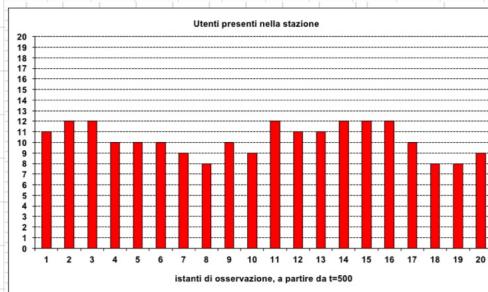
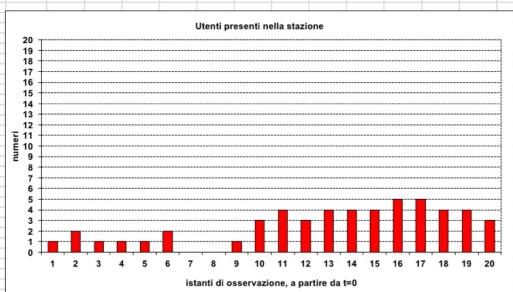
Quando il sistema arriva a regime il numero di arrivi e partenze tende a uguagliarsi

Arrivi (x_0, y_0) – Partenze(x_0, y_0) = numero di persone coinvolte

Tasso Interarrivi	1
Valore Atteso in Input	
Interarrivi ($1/\lambda$)	1
Media su 3200 Osservazioni	
Interarrivi	0.958853087

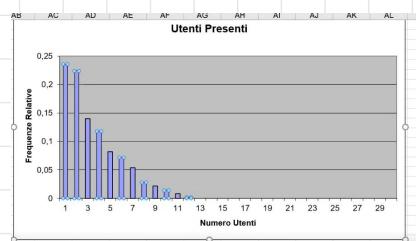
Tasso di Servizio	1,1
Valore Atteso in Input	
Ordine	FIFO
Tempo di Servizio ($1/\mu$)	0,909090909
Media su 3200 Osservazioni	
Tempo di Servizio	0,907979337

Tempi di Soggiorno	
Valore Atteso Calcolato	
$E[S]=1/[\mu*(1-p)] =$	10
Media su 3200 Osservazioni	
Tempi di Soggiorno	13,92191877



In questo caso, **TASSO DI SERVIZIO > TASSO INTERARRIVI**

→ 10% più veloce



Il grafico rappresenta proprio il modello geometrico di occupazione del buffer

Cosa accade se tasso di servizio<tasso interarrivi? Cosa accade se se tasso di servizio=tasso interarrivi? Cosa accade se tasso di servizio>>tasso interarrivi? Da notare che con un tasso 10% più alto di quello degli interarrivi, il sistema comunque tende a congestionarsi.

A lungo andare se non "chiudo" il sistema ci sarà solo congestione

Il TLC per la “media campionaria”

Nell’analisi statistica del modello PRODUTTORE - CONSUMATORE, è assai utile poter assumere che una realizzazione della media campionaria corrisponda alla media aritmetica di una sequenza di realizzazioni indipendenti della stessa variabile aleatoria, X , magari rilevate con osservazioni sperimentali, indipendenti (runs del Metodo Monte Carlo).

Infatti, particolarizzando il teorema limite centrale a questo caso, risulta:

in giallo sarebbe la standardizzazione della media campionaria $\tilde{Z}_n = \frac{\bar{X}(n) - E[\bar{X}(n)]}{\sqrt{VAR[\bar{X}(n)]}} = \frac{\bar{X}(n) - \mu}{\sqrt{\sigma^2 / n}}$ ricordando che il TCL riguarda la somma di variabili aleatorie.

che tende alla normale standard per $n \rightarrow \infty$ e, di conseguenza:

$$\bar{X}(n) = \frac{\sigma}{\sqrt{n}} \tilde{Z}_n + \mu \quad \text{tende ad essere distribuita come una legge normale di media } \mu \text{ e varianza } \sigma^2/n \text{ al crescere di } n$$

deviazione standard

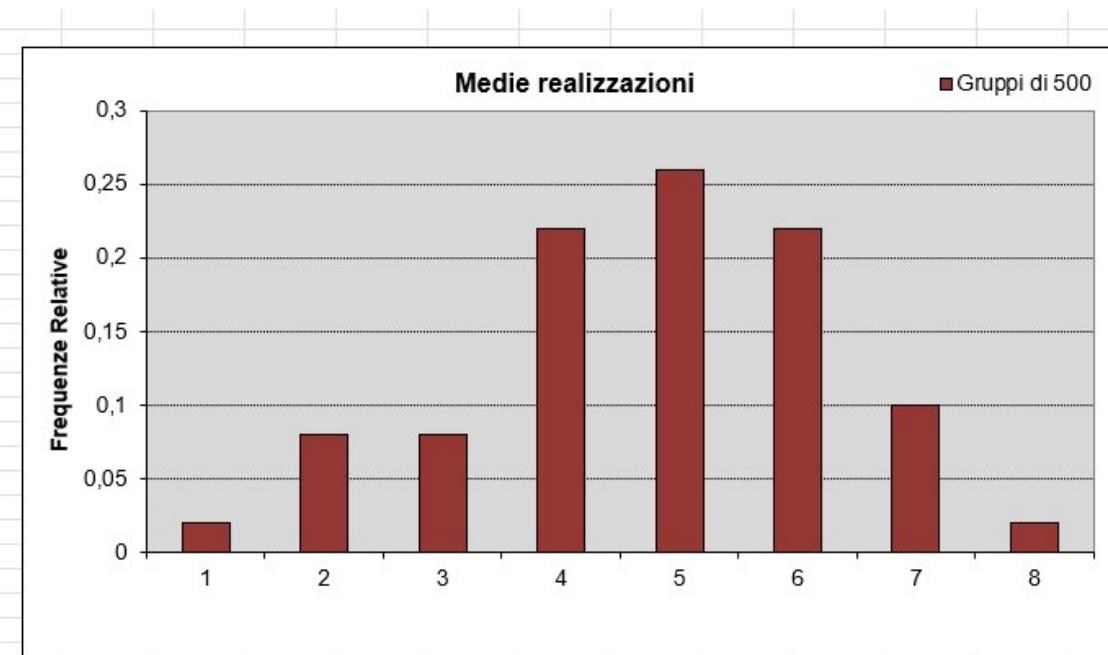
In particolare, si verifica sperimentalmente che la forma della $\bar{X}(n)$ diventa approssimabile ai fini pratici con la forma normale per $n > 30$

Per il modello produttore consumatore

Sperimentalmente aprodo il foglio excel: normalità della media campionaria si verifica il teorema del limite centrale

TESI:
La media campionaria tende a essere distribuita come una gaussiana centrata sul valore medio della legge esponenziale

Attraverso le generazioni Montecarlo, l'obiettivo di tale esperimento è stato quello di cercare di convalidare il teorema del limite centrale. Nella pratica, aumentando le n (dimensione del campione) ho cercato di approssimare fedelmente la "campana di Gauss". Con un numero di medie campionarie pari a 200 e poi ancora più con un numero di campioni pari 500, riesco a verificare sperimentalmente il suddetto teorema, ottenendo nelle varie simulazioni, sempre risultati più o meno attendibili. Ovviamente per campioni sempre maggiori l'attendibilità del teorema risulterà ancora più evidente.



Appunto più sale il gruppo di medie più si tende alla gaussiana. Oppure si poteva salire con il numero di realizzazioni!

La media di medie è detta grande media, il cui valore atteso della grande media è pari alla somma tra il valore atteso delle singole medie.

L'intervallo di confidenza per la media (valore atteso)

Siano X_1, X_2, \dots, X_n variabili aleatorie tutte indipendenti e identicamente distribuite

$\approx N(\mu, \sigma^2)$, allora:

$$\bar{X}(n) \hat{=} \frac{\sum_{i=1}^n X_i}{n} \approx N\left(\mu, \frac{\sigma^2}{n}\right)$$

Ricorda che il valore atteso non è una media di per sé, ma perché la media aritmetica lo stima!

per il “teorema di riproducibilità” della normale.

Rammentando che: (grazie all'indipendenza)

$$Z \hat{=} \frac{\bar{X}(n) - \mu}{\sigma / \sqrt{n}} \approx N(0,1) \quad \leftarrow$$

se inserisco S (deviazione della var. camp.) al posto della deviazione standard σ ottengo un rapporto tra variabili aleatorie e perciò una nuova variabile aleatoria

e che:

$$\Pr_{\text{quantile}}[-z_{\alpha/2} \leq Z \leq z_{\alpha/2}] = 1 - \alpha \quad \leftarrow$$

dove:

$$\alpha/2 = \int_{-\infty}^{z_{\alpha/2}} f_Z(z) dz = \int_{z_{\alpha/2}}^{+\infty} f_Z(z) dz$$

si ottiene: (isolando μ)

$$\Pr\left[\bar{X} - \frac{\sigma}{\sqrt{n}} z_{\alpha/2} \leq \mu \leq \bar{X} + \frac{\sigma}{\sqrt{n}} z_{\alpha/2}\right] = 1 - \alpha$$

significa:
probabilità che la realizzazione di Z sia compresa tra i quantili è abbastanza vicino a 1

In pratica, è stato stabilito che l'intervalle aleatorio:

$$\left[\bar{X} - \frac{\sigma}{\sqrt{n}} z_{\alpha/2}, \bar{X} + \frac{\sigma}{\sqrt{n}} z_{\alpha/2} \right]$$

(IC) Da notare che l'intervalle è simmetrico!

contiene, con probabilità $1 - \alpha$, il valore (incognito) del parametro .

Ogni realizzazione (intervallo numerico) di (IC) può essere considerata una stima di , ma non si può dire che essa contiene e tanto meno che il valore corrispondente a è il centro dell'intervalle: ogni punto dell'intervalle ha la stessa probabilità di essere .

(IC) è detto intervallo di confidenza al $100(1 - \alpha)\%$ (livello di confidenza).

Infine, posto $d \hat{=} z_{\alpha/2} \sigma / \sqrt{n}$, si tenga presente che la numerosità (n) del campione richiesto per stimare con un intervallo di ampiezza $2d$ risulta:

$$n = \frac{(z_{\alpha/2})^2 \sigma^2}{d^2}$$

Per progettare un intervallo di confidenza serve un parametro ed una statistica

OSSERVAZIONE: Per ottenere una realizzazione dell'intervallo di confidenza sulla media del processo, occorre una stima della varianza del processo!

Importanza dell'intervallo di confidenza:

- introduce l'idea di stimare un parametro non più attraverso la realizzazione di una variabile aleatoria, bensì attraverso la realizzazione di un intervallo aleatorio che contiene, con la probabilità voluta, il parametro stesso.

L'intervallo però non deve essere né troppo grande né troppo piccolo.

Qualità dell' intervallo:

- fissato il livello di confidenza, $100(1-\alpha)\%$, e con una certa deviazione standard (σ), intervalli migliori (cioè più ristretti) possono essere ottenuti solo aumentando di parecchio la numerosità (n) del campione.

Problemi d'uso:

- La stima per intervallo di un parametro del 1° ordine, quale la “media”, richiederebbe la conoscenza di un parametro del 2° ordine, quale la “deviazione standard”.
- Sembrerebbe valido solo nell'ipotesi che il parametro-media da stimare sia quello di una legge normale.

Soluzione dei problemi:

- Si può usare la varianza campionaria al posto della varianza vera e, sfruttando il teorema limite centrale, si può dimostrare che:

$$\Pr\left[\bar{X} - \frac{S}{\sqrt{n}} z_{\alpha/2} \leq \bar{X} \leq \bar{X} + \frac{S}{\sqrt{n}} z_{\alpha/2}\right] \cong 1 - \alpha \quad \text{per } n \rightarrow \infty$$

quando manca l'ipotesi di normalità delle variabili i.i.d. X_1, X_2, \dots, X_n .

L'intervallo: $\left[\bar{X} - \frac{S}{\sqrt{n}} z_{\alpha/2}, \bar{X} + \frac{S}{\sqrt{n}} z_{\alpha/2}\right]$ è considerato una buona approssimazione dell'intervallo vero già con $n \geq 30$.

NOTA:

Nella pratica si usa fissare il livello di confidenza al 90% o 95% a ciò corrisponde: $\alpha = 0.10$ $\alpha = 0.05$ $z_{\frac{\alpha}{2}} = 1.645$ $z_{\frac{\alpha}{2}} = 1.960$

La statistica “varianza campionaria” 1(2)

Siano X_1, X_2, \dots, X_n I.I.D. $E[X_i]$ è il valore atteso della popolazione da cui è estratto il campione

con: $E[X_i] \hat{=} \mu, \quad Var[X_i] \hat{=} \sigma^2, \quad i = 1, \dots, n$

DA: $\sum_{i=1}^n (X_i - \bar{X})^2 = \sum_{i=1}^n (X_i - \mu)^2 - n(\bar{X} - \mu)^2 \quad (\bar{X} \hat{=} \frac{1}{n} \sum_{i=1}^n X_i)$

SI OTTIENE: $E \left[\sum_{i=1}^n (X_i - \bar{X})^2 \right] = (n-1)\sigma^2$

I passaggi algebrici sono stati indicati nella dispensa del corso, parte II, “Analisi Statistica”, pag. 24 e 25, ma NON fanno parte del programma di esame!

Si userà come stima della varianza S al posto di sigma

IN CONCLUSIONE: $E \left[\frac{1}{(n-1)} \sum_{k=1}^n (X_k - \bar{X})^2 \right] = \sigma^2$

“n-1” e non “n” perchè per ottenere una stima più accurata della varianza usiamo un “aggiustamento statistico”

se calcolo la varianza campionaria su molti campioni diversi le media di questa varianza campionaria si avvicinerebbe sempre di più alla vera varianza della popolazione

NON SI TRATTA DI GAUSS

Osservazione: La varianza campionaria è la stima puntuale della varianza.

Nella parentesi quadrata c’è uno stimatore corretto del parametro varianza, cioè la statistica “varianza campionaria”!

Formula alternativa usata in Excel per esprimere lo stimatore della varianza

https://www2.isye.gatech.edu/people/faculty/David_Goldsman/

$$\begin{aligned} S^2 &= \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n - 1} \\ &= \frac{\sum_{i=1}^n (X_i^2 - 2\bar{X}X_i + \bar{X}^2)}{n - 1} \\ &= \frac{\sum_{i=1}^n X_i^2 - 2\bar{X} \sum_{i=1}^n X_i + n\bar{X}^2}{n - 1} \\ &= \frac{\sum_{i=1}^n X_i^2 - 2n\bar{X}^2 + n\bar{X}^2}{n - 1} \\ &= \frac{\sum_{i=1}^n X_i^2 - n\bar{X}^2}{n - 1} \end{aligned}$$

La statistica “varianza campionaria” 2(2)

In base al precedente risultato, la variabile aleatoria:

$$S^2 \triangleq \frac{1}{(n-1)} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{\sum_{i=1}^n X_i^2 - n\bar{X}^2}{n-1}$$

è detta “varianza campionaria” e viene usata per “stimare” “puntualmente” il parametro σ^2 grazie alla seguente (che non dimostreremo):

$$Var[S^2] = \frac{2\sigma^4}{n-1} \xrightarrow{n \rightarrow \infty} 0 \quad \text{per } n \rightarrow \infty$$

quadrato della varianza!

Osservazione:

Lo stimatore corretto del parametro varianza migliora al crescere di “n” (perché si riduce la sua varianza)

Però, purtroppo, ~~questo stimatore ha una varianza sua che è pari al quadrato della varianza che deve stimare!~~

La distribuzione chi-quadrato

è una particolare Gamma ricordalo!

Come si è già detto, la distribuzione gamma, ha dato vita ad una particolare distribuzioni, dette chi-quadrato. Andiamo adesso a caratterizzarne la densità della variabile aleatoria chi-square. Considerando una variabile aleatoria X_γ^2 , detta chi-square la densità della chi-square è pari a:

$$f_X(x) = \frac{1}{\Gamma(\gamma/2)2^{\gamma/2}} x^{\frac{\gamma}{2}-1} e^{-\frac{x}{2}} \text{ con } x \geq 0$$

con $X \equiv X_\gamma^2 \equiv x_\gamma^2$ con γ "gradi di libertà". Su Excel la densità gamma è pari a:

$$f_X(x) = \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-\frac{x}{\beta}} \text{ con } \beta = \frac{1}{\lambda} \quad \text{dunque è una gamma con: } \beta = 2 \alpha = \frac{\gamma}{2} \gamma \in [1, 2 \dots n]$$

x_γ^2 individua il punto della semiretta reale a partire dal quale l'area sottesa della densità è proprio γ , ovvero $Pr[X_\gamma^2 \geq x_\gamma^2] = \gamma$ (N.B. sta definizione nel powerpoint non c'è)

Si ricava che la media è la varianza sono pari a rispettivamente a: $E[X] = \gamma$ $Var[X] = 2 \cdot \gamma$

In particolare i gradi di libertà coincidono con il valore atteso. Si vuole dimostrare il seguente teorema: la variabile aleatoria "chi-quadrato" con 1 grado di libertà corrisponde al quadrato della "normale standard".

$$F_{Z^2}(z) \hat{=} \Pr\{Z^2 \leq z\} = \Pr\{-\sqrt{z} \leq Z \leq \sqrt{z}\} \quad \text{Sarebbe la dimostrazione di Trivedi}$$

$$= F_Z(\sqrt{z}) - F_Z(-\sqrt{z}) = 2 \int_0^{\sqrt{z}} \frac{1}{\sqrt{2\pi}} \cdot \exp(-u^2/2) \cdot du$$

$$= 2 \int_0^{\sqrt{z}} \left(1/\Gamma(1/2)\sqrt{2}\right) \cdot \exp(-u^2/2) \cdot du$$

$$\left(\text{con } u \hat{=} \sqrt{v} \Rightarrow du = v^{-1/2} \cdot dv = v^{1/2-1} \cdot dv \right)$$

$$= \int_0^z \left(1/\Gamma(1/2)2^{1/2}\right) \cdot v^{1/2-1} \cdot \exp(-v/2) \cdot dv \quad \text{Ricordando che:}$$

$$f_{x_\gamma^2}(x) = \left(\frac{1}{\Gamma(\frac{\gamma}{2})}2^{\frac{\gamma}{2}}\right) \cdot x^{\frac{\gamma}{2}-1} \cdot e^{-\frac{x}{2}} \implies F_{x_\gamma^2}(z) = F_{Z^2}(z)$$

Teorema di riproducibilità della legge chi-quadrato (non dimostrato)

Siano: $X_{\gamma_1}^2, X_{\gamma_2}^2 \dots X_{\gamma_n}^2$ indipendenti, con i rispettivi gradi di libertà: $\gamma_1^2, \gamma_2^2 \dots \gamma_n^2$ allora:

$X_{\gamma_1}^2 + X_{\gamma_2}^2 + \dots + X_{\gamma_n}^2$ è ancora una chi-quadrato, con gradi di libertà pari a: $\gamma_1, \gamma_2 \dots \gamma_n$

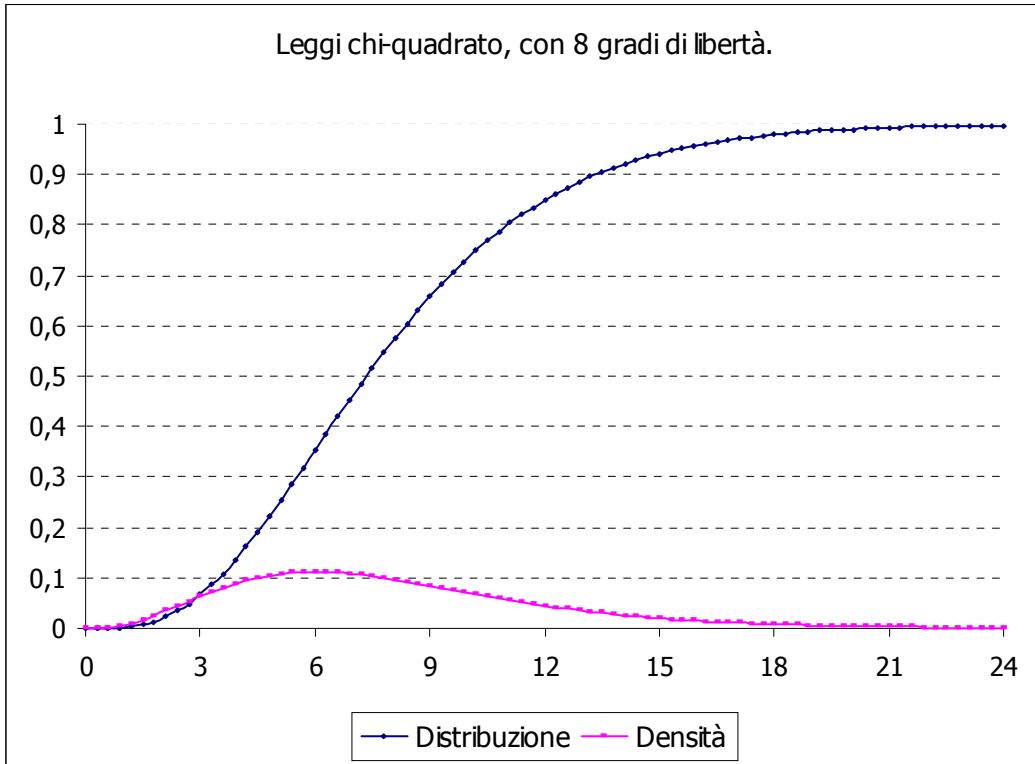
Attraverso le trasformate di Laplace ed al prodotto di convoluzione si prova il teorema.

IMPORTANZA: per "stimare" la varianza e la forma di una distribuzione, a partire da un insieme di realizzazioni sperimentali.

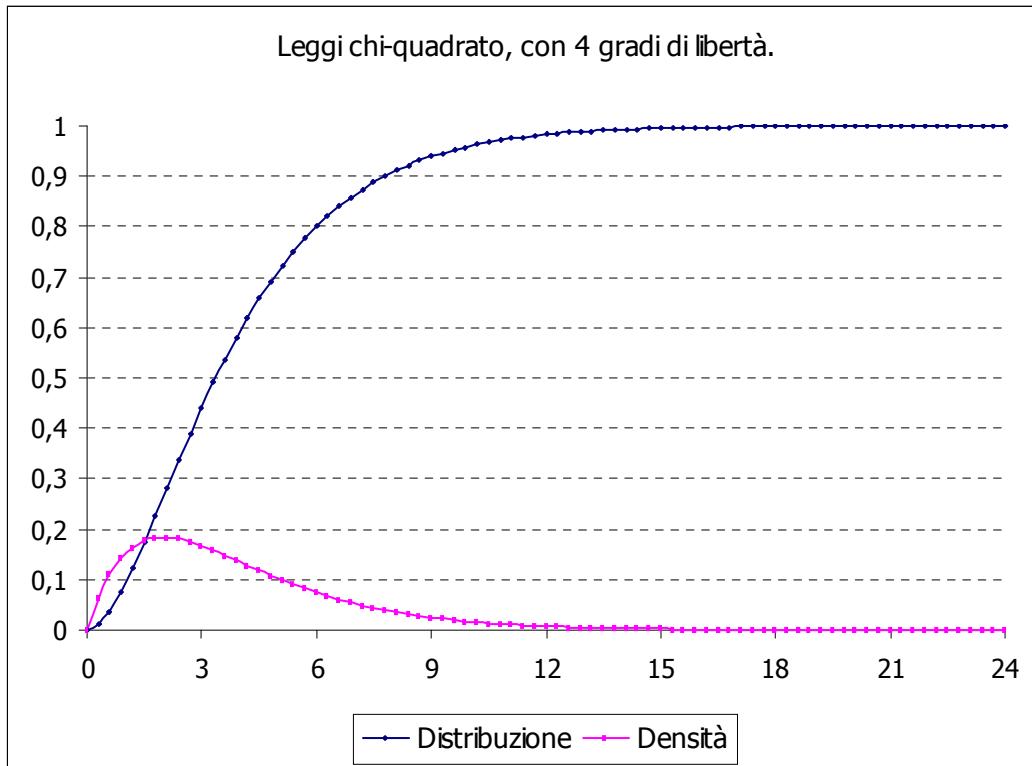
In parole povere il teorema afferma che la somma di chi-quadrato è ancora una chi-quadrato dove i gradi di libertà si sommano. Come detto è importante per "stimare" la varianza e la bontà della forma. (Si vedrà in futuro)(Test sulla forma con chi-square)

Bisognerebbe separare il grafico,
ad esempio il punto di intersezione
non si capisce ed una curva "sovrastra"
l'altra

Rappresentazione della chi-quadrato



da notare anche che non c'è nessun valore negativo. la chi-square è solo positiva!



N.B. più aumentano i gradi di libertà più la chi-quadrato tende in forma ad una normale.
Vedi EXCEL

L'intervallo di confidenza per la varianza

Ripensando al ragionamento che ha condotto a “scoprire” un intervallo stimatore (detto, poi, intervallo di confidenza) per il parametro σ^2 , si dovrebbe riconoscere che è stata fondamentale la disponibilità di una variabile aleatoria di distribuzione nota che conteneva quel parametro:

$$Z \triangleq \frac{\bar{X} - \mu}{\sigma / \sqrt{n}} \approx N(0,1)$$

Dunque, volendo insistere su una strada analoga per individuare un intervallo di confidenza per un altro parametro importante quale la varianza, si deve cercare un'altra variabile aleatoria di distribuzione nota che contenga il parametro varianza e, se possibile, priva di ulteriori parametri che potrebbero creare complicazioni nell'uso pratico dell'intervallo, perché incogniti. Nel linguaggio degli statistici, si direbbe che si sta cercando una “statistica”, cioè una variabile aleatoria capace di produrre una stima.

Col seguente teorema si trova la statistica per la varianza:

Teorema (nascita della chi-square) Stessa ipotesi della media campionaria

Siano X_1, X_2, \dots, X_n indipendenti e identicamente distribuite $\approx N(\mu, \sigma^2)$, allora:

$$\text{statistica} \rightarrow \frac{(n-1)S^2}{\sigma^2} = \frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \bar{X})^2 = \chi^2_{\gamma=n-1} \quad (\text{Tesi}) \quad \begin{array}{l} \text{ricordando la varianza campionaria} \\ S^2 = \frac{1}{(n-1)} \sum_{i=1}^n (X_i - \bar{X})^2 \end{array}$$

La statistica è: $(n-1)S^2 / \sigma^2$. Infatti, grazie al teorema, si può scrivere:

$$\Pr[\chi^2_{1-\alpha/2} \leq (n-1)S^2 / \sigma^2 \leq \chi^2_{\alpha/2}] = 1 - \alpha \quad \begin{array}{l} \text{ricorda che } S \text{ è la} \\ \text{stima della varianza} \end{array}$$

da cui: probabilità che la realizzazione della statistica cada nell'intervallo/quantili
isolando sigma

$$\Pr\left[\frac{(n-1)S^2}{\chi^2_{\alpha/2}} \leq \sigma^2 \leq \frac{(n-1)S^2}{\chi^2_{1-\alpha/2}}\right] = 1 - \alpha$$

Quindi,

$$\left[\frac{(n-1)S^2}{\chi^2_{\alpha/2}}, \frac{(n-1)S^2}{\chi^2_{1-\alpha/2}} \right]$$

è l'intervallo di confidenza al $100(1-\alpha)\%$ per σ^2 .

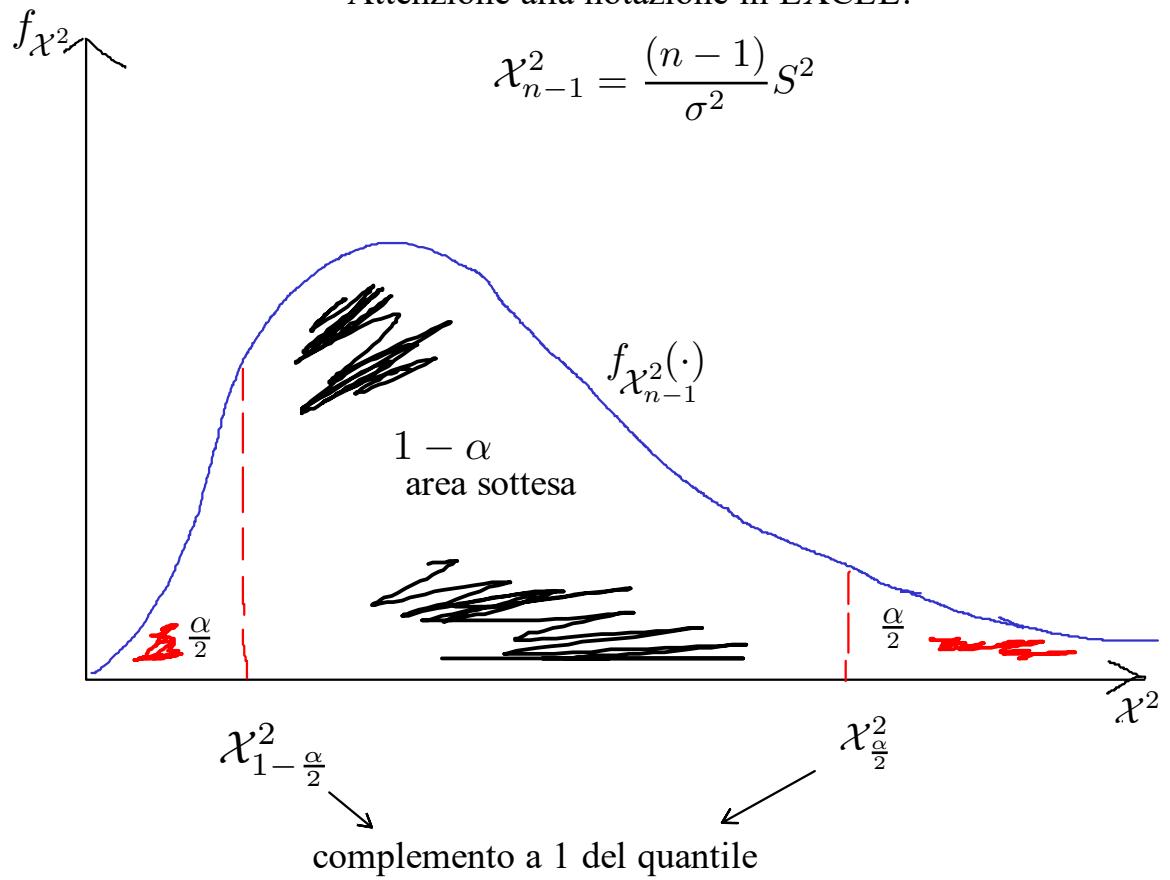
Da notare che in particolare gli intervalli di confidenza sulla varianza a differenza di quelli sulla media campionaria, escono "larghi" già in partenza. Si possono stringere quanto si vuole ma resteranno comunque "larghi". Vedi file Excel

INOLTRE NON SONO SIMMETRICI COME NEL CASO DELLA MEDIA CAMPIONARIA
basta guarda i due denominatori dell'intervallo.

Attenzione alla notazione in EXCEL:

$$\chi_{n-1}^2 = \frac{(n-1)}{\sigma^2} S^2$$

In rosso si ha l'area pari a $\frac{\alpha}{2}$



$\chi_{\frac{\alpha}{2}}^2$ sarebbe l'area che si lascia a destra
ovvero il complemento del quantile

Relazione base per la dimostrazione della tesi

$$\frac{(n-1)S^2}{\sigma^2} = \sum_{i=1}^n \left(\frac{X_i - \mu}{\sigma} \right)^2 - \left(\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \right)^2$$

$$\begin{aligned}\frac{(n-1)S^2}{\sigma^2} &= \frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{1}{\sigma^2} \sum_{i=1}^n [(X_i - \mu) - (\bar{X} - \mu)]^2 \\ &= \frac{1}{\sigma^2} \left[\sum_{i=1}^n (X_i - \mu)^2 - 2(\bar{X} - \mu) \sum_{i=1}^n (X_i - \mu) + n \cdot (\bar{X} - \mu)^2 \right] \\ &= \frac{1}{\sigma^2} \left[\dots - 2(\bar{X} - \mu) \left(\sum_{i=1}^n X_i - n\mu \right) + \dots \right] \\ &= \frac{1}{\sigma^2} \left[\dots - 2n(\bar{X} - \mu)^2 + \dots \right] = \sum_{i=1}^n \left(\frac{X_i - \mu}{\sigma} \right)^2 - \left(\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \right)^2\end{aligned}$$

Completamento della dimostrazione

A partire dalla relazione base:

$$\frac{(n-1)S^2}{\sigma^2} = \sum_{i=1}^n \left(\frac{X_i - \mu}{\sigma} \right)^2 - \left(\frac{\bar{X} - \mu}{\sigma / \sqrt{n}} \right)^2 \quad (+)$$

Si sfruttano i seguenti:

Teorema 1:

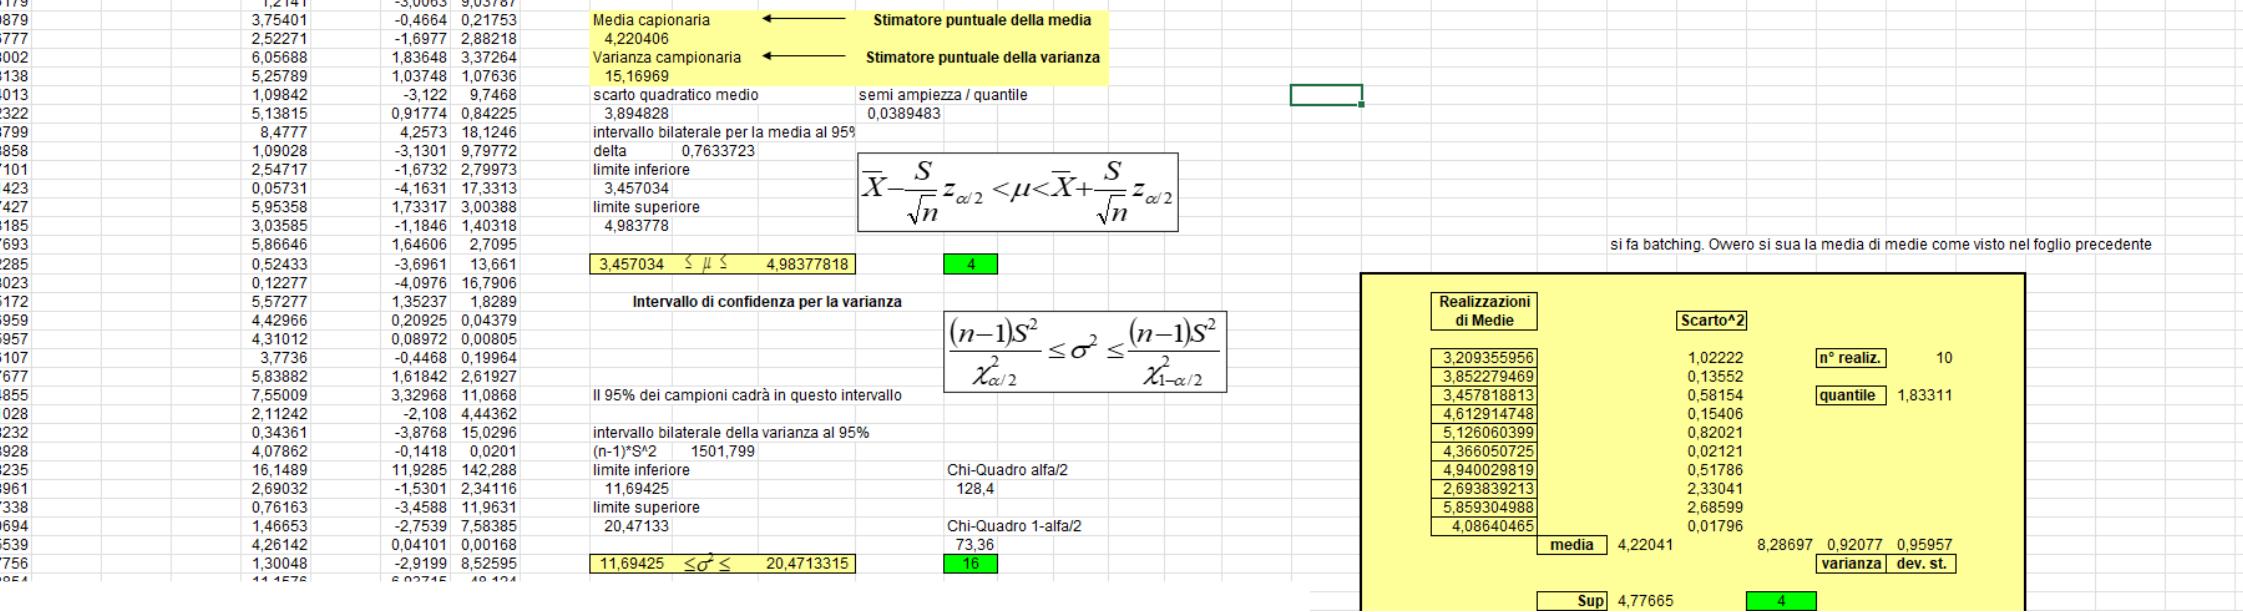
La variabile aleatoria “chi-quadrato” con “1” grado di libertà corrisponde al quadrato della “normale standard”.

Teorema 2:

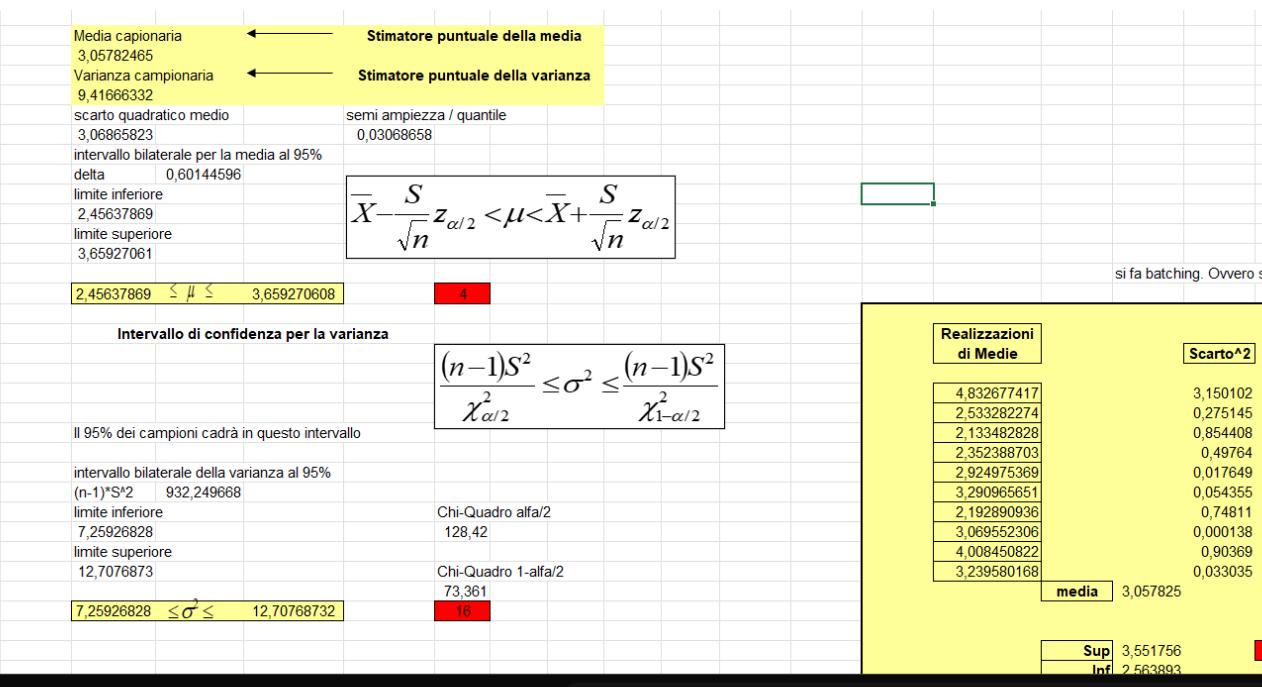
La somma di “n” variabili “chi-quadrato” con “1” grado di libertà corrisponde ad una “chi-quadrato” con “n” gradi di libertà.

Per interpretare la (+)
alla seguente maniera:

$$X_{\gamma=n-1}^2 = X_{\gamma=n}^2 - X_1^2$$



Nello screenshot si nota che gli intervalli sia per media che per varianza contengono il valore vero rispettivo. In particolare l'intervalllo per la media è sufficientemente largo, ma non simmetrico(!) dato il caso esponenziale. Mentre il caso della varianza è molto largo. Le stime sono uscite anche relativamente buone. Con un 4.22 a fronte di 4 e 15.19 a fronte di 16.



In questo altro caso invece, si hanno intervalli errati! Per la media si ha una stima di 3.05 a fronte di 4. ed un intervallo "stretto" di : 1.2 e spostato a sinistra del valore reale. Per la varianza si ha una stima di 9.4(!) a fronte di 16. L'intervalllo è largo 5.5 e spostato a destra del valore reale.

STIMATORI CORRETTI, ASINTOTICAMENTE CORRETTI E CONSISTENTI

-) X_1, \dots, X_n v. a. ind. e id. distr. con media μ e var σ^2

$$T(X_1, \dots, X_n) \hat{=} \frac{1}{n} \sum_{i=1}^n X_i \equiv \bar{X}(n) \equiv \bar{X}$$

si puo' omettere di indicare la dipendenza da "n" o "n-1"

$$T(X_1, \dots, X_n) \hat{=} \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 \equiv S^2(n-1) \equiv S^2$$

stimatore CORRETTO
varianza

per n grande il rapporto si semplifica.
quindi asintoticamente corretto

$$T(X_1, \dots, X_n) \hat{=} \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 \equiv S^2(n) = \frac{n-1}{n} S^2(n-1)$$

Quindi uno stimatore è asintoticamente corretto se per n tendente all'infinito risulta corretto

RISULTATI UTILI PER STABILIRE LE PROPRIETA'(o caratteristiche) DEGLI STIMATORI:

$$E[\bar{X}] = \mu, \quad VAR[\bar{X}] = \frac{\sigma^2}{n} \quad E[S^2] = \sigma^2, \quad VAR[S^2] = \frac{2\sigma^4}{n-1}$$

deviazione tra la stima e valore atteso

Lemma di Chebyshev:

$$\Pr \left\{ |T - \theta| \geq n \cdot \sqrt{Var[T]} \right\} \leq \left(1/n^2 \right)^{\text{di quante deviazioni ti allontani dalla deviazione standard?}}$$

n<1 non ha senso perché le prob. SONO 1

Probabilità che la deviazione sia maggiore di n volte della deviazione standard.

Lo stimatore $S^2(n-1)$ è corretto

Dimostrazione

$$T(X_1, \dots, X_n) \hat{=} \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 \equiv S^2(n-1) \equiv S^2$$

Mi gioco l'ipotesi che le variabili aleatorie sono indipendenti ed identicamente distribuite. Vale perciò che il valore atteso di una somma è pari alla somma dei valori attesi.

$$\begin{aligned}\mathbb{E}[S^2] &= \mathbb{E}\left[\frac{\sum_{i=1}^n X_i^2 - n\bar{X}^2}{n-1}\right] = \frac{\sum_{i=1}^n \mathbb{E}[X_i^2] - n\mathbb{E}[\bar{X}^2]}{n-1} \\ &= \frac{n}{n-1} \left(\mathbb{E}[X_1^2] - \mathbb{E}[\bar{X}^2] \right) \quad \text{si usa: } VAR[X] = E[X^2] - E[X]^2 \\ &= \frac{n}{n-1} \left(\text{Var}(X_1) + (\mathbb{E}[X_1])^2 - \text{Var}(\bar{X}) - (\mathbb{E}[\bar{X}])^2 \right) \\ &= \frac{n}{n-1} (\sigma^2 - \sigma^2/n) = \sigma^2. \quad \text{Done.}\end{aligned}$$

Risultato fondamentale sull' errore quadratico medio

$MSE \doteq E[(T(X_1, \dots, X_n) - \theta)^2]$ è l'**errore quadratico medio**

ALLORA RISULTA:

$$MSE(T(\mathbf{X})) = E[T^2] - 2\theta E[T] + \theta^2$$

$$= E[T^2] - (E[T])^2 + (E[T])^2 - 2\theta E[T] + \theta^2$$

$$= \text{Var}(T) + \underbrace{(E[T] - \theta)^2}_{\substack{\text{intervallo più} \\ \text{largo o stretto}}}.$$

il bias sposta centro del intervallo ed è indotto dal casualità
Bias vista nell'intervallo di confidenza

Per il momento non fornisco alcun esempio di calcolo di MSE.

Mi limito a definire “stima puntuale” (del parametro θ) qualunque realizzazione della variabile aleatoria stimatore. Pertanto, maggiore è il MSE dello stimatore e più rischioso risulta affidarsi a quella stima.

Stimatori efficienti

conosciamo lo stimatore del valore atteso ovvero la media campionaria. Ma è il migliore stimatore?

Siano $T_1(X)$ e $T_2(X)$ due stimatori differenti dello stesso parametro θ . E siano valide le seguenti:

- 1) $T_1(X)$ e $T_2(X)$ sono entrambi non distorti per θ ; distorto se $MSE = E[T(X)] \neq \theta$
- 2) $Var [T_1(X)] \leq Var [T_2(X)]$, per ogni valore di θ ;
- 3) $Var [T_1(X)] < Var [T_2(X)]$, per qualche valore di θ ; per qualche valore è più preciso

Allora si dirà che $T_1(X)$ è stimatore più efficiente di $T_2(X)$ per θ

ESEMPIO: la media campionaria è lo stimatore più efficiente tra quelli definibili tramite una combinazione lineare delle X_1, \dots, X_n , di coefficienti a_1, \dots, a_n .

Infatti:

$$T(X_1, \dots, X_n) \triangleq \sum_{i=1}^n a_i X_i \Rightarrow Var \left[\sum_{i=1}^n a_i X_i \right] = \dots = \sum_{i=1}^n a_i^2 \sigma^2$$

essendo indipendenti

risolvendo il problema di ricerca operativa, si dimostra che la media campionaria è lo stimatore più efficiente

Da qui:

$$\begin{cases} \text{MIN : } \sigma^2 \sum_{i=1}^n a_i^2 \\ \text{a}_1, \dots, \text{a}_n \\ \text{sub. to : } \sum_{i=1}^n a_i = 1, \end{cases}$$

$$\rightarrow \boxed{a_i = 1/n, \quad i = 1, \dots, n.}$$

Stimatore consistente: la distribuzione empirica

Sia n_x il numero di valori generati dal modello F

che cadono nell'intervallo $(0,x]$ e sia $\hat{F}_n(x) \triangleq n_x / n$.

Intervalli visti in Monte Carlo

Ebbene, la distribuzione empirica, \hat{F} ,
è uno stimatore consistente della distribuzione vera, F .

Osservando che un meccanismo bernoulliano è alla base del risultato
“numero di realizzazioni che cadono in un intervallo x ” e che la
corrispondente probabilità (di successo) è $p=F(x)$:

La distribuzione
empirica porta
ad uno stimatore consistente.

$$\hat{F}(x) \triangleq \frac{n_x}{n} = \frac{1}{n} \sum_{i=1}^n B_i \quad \begin{matrix} \text{binomiale} \\ \text{ovvero} \end{matrix} \quad \text{con } E[\bar{B}(n)] = np / n = p$$

0,1. cade o non cade nell'intervallo

Grazie al teorema di Bernoulli, caso particolare della LGN:

$$\lim_{n \rightarrow \infty} P(|\bar{B}(n) - E[\bar{B}(n)]| \geq \varepsilon) = 0 \quad \text{appunto DEFINIZIONE stimatore consistente}$$

Stimatore consistente se: $\lim_{n \rightarrow \infty} \Pr(|T(X_1, \dots, X_n) - \theta| \geq \varepsilon) = 0$

Ovvero, esprimendo il risultato in termini di F e di \hat{F}

$$\lim_{n \rightarrow \infty} P(|\hat{F}_n(x) - F(x)| \geq \varepsilon) = 0$$

$\hat{F}_n(x)$ sarebbe una famiglia di funzioni
che converge tutta in forma.

I parametri definiscono/caratterizzano il sistema. L'uscita non è un parametro

Stima di parametri di una distribuzione (in input)
con
Metodo dei momenti (equazioni)
e
Metodo della massima verosimiglianza
(problema di ricerca operativa)

Applicazione alle distribuzioni seguenti:

ESPONENZIALE, NORMALE,
IPERESPONENZIALE, di ERLANG,
di BERNOULLI, di POISSON e di WEIBULL

Ricordando che per Weibull i parametri ci fanno ricavare media e varianza

STIMA DEI PARAMETRI

IMPOSTAZIONE FREQUENTISTA

Le realizzazioni che formano il campione contengono tutta la informazione necessaria per fare inferenza sul VERO, UNICO e INCOGNITO valore del parametro di interesse diretto o indiretto perché vogliamo inferire alcune caratteristiche del fenomeno governato da quel parametro.

IMPOSTAZIONE BAYESIANA

Al parametro di interesse, incognito, viene attribuita un modello probabilistico iniziale, a prescindere dalle realizzazioni del campione, e del quale esso sarebbe una realizzazione. Il modello probabilistico iniziale è detto “modello a priori” e sarà aggiornato sulla base delle realizzazioni che formano il campione. Il modello aggiornato è detto “modello a posteriori”.

Ad esempio voglio calcolare il valore atteso in un modello che sembra un exp, allora modello a priori lo pongo appunto come exp.

DALLA FORMULA DI BAYES ALL'INFERENZA BAYESIANA

Ricordando Bayes

A è un evento di interesse e B_1, \dots, B_n sono eventi di probabilità nota

$$P(B_j | A) = \frac{P(B_j \cap A)}{P(A)} = \frac{P(A \cap B_j)}{P(A)}$$

B_1, \dots, B_n è una partizione di Ω

$$= \frac{P(A | B_j)P(B_j)}{\sum_{i=1}^n P(A | B_i)P(B_i)}$$

Problema:

Abbiamo un campione di realizzazioni indipendenti (D) di una variabile aleatoria che afferisce certamente ad un modello esistente in letteratura e caratterizzato dal parametro θ : vogliamo individuare questo parametro a partire da quei dati!

$$P(\theta | D) = \frac{P(D | \theta) \cdot P(\theta)}{\sum_{\substack{\text{possibili} \\ \text{valori di } \theta}} P(D | \theta) \cdot P(\theta)}$$

$P(\theta)$ è la prob. "a priori"
 $P(\theta | D)$ è la prob. "a posteriori"

$P(D | \theta)$ è detta
"Verosimiglianza di θ "

Il metodo dei momenti

*Siano X_1, X_2, \dots, X_n indip. e id. distr.
con μ^k momento di ordine "k", $k = 1, 2, \dots$*

Allora, pensando alla legge dei grandi numeri: (che vedremo)

$$\sum_{i=1}^n \frac{X_i}{n} \xrightarrow{\text{media campionaria converge al valore atteso come visto tramite monte carlo}} E[X_i] \hat{=} \mu, \quad \sum_{i=1}^n \frac{X_i^2}{n} \xrightarrow{} E[X_i^2] \hat{=} \mu_2, \quad \dots$$

Spesso è utile la seguente:

$$VAR[X_i] = E[X_i^2] - (E[X_i])^2$$

$$\Rightarrow \widetilde{S}^2 \hat{=} \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2 = \frac{\sum_{i=1}^n X_i^2 - n\bar{X}^2}{n} = \frac{n-1}{n} S^2$$

Il metodo dei momenti (MOM)

- Il MOM consiste nell'eguagliare i momenti di ordine $1, 2, \dots k$ ($m_1, m_2, \dots m_k$) con le corrispondenti formule di stima, **fino ad ottenere (non sempre facile!)** tante equazioni quanti sono i parametri incogniti:

$$\sum_{i=1}^n \frac{x_i^k}{n} = m_k, \quad k = 1, 2, \dots$$

momento di
ordine k momento k-esimo

- Per il modello esponenziale di parametro λ , siamo alla banalità!
perchè è $k=uno!$

$$\frac{1}{n} \sum_{i=1}^n x_i^1 = m_1 (= 1/\lambda) \Rightarrow \hat{\lambda} \equiv m_1 = n / \sum x_i$$

senza saperlo su Excel si stava attuando il metodo dei momenti

M O M per la distribuzione normale:

- **X₁, ..., X_n estratte da N(μ, σ²)**
- **2 parametri da stimare ⇒ sistema in 2 equazioni:**

$$\begin{cases} E(X) = \mu = \frac{1}{n} \sum_{i=1}^n X_i & (\hat{=} \bar{X}) \quad \text{momento primo ordine} \\ \\ E(X^2) = \mu^2 + \sigma^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 & \text{momento del secondo ordine} \end{cases}$$

appunto utilizzando: $VAR[X] = E[X^2] - E[X]^2$

- Dunque:

$$\hat{\mu} = \bar{X} \quad \text{e} \quad \hat{\sigma}^2 = \frac{n-1}{n} S^2$$

(stessi risultati
della stima MLE)

Es3: MOM per la distribuzione iperesponenziale

(vedi anche file Excel)

Il metodo di massima verosimiglianza per la iperesponenziale è complicato da attuare

- **Distribuzione iperesponenziale**

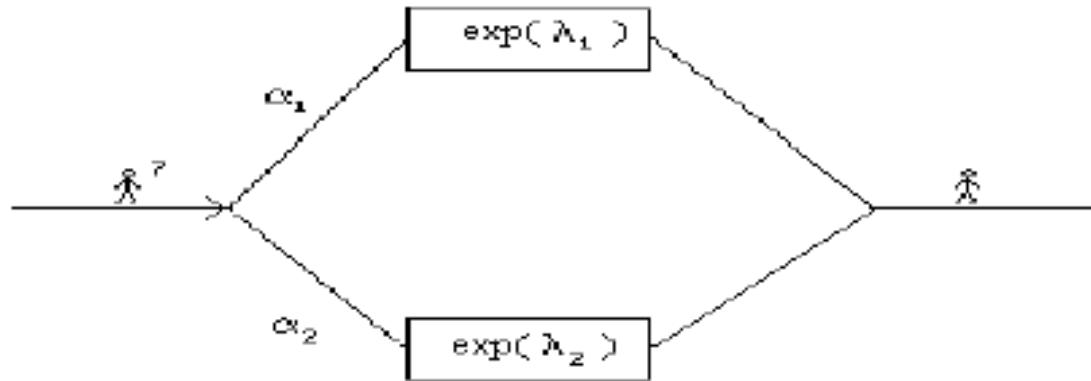
$$F_y(y) = \sum_{i=1}^n \alpha_i \left(1 - e^{-\lambda_i y}\right) \quad y \geq 0$$

parametri della distribuzione

- 3 parametri da stimare: $\alpha, \lambda_1, \lambda_2$. e non 2 banali

$$\alpha_1 = \alpha$$

$$\alpha_2 = 1 - \alpha$$



- In questo caso ci servirebbero i momenti del 1°, 2° e 3° ordine. Ma abbiamo a disposizione solo la media e la varianza campionaria (un livello di libertà!).
- Perciò si sceglie di impostare un'ulteriore condizione per rendere determinato il sistema:

$$\frac{1}{\lambda_1 + \lambda_2} = \frac{\frac{\alpha}{\lambda_1} + \frac{1-\alpha}{\lambda_2}}{2}$$

a questo punto sostituendo con gli stimatori di media e varianza

\bar{X} media c. $\frac{(n-1)}{n} S^2$ varianza campionaria

- momento del 1° ordine :

$$E[Y] = \sum_{i=1}^n \frac{\alpha_i}{\lambda_i} = \left(\frac{\alpha}{\lambda_1} + \frac{1-\alpha}{\lambda_2} \right)$$

probabilità totale
cioè valore atteso condizionato
da λ_1 e condizionato da λ_2

- Varianza:

$$VAR[Y] = E[Y^2] - E^2[Y]$$

- momento del 2° ordine :

$$E[Y^2] = \sum_{i=1}^n \frac{2\alpha_i}{\lambda_i^2} = 2 \left(\frac{\alpha}{\lambda_1^2} + \frac{1-\alpha}{\lambda_2^2} \right)$$

anche qui
probabilità totale

- Stimatore:

- 1° ordine : $M_1 \rightarrow \bar{X}$
- 2° ordine :

$$M_2 \rightarrow S^2 - E^2[Y]$$

nello svolgimento useremo
 S^2 e non $(n-1)S^2/n$

- Il nostro sistema di 3 equazioni in 3 incognite diventa perciò:

$$\left\{ \begin{array}{l} \frac{1}{\lambda_1 + \lambda_2} = \frac{\frac{\alpha}{\lambda_1} + \frac{1-\alpha}{\lambda_2}}{2} \quad \text{condizione aggiunta} \\ \\ \bar{X} = \frac{\alpha}{\lambda_1} + \frac{1-\alpha}{\lambda_2} \quad \text{media ottenuta} \\ \\ S^2 = 2 \left(\frac{\alpha}{\lambda_1^2} + \frac{1-\alpha}{\lambda_2^2} \right) - \left(\frac{\alpha}{\lambda_1} + \frac{1-\alpha}{\lambda_2} \right)^2 \quad \text{varianza ottenuta} \end{array} \right.$$

risoluzione che puoi "saltare"

- Osservando che il secondo membro della prima equazione è uguale a quello della seconda: $\lambda_1 = \frac{2}{\bar{X}} - \lambda_2$
- Dalla seconda equazione ricaviamo: $\hat{\alpha} = \frac{\lambda_1(\lambda_2 \bar{X} - 1)}{\lambda_2 - \lambda_1}$
- Sostituendo λ_1 : $\alpha = 1 - \frac{\lambda_2 \bar{X}}{2}$
- Osserviamo che :

$$\frac{\alpha}{\lambda_1} = \frac{1-\alpha}{\lambda_2} = \frac{\bar{X}}{2} \quad \frac{\alpha}{\lambda_1^2} = \frac{\bar{X}^2}{2(2 - \lambda_2 \bar{X})} \quad \frac{1-\alpha}{\lambda_2^2} = \frac{\bar{X}}{2\lambda_2}$$

- La terza equazione diventa:

$$S^2 = 2 \left(\frac{\bar{X}^2}{2(2 - \lambda_2 \bar{X})} + \frac{\bar{X}}{2\lambda_2} \right) - \left(\frac{\bar{X}}{2} + \frac{\bar{X}}{2} \right)^2$$

da cui:

$$\lambda_2(2 - \lambda_2 \bar{X}) = \frac{2\bar{X}}{S^2 + \bar{X}^2}$$

- Manipolando tale equazione giungiamo ad un'equazione di 2° grado in λ_2 ...

$$\lambda_2^2 \bar{X} (S^2 + \bar{X}^2) - 2\lambda_2 (S^2 + \bar{X}^2) + 2\bar{X} = 0$$

si arriva ad un problema di analisi numerica che si risolve

- ... che ammette come soluzioni:

$$\hat{\lambda}_2 = \frac{1}{\bar{X}} \pm \frac{1}{\bar{X}} \sqrt{\frac{(S^2 - \bar{X}^2)}{(S^2 + \bar{X}^2)}}$$

- Da cui: $\hat{\lambda}_1 = \frac{1}{\bar{X}} \mp \frac{1}{\bar{X}} \sqrt{\frac{(S^2 - \bar{X}^2)}{(S^2 + \bar{X}^2)}}$

(si suppone che $S^2 \geq \bar{X}^2$)

- Per completezza riscriviamo il terzo coefficiente:

$$\hat{\alpha} = \frac{\lambda_1(\lambda_2 \bar{X} - 1)}{\lambda_2 - \lambda_1}$$

Il metodo della massima verosimiglianza.

Consideriamo delle variabili casuali i.i.d. X_1, \dots, X_n con una funzione di densità $f(x)$.

Definiamo nel modo seguente la **funzione di verosimiglianza**:

$$L(\theta) \equiv f(X_1) \cdot f(X_2) \cdots f(X_n) = \prod_{i=1}^n f(X_i)$$

Poiché conosciamo le X_i , tale funzione ha come unica incognita il parametro (o i parametri) θ che si vuole valutare.

La stima di massima verosimiglianza (MLE) di θ è il valore di θ che massimizza la funzione di verosimiglianza, ponendo uguale a zero la sua derivata rispetto il parametro o nel caso di più parametri ponendo le derivate parziale rispetto ad ogni parametro. Se all'interno della funzione inserisco anche i differenziali: dx_1, dx_2, \dots, dx_n ottengo una produttoria tra probabilità. Quindi si mira a massimizzare la probabilità che le realizzazioni sono figlie della forma con il parametro incognito. Per facilitare la ricerca del massimo viene utilizzata la seguente funzione:

$$l(\theta) = \ln[L(\theta)]$$

che è nota come funzione di **verosimiglianza ridotta**.

I massimi restano sempre uguali ed essendo il logaritmo una funzione monotona è corretto l'uso della funzione di verosimiglianza ridotta. Si utilizza il logaritmo anche perché distribuzioni comuni sono espresse con esponenziali e prodotti.

Infatti come già detto per l'iperesponenziale, il logaritmo di una somma non facilita nulla mentre il logaritmo di prodotti esponenziali sì.

Per essere sicuri che θ sia un massimo, piuttosto che un minimo o un punto di flesso, la derivata di $l(\theta)$, valutata in θ deve essere negativa.

Es. 1: la densità esponenziale,

A partire da: $f_x(X) = \lambda e^{-\lambda x}$ ricocco λ

$$L(\theta) \hat{=} \prod_{i=1}^n f(x_i) = \prod_{i=1}^n \theta e^{-\theta x_i} = \theta^n e^{-\theta \sum_i x_i}$$

$$\ln [L(\theta)] = \ln \left[\theta^n e^{-\theta \sum_i x_i} \right] = n \ln \theta - \theta \sum_i x_i$$

$$\frac{d}{d\theta} l(\theta) = \frac{d}{d\theta} [n \ln \theta - \theta \sum_i x_i]$$

non è detto che i due metodi diano la stessa stima

$$= \frac{n}{\theta} - \sum_i x_i = 0 \Rightarrow \hat{\theta} = n / \sum_{i=1}^n x_i$$

Es. 2: la distribuzione normale

Ho 2 parametri da stima, valore atteso e varianza quindi andrò a risolvere le derivate parziali per ognuno.

$$L(\mu, \sigma^2) = \prod_{i=1}^n f(x_i)$$

$$= \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left\{-\frac{1}{2} \frac{(x_i - \mu)^2}{\sigma^2}\right\}$$

$$= \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\left\{-\frac{1}{2} \sum_{i=1}^n \frac{(x_i - \mu)^2}{\sigma^2}\right\}$$

- Stima del parametro μ

$$\ln(L(\mu, \sigma^2)) = -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln(\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2$$

$$\frac{\partial}{\partial \mu} \ln(L(\mu, \sigma^2)) = \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu) \equiv 0$$

$$\Rightarrow 0 = \sum_{i=1}^n (x_i - \mu) = \sum_{i=1}^n x_i - n\mu$$

$$\Rightarrow \mu = \frac{1}{n} \sum_{i=1}^n x_i$$

- Stima del parametro σ^2

$$\frac{\partial}{\partial \sigma^2} \ln(L(\mu, \sigma^2)) = -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^n (x_i - \hat{\mu})^2 \equiv 0$$

$$\Rightarrow -n\sigma^2 + \sum_{i=1}^n (x_i - \bar{x})^2 = 0$$

la stima qui risulta non distorta

$$\Rightarrow \widehat{\sigma^2} = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n} = \boxed{\frac{n-1}{n} S^2}$$

Es. 3: la ripartizione bernoulliana

Example: Suppose $X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Bern}(p)$. Find the MLE for p .

Useful trick for this problem: Since

$$X_i = \begin{cases} 1 & \text{w.p. } p \\ 0 & \text{w.p. } 1 - p \end{cases},$$

we can write the p.m.f. as

probability max function. perchè nel discreto non si usa la densità. noi la potremmo chiamare ripartizione massima di probabilità

$$f(x) = p^x(1-p)^{1-x}, \quad x = 0, 1.$$

La funzione di verosimiglianza per la legge bernoulliana:

$$L(p) = \prod_{i=1}^n f(x_i)$$

$$= \prod_{i=1}^n p^{x_i} (1-p)^{1-x_i}$$

$$= p^{\sum_{i=1}^n x_i} (1-p)^{n-\sum_{i=1}^n x_i}$$

ESPRIME LA PROBABILITA' DI OSSERVARE CONGIUNTAMENTE LE REALIZZAZIONI x_i , $i = 1, \dots, n$

Lo stimatore di massima verosimiglianza:

$$\ln(L(p)) = \sum_{i=1}^n x_i \ln(p) + (n - \sum_{i=1}^n x_i) \ln(1-p)$$

$$\frac{\partial}{\partial p} \ln(L(p)) = \frac{\sum_i x_i}{p} - \frac{n - \sum_i x_i}{1-p} \equiv 0.$$

derivata parziale perchè
ho $\ln(L(p))$

$$(1-p)\left(\sum_{i=1}^n x_i\right) - p\left(n - \sum_{i=1}^n x_i\right) = 0$$

andando ad isolare per ottenere lo stimatore di massima verosimiglianza, ottengo appunto la media campionaria

$$\sum_{i=1}^n x_i - pn = 0 \quad \Rightarrow \hat{p} = \frac{1}{n} \sum_{i=1}^n x_i$$

e ricordando che una binomiale converge ad una Gaussiana riusciamo a fare un intervallo di confidenza

Es. 4: la ripartizione poissoniana

Si parte dalla densità della Poissoniana per ricavare λ

$$L(\lambda) \doteq \prod_{i=1}^n \frac{\lambda^{x_i}}{x_i!} e^{-\lambda} = \frac{\lambda^{\sum x_i}}{x_1! x_2! \cdots x_n!} \cdot e^{-n\lambda}$$

$$\ln [L(\lambda)] = -\ln(x_1! x_2! \cdots x_n!) - n\lambda + \left(\sum_i x_i\right) \cdot \ln(\lambda)$$

$$\frac{d}{d\lambda} \ln[L(\lambda)] = -n + \frac{1}{\lambda} \sum_i x_i$$

$$\Rightarrow \hat{\lambda} = \frac{1}{n} \sum_{i=1}^n x_i$$

Es. 5: la distribuzione di Weibull

Weibull di Trivedi e non di EXCEL

$$L(\lambda, \alpha) = \prod_{i=1}^n f(x_i) = \prod_{i=1}^n \lambda \alpha \cdot {x_i}^{\alpha-1} \cdot e^{-\lambda {x_i}^\alpha}$$

$$= \lambda^n \alpha^n \cdot \left(\prod_{i=1}^n x_i \right)^{\alpha-1} \cdot e^{-\lambda \sum_{i=1}^n {x_i}^\alpha}$$

$$\ln L(\lambda, \alpha) = n \ln \lambda + n \ln \alpha + (\alpha - 1) \sum_{i=1}^n \ln x_i - \lambda \sum_{i=1}^n {x_i}^\alpha$$

altro problema di analisi numerica

$$\left\{ \begin{array}{l} \frac{n}{\lambda} - \sum_{i=1}^n {x_i}^\alpha = 0 \\ \frac{n}{\alpha} + \sum_{i=1}^n \ln x_i - \lambda \sum_{i=1}^n {x_i}^\alpha \ln x_i = 0 \end{array} \right.$$

Se cerco di massimizzare i parametri lambda e alpha, ottengo un sistema che non ha un'unica soluzione, cioè non vi sono soluzioni in forma chiusa.

Appunto

- Non esistono soluzioni in forma chiusa per λ ed α .
Comunque si può scrivere λ in funzione di α . per risolvere il problema

formula per stimare
lambda

$$\hat{\lambda} = \frac{n}{\sum_{i=1}^n x_i^\alpha}$$

appunto fissando alpha. si ottiene
lambda

- Sostituendo nella seconda equazione:

problema di analisi numerica

$$\frac{n}{\alpha} + \sum_{i=1}^n \ln x_i - \frac{n \sum_{i=1}^n x_i^\alpha \ln x_i}{\sum_{i=1}^n x_i^\alpha} = 0$$

che può essere risolta con un metodo di “punto fisso”

Trovato il valore di α , lo si userà per ricavare λ .

ovvero calcolo
numerico. Un metodo
è ad esempio l'iterazione

Tramite Excel andiamo a stimare i parametri di una Weibull con una generazione Monte Carlo

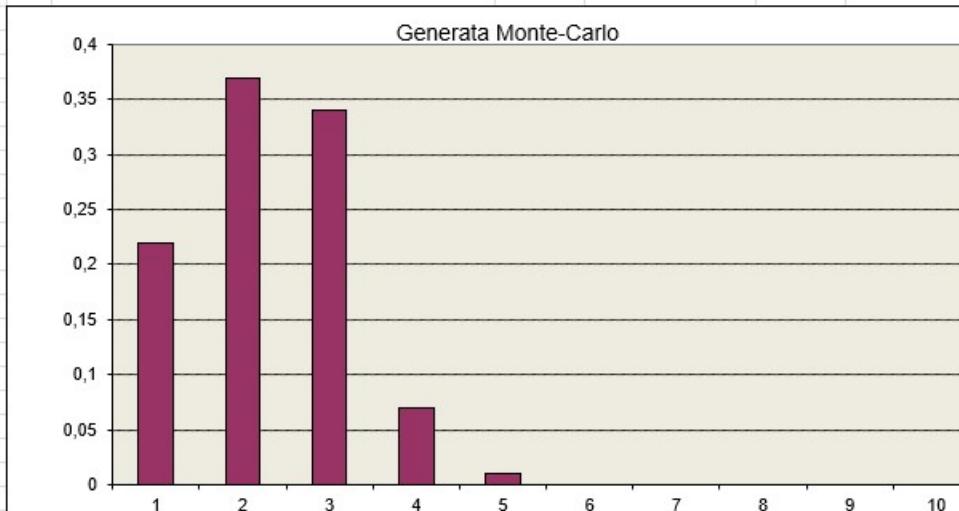
Realizz di una Weibull	Real Weib ^alpha	alfa	assegnato. Per ipotesi stimato	media camp di real Weib ovvero media aritmetica la sua realizzazione =	num realizzazioni =
2,278184076	5,190122686	2		1,753074621	100
2,980528663	8,883551111				
1,374309393	1,888726308	somma x-i ^ α			
4,09979484	16,80831773	388,3024			
2,178630612	4,746431344	lambda_cap			
0,513064168	0,26323484	0,2575			
1,272460527	1,619155792				
0,729703423	0,532467086				
0,371302031	0,137865198				
2,035413355	4,142907527				
1,164327462	1,356558439				
3,003493793	9,020974966				
2,568384657	6,596599748				
1,937524553	3,754001395				
1,226054467	1,503209556				
1,551545773	2,407294287				
1,528032867	2,334884444				
0,925785038	0,857077937				
2,9857528	8,914719784				
3,009518122	9,057199324				
1,187021164	1,409019245				
1,496110558	2,238346801				
2,741617091	7,516464273				
3,167702269	10,03433767				
0,559882418	0,313468322				
1,655650865	2,741179787				
2,424995768	5,880604476				
1,027026841	1,054784131				
1,590254249	2,528908578				
1,75606515	3,083764812				
0,913556142	0,834584825				
2,510023938	6,300220168				
1,19593173	1,430252702				
0,327620248	0,107335027				
0,880801391	0,77581109				
2,501043325	6,255217714				

$$\hat{\lambda} = \frac{n}{\sum_{i=1}^n x_i^\alpha}$$

$$E[Weib] = \beta \cdot \Gamma(1 + 1/\alpha)$$

beta
2

La stima risulta abbastanza vicina al valore vero



L'analisi sui parametri di una Weibull porta alla conclusione che:

- Lambda è il parametro di scala, solitamente durante una ricostruzione non "danneggia" il risultato
- Alpha è il parametro di forma, è consigliato scegliere un valore maggiore di 1 per visualizzare bene il metodo di Monte Carlo

La densità “gamma”

Si ottiene dalla funzione gamma ed è un'estensione della densità di Erlang dove il parametro di forma diventa un reale positivo. Serve indirettamente a costruire altre funzioni utili nella statistica

- La funzione gamma (Il integrale di Eulero):

$$\Gamma(\alpha) \hat{=} \int_0^\infty x^{\alpha-1} e^{-x} dx, \quad \alpha \in \Re^+$$

E' facile verificare che: $\Gamma(1) = 1$, meno facile che: $\Gamma(1/2) = \sqrt{\pi}$

- Integrando per parti, si ottiene la seguente:

$$\Gamma(\alpha) = (\alpha - 1)\Gamma(\alpha - 1), \quad se \alpha > 1$$

e quindi: $\Gamma(n) = \underset{\text{importante}}{(n-1)!}, \quad se \alpha \equiv n \in \mathbb{N}$

- E' utile riscriverla nella forma seguente, con $x = \lambda y$ e $\lambda > 0$:

$$\Gamma(\alpha) = \int_0^\infty (\lambda y)^{\alpha-1} \cdot e^{-\lambda y} \cdot d(\lambda y) = \int_0^\infty (\lambda y)^{\alpha-1} \cdot e^{-\lambda y} \cdot \lambda dy$$

$$\Rightarrow 1 = \int_0^\infty \frac{(\lambda y)^{\alpha-1} \cdot \lambda e^{-\lambda y}}{\Gamma(\alpha)} \cdot dy \quad (*)$$

mostra come costruire una densità

La densità di Erlang

Erlang si ottiene a partire da una somma di esponenziali identiche e indipendenti

- Dalla densità di una Erlang {n,λ}:

$$f_X(x) = \frac{(\lambda x)^{n-1}}{(n-1)!} \lambda e^{-\lambda x}, \quad \lambda > 0, x \geq 0$$

La densità di Erlang può quindi essere riscritta con la funzione Gamma e passando da n numero naturale ad alpha numero reale si possono generare realizzazioni

la seguente rispetta i requisiti di una densità grazie alla (*):

$$f_X(x) = \frac{(\lambda x)^{\alpha-1}}{\Gamma(\alpha)} \lambda e^{-\lambda x}, \quad \alpha > 0, \lambda > 0, x \geq 0$$

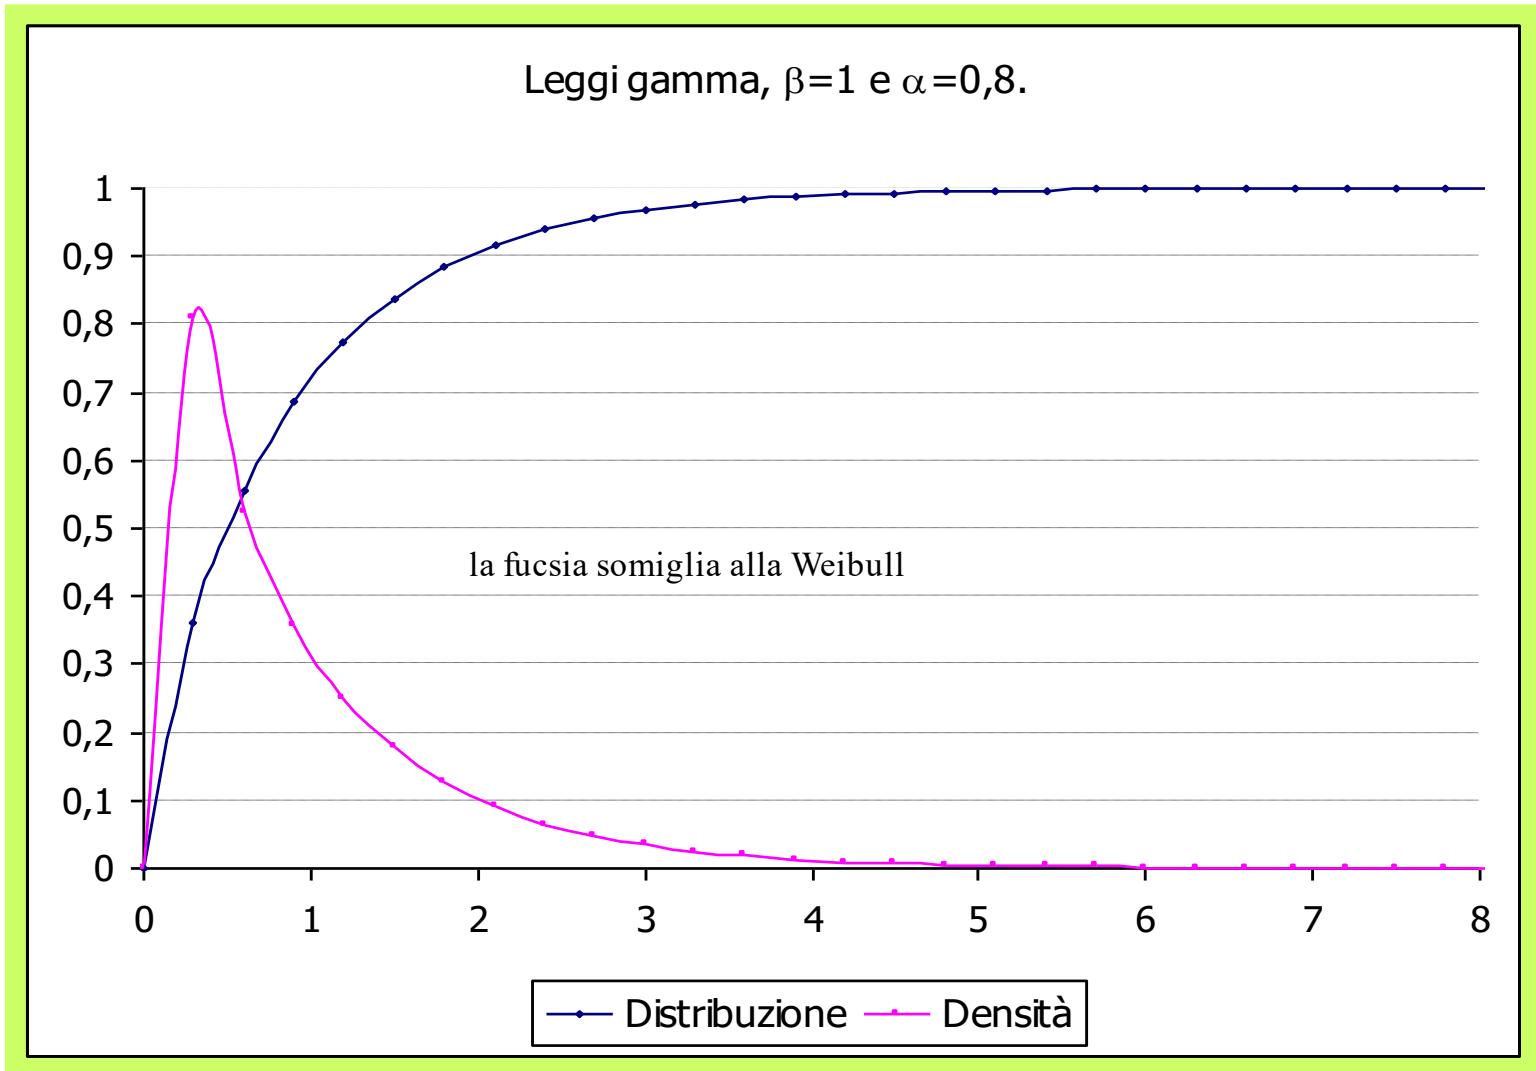
IN EXCEL: $f_X(x) = \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-x/\beta}, \quad \beta \triangleq \frac{1}{\lambda}$

parametro di scala perché rapporto tra 1 e valore atteso. Quindi alpha sarà parametro di forma

Valore atteso e varianza: $E[X] = \alpha \beta, \text{Var}[X] = \alpha \beta^2$

ricorrendo a: $L_X(s) \triangleq \int_{x=0}^{\infty} e^{-sx} f_X(x) dx = (1 - \beta s)^{-\alpha}, \quad 0 \leq s < \beta^{-1}$

La densità e la distribuzione “gamma”



MOM PER LA GAMMA

Esempio di applicazione n. 1: distribuzione gamma

Si supponga di disporre di un campione di n misurazioni, e si ipotizzi che le misurazioni siano tutte modellabili con variabili aleatorie indipendenti con distribuzione di probabilità $\Gamma(\alpha, \beta)$. Si ipotizzi inoltre che α e β siano parametri incogniti e che si desideri fornirne delle stime $\hat{\alpha}$ e $\hat{\beta}$.

Allora, seguendo il procedimento descritto poco fa, calcoliamo il momento primo \bar{X} e il momento secondo M_2 (che saranno semplicemente dei numeri ottenuti a partire dai dati sperimentali), e costruiamo il sistema:

$$\begin{cases} \mu_1(\alpha, \beta) = \bar{X} \text{ media} \\ \mu_2(\alpha, \beta) = M_2 \text{ scarto quadratico} \end{cases}$$

Ricordando che in una distribuzione gamma la media è data dal prodotto tra i due parametri:

$$\mu_1(\alpha, \beta) = \alpha\beta$$

E che vale la relazione:

$$\mu_2(\alpha, \beta) - [\mu_1(\alpha, \beta)]^2 = Var(X) = \sigma^2 \rightarrow \mu_2(\alpha, \beta) = \sigma^2 + [\mu_1(\alpha, \beta)]^2 = \sigma^2 + (E[X])^2$$

Dove, nel caso di distribuzione gamma:

In arancione la nota relazione
 che la varianza è esprimibile come
 momento del secondo ordine meno
 momento del primo ordine al quadrato.

$$\sigma^2 = \alpha\beta^2$$

Andando a creare il sistema di equazioni

Otteniamo:

$$\begin{cases} \alpha\beta = \bar{X} \\ \alpha\beta^2 + (\text{E}[X])^2 = M_2 \end{cases} \rightarrow \begin{cases} \alpha\beta = \bar{X} \\ \alpha\beta^2 = M_2 - (\text{E}[X])^2 \end{cases} \rightarrow \begin{cases} \alpha\beta = \bar{X} \\ \alpha\beta^2 = M_2 - \bar{X}^2 \end{cases}$$

Notando che:

$$\sum_{j=1}^n (X_j - \bar{X})^2 = \sum_{j=1}^n X_j^2 - 2\bar{X} \sum_{j=1}^n X_j + n\bar{X}^2 = nM_2 - 2n\bar{X}^2 + n\bar{X}^2 = nM_2 - n\bar{X}^2$$

Possiamo riscrivere il sistema come segue:

$$\begin{cases} \alpha\beta = \bar{X} \\ \alpha\beta^2 = \frac{1}{n} \sum_{j=1}^n (X_j - \bar{X})^2 \end{cases}$$

Ricordando poi che lo stimatore varianza campionaria è definito come:

$$S^2 = \frac{1}{n-1} \sum_{j=1}^n (X_j - \bar{X})^2$$

Otteniamo facilmente:

$$\begin{cases} \alpha\beta = \bar{X} \\ \alpha\beta^2 = \frac{n-1}{n} S^2 \end{cases} \rightarrow \begin{cases} \frac{n-1}{n} \frac{S^2}{\beta} = \bar{X} \\ \alpha = \frac{n-1}{n} \frac{S^2}{\beta^2} \end{cases} \rightarrow \begin{cases} \hat{\beta}_{mom} = \frac{S^2}{\bar{X}} \frac{n-1}{n} \\ \hat{\alpha}_{mom} = \frac{\bar{X}}{\beta} = \frac{n}{n-1} \frac{\bar{X}^2}{S^2} \end{cases}$$

La disuguaglianza di Chebyshev

Sia Y variabile aleatoria di media μ e varianza σ^2 con funzione di densità definita da $-\infty$ a $+\infty$ quindi Gaussiana e non. Si definisce disuguaglianza di Chebyshev quella sottostante, che è utilizzata per calcolare la probabilità che una realizzazione si trovi entro una certa distanza dalla media espressa in multipli della deviazione standard o meglio la probabilità che si trovi all'interno di un intervallo di confidenza.

$h > 0$ costante

$$\Pr \left\{ |Y - \mu| \geq h \right\} \leq \frac{\sigma^2}{h^2}$$

scarto, ancora v.a.

se $k\sigma \hat{=} h \Rightarrow$
considero
multipli della deviazione standard

disuguaglianza vista nella lezione degli stimatori

$$\Pr \left\{ |Y - \mu| \geq k\sigma \right\} \leq \frac{1}{k^2}$$

ovvero:

esplcitando il valore assoluto
ottengo appunto un intervallo

$$\Pr \left\{ \mu - k\sigma \leq Y \leq \mu + k\sigma \right\} \geq 1 - \frac{1}{k^2}$$

con $k > 0 : (1/k) \leq 1$

quantità arbitrariamente vicina a 1

Cantelli si usa per il caso di v.a. continue e non negative come Weibull, exp ecc.

Cantelli per densità in $[0, +\infty)$ →

Prova: partendo dalla def. di varianza oppure
ricordando il collegamento tra scarti e varianza

$$\sigma^2 \hat{=} \int_{-\infty}^{+\infty} (y - \mu)^2 f(y) dy$$

maggiore uguale perchè
si taglia un pezzo di area,
e dato che $f(y) > 0$, allora
l'area è $>= 0$ quindi anche
 $(y - \mu)^2 f(y) \geq 0$

non si perde e non si deve
perdere la disuguaglianza

$$\geq \int_{-\infty}^{\mu-h} (y - \mu)^2 f(y) dy + \int_{\mu+h}^{+\infty} (y - \mu)^2 f(y) dy$$

con $h = y - \mu$

a questo punto ci si esprime
con la deviazione standard

1° integrale vale
 $\Pr\{Y < \mu - h\}$
2° integrale vale
 $\Pr\{Y > \mu + h\}$

$$\Rightarrow \sigma^2 \geq h^2 \left(\Pr \left\{ |Y - \mu| \geq h \right\} \right) = \Pr \left\{ |Y - \mu| \geq h \right\} \leq \frac{\sigma^2}{h^2}$$

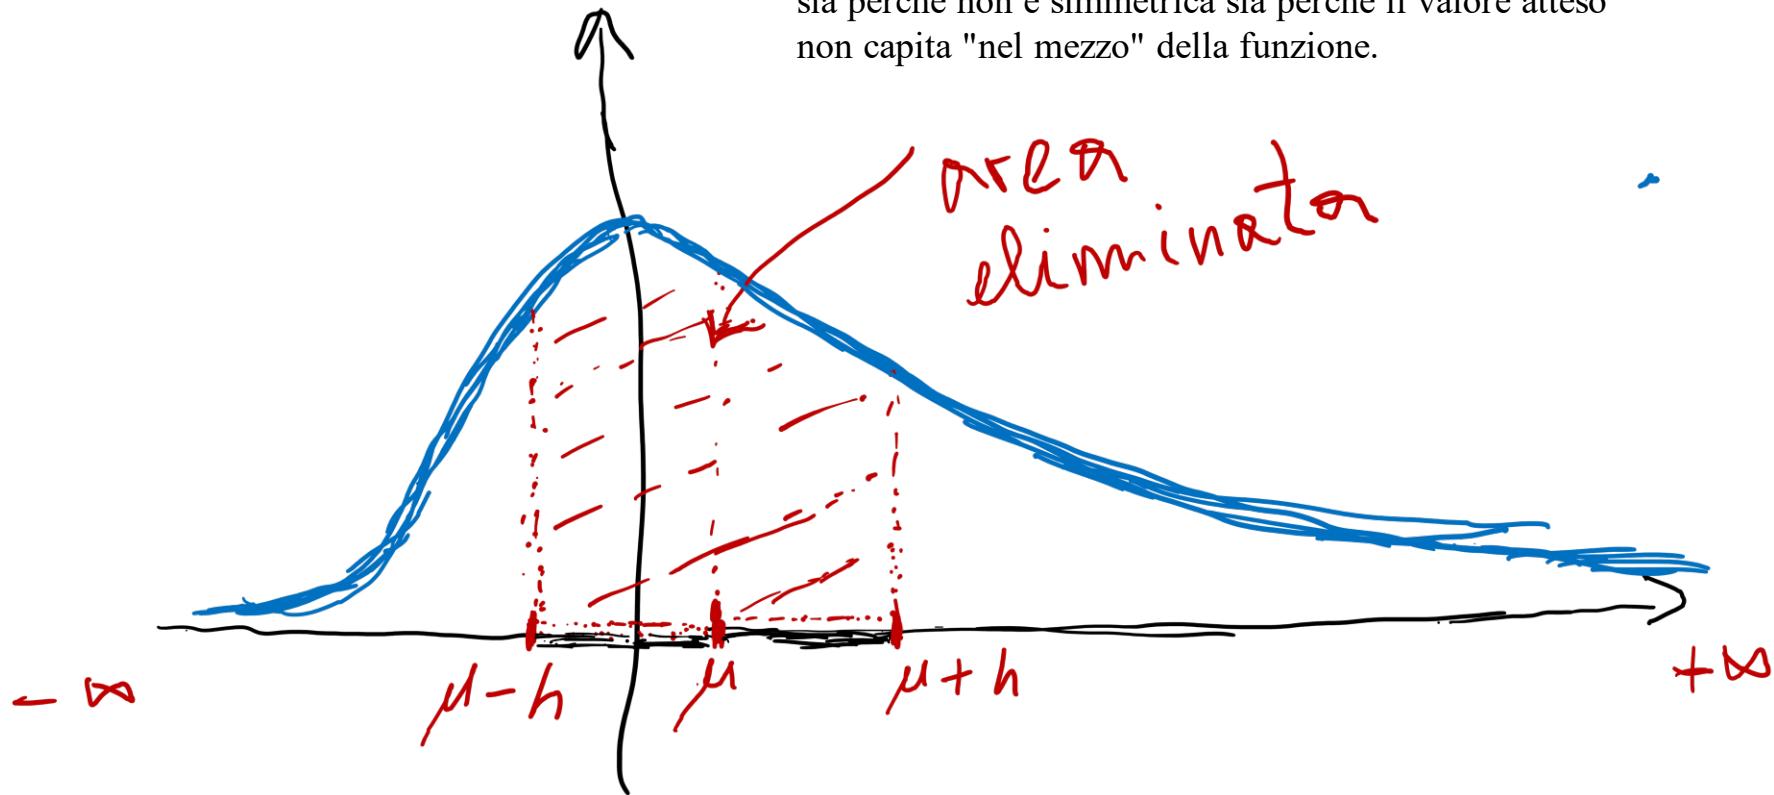
← Il primo integrale è una distribuzione il secondo no!

Se Y è la variabile aleatoria media campionaria, allora $VAR[Y] = \frac{\sigma^2}{n}$ e sostituendo nella diseguaglianza di Chebyshev, si ottiene che

$$Pr\{|Y - \mu| \geq h\} \leq \frac{VAR[Y]}{h^2} = \frac{\sigma^2}{n} \cdot \frac{1}{h^2} \quad \text{se } h = \sigma \quad Pr\{|Y - \mu| \geq \sigma\} \leq \frac{1}{n} \quad \text{dunque la dimensione del campione } n, \text{ influisce.}$$

Al crescere del campione, la probabilità che una realizzazione della media campionaria abbia una distanza apprezzabile dal valore atteso diventa sempre più piccola.

La funzione si nota che non è una Gaussiana sia perché non è simmetrica sia perché il valore atteso non capita "nel mezzo" della funzione.



CONVERGENZA IN PROBABILITÀ

Nata grazie a disuguaglianza di Chebyshev

Si dice che una **generica** sequenza di variabili aleatorie:

(non dice se indipendenti ed identicamente distribuite e o altro)

$Y_1, Y_2, \dots, Y_n \rightarrow \vartheta$ (valore finito)
(che convergono, tutte
o a meno di poche che si ignorano)

Converge in probabilità
ad un valore finito.

e si scrive: $\lim_{n \rightarrow \infty} \Pr \{ |Y_n - \vartheta| < \delta \} = 1, \quad \forall \delta > 0$ notazione
sarebbe diverso
il lim della sequenza di v.a.

quando: fissati $\varepsilon > 0$ e quindi $\delta > 0$ $\exists \tilde{n}$ tale che

sono diverse

grazie a Chebyshev

NON DÀ N TILDE IN POI!

risulta: $\Pr \{ |Y_{\tilde{n}} - \vartheta| < \delta \} > 1 - \varepsilon$

$$\delta \triangleq \delta_\varepsilon$$

δ dipende da ε !
 ε piccolo a piacere

probab. che da una v.a. la distanza dal valore finito è minore di delta è molto vicino a 1, quindi quasi certa!

Si osservi che l'affermazione "risulta Pr ..." si riferisce ad una sola diseguaglianza e non può essere estesa alla seguente:

sarebbe un AND $|Y_{\tilde{n}+1} - \vartheta| \cap |Y_{\tilde{n}+2} - \vartheta| \cap |Y_{\tilde{n}+3} - \vartheta| \cap \dots$
avranno valori variabili. chi più vicino e chi meno vicino

che esprime un tipo di convergenza detta "forte". Che quindi vale per più variabili aleatorie

Teorema di Bernoulli - Teorema di convergenza debole

Prese X_1, X_2, \dots variabili aleatorie **indipendenti BERNOULLIANE** ovvero:

$$X_i = \begin{cases} 1 & \text{con prob} = p \\ 0 & \text{con prob} = 1-p \end{cases}, \quad i=1,2,\dots,n$$

$B \triangleq \sum_{i=1}^n X_i$ è la binomiale con $E[B]=np$ e $\text{VAR}[B]=np(1-p)$ allora:
LA BINOMIALE È UNA SOMMA!

(B rappresenta i casi favorevoli, B/n è la media campionaria che rappresenta gli esiti di n prove di Bernoulli ovvero la proporzione di successi su n prove.)

$\lim_{n \rightarrow \infty} \Pr\left\{\left|\frac{B}{n} - p\right| < \delta\right\} = 1, \forall \delta > 0$ Il limite per n che tende a infinito della probabilità che B/n è abbastanza vicina a p è minore di δ è pari a 1 ovvero:

il rapporto tra casi favorevoli e casi possibili può approssimare la probabilità vera, su un numero infinitamente grande di esperimenti indipendenti.

Prova: parto dalla distanza dal valore atteso espressa rispetto a k deviazioni standard. (quante deviazioni standard sono lontano dal valore atteso?)

$$\Pr\left\{\left|B - E[B]\right| < k\sqrt{\text{Var}[B]}\right\} > 1 - \frac{1}{k^2}$$

Visto che non è negativa la binomiale uso:
(Chebyshev-Cantelli)

$$k^2 := 1 + k^2$$

assegnazione non uguale

$$\text{con } \varepsilon \hat{=} 1/k^2$$

$$\Pr\left\{\left|\frac{B - np}{n}\right| < \frac{k}{n}\sqrt{np(1-p)}\right\} > 1 - \varepsilon$$

$$\Pr\left\{\left|\frac{B}{n} - p\right| < \sqrt{\frac{k^2}{n} p(1-p)}\right\} > 1 - \varepsilon$$

$$\text{con } \delta \hat{=} \sqrt{\frac{p(1-p)}{n\varepsilon}}$$

delta dipende da epsilon ed è inversamente proporzionale.
più piccolo epsilon, più è grande delta e viceversa.

Per n infinitamente grande, non si esclude il caso in cui, la differenza $B - np$ fra il numero di successi realizzati e numero di successi attesi (testa che escono e testa che mi aspetto ovvero 50%) diverge (non ho 50% di fare testa) con la velocità della radice di n mentre n cresce linearmente verso l'infinito. In parole povere se $B-np$ cresce alla velocità della radice di n mentre n cresce linearmente verso l'infinito, la probabilità di trovarsi a distanza δ dal valore atteso p non converge a zero. In questo caso il teorema di convergenza debole non si applica. Per questo si deve ricorrere al teorema di Borel-Cantelli.

IL TEOREMA DI BOREL

da guardare alla fine

Stabilisce un risultato di convergenza “forte”:

$$\Pr \left\{ \lim_{n \rightarrow \infty} \left| \frac{B}{n} - p \right| < \delta \right\} = 1, \quad \forall \delta > 0$$

Si dice che $\frac{B}{n} \rightarrow p$ "con prob. 1", per $n \rightarrow \infty$

e si intende che $\forall \varepsilon > 0$ e quindi $\delta > 0$ $\exists \tilde{n}, \tilde{n}+1, \tilde{n}+2, \dots$ tale che
qui debbo dire da n tilde in poi!

$$Prob \left[\left| \frac{B}{\tilde{n}} - p \right| < \delta \cap \left| \frac{B}{\tilde{n}+1} - p \right| < \delta \cap \left| \frac{B}{\tilde{n}+2} - p \right| < \delta \cap \dots \right] < 1 - \varepsilon$$

Questo risultato forte della legge dei grandi numeri garantisce che a partire da un “certo n ” in poi le realizzazioni della variabile aleatoria B/n che risulteranno tanto vicine a p quanto più si vuole corrisponderanno ad un sottospazio di Ω che ha probabilità 1 (convergenza “con prob 1”).

quasi sempre negli esperimenti
quasi tutti i risultati elementari
quasi ovunque nello spazio

In questo senso, il verificarsi di realizzazioni apprezzabilmente distanti da p è un evento che ha probabilità $1 - P(\Omega)$, dunque nulla. Cioè tutte le realizzazioni convergono tranne al più un sottoinsieme dello spazio dei risultati a cui si da probabilità nulla, perché non si da importanza.

Legge (debole) dei grandi numeri (per la media campionaria)

Che si può dimostrare

La legge dei grandi numeri si applica per somme di variabili aleatoria, ed essendo la media somma di variabili diviso una costante non ci sono problemi nell'applicarla.

Prima ipotesi:

-) X_1, X_2, \dots var. al. ind., con valore atteso finito e identico, μ e varianze sia pur non identiche ma finite, $\sigma_k^2, k = 1, \dots, n$ e tutte limitate da una stessa costante, C.

Oppure seconda ipotesi:

-) X_1, X_2, \dots var. al. con val.att.identico e finito, μ (non indipendenti)

Quindi la varianza dovrà essere in gerarchia degli infiniti sotto n quadro così da rispettare la condizione di limite pari a 0

e con $\lim_{n \rightarrow \infty} \frac{Var\left[\sum_{i=1}^n X_i\right]}{n^2} = 0$ non somma delle varianze perchè non sono indipendenti!

OSSERVAZIONE: La prima ipotesi serve sulla sequenza di input al modello P-C (tempi di interarrivo, ad esempio), mentre la seconda serve sulla sequenza di output (tempi di soggiorno, ad esempio).

perché output non sono indipendenti

Legge (debole) dei grandi numeri (per la media campionaria)

TESI comune alle due ipotesi :

Per la v.a. med camp: $\bar{X}(n) \hat{=} (X_1 + \dots + X_n) / n$ ma anche per somme di v.a.

risulta:

$$\lim_{n \rightarrow \infty} \text{Prob} \left[|\bar{X}(n) - E[\bar{X}(n)]| < \delta \right] = 1, \quad \forall \delta > 0$$

Il limite significa che dopo molto tempo è certo (=1) che la distanza tra media campionaria (stima del valore atteso) e valore atteso è molto piccola

Il problema è che nella realtà non si può aspettare per sempre.

e s'intende che:

fissati $\varepsilon > 0$ e quindi $\delta_\varepsilon > 0$ $\exists \tilde{n}$ tale che

risulta: $\text{Prob} \left[|\bar{X}(\tilde{n}) - E[\bar{X}(\tilde{n})]| < \delta_\varepsilon \right] > 1 - \varepsilon$

rivediamo il concetto di convergenza in probabilità

Quindi dopo un certo n tilde, la probabilità che la distanza tra stima del valore atteso e valore atteso sia minore di delta arbitrariamente piccolo è arbitrariamente vicino a 1, ovvero alla certezza. Ad esempio dopo 500 tiri di moneta, si sa dalla vita che la probabilità che esca testa è 50%.

La legge ci dice che facendo 500 tiri quasi sicuramente sarai sarà uscito testa circa il 50% dei tiri. Infatti empiricamente dopo 500 tiri si stima che la probabilità è attorno al 50%, magari 49.87%, 48%. Questa convergenza è debole perché è maggiore di $1 - \varepsilon$ non è esattamente 1!

Dimostrazione della legge debole (per var. al. correlate)

(non indipendenti)

A partire dalla ipotesi:
seconda

La tesi da validare è che valgano:

$$\begin{aligned} \text{Prob}\left[\left|\bar{X}(\tilde{n}) - E[\bar{X}(\tilde{n})]\right| < \delta_{\varepsilon}\right] &> 1 - \varepsilon \\ \lim_{n \rightarrow \infty} \text{Prob}\left[\left|\bar{X}(n) - E[\bar{X}(n)]\right| < \delta\right] &= 1, \quad \forall \delta > 0 \end{aligned}$$

$$VAR[\bar{X}(n)] = \frac{1}{n^2} VAR\left[\sum_{i=1}^n X_i\right] \stackrel{\text{essendo } v^2(n) \text{ sempre positiva}}{\hat{=}} v^2(n)$$

funzione che rispetta l'ipotesi

basta riprendere la diseguaglianza di Chebyshev-Cantelli:

essendo $v^2(n)$ sempre positiva

$$\Pr\left\{\left|\bar{X}(n) - \mu\right| \geq k \cdot v(n)\right\} \leq \frac{1}{k^2}$$

e porre: $\varepsilon \hat{=} (1/k^2)$ e $\delta \hat{=} k \cdot v(n)$

posto ciò si può
riscrivere alla seguente maniera:

$$\Pr\left\{\left|\bar{X}(n) - \mu\right| < k \cdot v(n) = \delta\right\} > 1 - (v^2(n)/\delta^2) = 1 - \varepsilon$$

e riconoscere che l'ipotesi fatta:

è sufficiente a provare la tesi.

$$\lim_{n \rightarrow \infty} v^2(n) = 0 \rightarrow \text{serve per validare}$$

$\lim_{n \rightarrow \infty} \text{Prob}\left[\left|\bar{X}(n) - E[\bar{X}(n)]\right| < \delta\right] = 1, \quad \forall \delta > 0$

perchè così facendo $\varepsilon = \frac{v^2(n)}{\delta^2} = 0$ quindi $1 - \varepsilon = 1$

Dimostrazione della legge debole (per var. indipendenti)

Per la PRIMA IPOTESI

partendo ancora da Chebyshev

$$\Pr \left\{ \left| \bar{X}(n) - E[\bar{X}(n)] \right| \geq h \right\} \leq \left(\text{VAR}[\bar{X}(n)] / h^2 \right) \quad (h \doteq n \sqrt{\text{VAR}[\bar{X}(n)]})$$

riscrivo il tutto sotto Chebyshev-Cantelli

$$\Pr \left\{ \left| \bar{X}(n) - E[\bar{X}(n)] \right| < h \right\} \geq 1 - \left(\text{Var}[\bar{X}(n)] / h^2 \right)$$

e sfruttando l'ipotesi di varianze finite, limitate da una medesima costante C

$$\left. \text{Var}[\bar{X}(n)] = \frac{1}{n^2} \sum_{k=1}^n \text{Var}[X_k] \right\}$$

 sommatoria pari a nC

con: $\text{Var}[\bar{X}(n)] = \frac{1}{n^2} \sum_{k=1}^n \sigma_k^2 < \frac{C}{n}$ l'ipotesi di costanza di C servirà per il limite.

andando a sostituire si ottiene che:

$$\Pr \left\{ \left| \bar{X}(n) - E[\bar{X}(n)] \right| < h \right\} > 1 - \left(\frac{C}{n \cdot h^2} \right) > 1 - \varepsilon$$

dunque se n tende a infinito
il rapporto è 0

tollerò di meno
lo sbaglio di tanto,
ma tollero di più
lo sbaglio di poco.

ovvero:

$$\lim_{n \rightarrow \infty} \Pr \left\{ \left| \bar{X}(n) - E[\bar{X}(n)] \right| < h \right\} = 1, \quad \forall h > 0$$

Legge forte dei grandi numeri (per la media campionaria)

non dimostrabile

IPOTESI ALTERNATIVE:

-) X_1, X_2, \dots v.a. ind. e id. distr., con media μ finita

OPPURE

-) X_1, X_2, \dots v.a. ind. $\left\{ \begin{array}{l} \text{con media identica, } \mu, \text{ finita} \\ \text{e non ident. varianze } \sigma_1^2, \sigma_2^2, \dots \end{array} \right.$
con $\sum_{k=1}^{\infty} \frac{\sigma_k^2}{k^2} < \infty$

TESI COMUNE:

Allora, con: $\bar{X}(n) \hat{=} (X_1 + \dots + X_n)/n$ media campionaria

$$Prob \left[\lim_{n \rightarrow \infty} |\bar{X}(n) - \mu| < \delta \right] = 1, \quad \forall \delta > 0$$

probabilità di limite non limite di probabilità!

E s'intende che:

$$\forall \varepsilon > 0, \delta_\varepsilon > 0 \quad \exists \tilde{n} \mid \forall m \in [1, 2, \dots]$$

$$Prob \left[\left| \bar{X}(\tilde{n}) - E[\bar{X}(\tilde{n})] \right| < \delta_\varepsilon \cap \left| \bar{X}(\tilde{n}+1) - E[\bar{X}(\tilde{n}+1)] \right| < \delta_\varepsilon \cap \dots \cap \left| \bar{X}(n+2) - E[\bar{X}(n+2)] \right| < \delta_\varepsilon \right] > 1 - \varepsilon$$

AND visto nella slide della convergenza in probabilità

Di grande interesse pratico: (si lavora con)

-) X_1, X_2, \dots v.a. ind.e id.distr. con $E[X] = \mu$

ALLORA $\bar{X}(n) \hat{=} \frac{\sum_{i=1}^n X_i}{n}$ converge μ "con pr 1"
quasi sempre
quasi ovunque

Applicazione della legge forte

Sia “X” la variabile aleatoria bernelliana (real. 0 e 1) che indica il verificarsi o meno di un evento “A” e sia “n” il numero di esperimenti indipendenti.

$$\begin{aligned} \text{Siccome: } E[X] &= 0 \cdot \Pr(0) + 1 \cdot \Pr(1) \\ &\Rightarrow \text{Prob}(A) \equiv E[X] \end{aligned}$$

$$\text{allora: } \bar{X}(n) \triangleq \frac{\sum_{i=1}^n X_i}{n} \stackrel{pr\ 1}{\rightarrow} \text{Prob}(A), \quad n \rightarrow \infty$$

IMPORTANTE

Il rapporto fra il numero di volte in cui si verifica l’evento A e il numero sufficientemente grande di esperimenti indipendenti effettuati può essere preso come la $\text{Prob}(A)$.

Seconda applicazione della Legge forte dei G.N. :

$$\Pr \left\{ \lim_{t \rightarrow \infty} \frac{N(t)}{t} = \frac{1}{E[X]} \hat{=} \lambda \right\} = 1$$

Sperimentazione
della convergenza
forte:

con :

$$N(t) \hat{=} \text{ numero di arrivi in } (0, t] \quad \begin{array}{l} \text{se uso t1, t2, ecc.} \\ \text{sarebbe un processo stocastico} \end{array}$$

$$X_1, X_2, \dots, X_{N(t)} \quad \text{INTERARRIV ind. e id. distr.} \equiv X$$

$$S_{N(t)} \hat{=} X_1 + X_2 + \dots + X_{N(t)} \quad \begin{array}{l} \text{somma di tempi aleatori. se N(t) fissato} \\ \text{ho somma di tempi finiti} \end{array}$$

PROVA: t istante tra l'ultimo arrivato e quello che deve arrivare

$$\frac{S_{N(t)}}{N(t)} \leq \frac{t}{N(t)} < \frac{S_{N(t)+1}}{N(t)} \quad \Rightarrow \quad \frac{S_{N(t)}}{N(t)} \leq \frac{t}{N(t)} < \frac{S_{N(t)+1}}{N(t)+1} \frac{N(t)+1}{N(t)}$$

non è lim di prob,
ma prob di lim

$$\lim_{t \rightarrow \infty} \frac{S_{N(t)}}{N(t)} = \lim_{t \rightarrow \infty} \frac{X_1 + X_2 + \dots + X_{N(t)}}{N(t)} = E[X] \quad \begin{array}{l} \text{con probabilità 1} \\ \text{quasi ovunque,} \\ \text{quasi sempre} \end{array}$$

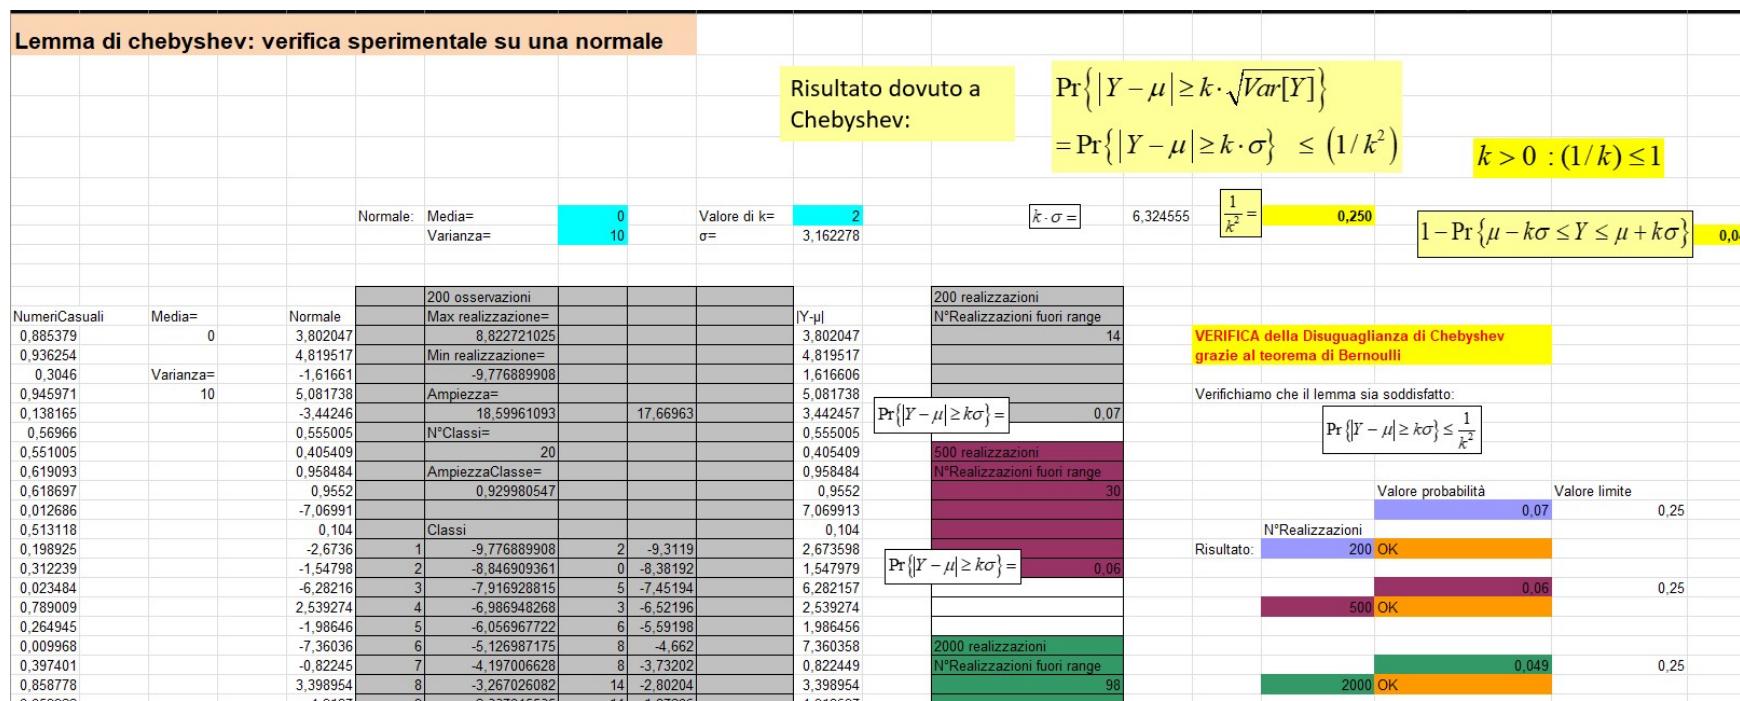
grazie alla legge forte converge al valore atteso con prob 1

$$\lim_{t \rightarrow \infty} \left[\frac{S_{N(t)+1}}{N(t)+1} \frac{N(t)+1}{N(t)} \right] = E[X] \lim_{t \rightarrow \infty} \frac{N(t)+1}{N(t)} = E[X] \quad \text{con prob 1}$$

tramite teorema del confronto

$$\Rightarrow E[X] \leq \lim_{t \rightarrow \infty} \frac{t}{N(t)} < E[X] \quad \text{con probabilità 1}$$

Tramite monte carlo andiamo a provare la disegualanza di Chebyshev su una normale con:



Media=0
Varianza=10
k=2

Ricordando che k non deve essere intero.

$$\frac{1}{k^2} = 0.25$$

L'esperimento funziona perché della normale conosciamo la distribuzione, quindi possiamo calcolare il valore vero!

Perciò con questi parametri Chebyshev afferma che la probabilità che la realizzazione differisca dal valore atteso per 2 volte (k=2) la deviazione standard è minore uguale di 0.25. Ma utilizzando la distribuzione della normale andando a calcolare su Excel $1 - (\text{DISTRIB.NORM}(\mu+k\sigma; \mu; \sigma; \text{VERO}) - \text{DISTRIB.NORM}(\mu-k\sigma; \mu; \sigma; \text{VERO}))$ si ottiene 0.046! Si deduce che il bound di Chebyshev è lasso! Si vogliono bound sufficientemente stretti altrimenti se troppo stretti si hanno problemi con il bias (ovvero lo spostamento a destra o sinistra rispetto al valore). Si è poi andato a verificare la disegualanza di Chebyshev su 200, 500 e 2000 realizzazioni. Da notare che con varianza 10 con 2000 realizzazioni l'istogramma assomiglia alla normale, ma se aumenta le realizzazioni ovviamente la rappresentazione viene più fine. Con una varianza diversa magari servono meno o più osservazioni per rappresentare bene la normale. Su Excel c'è anche la verifica di Chebyshev, o meglio Cantelli per l'esponenziale con una modifica sulla disegualanza.

